

## Highlights

### **RutAI: A Bandit-Driven Mobile Framework for Route Diversification, Geofenced Reminders and Collaborative Urban Tracking**

Gleiston Guerrero-Ulloa, Aarón Reyes, Miguel J. Hornos, Carlos Rodríguez-Domínguez, Efraín Díaz-Macías

- RutAI integra rutas bandit-UCB, recordatorios geocercados y seguimiento colaborativo en un marco CBSE.
- La recompensa incorpora un término de entropía que convierte la diversificación en objetivo explícito.
- Banco de pruebas técnico: regret, latencia, consumo energético, precisión y rendimiento.
- Entropía de Shannon de rutas por usuario duplicada frente a la heurística “más rápida”.
- TAM extendido con Seguridad Percibida y reporte explícito de HTMT, Fornell-Larcker y amenazas a la validez.

# RutAI: A Bandit-Driven Mobile Framework for Route Diversification, Geofenced Reminders and Collaborative Urban Tracking<sup>\*</sup>

Gleiston Guerrero-Ulloa<sup>a</sup>, Aarón Reyes<sup>a</sup>, Miguel J. Hornos<sup>b</sup>, Carlos Rodríguez-Domínguez<sup>b,\*</sup> and Efraín Díaz-Macías<sup>a</sup>

<sup>a</sup>Facultad de Ciencias de la Computación, Universidad Técnica Estatal de Quevedo, Av. Quito Km. 1 Vía a Santo Domingo, Quevedo, 120301, Los Ríos, Ecuador

<sup>b</sup>Departamento de Ingeniería de Software, Universidad de Granada, C. Periodista Daniel Saucedo Aranda s/n, Granada, 18014, España

## ARTICLE INFO

### Keywords:

Computación móvil ubicua  
Recordatorios geolocalizados  
Bandido multibrazo  
Ruteo sensible al contexto  
Compartición colaborativa de ubicación  
Modelo de Aceptación Tecnológica

## Resumen

Antecedentes: En ciudades con alta presión de inseguridad, los desplazamientos urbanos cotidianos se vuelven predecibles, los encargos ligados al contexto se olvidan durante el trayecto y los canales para coordinarse con personas de confianza son improvisados. La mayoría de soluciones móviles abordan la recomendación de rutas, los recordatorios geolocalizados y el seguimiento compartido de forma aislada. **Objetivo:** Presentar RutAI, un marco móvil basado en componentes que integra rutas alternativas aprendidas mediante un bandido UCB con diversificación explícita como objetivo, recordatorios geolocalizados con disparadores compuestos de tiempo y espacio, y monitoreo colaborativo en tiempo real con controles de privacidad; y evaluar el sistema con mediciones técnicas objetivas y con un estudio de aceptación extendido con el constructo de Seguridad Percibida. **Métodos:** El desarrollo siguió Ingeniería de Software Basada en Componentes (CBSE) en seis fases, con cumplimiento de ISO/IEC/IEEE 12207:2017 y 29148:2018. El cliente Android emplea Kotlin, Jetpack Compose y el patrón Model-View-ViewModel (MVVM); el backend usa FastAPI, PostgreSQL y Redis sobre WebSocket. La recompensa del bandido se extendió con un término de entropía que promueve la diversificación. Se midieron el regret empírico frente a tres líneas base, la latencia extremo-a-extremo, el consumo energético del muestreo GPS adaptativo, la precisión del geofencing y el rendimiento sostenido de WebSocket. La aceptación se evaluó con un cuestionario basado en el Modelo de Aceptación Tecnológica (TAM) ampliado a Seguridad Percibida, con controles de validez discriminante Heterotrait-Monotrait (HTMT) y Fornell-Larcker, y un análisis explícito de amenazas a la validez. **Resultados:** El bandido UCB con regularización de entropía alcanza un regret acumulado un 22,6 % inferior al de  $\epsilon$ -greedy y comparable a Thompson sampling, con el doble de entropía de rutas por usuario (Shannon  $H = 1,38$  bits frente a 0,71 bits de la recomendación fija “más rápida”). La latencia p95 de REST se situó en 312 ms y la de WebSocket en 184 ms; el consumo adicional del muestreo adaptativo fue de 48,3 mAh/h frente a 112,7 mAh/h del muestreo continuo; la precisión del geofencing fue del 94,1 % con radio de 100 m. En la aceptación, los cinco constructos superaron el umbral 3,5 y el HTMT medio fue 0,91, lo que *no* satisface el criterio de  $< 0,85$  e indica validez discriminante débil, tal como se discute. **Conclusiones:** RutAI demuestra que la integración móvil de los tres módulos es técnicamente viable, promueve la diversificación medible de rutas y recibe una aceptación favorable en primer contacto, aunque el tamaño de muestra ( $n = 25$ ) y la validez discriminante requieren replicación multicuidad con  $n \geq 100$  para confirmar la estructura del TAM extendido.

## 1. Introducción

Las ciudades son el escenario en el que transcurre la mayor parte de la actividad humana. Según el Departamento de Asuntos Económicos y Sociales de las Naciones Unidas (UN-DESA), la revisión 2025 del World Urbanization Prospects estima que en 2025 el 57 % de la población mundial reside en áreas urbanas y proyecta que esa cifra

<sup>\*</sup> Esta investigación se llevó a cabo en la Facultad de Ciencias de la Computación de la Universidad Técnica Estatal de Quevedo, en colaboración con el Departamento de Ingeniería de Software de la Universidad de Granada.

<sup>\*</sup> Autor para correspondencia.

✉ gguerrero@uteq.edu.ec (G. Guerrero-Ulloa); lreyesp@uteq.edu.ec (A. Reyes); mhornos@ugr.es (Miguel J. Hornos); carlosrodriguez@ugr.es (C. Rodríguez-Domínguez); efraindiaz@uteq.edu.ec (E. Díaz-Macías)

ORCID(s): 0000-0001-5990-2357 (G. Guerrero-Ulloa); 0009-0000-8611-3046 (A. Reyes); 0000-0001-5722-9816 (Miguel J. Hornos); 0000-0001-5626-3115 (C. Rodríguez-Domínguez); 0000-0003-4087-029X (E. Díaz-Macías)

alcanzará el 68 % hacia 2050, con América Latina y el Caribe ya por encima del 82 % de urbanización (United Nations, Department of Economic and Social Affairs, Population Division, 2025). A escala individual, las trayectorias humanas son notablemente regulares: el estudio entrópico de Song, Qu, Blumm and Barabási (2010) estableció un techo teórico de predictibilidad del 93 % para trazas derivadas de teléfonos móviles, resultado confirmado por la minería de movilidad a gran escala (Cagney, Cornwell, Goldman and Cai, 2020; Liu, 2022). La combinación de urbanización densa y patrones de viaje predecibles abre un espacio de investigación en el que la computación ubicua y móvil puede aportar mejoras significativas en eficiencia, bienestar y seguridad.

Esa misma regularidad se vuelve un pasivo cuando la ciudad carga con alta presión delictiva. El informe 2025 del Banco Mundial documenta que América Latina y el Caribe concentran aproximadamente un tercio de los homicidios mundiales pese a albergar menos del 10 % de la población (Maloney, Melendez and Morales, 2025), cifra corroborada por el análisis macroeconómico del Fondo Monetario Internacional (Bisca, Chau, Dudine, Espinoza, Fournier, Guérin, Hansen and Salas, 2024) y por el Estudio Global sobre Homicidio para la región de la Oficina de las Naciones Unidas contra la Droga y el Delito (UNODC) (United Nations Office on Drugs and Crime, 2023). En contextos de alta presión, repetir día a día la misma ruta vuelve a la persona fácilmente perfilable y expone su rutina; en megaciudades muy densas con sistemas de transporte público complejos, la misma costumbre limita la capacidad de reaccionar ante incidentes en tiempo real. Estas presiones justifican una familia de servicios móviles ubicuos que (i) diversifique rutas sin sacrificar conveniencia, (ii) externalice la memoria para que encargos atados a lugares u horarios no se olviden, y (iii) permita a personas de confianza coordinarse en tiempo real.

### 1.1. Motivación y problema de investigación

El problema se comparte en contextos urbanos muy distintos. En la Ciudad de México, la Encuesta Nacional de Seguridad Pública Urbana (ENSU) del Instituto Nacional de Estadística y Geografía (INEGI) reportó en septiembre de 2024 que el 58,6 % de la población adulta consideraba inseguro vivir en su ciudad, con brechas de género significativas (64,0 % en mujeres frente a 52,2 % en hombres) (Instituto Nacional de Estadística y Geografía (INEGI), 2024), y la percepción de inseguridad se ha vinculado con modificaciones en los horarios y rutas de viaje cotidiano (Maloney et al., 2025). En Bogotá, los reportes oficiales más recientes situán la tasa de hurto en niveles significativamente superiores a los de capitales europeas (Bisca et al., 2024). En São Paulo, las encuestas de percepción la ubican entre las ciudades con menor confianza en la seguridad pública del hemisferio pese a la caída de la tasa de homicidios (United Nations Office on Drugs and Crime, 2023). En ciudades ecuatorianas medianas como Quevedo, la evidencia local indica que el 96,8 % de los estudiantes universitarios expresa temor a ser víctima de inseguridad en su rutina diaria (Tapia Chamba, 2024). Estas cuatro ciudades difieren en tamaño y contexto, pero convergen en la misma necesidad: las personas perciben su rutina como demasiado predecible, olvidan encargos atados al contexto durante el trayecto y los canales informales de coordinación resultan insuficientes para transmitir en tiempo real su ubicación a familiares y círculos de confianza.

Tres cuerpos de evidencia refuerzan la motivación de una respuesta integrada. Primero, las trayectorias individuales concentran gran parte de su masa en un conjunto pequeño de ubicaciones preferidas (Cagney et al., 2020; Liu, 2022; Song et al., 2010), por lo que la exploración de rutas alternativas debe ser promovida activamente por el sistema. Segundo, la evidencia cognitiva muestra que las intenciones atadas a claves contextuales se olvidan sistemáticamente a menos que se externalicen como recordatorios sensibles al lugar o al tiempo (Rummel, Snijder and Kvavilashvili, 2023; Ball and Peper, 2025). Tercero, quienes se desplazan ya improvisan coordinación en tiempo real usando llamadas y mensajes de texto, pero ese canal ad hoc no es continuo ni confiable; la literatura ha propuesto de manera repetida sustratos en tiempo real con privacidad explícita como alternativa (Li, Yan, Liu, Chen, Huang and Wong, 2017; McKenzie, Romm, Zhang and Brunila, 2022; Shokri, Theodorakopoulos, Papadimitratos, Kazemi and Hubaux, 2014). Ninguna de las tres líneas, por sí sola, aborda el fenómeno completo.

La pregunta de investigación que articula este trabajo es, por tanto: *¿cómo pueden combinarse la diversificación de rutas, los recordatorios sensibles al contexto y la compartición colaborativa de ubicación en un único marco móvil basado en componentes, de modo que los usuarios lo acepten y que su uso contribuya a la seguridad percibida durante los desplazamientos urbanos?*

### 1.2. Contribuciones y organización del artículo

Para responder a esa pregunta, el artículo aporta seis contribuciones que se articulan con las deficiencias identificadas en la Sección 2:

- Una arquitectura unificada basada en componentes (Android + FastAPI) que compone alternancia de rutas, recordatorios geocercados y monitoreo colaborativo bajo los mismos patrones MVVM y Repository.

- Un mecanismo de personalización de rutas basado en un Bandido Multibrazo (MAB) con política de Cota Superior de Confianza (UCB), reformulado con un término de regularización por entropía que convierte la diversificación en un objetivo explícito de la función de recompensa.
- Un subsistema de geocercado que soporta condiciones espaciales compuestas y disparadores con ventanas temporales, alineado con los requisitos metodológicos recientes para investigación conductual basada en geofencing (Shevchenko and Reips, 2024).
- Un módulo de monitoreo colaborativo sobre WebSocket con pertenencia consentida al grupo y acuses de recibo/lectura, que reconcilia la protección de la privacidad con la necesidad de coordinación en tiempo real (Li et al., 2017; McKenzie et al., 2022).
- Un banco de pruebas técnico reproducible con mediciones objetivas de regret, latencia, consumo energético, precisión del geofencing y rendimiento sostenido del canal en tiempo real.
- Un estudio empírico de aceptación con Modelo de Aceptación Tecnológica (TAM) extendido con Seguridad Percibida y con controles explícitos de validez discriminante (HTMT, Fornell-Larcker) y amenazas a la validez.

El resto del artículo se organiza como sigue. La Sección 2 agrupa el estado del arte por temas comunes y deriva la brecha de investigación. La Sección 3 describe los materiales y métodos, incluidas la CBSE y el plan estadístico. La Sección 4 reporta los resultados técnicos y la aceptación. La Sección 5 discute los hallazgos frente a la literatura y expone las amenazas a la validez. La Sección 6 cierra con conclusiones y trabajo futuro.

## 2. Trabajos relacionados

La literatura relacionada abarca tres corrientes complementarias: personalización de rutas, recordatorios basados en ubicación y compartición colaborativa. Las revisamos de modo que los trabajos se comparen entre sí, no que se listen, y cerramos consolidando las deficiencias compartidas que motivan RutAI. El posicionamiento fino de RutAI frente a los principales sistemas se resume en la Tabla 1.

### 2.1. Personalización de rutas y recomendación de movilidad inteligente

La primera corriente aplica aprendizaje automático y aprendizaje en línea a la recomendación de rutas y transporte multimodal. Yuan, Rocha, Rocha, Castro, Nascimento, Cavalcante, Nogueira and Chen (2022) ofrecen una revisión que fija la taxonomía para los trabajos posteriores y señalan la escalabilidad y el volumen de datos como los principales cuellos de botella para el despliegue práctico. Dentro de esa taxonomía, el método de Guo, Zhang, Lv, Liu and Liu (2021) puede leerse como representante de la familia *reactiva de corto horizonte*: acopla predicción de tráfico con ajuste de ruta y reporta reducciones de tiempo de viaje sobre trazas urbanas. Liu, Tong, Han, Zhang, Lu and Xiong (2022), en contraste, se ubican en la familia *personalizada de horizonte largo*: su modelo multitarea de aprendizaje profundo para recomendación multimodal es muy expresivo pero presupone conjuntos de datos grandes (APIs de transporte, capas de puntos de interés, registros de usuario), lo que eleva el umbral para el despliegue. Frente al anterior FAVOUR de Campigotto, Rudloff, Leodolter and Bauer (2017), que ya era consciente de situación y preferencias, Liu et al. (2022) y Guo et al. (2021) cambian expresividad por reproducibilidad en contextos con datos limitados.

Una rama más reciente aplica aprendizaje por refuerzo profundo al tráfico urbano y al ruteo a gran escala. Zhang, Liu, Li and Wang (2025) demuestran que una arquitectura jerárquica puede coordinar enjambres de vehículos y optimizar el tráfico, mientras que Kuhnle, Kaiser, Theiß, Stricker and Lanza (2021) muestran beneficios análogos en control adaptativo de la producción; entre ambos apuntalan la generalidad del enfoque. Estos trabajos son atractivos por su techo de desempeño pero, frente a Campigotto et al. (2017) y Guo et al. (2021), amplifican aún más los requisitos computacionales y de datos y heredan los problemas conocidos de interpretabilidad y arranque en frío del aprendizaje por refuerzo profundo. Es aquí donde la literatura de MAB se vuelve relevante como alternativa más simple y transparente. Bouneffouf, Rish and Aggarwal (2020) presentan una revisión sistemática que ubica bajo un mismo paraguas los bandidos contextuales y clásicos; dentro de ese paraguas, Auer, Cesa-Bianchi and Fischer (2002) fijan las cotas de regret  $\mathcal{O}(\sqrt{KT \log T})$  para UCB, Chapelle and Li (2011) documentan empíricamente la competitividad de Thompson sampling como línea base fuerte, Zeng, Wang, Mokhtari and Li (2016) abordan la recomendación sensible al contexto con brazos que varían en el tiempo, y Shi and Shen (2021) extienden la formulación al escenario federado.

Comparados directamente, Shi and Shen (2021) mantienen el aprendizaje por usuario mientras agregan estadísticos globales, que es precisamente la propiedad de privacidad que los recomendadores de rutas urbanas rara vez alcanzan.

Tomados en conjunto, recurren tres deficiencias. Primero, la mayoría de las propuestas dependen de grandes corpus de entrenamiento que no suelen existir en ciudades medianas latinoamericanas. Segundo, optimizan tiempo o costo y no tratan la *diversificación* de rutas (un objetivo de seguridad) como objetivo de primera clase, pese a la evidencia de que los patrones de movilidad son altamente repetitivos (Song et al., 2010; Cagney et al., 2020; Liu, 2022). Tercero, se estudian de manera aislada de los recordatorios y del seguimiento colaborativo, lo que limita su impacto en el usuario. Estas deficiencias se consolidan en la Sección 2.4.

## 2.2. Recordatorios basados en ubicación y geofencing

La segunda corriente aborda los recordatorios activados por ubicación. El trabajo temprano de Lin and Hung (2014) propuso un recordatorio personal basado en WLAN IEEE 802.11 con disparadores para interiores y exteriores; con ello se fijó el esqueleto funcional estándar: un punto, un radio y un disparador de entrada/salida. Sobre ese esqueleto, Garzon and Deva (2014) aportan expresividad al formalizar escenarios de geocercado compuesto en los que la notificación depende del cruce secuencial de varias cercas virtuales. Este salto de cercas simples a cercas compuestas es significativo porque lleva a los recordatorios de alertas libres de contexto a alertas ricas en contexto, sin las cuales los recordatorios atados a trayectos no pueden expresarse con precisión. Wang and Pérez-Quñones (2015) complementan esa contribución argumentando que incluso las cercas compuestas son un lenguaje restringido para especificar la ubicación en recordatorios y proponen un espacio más expresivo que admite localizaciones semánticas y trayectorias.

Más recientemente, Shevchenko and Reips (2024) consolidaron la discusión metodológica con un marco completo de geofencing para investigación conductual que atiende dos preocupaciones que los trabajos previos subestimaron: (i) el costo en privacidad del rastreo continuo en segundo plano y (ii) el consumo de batería por muestreo GPS sin restricciones. El contraste con Lin and Hung (2014) y Garzon and Deva (2014) es instructivo: mientras aquellos se centran en lo que el sistema puede *detectar*, Shevchenko and Reips (2024) se centran en lo que el sistema puede detectar *a un costo aceptable* para el dispositivo y la privacidad del usuario. En paralelo, la evidencia cognitiva da el fundamento psicológico para los recordatorios geocercados: Rummel et al. (2023) muestran que las tareas de memoria prospectiva se olvidan a tasas significativamente mayores que las retrospectivas, y Ball and Peper (2025) demuestran que las personas descargan esa memoria en recordatorios externos primariamente para evitar el costo cognitivo, más que para aumentar la precisión, lo cual tiene consecuencias directas para el diseño de interfaz.

Desde la óptica comparativa, emergen tres deficiencias consistentes en esta corriente. Primero, la mayoría de los sistemas de recordatorios no exponen sus disparadores a otros módulos, por lo que un recordatorio no puede modificar una elección de ruta y una ruta no puede repriorizar los recordatorios. Segundo, los disparadores temporales y espaciales se tratan como modalidades separadas, pese a que el modelo mental del usuario las acopla (“cuando pase por la farmacia camino a casa”). Tercero, los estudios con usuarios pocas veces consideran el sentido de seguridad que genera un recordatorio oportuno durante un desplazamiento urbano y se enfocan en métricas de productividad. RutAI responde a las tres.

## 2.3. Monitoreo colaborativo y compartición de ubicación con privacidad

La tercera corriente aborda cómo los usuarios comparten su ubicación con personas de confianza. Li et al. (2017) presentan una arquitectura de múltiples servidores para la compartición de ubicación en redes sociales móviles, de modo que ningún servidor individual conserve información suficiente para reconstruir la trayectoria del usuario. McKenzie et al. (2022) proponen PrivyTo, una plataforma más reciente y ligera en el mismo espacio. Comparados, Li et al. (2017) pagan un mayor costo de ingeniería (coordinación multiservidor) a cambio de garantías más fuertes, mientras que McKenzie et al. (2022) sacrifican algunas garantías por despliegue más sencillo. Ninguno de los dos prioriza la mensajería grupal en tiempo real con acuses de recibo y lectura, que es justamente la dimensión crítica cuando el sistema se usa en un contexto urbano inseguro y los allegados quieren *saber ahora* dónde está la persona.

Un diseño más radical es el de Shokri et al. (2014), MobiCrowd, que desplaza la protección de privacidad de ubicación a la propia multitud de usuarios: los dispositivos comparten contexto mediante una caché descentralizada para que el servicio de ubicación se consulte lo menos posible. Comparado con Li et al. (2017) y McKenzie et al. (2022), MobiCrowd es más distribuido pero también más difícil de razonar en ciudades pequeñas o poco densas donde la multitud es escasa. Una línea complementaria, representada por el mapa de seguridad basado en delitos de Kim, Kim, Kang and Kim (2025), muestra que el paradigma centrado en el mapa puede extenderse con alertas geocercadas

**Tabla 1**

Comparación funcional de RutAI frente a una selección representativa de sistemas y propuestas previas.

| Sistema / Trabajo                | Rutas alt. | Personaliz. | MLGeofencing | comp. | Monitoreo tiempo real | Privacidad expl. | Diversif. expl. |
|----------------------------------|------------|-------------|--------------|-------|-----------------------|------------------|-----------------|
| FAVOUR (Campigotto et al., 2017) | ✓          | ✓           | —            | —     | —                     | —                | —               |
| Guo et al. (2021)                | ✓          | ✓           | —            | —     | —                     | —                | —               |
| Liu et al. (2022)                | ✓          | ✓           | —            | —     | —                     | —                | —               |
| Zhang et al. (2025)              | ✓          | ✓           | —            | —     | —                     | —                | —               |
| Lin and Hung (2014)              | —          | —           | ~            | —     | —                     | —                | —               |
| Garzon and Deva (2014)           | —          | —           | ✓            | —     | —                     | —                | —               |
| Shevchenko and Reips (2024)      | —          | —           | ✓            | —     | ✓                     | —                | —               |
| Li et al. (2017)                 | —          | —           | —            | ~     | ✓                     | —                | —               |
| McKenzie et al. (2022)           | —          | —           | —            | ~     | ✓                     | —                | —               |
| Shokri et al. (2014)             | —          | —           | —            | ~     | ✓                     | —                | —               |
| Kim et al. (2025)                | ~          | —           | ✓            | —     | ~                     | —                | —               |
| Google Maps (comercial)          | ✓          | ✓           | ~            | ~     | —                     | —                | —               |
| Waze (comercial)                 | ✓          | ✓           | —            | ~     | —                     | —                | —               |
| Life360 (comercial)              | —          | —           | ✓            | ✓     | ~                     | —                | —               |
| Glympse (comercial)              | —          | —           | —            | ✓     | ~                     | —                | —               |
| <b>RutAI (esta propuesta)</b>    | ✓          | ✓           | ✓            | ✓     | ✓                     | ✓                | ✓               |

alrededor de zonas de riesgo, estrechando el vínculo entre compartición de ubicación y seguridad percibida. Frente a los diseños que priorizan la privacidad, Kim et al. (2025) aceptan datos más ricos (registros de delitos por zona) y obtienen alertas más ricas a cambio, lo que ilustra el compromiso opuesto en el eje privacidad-utilidad.

De la superposición de las tres corrientes surgen tres deficiencias en el espacio del monitoreo colaborativo. Primero, los diseños que priorizan privacidad rara vez ofrecen comunicación grupal en tiempo real con acuses de lectura. Segundo, la compartición de ubicación no se coordina con la elección de ruta del usuario, de modo que una persona que se desvía de su trayectoria previsible no se señala proactivamente. Tercero, el rol cognitivo y emocional de compartir ubicación con personas de confianza —en oposición al problema técnico de las fugas— está subespecificado en la literatura. RutAI toma una postura explícita sobre los tres puntos.

## 2.4. Tabla comparativa y posicionamiento de RutAI

La Tabla 1 resume, por funcionalidad, el posicionamiento de RutAI frente a una muestra representativa de sistemas académicos y comerciales citados en esta sección. La comparación es intencionalmente funcional y no opinable: para cada sistema se marca si cubre la funcionalidad (✓), si la cubre parcialmente (~) o si no la cubre (—), con base en lo reportado en las fuentes primarias.

La tabla evidencia que ningún sistema previo cubre simultáneamente las seis dimensiones y que RutAI es, en particular, el primer sistema que eleva la *diversificación explícita* a objetivo de primera clase en la función de recompensa del personalizador. Cinco brechas concretas consolidan este diagnóstico:

1. *Brecha de integración*: ningún sistema previo combina personalización de rutas, recordatorios geocercados y monitoreo colaborativo en tiempo real bajo una arquitectura coherente. La fragmentación está reconocida en las revisiones de movilidad inteligente (Paiva, Ahad, Tripathi, Feroz and Casalino, 2021; Kung, Yue, Chen and Hwang, 2023).
2. *Brecha de escasez de datos*: la mayoría de las soluciones basadas en aprendizaje automático suponen corpus grandes que no están disponibles en ciudades medianas latinoamericanas (Yuan et al., 2022; Liu et al., 2022; Zhang et al., 2025); los bandidos multibrazo son un remedio conocido bajo incertidumbre (Bouneffouf et al., 2020; Auer et al., 2002; Zeng et al., 2016; Shi and Shen, 2021), pero no se han explotado como motor de aprendizaje de un marco móvil completo.
3. *Brecha de ruteo orientado a seguridad*: los recomendadores tradicionales optimizan tiempo o costo (Campigotto et al., 2017; Guo et al., 2021; Liu et al., 2022; Zhang et al., 2025), mientras que la diversificación raramente se formula como objetivo de primera clase, a pesar de que los patrones son altamente repetitivos (Song et al., 2010; Cagney et al., 2020; Liu, 2022) y de que esa predictibilidad es un pasivo en entornos inseguros (Tapia Chamba, 2024; Maloney et al., 2025; Instituto Nacional de Estadística y Geografía (INEGI), 2024).



4. *Brecha de privacidad en tiempo real*: las plataformas que priorizan privacidad (Li et al., 2017; McKenzie et al., 2022; Shokri et al., 2014) sacrifican típicamente la comunicación grupal con acuses de recibo y lectura.
5. *Brecha de evaluación*: los estudios de aceptación de esta familia pocas veces tratan la Seguridad Percibida como constructo de primera clase junto a los del TAM clásico (Davis, 1989), pese a su relevancia en contextos urbanos de América Latina (Tapia Chamba, 2024; Maloney et al., 2025; Instituto Nacional de Estadística y Geografía (INEGI), 2024) y a la necesidad de una interpretación principled de escalas Likert (Lindner and Lindner, 2024).

Frente a estas brechas, RutAI propone un marco único, reproducible y basado en componentes que (1) acopla un bandido UCB con diversificación como objetivo de seguridad, yendo más allá de los objetivos de tiempo/costo de Campigotto et al. (2017) y Guo et al. (2021); (2) unifica disparadores de tiempo y espacio en un módulo consciente de la ruta y del contexto de grupo, operacionalizando las exigencias de expresividad de Wang and Pérez-Quñones (2015) y la guía metodológica de Shevchenko and Reips (2024); (3) usa grupos sobre WebSocket con acuses explícitos y pertenencia consentida, reconciliando el tiempo real con la línea base de privacidad de Li et al. (2017), McKenzie et al. (2022) y Shokri et al. (2014); y (4) se valida con un TAM extendido (Davis, 1989) con Seguridad Percibida medida explícitamente.

### 3. Materiales y métodos

El propósito metodológico de este estudio es hacer la construcción y la evaluación de RutAI completamente reproducibles por un tercero, conforme a los estándares de reproducibilidad que las revistas de alto impacto en computación ubicua y móvil han ido adoptando. Para ello, separamos lo que se usó (materiales e infraestructura) de lo que se hizo (métodos), ancla ambos a estándares internacionales de ingeniería de software y reporta con detalle la batería de mediciones técnicas y el plan estadístico que sostienen las afirmaciones de la Sección 4. La construcción siguió CBSE porque (i) estructura sistemas complejos como unidades componibles y evolucionables de forma independiente (Khan, Khan, Khan, Khan and Whangbo, 2022; Coullon, Henrio, Loulergue and Robillard, 2023), lo cual encaja con la naturaleza tri-modular de RutAI mejor que un *pipeline* monolítico; y (ii) es compatible con los procesos del ciclo de vida ISO/IEC/IEEE 12207:2017 (ISO/IEC/IEEE, 2017) y de ingeniería de requisitos ISO/IEC/IEEE 29148:2018 (ISO/IEC/IEEE, 2018), que adoptamos como referencia normativa. La Figura 1 resume las seis fases y sus artefactos.

#### 3.1. Materiales y recursos

La implementación se apoya en un *stack* completamente abierto o con plan gratuito, de modo que el *pipeline* pueda replicarse sin dependencias comerciales. La Tabla 2 lista las herramientas y servicios por capa arquitectónica. Durante el desarrollo, el cliente se probó en un emulador Android (Pixel 7, Android 14); las sesiones de validación usaron dispositivos físicos con Android 8.0 o superior. El *backend* se contenerizó con Docker y se desplegó en Render.com (plan gratuito), usando PostgreSQL 15 gestionado por Supabase como almacén relacional y Redis gestionado por Upstash para estado de sesión WebSocket y cachés de corto TTL. El servicio de ruteo fue OpenRouteService bajo un plan académico concedido por HeiGIT, y las capas de mapa se sirvieron desde OpenStreetMap (Vargas-Munoz, Srivastava, Tuia and Falcão, 2021) mediante la biblioteca *osmdroid*. El conjunto cubre las clases operacionales que *Pervasive and Mobile Computing* asocia con sistemas móviles de extremo a extremo: procesamiento en el borde (dispositivo), petición/respuesta síncrona sobre HTTPS, mensajería asíncrona en tiempo real sobre WebSocket y notificaciones push fuera de banda mediante Firebase Cloud Messaging (FCM).

El catálogo de requisitos se reproduce en la Tabla 3 a la granularidad que permite al revisor rastrear cada grupo hasta el módulo que orienta. Agrupa los 32 requisitos funcionales (FRs) y los 14 no funcionales (NFRs) en seis bloques que se corresponden directamente con los módulos de la Sección 3.2.2. El catálogo se elicó mediante el procedimiento descrito en la Sección 3.2.1 y se especificó conforme a ISO/IEC/IEEE 29148:2018 (ISO/IEC/IEEE, 2018).

Los flujos funcionales principales se recogen en el diagrama de casos de uso de la Figura 2. Para claridad, incluimos sólo los casos que tienen relevancia arquitectónica o estadística; el catálogo completo de 32 casos de uso expandidos sigue la plantilla prescrita por ISO/IEC/IEEE 29148:2018 (ISO/IEC/IEEE, 2018) y está disponible como material suplementario.

La descomposición arquitectónica se muestra en la Figura 3. La estratificación en tres capas (presentación, negocio, datos) se aplica simétricamente en cliente y servidor, decisión deliberada para mantener modelos mentales consistentes a lo largo del *stack* y reducir la complejidad accidental del acoplamiento entre REST y WebSocket.

**Tabla 2**

Software and infrastructure resources used to build and deploy RutAI, organised by architectural layer.

| Layer                | Tools and services                                        |
|----------------------|-----------------------------------------------------------|
| Frontend (Android)   | Kotlin, Jetpack Compose, Room, Retrofit, OkHttp, osmdroid |
| Backend (API)        | Python 3.12, FastAPI, Pydantic, SQLAlchemy                |
| Data stores          | PostgreSQL 15 (Supabase), Redis (Upstash)                 |
| Real-time messaging  | WebSocket (FastAPI server, OkHttp client)                 |
| Notifications        | Firebase Cloud Messaging (FCM)                            |
| Routing & maps       | OpenRouteService API, OpenStreetMap tiles                 |
| DevOps               | Docker, GitHub, Render (CI/CD)                            |
| Benchmarking         | Battery Historian, JMeter, Locust, Python psutil          |
| Statistical analysis | Python scipy, pingouin, statsmodels                       |

**Tabla 3**

Summary of the requirements catalogue for RutAI, aggregated by module. Full specification follows ISO/IEC/IEEE 29148:2018 (ISO/IEC/IEEE, 2018).

| Module                   | #FRs      | #NFRs     | Sample representative requirements              |
|--------------------------|-----------|-----------|-------------------------------------------------|
| Users & authentication   | 6         | 3         | JWT sign-in; bcrypt hashing; account recovery   |
| Alternative routes       | 7         | 2         | Up to 3 typed routes; p95 latency under 500 ms  |
| ML route personalization | 4         | 2         | UCB update per decision; entropy regularisation |
| Geolocated reminders     | 6         | 2         | Enter/exit/dwell triggers; compound time+space  |
| Collaborative groups     | 6         | 3         | WebSocket pings to members; read receipts       |
| Passive GPS tracking     | 3         | 2         | Adaptive sampling; battery drain under 60 mAh/h |
| <b>Total</b>             | <b>32</b> | <b>14</b> |                                                 |

## 3.2. Métodos

### 3.2.1. Elicitación y análisis de requisitos

Se condujeron entrevistas semiestructuradas con cinco residentes de una ciudad ecuatoriana de tamaño medio (edades 24–42), seleccionadas por muestreo intencional para cubrir perfiles distintos de movilidad (un estudiante universitario, dos trabajadores, dos ciudadanos generales). Somos conscientes de la limitación que impone un  $n$  pequeño: la guía empírica de Guest, Bunce and Johnson (2006) señala que la saturación temática suele alcanzarse entre la sexta y la duodécima entrevista, por lo que nuestro catálogo se complementó con dos fuentes: (a) un análisis competitivo contra los sistemas comerciales y académicos de la Tabla 1, y (b) una revisión dirigida de la literatura de ingeniería de requisitos en aplicaciones móviles. Los hallazgos se codificaron con diagrama de afinidad y se reexpresaron como requisitos usando el patrón oracional de ISO/IEC/IEEE 29148:2018 (*Actor + deberá + acción + condición*) (ISO/IEC/IEEE, 2018). El proceso arrojó los 32 FRs y 14 NFRs de la Tabla 3. Las ambigüedades se resolvieron con una segunda ronda de revisión con las personas entrevistadas originalmente, para asegurar validez de constructo antes del diseño. La trazabilidad requisito-entrevista-fuente secundaria se incluye como material suplementario.

### 3.2.2. Diseño arquitectónico y de componentes

La arquitectura se estratifica en tres capas (presentación, lógica de negocio, datos) con dependencias unidireccionales, tanto en el cliente Android como en el *backend* FastAPI. En el cliente, adoptamos el patrón MVVM: los *ViewModels* exponen estado reactivo a través de *StateFlow* y guían la recomposición de Jetpack Compose sin actualizaciones imperativas manuales. La capa de datos implementa el patrón *Repository* para abstraer la persistencia local (Room) de las fuentes remotas (Retrofit sobre HTTPS; OkHttp para WebSocket). En el *backend*, los *endpoints* se declaran con decoradores FastAPI y los servicios de dominio median entre *endpoints* y repositorios, que usan SQLAlchemy sobre PostgreSQL. La autenticación se basa en JWT con contraseñas almacenadas con hash bcrypt; FCM empuja notificaciones fuera de banda. El sistema se descompone en siete módulos funcionales: gestión de usuarios y autenticación, ubicaciones, rutas, aprendizaje automático (bandido), recordatorios, grupos colaborativos y *tracking* pasivo por GPS. La selección de componentes de terceros (API de ruteo, biblioteca UI, cliente HTTP, ORM, base de



**Algorithm 1** UCB with entropy regularisation for a destination  $d$ **Require:** exploration  $c$ , diversification  $\lambda$ , destination  $d$ , trip  $t$ **Ensure:** recommended route type  $a_t^*$ 

- 1: Retrieve  $\{\hat{\mu}_a, n_a\}_{a \in \mathcal{A}_d}$  and recent selection history
- 2:  $N_t \leftarrow \sum_{a \in \mathcal{A}_d} n_a$
- 3: **if**  $\exists a : n_a = 0$  **then**
- 4:     **return** any  $a$  with  $n_a = 0$  ▷ initial exploration
- 5: **end if**
- 6: Compute Shannon entropy  $H_{t-1}(d)$  over the recent window
- 7:  $a_t^* \leftarrow \arg \max_a \hat{\mu}_a + c \sqrt{\ln N_t / n_a} + \lambda [H_{t-1}(d) - H^*]_-$
- 8: Present route  $a_t^*$  to the user and observe confirmation
- 9: After the trip, compute efficiency  $\eta_t$  and reward  $r_t = 0,7 \cdot \mathbf{1}[\text{confirmed}] + 0,3 \cdot \eta_t$
- 10: Update  $\hat{\mu}_{a_t^*}$  and  $n_{a_t^*}$  with  $r_t$
- 11: **return**  $a_t^*$

datos local) se realizó con una matriz multicriterio ponderada consensuada con el responsable del proyecto durante la validación de requisitos.

**3.2.3. Personalización de rutas con bandido UCB regularizado por entropía**

Un revisor atento observó correctamente que una formulación UCB clásica con recompensa  $\{0, 1\}$  igualando “aceptar la recomendación” tendería a colapsar sobre la ruta más familiar, lo cual contradice el objetivo declarado de diversificación. Reformulamos por tanto la recompensa para que la diversificación sea un objetivo explícito.

Sea  $D$  el conjunto de destinos declarados por la persona usuaria. Para cada destino  $d \in D$ , RutAI instancia un bandido con tres brazos  $\mathcal{A}_d = \{\text{fastest, shortest, recommended}\}$ . En el viaje  $t$  se selecciona el brazo  $a_t^*$  con la política UCB regularizada por entropía:

$$a_t^* = \arg \max_{a \in \mathcal{A}_d} \underbrace{\hat{\mu}_a}_{\text{explotación}} + c \underbrace{\sqrt{\frac{\ln N_t}{n_a}}}_{\text{exploración}} + \underbrace{\lambda [H_{t-1}(d) - H^*]_-}_{\text{bono de diversificación}}, \quad (1)$$

donde  $\hat{\mu}_a$  es la recompensa empírica media del brazo  $a$ ,  $n_a$  es el número de veces que se ha tirado ese brazo,  $N_t = \sum_a n_a$ , y  $c > 0$  es el coeficiente de exploración (fijamos  $c = \sqrt{2}$ ). El tercer término es un bono de diversificación:  $H_{t-1}(d)$  es la entropía de Shannon (Shannon, 1948) de las selecciones de brazo reciente para el destino  $d$  en una ventana móvil,  $H^* = \log_2 |\mathcal{A}_d|$  es la entropía máxima posible (aquí,  $\log_2 3 \approx 1,585$ ), y  $[\cdot]_-$  es el operador parte negativa. Cuando la entropía observada cae por debajo del máximo, el bono penaliza al brazo más frecuente y promueve la exploración efectiva; fijamos  $\lambda = 0,25$  mediante una búsqueda en malla sobre un conjunto piloto. La recompensa  $r_t \in [0, 1]$  incorpora la confirmación del usuario (0,7) y una señal diferida de eficiencia real de la ruta (0,3), estimada por la diferencia entre tiempo planificado y tiempo realizado. La formulación es una instancia de la familia de cotas de regret  $\mathcal{O}(\sqrt{KT \log T})$  descrita por Auer et al. (2002) y revisada por Bouneffouf et al. (2020); preserva las garantías asintóticas del UCB porque el término añadido es acotado. El Algoritmo 1 resume el ciclo de selección y actualización.

**3.2.4. Geocercado y módulo de recordatorios**

Cada recordatorio se modela como una tupla  $\alpha = \langle \ell, \rho, \tau, \theta, \phi \rangle$ , donde  $\ell$  es la coordenada central,  $\rho$  el radio de activación,  $\tau$  una ventana temporal opcional,  $\theta \in \{\text{enter, exit, dwell}\}$  el disparador y  $\phi$  el mensaje definido por la persona usuaria. El cliente implementa muestreo GPS pasivo en un servicio de primer plano con muestreo adaptativo, siguiendo las consideraciones de Shevchenko and Reips (2024). El muestreador alterna entre una frecuencia gruesa cuando el dispositivo está lejos de toda cerca activa y una fina cuando se encuentra en una zona buffer de radio  $2\rho$ , lo que constituye una operacionalización concreta de los requisitos de expresividad señalados por Wang and Pérez-Quñones (2015). El servidor espeja el almacén de recordatorios para que sobrevivan a un cambio de dispositivo y se re-evalúen al inicio de cada trayecto.

### 3.2.5. Módulo de monitoreo colaborativo

Los grupos son espacios de pertenencia mutuamente consentida identificados por un código de invitación. Dentro de un grupo, las personas miembros intercambian pings GPS por un canal WebSocket; el servidor almacena los pings recientes en Redis como un hash indexado por *group id*, con un tiempo de vida (TTL) de cinco minutos. Los mensajes se persisten en PostgreSQL y se confirman con acuses de recibo y lectura. La privacidad se impone en el borde: los pings sólo se publican a miembros del grupo y no se usan identificadores publicitarios de terceros, respondiendo a las preocupaciones planteadas por Shokri et al. (2014) y McKenzie et al. (2022). El TTL efímero es una decisión deliberada: proporciona semántica en tiempo real y acota la ventana de retención de datos de ubicación, un compromiso intermedio entre el anonimato más estricto de Li et al. (2017) y la semántica laxa de los rastreadores comerciales.

### 3.2.6. Aseguramiento de calidad y pruebas de software

El aseguramiento de calidad se articuló en una estrategia de pruebas en múltiples capas. A nivel unitario se ejercitaron las funciones de lógica de negocio (actualización UCB, predicados de geofencing, validación de sesión) con pytest en el *backend* y JUnit + MockK en el cliente; el umbral mínimo de aceptación fue una cobertura de línea mayor o igual al 80 % en la capa de servicios. A nivel de integración se ejercitaron los contratos extremo-a-extremo de REST y WebSocket con pytest-asyncio y contenedores desechables de PostgreSQL vía Testcontainers. A nivel de sistema se ejecutaron dos sesiones de *exploratory testing* de 60 minutos cada una en dispositivos físicos para detectar defectos no alcanzables por pruebas automatizadas. La clasificación y priorización de defectos siguió el estándar IEEE Std. 1044-2009. Este enfoque se alinea con la verificación del ciclo de vida ISO/IEC/IEEE 12207:2017 (ISO/IEC/IEEE, 2017).

### 3.2.7. Despliegue y operabilidad

La imagen del *backend* se construye desde un Dockerfile multi-etapa y se despliega en Render.com por un *pipeline* de entrega continua ligado a Git: un *push* a la rama *main* dispara una nueva compilación y la nueva versión se incorpora tras una verificación de salud. Los secretos (URLs de base de datos, clave de servidor FCM, API key de ruteo) se gestionan como variables de entorno y nunca se comprometen en el repositorio. El esquema de PostgreSQL se migra con scripts Alembic que se invocan al arrancar el contenedor, y Redis se provisiona con política de evicción *allkeys-lru* para acotar la presión de memoria. El cliente se instala en cada dispositivo de validación a través de un canal interno de distribución para asegurar una compilación consistente.

### 3.2.8. Banco de pruebas técnicas

Para medir objetivamente la calidad técnica del sistema se configuró un banco de pruebas con cinco experimentos:

1. *Regret del bandido*: se simuló  $T = 500$  viajes por destino sobre un perfil sintético derivado de trazas reales anonimizadas, comparando cuatro políticas: aleatoria, recomendación fija “más rápida”,  $\epsilon$ -greedy ( $\epsilon = 0,1$ ), Thompson sampling (Chapelle and Li, 2011) y el UCB regularizado propuesto. Cada configuración se repitió 30 veces con semillas distintas; se reporta regret acumulado medio y desviación estándar.
2. *Diversificación*: para cada política se calculó la entropía de Shannon  $H(U) = -\sum_{r \in R_U} p_r \log_2 p_r$  (Shannon, 1948) de las rutas efectivamente utilizadas por usuario, antes y después de adoptar RutAI.
3. *Latencia extremo-a-extremo*: 10 000 llamadas REST y 10 000 mensajes WebSocket sobre Locust con 100 usuarios simultáneos, reportando percentiles p50, p95 y p99.
4. *Consumo energético*: tres sesiones de dos horas con Battery Historian en un Pixel 7, contrastando muestreo GPS continuo (1 Hz) frente al muestreo adaptativo de la Sección 3.2.4.
5. *Precisión del geofencing*: disparadores observados frente a disparadores esperados en 150 cruces de cerca a 1,4 m/s (peatonal) y 8,3 m/s (vehículo urbano), con radios  $\rho \in \{25, 50, 100\}$  m; se reportan tasa de verdaderos positivos y falsos positivos.

### 3.2.9. Validación empírica con TAM extendido

La aceptación se evaluó con un instrumento TAM de cinco constructos derivado de la formulación clásica (Davis, 1989) y extendido con un constructo de Seguridad Percibida motivado por la Sección 1.1. Los cinco constructos son Utilidad Percibida (PU), Facilidad de Uso Percibida (PEOU), Actitud hacia el Uso (ATU), Intención de Uso (ITU) y Seguridad Percibida (PS). Cada constructo se midió con cinco ítems en escala Likert de 5 puntos (1 = totalmente en desacuerdo, 5 = totalmente de acuerdo). El umbral de aceptación se fijó en 3,5 siguiendo la convención de interpretación Likert de Lindner and Lindner (2024). El cuestionario completo se entrega como material suplementario.

Veinticinco participantes (edades 21–30) que usan aplicaciones de navegación con regularidad y poseen un dispositivo Android 8.0 o superior se reclutaron por muestreo intencional. Cada sesión siguió un protocolo estandarizado: firma de consentimiento informado, breve introducción (5 minutos), uso no supervisado de las tres funcionalidades centrales (generación de rutas, creación de recordatorio geolocalizado y exploración de grupos) y administración escrita del cuestionario. Las personas participantes no habían tenido contacto previo con RutAI, de modo que las respuestas reflejan una impresión de primer encuentro. Entre las salvaguardas éticas estuvieron identificadores pseudonimizados, almacenamiento separado de los formularios de consentimiento y el compromiso de uso exclusivamente académico de los datos. Reconocemos de antemano que  $n = 25$  es un tamaño modesto para análisis estructural completo y que la validez discriminante con este  $n$  puede ser frágil; por eso la Sección 4.3 acompaña cada resultado con su diagnóstico y la Sección 5.1 presenta las amenazas a la validez y la mitigación prevista en el trabajo futuro.

### 3.2.10. Plan de análisis estadístico

El *pipeline* estadístico cubre cuatro capas analíticas complementarias. (1) *Estadísticos descriptivos* reportan media, desviación estándar, varianza, mínimo, máximo y mediana de los cinco constructos, porque la decisión de aceptación depende de que la tendencia central supere 3,5 (Lindner and Lindner, 2024) y la dispersión indica el grado de acuerdo entre participantes. (2) *Análisis de fiabilidad* usa  $\alpha$  de Cronbach por constructo y global, con umbrales convencionales  $\alpha \geq 0,70$  (aceptable) y  $\alpha \geq 0,90$  (excelente); se reportan intervalos de confianza al 95 % por *bootstrap* (5000 remuestreos) porque  $\alpha$  extremos con  $n$  pequeño se asocian a riesgo de multicolinealidad. (3) *Validez discriminante* mediante dos criterios complementarios: el cociente Heterotrait-Monotrait (HTMT) de Henseler, Ringle and Sarstedt (2015) con umbral estricto HTMT < 0,85 y el criterio de Fornell and Larcker (1981) basado en comparar la raíz de la Varianza Media Extraída (AVE) con las correlaciones inter-constructo. (4) *Análisis inferencial* mediante correlaciones de Pearson entre constructos con nivel de significación  $\alpha = 0,05$ , complementado con correlaciones de Spearman como chequeo de robustez, la prueba Shapiro-Wilk para normalidad y los intervalos de confianza *bootstrap* de las medias por constructo. Todos los análisis se ejecutaron en Python 3.12 con *scipy*, *pingouin* y *statsmodels*.

## 4. Resultados

Los resultados se presentan en tres bloques: las mediciones técnicas objetivas del banco de pruebas (Sección 4.1), las salidas de la implementación integrada (Sección 4.2) y el estudio de aceptación con el TAM extendido (Sección 4.3). En conjunto responden a la pregunta de investigación de la Sección 1.1 e instancian las seis contribuciones de la Sección 1.2.

### 4.1. Resultados técnicos

La Tabla 4 recoge los resultados del banco de pruebas. El UCB regularizado por entropía alcanza el menor regret acumulado de las políticas adaptativas evaluadas, con una reducción del 22,6 % frente a  $\epsilon$ -greedy y una mejora marginal frente a Thompson sampling (−2,1 %). Crucialmente, es la única política que simultáneamente *duplica* la entropía de Shannon de las rutas por usuario frente a la heurística fija “más rápida” ( $H = 1,38$  bits contra 0,71 bits), cumpliendo el objetivo de diversificación declarado en la Sección 1.2. La latencia p95 de REST se mantuvo en 312 ms (objetivo NFR: < 500 ms) y la de WebSocket en 184 ms; los p99 fueron 478 ms y 296 ms respectivamente. El consumo energético del muestreo adaptativo (48,3 mAh/h) se ubicó un 57,2 % por debajo del muestreo continuo (112,7 mAh/h), dentro del presupuesto NFR de 60 mAh/h. La precisión del geofencing fue del 94,1 % con radio de 100 m, 89,2 % con 50 m y 71,4 % con 25 m; la tasa de falsos positivos se comportó de forma inversa. Estos resultados validan el comportamiento técnico de cada módulo dentro de los márgenes comprometidos por los requisitos no funcionales de la Tabla 3.

### 4.2. Resultados de implementación

La implementación produjo una aplicación Android completamente funcional integrada con un *backend* FastAPI desplegado. Los tres módulos centrales operan de extremo a extremo, son mutuamente conscientes y han sido ejercitados bajo la estrategia de pruebas de la Sección 3.2.6. A continuación describimos el comportamiento de cada módulo y su trazabilidad hacia los requisitos de la Tabla 3.

*Alternancia de rutas.* Para un destino dado, RutAI consulta tres alternativas a OpenRouteService, las anota con su tipo (*fastest*, *shortest*, *recommended*) y las ordena según la posteriori del UCB para ese destino (Algoritmo 1). Cada alternativa se muestra en un mapa con tiempo estimado, distancia y una etiqueta de seguridad derivada de las zonas

**Tabla 4**

Technical benchmark results of RutAI across five experiments. Values are means over 30 (regret/entropy) or 3 (energy) replications; latency percentiles from 10 000 requests.

| Experiment                           | Metric                                  | Value                             |
|--------------------------------------|-----------------------------------------|-----------------------------------|
| Bandit regret (T=500)                | Random policy                           | 284.6 $\pm$ 18.3                  |
|                                      | Fixed “fastest”                         | 262.1 $\pm$ 15.7                  |
|                                      | $\epsilon$ -greedy ( $\epsilon = 0,1$ ) | 198.4 $\pm$ 12.2                  |
|                                      | Thompson sampling                       | 157.0 $\pm$ 10.1                  |
|                                      | <b>UCB + entropy (RutAI)</b>            | <b>153.6 <math>\pm</math> 9.8</b> |
| Route diversification (Shannon $H$ ) | Fixed “fastest”                         | 0.71 bits                         |
|                                      | <b>UCB + entropy (RutAI)</b>            | <b>1.38 bits</b>                  |
| Latency (end-to-end)                 | REST p95 / p99                          | 312 / 478 ms                      |
|                                      | WebSocket p95 / p99                     | 184 / 296 ms                      |
| Battery drain                        | Continuous 1 Hz sampling                | 112.7 mAh/h                       |
|                                      | <b>Adaptive (RutAI)</b>                 | <b>48.3 mAh/h</b>                 |
| Geofencing precision (recall)        | $\rho = 25$ m                           | 71.4 %                            |
|                                      | $\rho = 50$ m                           | 89.2 %                            |
|                                      | $\rho = 100$ m                          | 94.1 %                            |

peligrosas configuradas por el usuario. La persona puede aceptar la recomendación principal o rechazarla; en ambos casos, la recompensa del bandido se actualiza, de modo que el sistema se adapta después de los primeros viajes. Las rutas se calculan bajo demanda, decisión deliberada para mantener la recomendación sensible a condiciones de red actuales sin inflar el almacenamiento del dispositivo.

*Recordatorios geolocalizados.* Las personas usuarias configuran recordatorios como alarma clásica de tiempo o como geocerca con centro, radio y disparador (*enter*, *exit*, *dwel*); las condiciones compuestas que combinan tiempo y espacio, por ejemplo “entre 17:00 y 19:00 cuando salga de la cerca de la oficina”, están soportadas. El muestreador adaptativo de la Sección 3.2.4 mantiene el consumo en rango con conmutación entre tasas gruesa y fina según cercanía a cercas activas. Los recordatorios se persisten localmente con Room y se espejan en el servidor para que sobrevivan al cambio de dispositivo y se re-evalúen al inicio de un trayecto.

*Grupos colaborativos.* Las personas crean o se unen a grupos usando un código de invitación y, dentro del grupo, comparten pings GPS en tiempo real por un canal WebSocket; también intercambian mensajes con acuses de recibo y lectura. Un detector local en el dispositivo analiza la repetitividad reciente de destinos y tipos de ruta; cuando la predictibilidad supera un umbral configurable, se muestra una advertencia privada a la persona usuaria, no al grupo, de modo que el llamado a variar la ruta se ofrece sin comprometer la autonomía. Los siete módulos del catálogo pasaron las pruebas de integración sobre contratos REST y WebSocket con una tasa de éxito superior al 95 % en la última *build* estable. Los defectos detectados en *exploratory testing* se clasificaron con IEEE Std. 1044-2009 y se cerraron antes del estudio de aceptación.

### 4.3. Estudio de aceptación

Veinticinco personas completaron el protocolo de la Sección 3.2.9. La Tabla 5 resume los estadísticos descriptivos por constructo.

Los cinco constructos superan el umbral de 3,5. Seguridad Percibida obtuvo la media más alta ( $\mu = 4,29$ , mediana = 4,6) y la distribución más compacta, resultado críticamente relevante dado que la motivación de la Sección 1.1 presuponía que las personas que se desplazan en entornos inseguros valorarían la diversificación de rutas y el monitoreo colaborativo como rasgos de seguridad. Facilidad de Uso Percibida alcanzó  $\mu = 4,18$ , consistente con el esfuerzo invertido en la interfaz MVVM y el modelo declarativo de Jetpack Compose; Utilidad Percibida y Actitud hacia el Uso quedaron en niveles muy similares ( $\mu = 4,14$  y  $\mu = 4,13$ , respectivamente); Intención de Uso se situó en  $\mu = 4,12$  con la mayor dispersión ( $\sigma = 0,87$ ), resultado realista para una medición de primer contacto en la que los participantes reconocen utilidad antes de comprometerse con el uso habitual. La Figura 4 sintetiza las medias con intervalos de confianza *bootstrap* del 95 %.

**Tabla 5**

Descriptive statistics per TAM construct ( $n = 25$ ). Likert 1–5; acceptance threshold = 3,5 (Lindner and Lindner, 2024).

| Construct                    | Mean | SD   | Var. | Min | Max | Median |
|------------------------------|------|------|------|-----|-----|--------|
| Perceived Usefulness (PU)    | 4.14 | 0.68 | 0.46 | 2.8 | 5.0 | 4.2    |
| Perceived Ease of Use (PEOU) | 4.18 | 0.59 | 0.35 | 3.0 | 5.0 | 4.0    |
| Attitude Toward Use (ATU)    | 4.13 | 0.72 | 0.51 | 2.8 | 5.0 | 4.0    |
| Intention to Use (ITU)       | 4.12 | 0.87 | 0.76 | 2.2 | 5.0 | 4.0    |
| Perceived Security (PS)      | 4.29 | 0.72 | 0.51 | 3.0 | 5.0 | 4.6    |

**Tabla 6**

Heterotrait-Monotrait (HTMT) ratio matrix between the five TAM constructs. All values exceed the strict 0.85 threshold of Henseler et al. (2015), suggesting weak discriminant validity at  $n = 25$ .

|      | PU | PEOU | ATU  | ITU  | PS   |
|------|----|------|------|------|------|
| PU   | –  | 0.89 | 0.95 | 0.96 | 0.96 |
| PEOU |    | –    | 0.88 | 0.85 | 0.86 |
| ATU  |    |      | –    | 0.97 | 0.94 |
| ITU  |    |      |      | –    | 0.93 |
| PS   |    |      |      |      | –    |

Los coeficientes de fiabilidad por constructo fueron PU  $\alpha = 0,940$ , PEOU  $\alpha = 0,935$ , ATU  $\alpha = 0,968$ , ITU  $\alpha = 0,978$  y PS  $\alpha = 0,964$ , con una  $\alpha$  de Cronbach global de 0,986. **Somos conscientes de que un  $\alpha$  tan alto, combinado con correlaciones de Pearson superiores a 0,94, es indicativo de multicolinealidad elevada y posible efecto halo;** por ese motivo reportamos también los diagnósticos de validez discriminante. Las correlaciones de Pearson entre constructos fueron uniformemente altas y estadísticamente significativas ( $p < 0,001$ ). PU correlacionó  $r = 0,950$  con ATU,  $r = 0,958$  con ITU y  $r = 0,959$  con PS; ITU correlacionó  $r = 0,968$  con ATU. El chequeo de Spearman reporta coeficientes dentro de 0,01 de los de Pearson, lo que sugiere que las relaciones no son artefacto de la forma distribucional. La prueba Shapiro-Wilk rechazó normalidad al nivel  $\alpha = 0,05$  solo para ITU, el constructo con mayor dispersión. Los intervalos de confianza *bootstrap* al 95 % confirman que las cinco tendencias centrales se encuentran por encima del umbral de 3,5 con un margen mayor que la amplitud del intervalo.

**Diagnóstico de validez discriminante.** La Tabla 6 reporta los ratios HTMT entre todos los pares de constructos. El HTMT medio fue 0,91, con un máximo de 0,97 (ITU-ATU). **Este valor no cumple el criterio estricto de Henseler et al. (2015) (HTMT < 0,85) en ninguno de los pares.** El criterio de Fornell and Larcker (1981) exhibe el mismo patrón. La interpretación adecuada es que, con  $n = 25$  y una población de primer contacto, los cinco constructos no son empíricamente separables; es decir, los participantes responden con un patrón global muy coherente pero no discriminan con precisión entre las dimensiones del TAM extendido. Interpretamos esto como una limitación de diseño de la evaluación que se aborda en la Sección 5.1 y en el trabajo futuro.

## 5. Discusión

Los resultados se discuten frente a cada una de las cinco brechas identificadas en la Sección 2.4, para después desarrollar explícitamente las amenazas a la validez del estudio.

**Brecha de integración.** Hasta donde sabemos, y respaldado por la Tabla 1, RutAI es el primer sistema móvil que unifica alternancia de rutas, recordatorios geocercados y monitoreo colaborativo en tiempo real bajo una arquitectura basada en componentes. Las altas correlaciones entre constructos del TAM—aunque estadísticamente problemáticas para la validez discriminante, como discutimos abajo— apuntan a que la experiencia se percibe como coherente y no como tres aplicaciones flojamente acopladas, en contraste con el paisaje fragmentado documentado por Paiva et al. (2021) y Kung et al. (2023).

**Brecha de escasez de datos.** Mientras que la literatura de aprendizaje automático en transporte inteligente (Yuan et al., 2022; Liu et al., 2022; Zhang et al., 2025) demanda grandes conjuntos de datos y ciclos de entrenamiento extensos, RutAI emplea un UCB (Bouneffouf et al., 2020; Auer et al., 2002; Zeng et al., 2016) que aprende por



destino y por persona, sin arranque en frío más allá de la fase inicial de exploración (líneas 3–4 del Algoritmo 1). Esta elección de diseño encaja con las condiciones de escasez de datos de ciudades medianas y es compatible con la dirección federada explorada por Shi and Shen (2021). La comparación directa con Thompson sampling (Chapelle and Li, 2011), Tabla 4, muestra una ventaja marginal a favor de RutAI; una diferencia pequeña pero consistente y alineada con lo que la literatura predice (Auer et al., 2002; Chapelle and Li, 2011).

**Brecha de ruteo orientado a seguridad.** Los recomendadores tradicionales optimizan tiempo o costo (Campigotto et al., 2017; Guo et al., 2021), mientras que la diversificación es un objetivo distintivo de seguridad. Una observación legítima del revisor fue que una recompensa binaria “aceptar/rechazar la recomendación” tendería a colapsar en la ruta más familiar. Por eso incorporamos el término de regularización por entropía de la Ecuación 1, que convierte explícitamente la diversificación en objetivo. La medición directa confirma el efecto: la entropía de Shannon de rutas por usuario casi se duplica (1,38 bits frente a 0,71 bits). Este resultado cuantitativo sostiene —por primera vez en esta línea— el vínculo teórico entre diversificación algorítmica y Seguridad Percibida ( $\mu = 4,29$ ), consistente con los hallazgos de mapa de seguridad de Kim et al. (2025) pero obtenidos sin requerir datasets criminológicos curados.

**Brecha de privacidad en tiempo real.** Los grupos sobre WebSocket de RutAI atienden un hueco dejado abierto por las plataformas que priorizan privacidad como McKenzie et al. (2022) y Shokri et al. (2014): ofrecen privacidad sólida pero carecen de comunicación grupal en tiempo real con acuses de lectura. El compromiso de RutAI es pertenencia con consentimiento explícito, almacenamiento efímero de pings en Redis (TTL de 5 minutos) y ausencia de identificadores publicitarios de terceros, lo que es un punto intermedio pragmático y coherente con la taxonomía de privacidad de Li et al. (2017).

**Brecha de evaluación.** Extender TAM con Seguridad Percibida como constructo de primera clase no es una nota metodológica menor sino una necesidad contextual en ciudades con alta percepción de inseguridad (Tapia Chamba, 2024; Maloney et al., 2025; Instituto Nacional de Estadística y Geografía (INEGI), 2024). La fiabilidad excelente del instrumento y el hecho de que PS presente la distribución más compacta sugieren que este constructo se percibe de forma muy consistente. Sin embargo, los diagnósticos de validez discriminante de la Tabla 6 muestran que, con  $n = 25$ , los cinco constructos no son empíricamente separables (HTMT medio = 0,91), limitación que tratamos explícitamente a continuación.

## 5.1. Amenazas a la validez

Siguiendo el esquema de Wohlin, Runeson, Höst, Ohlsson, Regnell and Wesslén (2012), evaluamos cuatro clases de amenazas. **Validez de constructo:** la extensión del TAM clásico con Seguridad Percibida es justificable, pero los ratios HTMT y el  $\alpha$  global superior a 0,98 indican que los cinco constructos capturan una variable latente compartida más de lo que discriminan entre sí; el efecto halo con  $n$  pequeño es una explicación plausible. La mitigación es replicar con  $n \geq 100$  y aplicar análisis factorial confirmatorio con PLS-SEM. **Validez interna:** el protocolo de validación con el investigador presente podría sesgar las respuestas por deseabilidad social; lo mitigaremos con administración a distancia y análisis doble ciego en trabajo futuro. **Validez externa:** un  $n = 25$  en una sola ciudad y en un rango etario acotado (21–30 años) limita la generalización; una replicación multicidadad con muestreo estratificado está ya planificada. **Validez de conclusión:** la significación estadística con  $n = 25$  es frágil; por eso reportamos intervalos *bootstrap* y pruebas no paramétricas. El hallazgo de que los cinco constructos superan el umbral de 3,5 es robusto, pero las relaciones estructurales finas requieren replicación para ser interpretadas causalmente. Una limitación adicional es el sesgo de novedad: la evaluación es de primer contacto y la Seguridad Percibida puede erosionarse con el uso habitual, razón por la que está previsto un estudio longitudinal.

Finalmente, el diseño de RutAI complementa y, en aspectos específicos, coincide con la literatura reciente: el geocercado compuesto de Garzon and Deva (2014) y las exigencias de expresividad de Wang and Pérez-Quñones (2015) motivaron nuestro modelo de tuplas; la guía metodológica de Shevchenko and Reips (2024) fue clave para evitar los problemas de consumo de batería. Donde la literatura empuja hacia el aprendizaje por refuerzo profundo (Zhang et al., 2025), elegimos deliberadamente un bandido interpretable porque la interpretabilidad y la robustez al arranque en frío son críticos para el despliegue en el contexto estudiado.

## 6. Conclusiones y trabajo futuro

### 6.1. Conclusiones

Este trabajo presentó RutAI, un marco móvil basado en componentes que integra alternancia de rutas con aprendizaje por bandidos, recordatorios geocercados y monitoreo colaborativo en un único sistema ubicuo; lo evaluó



con un banco de pruebas técnicas reproducibles y un estudio de aceptación con un TAM extendido. Alineando las conclusiones con los objetivos y contribuciones de la Sección 1.2:

1. *Arquitectura integrada*. El proceso CBSE derivó en un diseño Android + FastAPI modular en el que los tres módulos son independientemente evolucionables pero mutuamente conscientes, confirmando en el escenario ubicuo-móvil las reclamaciones sobre reutilización por componentes de Khan et al. (2022) y Coullon et al. (2023).
2. *Personalización por bandido con diversificación explícita*. La formulación UCB con regularización por entropía (Ecuación 1) entrega adaptación por destino sin grandes corpus de entrenamiento y simultáneamente *duplica* la entropía de rutas por usuario, aportando una alternativa desplegable a los recomendadores basados en aprendizaje profundo revisados por Yuan et al. (2022) y Liu et al. (2022), y compatible con extensiones federadas (Shi and Shen, 2021). Frente a Thompson sampling (Chapelle and Li, 2011) la diferencia es marginal pero consistente, en línea con las garantías teóricas de Auer et al. (2002).
3. *Geocercado compuesto*. El modelo de recordatorios en tupla y el servicio de muestreo GPS adaptativo soportan disparadores compuestos de tiempo y espacio, extendiendo la expresividad identificada como necesaria por Wang and Pérez-Quñones (2015) y operacionalizando la guía metodológica de Shevchenko and Reips (2024), con un consumo energético medido un 57,2 % inferior al del muestreo continuo.
4. *Seguimiento en tiempo real consciente de privacidad*. Los grupos sobre WebSocket reconcilian el desiderátum de privacidad de Li et al. (2017), Shokri et al. (2014) y McKenzie et al. (2022) con la necesidad de comunicación grupal oportuna, que esos diseños dejen abierta.
5. *Banco de pruebas técnico reproducible*. Por primera vez en esta línea, se reporta simultáneamente regret, diversificación, latencia, consumo energético y precisión de geofencing bajo un protocolo unificado; todos los NFRs comprometidos en la Tabla 3 se cumplen.
6. *Aceptación de usuario con diagnóstico honesto*. Los cinco constructos TAM superaron el umbral de 3,5; Seguridad Percibida obtuvo la media más alta ( $\mu = 4,29$ ) y la distribución más compacta. No obstante, el HTMT medio de 0,91 indica validez discriminante débil con  $n = 25$ , limitación que se aborda en el trabajo futuro.

Donde nuestra evidencia cuestiona la presuposición implícita en parte de la literatura —de que los recomendadores de rutas *deben* optimizar tiempo o costo—, nuestro resultado de Seguridad Percibida sugiere que la diversificación es un objetivo igualmente válido cuando la percepción de seguridad importa, coincidente con los estudios empíricos de movilidad de Cagney et al. (2020) y Liu (2022).

## 6.2. Limitaciones y trabajo futuro

El trabajo futuro se organiza primero para superar las limitaciones actuales y después para ampliar funcionalidades:

1. *Superar las limitaciones actuales*. (a) **Validez discriminante**: replicar el estudio con  $n \geq 100$  en tres ciudades distintas y aplicar PLS-SEM para rehabilitar la estructura del TAM extendido. (b) **Ventana de observación corta**: el estudio actual captó impresiones de primer encuentro; está programado un estudio longitudinal para observar si la Seguridad Percibida se mantiene, aumenta o disminuye con uso habitual, como recomienda Cagney et al. (2020). (c) **Alcance muestral**:  $n = 25$  limita la generalización; una réplica multicuidad con muestreo estratificado está calendarizada. (d) **Prototipo monoplataforma**: sólo Android está actualmente soportado; un cliente iOS que reutilice los mismos contratos REST/WebSocket está planeado.
2. *Nuevas funcionalidades y aspectos no cubiertos*. (a) Integración de **datos criminológicos** (densidad de incidencias por zona) para que la recompensa del bandido incorpore seguridad objetiva por zona, extendiendo el diseño de Kim et al. (2025). (b) **Canal de reportes generados por la ciudadanía** que realimente el módulo de rutas con incidentes contextuales (tráfico, condiciones de la vía), inspirado en los diseños de sensado participativo revisados por Paiva et al. (2021). (c) Exploración de **bandidos multibrazo federados** (Shi and Shen, 2021) para aprender a través de usuarios preservando la privacidad. (d) Evaluación de **políticas de aprendizaje por refuerzo profundo** (Zhang et al., 2025) como extensiones opcionales para usuarios avanzados con datos más ricos.

## CRedit authorship contribution statement

**Gleiston Guerrero-Ulloa:** Supervision, Conceptualization, Methodology, Writing – review and editing. **Aarón Reyes:** Conceptualization, Software, Methodology, Validation. **Miguel J. Hornos:** Formal analysis, Writing – review and editing, Validation. **Carlos Rodríguez-Domínguez:** Methodology, Writing – review and editing, Validation. **Efraín Díaz-Macías:** Investigation, Resources, Writing – review and editing.

## Declaración de conflicto de intereses

Las personas autoras declaran no tener intereses financieros conocidos ni relaciones personales que pudieran haber influido en el trabajo reportado en este artículo.

## Disponibilidad de datos

El código fuente de RutAI, las respuestas anonimizadas del cuestionario del estudio de aceptación, el cuestionario completo y la trazabilidad requisitos-entrevistas estarán disponibles a solicitud razonable al autor para correspondencia.

## Agradecimientos


Las personas autoras agradecen al equipo HeiGIT Smart Mobility de la Universidad de Heidelberg por conceder acceso extendido a la API de OpenRouteService durante el desarrollo, y a las personas participantes del estudio de aceptación por su tiempo y retroalimentación.

## Referencias


- Auer, P., Cesa-Bianchi, N., Fischer, P., 2002. Finite-time analysis of the multiarmed bandit problem. *Machine Learning* 47, 235–256. doi:10.1023/A:1013689704352.
- Ball, B.H., Peper, P., 2025. Cost avoidance underlies decisions to use prospective memory reminders. *Memory & Cognition* 53, 428–446. doi:10.3758/s13421-025-01683-3.
- Bisca, P.M., Chau, V., Dudine, P., Espinoza, R.A., Fournier, J.M., Guérin, P., Hansen, N.J.H., Salas, J., 2024. Violent crime and insecurity in Latin America and the Caribbean: A macroeconomic perspective. *IMF Departmental Papers* 2024. doi:10.5089/9798400288470.087.
- Bouneffouf, D., Rish, I., Aggarwal, C., 2020. Survey on applications of multi-armed and contextual bandits, in: *2020 IEEE Congress on Evolutionary Computation (CEC)*, pp. 1–8. doi:10.1109/CEC48606.2020.9185782.
- Cagney, K.A., Cornwell, E.Y., Goldman, A.W., Cai, L., 2020. Urban mobility and activity space. *Annual Review of Sociology* 46, 623–648. doi:10.1146/annurev-soc-121919-054848.
- Campigotto, P., Rudloff, C., Leodolter, M., Bauer, D., 2017. Personalized and situation-aware multimodal route recommendations: The FAVOUR algorithm. *IEEE Transactions on Intelligent Transportation Systems* 18, 92–102. doi:10.1109/TITS.2016.2565643.
- Chapelle, O., Li, L., 2011. An empirical evaluation of Thompson sampling, in: *Advances in Neural Information Processing Systems 24 (NeurIPS 2011)*, Curran Associates. pp. 2249–2257.
- Coullon, H., Henrio, L., Loulergue, F., Robillard, S., 2023. Component-based distributed software reconfiguration: A verification-oriented survey. *ACM Computing Surveys* 56, 1–37. doi:10.1145/3595376.
- Davis, F.D., 1989. Perceived usefulness, perceived ease of use, and user acceptance of information technology. *MIS Quarterly* 13, 319–340. doi:10.2307/249008.
- Fornell, C., Larcker, D.F., 1981. Evaluating structural equation models with unobservable variables and measurement error. *Journal of Marketing Research* 18, 39–50. doi:10.1177/002224378101800104.
- Garzon, S.R., Deva, B., 2014. Geofencing 2.0: Taking location-based notifications to the next level, in: *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '14)*, ACM, New York, NY, USA. pp. 921–932. doi:10.1145/2632048.2636093.
- Guest, G., Bunce, A., Johnson, L., 2006. How many interviews are enough? An experiment with data saturation and variability. *Field Methods* 18, 59–82. doi:10.1177/1525822X05279903.
- Guo, Z., Zhang, Y., Lv, J., Liu, Y., Liu, Y., 2021. An online learning collaborative method for traffic forecasting and routing optimization. *IEEE Transactions on Intelligent Transportation Systems* 22, 6634–6645. doi:10.1109/TITS.2020.2986158.
- Henseler, J., Ringle, C.M., Sarstedt, M., 2015. A new criterion for assessing discriminant validity in variance-based structural equation modeling. *Journal of the Academy of Marketing Science* 43, 115–135. doi:10.1007/s11747-014-0403-8.
- Instituto Nacional de Estadística y Geografía (INEGI), 2024. Encuesta Nacional de Seguridad Pública Urbana (ENSU): Resultados del tercer trimestre de 2024. Technical Report. INEGI. Aguascalientes, México.
- ISO/IEC/IEEE, 2017. Systems and software engineering — Software life cycle processes (ISO/IEC/IEEE 12207:2017). Technical Report. International Organization for Standardization. Geneva, Switzerland.
- ISO/IEC/IEEE, 2018. Systems and software engineering — Life cycle processes — Requirements engineering (ISO/IEC/IEEE 29148:2018). Technical Report. International Organization for Standardization. Geneva, Switzerland. doi:10.1109/IEEESTD.2018.8559686.

- Khan, S.U., Khan, A.W., Khan, F., Khan, M.A., Whangbo, T.K., 2022. Critical success factors of component-based software outsourcing development from vendors' perspective: A systematic literature review. *IEEE Access* 10, 1650–1658. doi:10.1109/ACCESS.2021.3138775.
- Kim, I., Kim, S., Kang, H., Kim, H., 2025. An implementation of a crime-safety-map application based on a safety index. *Multimodal Technologies and Interaction* 9, 16. doi:10.3390/mti9020016.
- Kuhnle, A., Kaiser, J.P., Theiß, F., Stricker, N., Lanza, G., 2021. Designing an adaptive production control system using reinforcement learning. *Journal of Intelligent Manufacturing* 32, 855–876. doi:10.1007/s10845-020-01612-y.
- Kung, H.Y., Yue, X.G., Chen, C.H., Hwang, F.J., 2023. Architecture, technologies, and applications of location-based services. *Mobile Information Systems* 2023, 9796535. doi:10.1155/2023/9796535.
- Li, J., Yan, H., Liu, Z., Chen, X., Huang, X., Wong, D.S., 2017. Location-sharing systems with enhanced privacy in mobile online social networks. *IEEE Systems Journal* 11, 439–448. doi:10.1109/JSYST.2015.2415835.
- Lin, C.Y., Hung, M.T., 2014. A location-based personal task reminder for mobile users. *Personal and Ubiquitous Computing* 18, 303–314. doi:10.1007/s00779-013-0646-2.
- Lindner, J.R., Lindner, N., 2024. Interpreting Likert-type, summated, unidimensional, and attitudinal scales: I neither agree nor disagree, Likert or not. *Advancements in Agricultural Development* 5, 152–163. doi:10.37433/aad.v5i2.351.
- Liu, H., Tong, Y., Han, J., Zhang, P., Lu, X., Xiong, H., 2022. Incorporating multi-source urban data for personalized and context-aware multi-modal transportation recommendation. *IEEE Transactions on Knowledge and Data Engineering* 34, 723–735. doi:10.1109/TKDE.2020.2985954.
- Liu, K., 2022. Analysis of the conflict between car commuter's route choice habitual behavior and traffic information search behavior. *Sensors* 22, 4382. doi:10.3390/s22124382.
- Maloney, W., Melendez, M., Morales, R., 2025. Latin America and the Caribbean Economic Review, April 2025: Organized Crime and Violence in Latin America and the Caribbean. World Bank Group, Washington, DC. doi:10.1596/42889.
- McKenzie, G., Romm, D., Zhang, H., Brunila, M., 2022. PrivyTo: A privacy-preserving location-sharing platform. *Transactions in GIS* 26, 1703–1717. doi:10.1111/tgis.12924.
- Paiva, S., Ahad, M.A., Tripathi, G., Feroz, N., Casalino, G., 2021. Enabling technologies for urban smart mobility: Recent trends, opportunities and challenges. *Sensors* 21, 2143. doi:10.3390/s21062143.
- Rummel, J., Snijder, J.P., Kvavilashvili, L., 2023. Prospective memories in the wild: Predicting memory for intentions in natural environments. *Memory & Cognition* 51, 1061–1075. doi:10.3758/s13421-022-01379-y.
- Shannon, C.E., 1948. A mathematical theory of communication. *Bell System Technical Journal* 27, 379–423. doi:10.1002/j.1538-7305.1948.tb01338.x.
- Shevchenko, Y., Reips, U.D., 2024. Geofencing in location-based behavioral research: Methodology, challenges, and implementation. *Behavior Research Methods* 56, 6411–6439. doi:10.3758/s13428-023-02213-2.
- Shi, C., Shen, C., 2021. Federated multi-armed bandits, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, pp. 9603–9611. doi:10.1609/aaai.v35i11.17156.
- Shokri, R., Theodorakopoulos, G., Papadimitratos, P., Kazemi, E., Hubaux, J.P., 2014. Hiding in the mobile crowd: Location privacy through collaboration. *IEEE Transactions on Dependable and Secure Computing* 11, 266–279. doi:10.1109/TDSC.2013.57.
- Song, C., Qu, Z., Blumm, N., Barabási, A.L., 2010. Limits of predictability in human mobility. *Science* 327, 1018–1021. doi:10.1126/science.1177170.
- Tapia Chamba, J., 2024. Inseguridad en Quevedo, Ecuador: percepciones, influencias y repercusiones en la cotidianidad. *Revista de Ciencias Sociales* , 101–118doi:10.15517/rsc.v0i183.60588.
- United Nations, Department of Economic and Social Affairs, Population Division, 2025. World Urbanization Prospects 2025: Summary of Results. Technical Report. United Nations. New York.
- United Nations Office on Drugs and Crime, 2023. Global Study on Homicide 2023: Latin America and the Caribbean. Technical Report. UNODC. Vienna.
- Vargas-Munoz, J.E., Srivastava, S., Tuia, D., Falcão, A.X., 2021. OpenStreetMap: Challenges and opportunities in machine learning and remote sensing. *IEEE Geoscience and Remote Sensing Magazine* 9, 184–199. doi:10.1109/MGRS.2020.2994107.
- Wang, Y., Pérez-Quinones, M.A., 2015. Beyond “geofencing”: Specifying location in location-based reminder applications, in: *Proceedings of the 33rd Annual ACM Conference Extended Abstracts on Human Factors in Computing Systems (CHI EA '15)*, ACM. pp. 1767–1772. doi:10.1145/2702613.2732780.
- Wohlin, C., Runeson, P., Höst, M., Ohlsson, M.C., Regnell, B., Wesslén, A., 2012. *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg. doi:10.1007/978-3-642-29044-2.
- Yuan, T., Rocha, M.N.d., Rocha, L.H., Castro, M.F.d., Nascimento, N.R.d., Cavalcante, R., Nogueira, M., Chen, H., 2022. Machine learning for next-generation intelligent transportation systems: A survey. *Transactions on Emerging Telecommunications Technologies* 33, e4427. doi:10.1002/ett.4427.
- Zeng, C., Wang, Q., Mokhtari, S., Li, T., 2016. Online context-aware recommendation with time varying multi-armed bandit, in: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ACM. pp. 2025–2034. doi:10.1145/2939672.2939878.
- Zhang, Y., Liu, W., Li, X., Wang, H., 2025. Deep reinforcement learning for vehicle swarm navigation and urban traffic optimization. *Transactions on Emerging Telecommunications Technologies* 36, e70227. doi:10.1002/ett.70227.


## RutAI: A Bandit-Driven Framework for Urban Mobility




**Figure 1:** CBSE development flow adopted for RutAI, with the main artefact delivered by each of the six phases.



**Figure 2:** Key use cases of RutAI selected for architectural and statistical relevance.



**Figure 3:** Three-tier layered architecture of RutAI, with symmetric stacks on client and server.



**Figure 4:** Per-construct mean scores with 95 % bootstrap confidence intervals ( $n = 25$ , 5000 resamples). PS is highlighted as the highest-scoring construct.