

Sistema de Mensajería Móvil Inclusiva Impulsado por Inteligencia Artificial para Usuarios con Discapacidades Visual, Auditiva y del Habla

Jhon Byron Leturne Pluas, *Student Member, IEEE*, Gleiston Guerrero Ulloa, *Member, IEEE*

Resumen—La exclusión digital de personas con discapacidades sensoriales en plataformas de mensajería móvil constituye uno de los desafíos más críticos de la ingeniería de software centrada en el ser humano. Este artículo presenta el diseño, implementación y evaluación empírica de un sistema de mensajería móvil inclusiva potenciado por Inteligencia Artificial (IA), concebido específicamente para usuarios con discapacidades visuales, auditivas y del habla. La arquitectura propuesta integra una API de procesamiento inteligente que orquesta módulos de conversión texto-a-voz (*Text-to-Speech*, TTS), voz-a-texto (*Speech-to-Text*, STT), descripción automática de imágenes mediante visión por computador y reconocimiento óptico de caracteres (OCR), adaptando dinámicamente el formato de cada mensaje al perfil sensorial del receptor. El stack tecnológico integra React Native para la interfaz móvil multiplataforma, Spring Boot (Java) para la lógica de negocio, Django (Python) para el procesamiento de IA, RabbitMQ como bróker de mensajería y PostgreSQL para la persistencia, con cifrado de extremo a extremo mediante par de claves privadas asimétricas. El desarrollo siguió la metodología TDDM4IoT (*Test-Driven Development Methodology for IoT-Based Systems*). La evaluación se realizó con 25 participantes con diversas condiciones sensoriales, aplicando el Modelo de Aceptación Tecnológica (TAM) y una lista de cotejo derivada de las WCAG 2.1. Los resultados evidenciaron una puntuación media global de 4.28/5 en la escala TAM, con el 84 % de respuestas en el nivel máximo para el ítem de mayor valoración y el 72 % para el segundo. Las pruebas automatizadas de accesibilidad reflejaron una reducción global del 64 % en advertencias de accesibilidad tras la aplicación del ciclo iterativo de mejora. Los hallazgos validan que la integración estratégica de IA en aplicaciones móviles constituye un enfoque viable para cerrar la brecha comunicativa de personas con discapacidades sensoriales.

Index Terms—Accesibilidad, aplicación móvil, cifrado extremo a extremo, discapacidad sensorial, inclusión digital, inteligencia artificial, interacción hombre-máquina, mensajería inclusiva, React Native, reconocimiento de voz, síntesis de voz, TDDM4IoT, TAM, WCAG.

I. INTRODUCCIÓN

LA comunicación instantánea se ha consolidado como un derecho fundamental en la sociedad contemporánea y como uno de los pilares del ejercicio ciudadano pleno. No obstante, la proliferación de plataformas de mensajería móvil —cuya penetración global supera los 3,000 millones

de usuarios activos— no ha venido acompañada de una arquitectura de accesibilidad intrínseca que garantice su uso equitativo. Según la Organización Mundial de la Salud (OMS), aproximadamente el 15 % de la población mundial convive con algún tipo de discapacidad, de los cuales un porcentaje significativo corresponde a deficiencias visuales, auditivas y del habla [1]. En Ecuador, el Consejo Nacional para la Igualdad de Discapacidades (CONADIS) registra 124,801 personas con discapacidades sensoriales activas: las discapacidades auditivas representan el 50.30 %, las visuales el 45.39 % y las del habla el 4.31 %, con una distribución de género de 70,429 hombres (56.4 %) y 54,372 mujeres (43.6 %).

Las aplicaciones de mensajería más extendidas —WhatsApp, Telegram, Messenger e Instagram— ofrecen funcionalidades de accesibilidad parciales: compatibilidad limitada con lectores de pantalla TalkBack y VoiceOver, ajuste de contraste y, en el caso de WhatsApp, transcripción de mensajes de audio a texto introducida recientemente. Sin embargo, ninguna de estas plataformas aborda de forma integral las necesidades de usuarios con perfiles sensoriales múltiples: la adaptación bidireccional entre modalidades texto, audio e imagen; la descripción semántica automática de contenido visual; la navegación completa por comandos de voz; ni el cifrado de extremo a extremo para flujos de datos multimodales accesibles [2], [3].

Desde la perspectiva de la Interacción Hombre-Máquina (IHM), el diseño universal [4] y las Directrices de Accesibilidad para el Contenido Web (WCAG 2.1) [5] establecen que los sistemas deben ser perceptibles, operables, comprensibles y robustos para el mayor espectro posible de usuarios. En el contexto móvil, trabajos recientes han evidenciado que las evaluaciones sistemáticas de accesibilidad en aplicaciones Android e iOS revelan tasas de incumplimiento superiores al 60 % en criterios fundamentales como alternativas textuales para contenido no textual y navegabilidad completa sin interacción táctil precisa [6], [7].

Los avances en IA ofrecen oportunidades inéditas para superar estas barreras. Los sistemas TTS de última generación basados en redes neuronales profundas producen síntesis de voz naturalista [8], mientras que los modelos STT basados en transformadores han alcanzado tasas de error de palabra (*Word Error Rate*, WER) comparables a la transcripción humana [9]. Paralelamente, los modelos de descripción de imágenes han demostrado utilidad para usuarios con discapacidad visual en

escenarios del mundo real [10].

En este contexto, el presente trabajo realiza las siguientes contribuciones originales:

- Propone una arquitectura de microservicios orientada a la accesibilidad que integra TTS, STT, descripción de imágenes, OCR y cifrado asimétrico extremo a extremo en un sistema de mensajería móvil multiplataforma.
- Describe la aplicación sistemática de la metodología TDDM4IoTS [11] al desarrollo de un sistema de mensajería inclusiva.
- Aporta evidencia empírica sobre aceptación tecnológica y accesibilidad técnica mediante un estudio con 25 participantes con discapacidades sensoriales heterogéneas.
- Cuantifica el impacto de un proceso iterativo de mejora de accesibilidad, logrando una reducción global del 64 % en advertencias identificadas mediante *Accessibility Scanner*.

El resto del artículo se organiza de la siguiente manera. La Sección II revisa los trabajos relacionados en tres dimensiones: accesibilidad en aplicaciones móviles de mensajería, sistemas de comunicación aumentativa e inclusiva, e integración de IA para la accesibilidad, identificando las brechas que motivan la presente investigación. La Sección III describe el paradigma de investigación mixto adoptado, las once fases de la metodología TDDM4IoTS aplicadas al desarrollo del sistema y los 18 criterios de accesibilidad derivados de las WCAG 2.1 empleados como marco de evaluación. La Sección ?? detalla la arquitectura de microservicios en tres capas, el flujo de conversión inteligente de mensajes, el módulo de navegación por comandos de voz, el mecanismo de cifrado asimétrico de extremo a extremo y la infraestructura de despliegue híbrida empleada. La Sección IV presenta el diseño del estudio, las características de los 25 participantes, los resultados de las pruebas técnicas de rendimiento de la interfaz de programación de aplicaciones (API) —TTS, STT y descripción de imágenes—, la evaluación iterativa de accesibilidad y los resultados cuantitativos del cuestionario TAM con los 12 ítems analizados. La Sección V interpreta los hallazgos en el contexto de la literatura existente, discute las limitaciones del sistema en su estado actual —particularmente la latencia TTS y la optimización pendiente de la pantalla de mensajería— y reflexiona sobre las implicaciones sociales del trabajo en relación con los Objetivos de Desarrollo Sostenible. Finalmente, la Sección VI sintetiza las cuatro conclusiones principales del trabajo, enumera las cinco líneas de investigación futura identificadas y ofrece recomendaciones concretas para la adopción del sistema propuesto en contextos reales de inclusión digital.

II. TRABAJOS RELACIONADOS

II-A. Accesibilidad en Aplicaciones Móviles de Mensajería

II-A1. Evaluaciones empíricas con usuarios reales en plataformas específicas: La investigación sobre accesibilidad móvil ha cobrado especial relevancia con la proliferación de los *smartphones*. Weichbroth [3] realizó una revisión sistemática de 57 estudios sobre usabilidad de aplicaciones móviles, concluyendo que la accesibilidad es uno de los criterios

menos abordados en los procesos de diseño convencionales y que la mayoría de los trabajos se centran en eficiencia y satisfacción sin contemplar las necesidades de usuarios con discapacidad. En este mismo sentido, Chen *et al.* [6] llevaron a cabo un estudio empírico a gran escala de la accesibilidad en aplicaciones Android, incluyendo plataformas de mensajería populares, revelando tasas de incumplimiento superiores al 60 % en criterios fundamentales de las WCAG 2.1 tales como alternativas textuales para contenido no textual, etiquetado semántico de controles interactivos y compatibilidad con lectores de pantalla.

En el dominio específico de la mensajería, Da Silva *et al.* [12] realizaron la primera evaluación sistemática de WhatsApp desde la perspectiva de cinco usuarios con discapacidad visual, aplicando los criterios de éxito de las WCAG 2.0 mediante el lector de pantalla TalkBack en dispositivo móvil. Los autores identificaron 18 barreras críticas, entre las que destacan la ausencia de textos alternativos en imágenes, la falta de encabezados semánticos para la navegación, la retroalimentación auditiva insuficiente en notificaciones y la escasa visibilidad de los estados de los controles interactivos. Zahida *et al.* [13] extendieron este enfoque a usuarios mayores, empleando el método de Diseño Centrado en el Usuario (DCU, del inglés *User-Centered Design*) para rediseñar la interfaz de WhatsApp orientada a personas de edad avanzada con deterioro perceptivo y motriz progresivo. Los autores documentaron que la ausencia de ajuste de tamaño de fuente persistente, la densidad de iconos en pantallas pequeñas y la retroalimentación háptica insuficiente son las principales fuentes de error en esta población.

Por su parte, Swati *et al.* [14] analizaron la accesibilidad de Facebook Messenger con cinco participantes con ceguera completa mediante un protocolo de observación directa y pruebas de interacción en *smartphone*. Los resultados evidenciaron que la aplicación es sistemáticamente inaccesible para usuarios con ceguera: la ausencia de etiquetas de accesibilidad en botones críticos, el uso de iconos sin texto alternativo y la organización jerárquica de los menús sin soporte adecuado para la navegación lineal con lectores de pantalla impiden la ejecución autónoma de tareas básicas como iniciar una conversación o adjuntar archivos. Rumini y Astrid [15], por su parte, evaluaron Telegram empleando regresión lineal múltiple sobre los 10 principios heurísticos de Nielsen, identificando que las dimensiones de estética y diseño minimalista y consistencia y estándares presentan las mayores violaciones según la percepción de los usuarios, lo que genera confusión en la navegación y dificulta el uso para personas con menor alfabetización digital.

En el ámbito de las aplicaciones de comunicación asistida para usuarios con discapacidad auditiva, Kim *et al.* [16] presentaron un estudio de usabilidad mixto —que combina pruebas con usuarios con discapacidad auditiva y evaluación heurística por expertos en IHM— de aplicaciones móviles de comunicación. Los autores encontraron deficiencias significativas en el diseño de la dimensión emocional y afectiva de la interfaz, e identificaron la ausencia de estándares de evaluación específicos para personas con discapacidad auditiva como uno de los principales obstáculos para el desarrollo de aplicaciones

verdaderamente inclusivas.

II-A2. Revisiones sistemáticas y marcos de evaluación de accesibilidad móvil: La evidencia acumulada por los estudios empíricos anteriores ha motivado el desarrollo de marcos sistemáticos de evaluación. Ballantyne *et al.* [17] analizaron comparativamente las directrices de accesibilidad de W3C, Google, Apple y otras organizaciones normativas para aplicaciones móviles, concluyendo que la fragmentación entre plataformas —Android e iOS— genera inconsistencias significativas en los niveles de cumplimiento alcanzables y recomendando la adopción de un conjunto unificado de criterios de evaluación basado en las WCAG 2.1 como referencia transversal. Acosta-Vargas *et al.* [18] fueron más allá al proponer un enfoque combinado —herramientas automatizadas más inspección manual experta— para la evaluación de accesibilidad en aplicaciones nativas Android e iOS, demostrando que ningún método aislado detecta el espectro completo de barreras y que la complementariedad entre ambos enfoques incrementa la cobertura de detección en más de un 35 %.

Huang *et al.* [19] ampliaron el análisis empírico a las cuatro plataformas de mensajería más extendidas —WhatsApp, Telegram, Messenger e Instagram— aplicando un protocolo de evaluación estandarizado con adultos en edad laboral con discapacidades cognitivas leves y moderadas. Los resultados documentan patrones sistemáticos de incumplimiento en criterios de tamaño de objetivo táctil, contraste de color y orientación de pantalla, y revelan que la complejidad de las interfaces de mensajería, combinada con la ausencia de modos de visualización simplificados, excluye efectivamente a esta población de la comunicación digital autónoma. Bercau y Popescu [2], a su vez, sistematizaron en una revisión PRISMA de 2,819 artículos —publicados entre 2018 y 2024— el estado del arte de las tecnologías de accesibilidad en plataformas en línea, concluyendo que, si bien TTS y STT han alcanzado niveles de precisión y tasas de error de palabra comparables a la transcripción humana en condiciones controladas, el reconocimiento de lengua de señas continua exhibiendo precisiones insuficientes para su adopción masiva, y que la personalización adaptativa de la experiencia de usuario sigue siendo la dimensión más deficitaria del campo. Por su parte, Ara *et al.* [20] revisaron 92 estudios primarios sobre evaluación de accesibilidad web y móvil (2010–2021), identificando que el diseño de marcos de prueba y los procesos de *testing* iterativo son las fases del ciclo de desarrollo donde la investigación ha aportado mayor valor, y que la automatización de la evaluación de conformidad WCAG sigue siendo un problema abierto con cobertura parcial incluso en las herramientas más avanzadas.

II-B. Sistemas de Comunicación Aumentativa e Inclusiva

II-B1. Marco conceptual y tecnologías de base: La Comunicación Aumentativa y Alternativa (CAA) engloba el conjunto de procesos, herramientas y tecnologías que aumentan, complementan o reemplazan el habla de individuos con necesidades comunicativas complejas [21]. El Sahar *et al.* [21] ofrecen la revisión de referencia en este campo, sistematizando las modalidades de sensing y adquisición de señal empleadas en plataformas CAA de alta tecnología —sistemas táctiles,

imágenes, dispositivos electromecánicos, interfaces activadas por respiración e interfaces cerebro-computador (ICC)— y comparando su portabilidad, velocidad conversacional, coste y complejidad de integración. Los autores concluyen que el aprendizaje automático (AA) y el aprendizaje profundo (AP) representan el vector de avance más prometedor para el desarrollo de soluciones CAA inteligentes, particularmente a través de la generación de voz, la predicción de texto y la clasificación de señales biológicas, y que la telefonía móvil constituye la plataforma de despliegue con mayor potencial de adopción masiva dada su ubicuidad y asequibilidad en comparación con los dispositivos CAA dedicados.

II-B2. Sistemas de mensajería web y móvil inclusiva: En el dominio específico de la mensajería inclusiva, Guerrero-Ulloa *et al.* [22] presentaron BellChat, la primera aplicación web de mensajería inclusiva que integra simultáneamente TTS y STT para usuarios con discapacidades visuales y auditivas, superando las limitaciones de las plataformas de mensajería convencionales. BellChat permitió la conversión de texto a voz y de voz a texto en función del perfil sensorial del usuario, y su arquitectura sirvió como punto de partida para trabajos posteriores. Sin embargo, su implementación exclusivamente web representó una limitación significativa frente a las tendencias de acceso móvil predominantes. Stefanov *et al.* [23] diseñaron un prototipo de aplicación móvil de apoyo a personas con necesidades especiales, combinando notificaciones de emergencia, reconocimiento de voz e interfaces simplificadas; no obstante, su alcance quedó restringido a un perfil de usuario único y no contempló la adaptación dinámica del contenido al receptor según su discapacidad.

Yeratziotis *et al.* [24] extendieron el paradigma de la mensajería inclusiva a las redes sociales, desarrollando un sistema que integra lenguaje de señas en aplicaciones como WhatsApp, Messenger, Telegram y Viber para usuarios sordos. Su enfoque demostró que la inclusión de avatares que reproducen signos en vídeo responde a una necesidad comunicativa real de la comunidad sorda, que frecuentemente enfrenta barreras lingüísticas cuando interacciona con personas oyentes a través de mensajería basada exclusivamente en texto o audio. En una escala más amplia, Chang *et al.* [25] propusieron un sistema de ciudad inteligente que combina reconocimiento de gestos y comandos de voz para fomentar la participación de ciudadanos con discapacidades auditivas y visuales en entornos urbanos digitalizados, aportando evidencia de que la integración de múltiples modalidades de interacción aumenta significativamente la autonomía de estos usuarios.

Janaka *et al.* [26] exploraron la mensajería ubicua mediante gafas inteligentes con pantalla óptica semitransparente (*Optical See-Through Head-Mounted Displays*, OST-HMD), desarrollando GlassMessaging, una aplicación que combina entrada de voz y manual para escenarios de manos y ojos ocupados. Aunque su motivación principal fue la mensajería genérica durante la multitarea, el sistema demuestra que la entrada por voz en dispositivos *wearable* reduce el tiempo de respuesta en un 33.1 % e incrementa la velocidad de teclado en un 40.3 % con una penalización de precisión del 2.5 %, lo que tiene implicaciones directas para el diseño de interfaces de mensajería accesibles para personas con discapacidad visual o

motriz que no pueden interactuar con pantallas táctiles.

II-B3. Sistemas de reconocimiento de lenguaje de señas para comunicación bidireccional: El reconocimiento automático del lenguaje de señas (RALS) constituye una línea de investigación fundamental para dotar a los sistemas de mensajería inclusiva de capacidad de comunicación bidireccional con usuarios sordos. Saleem *et al.* [27] propusieron un sistema bidireccional basado en aprendizaje profundo que convierte gestos de lengua de señas en voz mediante clasificación supervisada con soporte multilingüe. Su arquitectura emplea redes neuronales convolucionales para la adquisición gestual y síntesis de voz por tarjeta de sonido, logrando comunicación en tiempo real entre personas sordas/mudas y oyentes sin requerir que ninguna de las partes aprenda la lengua de señas de la otra. Papatsimouli *et al.* [28] revisaron los avances de los últimos cinco años en traductores de lenguaje de señas en tiempo real integrados con tecnología IoT, evidenciando que la combinación de visión por computador, aprendizaje por refuerzo e integración con dispositivos móviles y wearables abre nuevas posibilidades para la comunicación inclusiva en entornos cotidianos, aunque persisten limitaciones en la generalización a variantes dialectales y en la latencia bajo condiciones de red débil.

Desde una perspectiva de aprendizaje profundo aplicado, Kothadiya *et al.* [29] desarrollaron un modelo híbrido LSTM-GRU para el reconocimiento de la lengua de señas india (ISL) en secuencias de video, alcanzando una precisión del 97 % sobre 11 signos distintos e incluyendo una aplicación Android como canal de comunicación inclusiva. La evaluación del modelo en condiciones ambientales variables —distintas iluminaciones, velocidades de signado y tamaños de mano— puso de manifiesto que los modelos de secuencia basados en memoria a largo-corto plazo son superiores a los enfoques de reconocimiento de fotogramas aislados para signos dinámicos, lo que tiene implicaciones directas para el diseño de módulos de reconocimiento gestual en aplicaciones de mensajería móvil inclusiva.

II-B4. Aplicaciones CAA con inteligencia artificial para trastornos del habla: Para usuarios con discapacidades del habla severas —como el síndrome de Down, la parálisis cerebral, el trastorno del espectro autista (TEA) o la esclerosis lateral amiotrófica—, las aplicaciones móviles CAA basadas en IA representan la vía más prometedora hacia la comunicación autónoma. Costanzo *et al.* [30] evaluaron Talkitt, una aplicación móvil desarrollada por Voiceitt y financiada por el programa Horizon 2020, que emplea modelos de ML para traducir en tiempo real sonidos ininteligibles a palabras claras mediante entrenamiento personalizado por usuario. El estudio, llevado a cabo con niños y adolescentes con síndrome de Down e italiano como lengua materna, demostró que el sistema mejora su precisión de reconocimiento del 75 % al 90 % tras el proceso de calibración, y que los cuidadores reportaron altos niveles de satisfacción. Esta evidencia valida el paradigma de entrenamiento personalizado del modelo con datos del propio usuario, con implicaciones directas para el diseño de módulos STT adaptativos en sistemas de mensajería inclusiva.

En el ámbito de las interfaces conversacionales para personas con discapacidad intelectual, Mateos-Sanchez *et al.*

[31] desarrollaron CapacitaBOT, un chatbot móvil basado en IBM Watson Assistant que entrena habilidades sociales y comunicativas mediante diálogos ramificados con vocabulario controlado y retroalimentación positiva sistemática. La herramienta demostró que las interfaces conversacionales con diseño inclusivo pueden suplir parcialmente las carencias de los sistemas de mensajería convencionales para este colectivo, subrayando la importancia del diseño del diálogo adaptativo como factor determinante de la aceptación tecnológica.

Desde la perspectiva organizacional, Tomczak *et al.* [32] propusieron un modelo de comunicación inclusiva para el ciclo de empleo de personas con TEA, identificando que la sustitución de la comunicación interpersonal por formas electrónicas —comunicadores en línea, chatbots y mensajería asíncrona— y el uso de tecnologías wearables de monitorización del estrés constituyen las estrategias digitales más efectivas para mejorar la participación de este colectivo en entornos laborales. Sus hallazgos refuerzan la necesidad de sistemas de mensajería especializados que adapten el contenido, la velocidad y el formato de los mensajes al perfil neurocognitivo del usuario.

Por último, Bleakley *et al.* [33] investigaron la experiencia de usuario de personas con tartamudez al interactuar con altavoces inteligentes durante tres semanas, mediante estudios de diario y entrevistas semiestructuradas con 11 participantes. Sus hallazgos revelan barreras críticas en los sistemas de reconocimiento de voz comerciales para este colectivo: tiempo de espera excesivamente corto antes de procesar el comando, incapacidad de gestionar las repeticiones y prolongaciones propias de la disfluencia, y presión social asociada al uso de la voz en público. Estos resultados tienen implicaciones directas para el diseño del módulo STT en sistemas de mensajería inclusiva, indicando que los umbrales de detección de fin de enunciado y los mecanismos de corrección automática deben configurarse de forma adaptativa según el perfil de disfluencia del usuario, y que la entrada multimodal —combinando voz, texto y comandos gestuales— es una estrategia necesaria para garantizar la accesibilidad para este colectivo.

II-C. Inteligencia Artificial para la Accesibilidad

II-C1. Marco general y revisión sistemática de IA para la accesibilidad digital: La relación entre la inteligencia artificial y la accesibilidad digital ha sido sistematizada recientemente por Chemnad & Othman [34], quienes realizaron una revisión bibliométrica y sistemática PRISMA de 3,706 artículos publicados entre 2018 y 2023 en cinco bases de datos de primer nivel (ACM Digital Library, IEEE Xplore, ScienceDirect, Scopus y Springer), depurando finalmente 43 trabajos para su análisis. Los autores presentan un marco de clasificación de las aplicaciones de IA para la accesibilidad en cuatro dimensiones —aplicaciones, retos, metodologías de IA y estándares de accesibilidad— y concluyen que la investigación se concentra de forma marcadamente asimétrica en las discapacidades visuales, mientras que las discapacidades auditivas, del habla, cognitivas y motoras presentan una cobertura significativamente menor. Esta brecha estructural subraya la urgencia de sistemas multimodales que atiendan simultáneamente a varios perfiles de discapacidad sensorial, como el propuesto en el presente trabajo.

Desde una perspectiva tecnológica integradora, Madake *et al.* [35] presentaron un análisis cualitativo y cuantitativo de las tecnologías de movilidad asistida para personas con discapacidad visual, revisando trabajos publicados entre 2005 y 2022 y comparando métodos de imagen monocular, estéreo, mapeo SLAM, nubes de puntos 3D y fusión multisensorial. Su revisión demuestra que la evolución de las CNNs profundas y la fusión de módulos de procesamiento de voz con módulos de reconocimiento de objetos constituye la tendencia más prometedora para dispositivos wearable, relevante para el módulo de descripción de imágenes del sistema propuesto.

II-C2. Síntesis de voz neuronal (TTS) y reconocimiento automático del habla (STT): En el dominio de la síntesis de voz de alta calidad para la accesibilidad, Ji *et al.* [36] propusieron modelos de control de estilo basados en códecs de lenguaje que permiten generar voz altamente naturalista con control fino de prosodia, expresividad y timbre, eliminando la rigidez artificial de los sistemas TTS clásicos. Tan *et al.* [8] sistematizaron en una revisión exhaustiva los avances en TTS neuronal —desde WaveNet hasta FastSpeech y Transformer TTS—, estableciendo el estado del arte en términos de MOS, latencia de inferencia y requisitos computacionales, y mostrando que los modelos TTS actuales han alcanzado o superado la calidad de voz humana en condiciones controladas.

En el reconocimiento automático del habla (STT/ASR), Baevski *et al.* [9] introdujeron wav2vec 2.0, un modelo de aprendizaje autosupervisado que preentrena representaciones del habla sobre grandes corpus sin etiquetar y las ajusta con tan solo 10 minutos de datos transcritos, reduciendo significativamente la WER incluso en condiciones de bajo recurso. Este modelo es directamente relevante para el módulo STT del sistema propuesto, ya que sus capacidades de aprendizaje autosupervisado permiten adaptarlo a lenguajes con escasos recursos o a dialectos específicos sin requerir grandes corpus etiquetados. Complementariamente, Radford *et al.* [37] presentaron Whisper, un sistema ASR de escala masiva entrenado sobre 680,000 horas de supervisión débil multilingüe y multitarea. Whisper alcanza una WER comparable a la de transcripores humanos en condiciones de distribución fuera de dominio (*out-of-distribution*) y demuestra una robustez marcadamente superior a la de los sistemas ASR supervisados clásicos en entornos ruidosos, acentos y habla espontánea, lo que lo convierte en una referencia clave para el diseño de módulos STT destinados a usuarios con discapacidades del habla o habla atípica.

II-C3. Descripción automática de imágenes (*image captioning*) para discapacidad visual: La descripción automática de imágenes constituye la tecnología central que permite a los sistemas de mensajería inclusiva hacer accesibles los mensajes visuales a usuarios con discapacidad visual. Ming *et al.* [38] presentaron una revisión más completa publicada hasta la fecha sobre *image captioning* automático, abarcando tanto los métodos clásicos basados en recuperación y plantillas como las técnicas más recientes de aprendizaje profundo, con especial énfasis en el marco encoder-decoder, los mecanismos de atención y las estrategias de entrenamiento mediante refuerzo y ajuste fino. Los autores analizan los conjuntos de datos estándar —MS-COCO, Flickr8k, Flickr30k y VizWiz—

e identifican como líneas prioritarias el *captioning* flexible, sin pares y a nivel de párrafo, directamente aplicables a la generación de descripciones de imágenes en aplicaciones de mensajería inclusiva.

Dognin *et al.* [10] demostraron experimentalmente con el conjunto de datos VizWiz —compuesto por imágenes tomadas por personas ciegas en condiciones reales de baja calidad— que los sistemas modernos de *image captioning* pueden alcanzar niveles de utilidad comparables a la descripción humana en contextos de accesibilidad, aunque con limitaciones específicas en imágenes borrosas, mal encuadradas o ambiguas. Extendiendo esta línea, Safiya y Pandian [39] desarrollaron un sistema de *image captioning* en tiempo real basado en VGG16-LSTM, desplegado en una Raspberry Pi 4B con capacidades de GPU embebida y evaluado sobre múltiples conjuntos de datos —Flickr8k, Flickr30k, VizWiz y un conjunto personalizado—. Las precisiones de VGG-16 durante el entrenamiento y la validación fueron del 84.13 % y el 83.88 % respectivamente, y las descripciones generadas se convierten a audio mediante una API TTS de alta fidelidad, constituyendo un sistema portátil y autosuficiente de asistencia visual. Este trabajo valida directamente la viabilidad de integrar *image captioning* en dispositivos móviles de bajo coste para la accesibilidad en mensajería.

II-C4. Reconocimiento óptico de caracteres (OCR) e IA multimodal para la accesibilidad: El reconocimiento óptico de caracteres (OCR) es la tecnología que permite a los sistemas de mensajería inclusiva convertir texto impreso en imágenes —carteles, documentos, etiquetas— en texto procesable que puede leerse mediante TTS. Mukherjee *et al.* [40] demostraron precisiones superiores al 95 % en OCR de caracteres impresos estándar empleando modelos de visión por computador de última generación, aunque identificaron limitaciones específicas en texto manuscrito y en condiciones de iluminación adversa, que representan los principales retos para el despliegue de OCR en entornos móviles no controlados.

El marco integrador más amplio de IA para la accesibilidad digital fue proporcionado por Chemnad y Othman [34], quienes clasificaron las metodologías de IA por tipo de discapacidad y señalaron que los sistemas multimodales —que integran visión, habla, procesamiento del lenguaje natural e interfaces hápticas— son los que consistentemente ofrecen mayor impacto en términos de accesibilidad real, en contraste con los sistemas monomodales que dominan la literatura. Sus resultados confirman que la combinación de OCR, TTS, STT e *image captioning* en una sola plataforma —tal como propone el presente sistema— representa la estrategia arquitectónica de mayor alcance para la inclusión sensorial, y que la ausencia de tal integración en los trabajos existentes constituye la brecha identificada más significativa en el campo.

II-D. Brechas Identificadas

El análisis crítico y transversal de los 35 trabajos revisados en las secciones anteriores permite identificar cinco brechas estructurales, cada una de las cuales agrupa limitaciones convergentes de múltiples publicaciones y justifica la contribución del presente trabajo.

Brecha 1 — Ausencia de plataformas móviles multi-modales que integren simultáneamente los perfiles visual, auditivo y de habla. Esta es la brecha más crítica y transversal de la literatura revisada. Los trabajos de evaluación de accesibilidad —Da Silva *et al.* [12], Swati *et al.* [14], Rumini y Astrid [15], Kim *et al.* [16] y Zahida *et al.* [13]— documentan con rigor empírico las barreras que enfrentan los usuarios con discapacidades visuales, auditivas o motoras en las plataformas de mensajería existentes, pero ninguno de ellos propone un sistema alternativo que las resuelva. Las revisiones sistemáticas de accesibilidad móvil de Ballantyne *et al.* [17], Acosta-Vargas *et al.* [18], Huang *et al.* [19], Bercaru y Popescu [2] y Ara *et al.* [20] confirman que el incumplimiento es generalizado y persistente, pero se limitan a proponer marcos evaluativos sin implementar soluciones. En la literatura de sistemas CAA, BellChat [22] integra TTS y STT, pero solo en entorno web y sin descripción de imágenes ni OCR. El prototipo de Stefanov *et al.* [23] atiende un único perfil de discapacidad. Yeratziotis *et al.* [24] incorporan lenguaje de señas pero solo para usuarios sordos, sin contemplar la discapacidad visual ni la del habla. Chang *et al.* [25] presentan un sistema de ciudad inteligente multimodal orientado a la participación urbana, no a la mensajería personal. Janaka *et al.* [26] exploran la mensajería en gafas inteligentes desde la perspectiva de la multitarea, sin incluir usuarios con discapacidad. Los sistemas RALS de Saleem *et al.* [27], Papatsimouli *et al.* [28] y Kothadiya *et al.* [29] abordan sólo la dimensión de la sordera. Por el lado de la IA, Chemnad y Othman [34] y Madake *et al.* [35] demuestran que la investigación existente privilegia la discapacidad visual de forma asimétrica, omitiendo la cobertura simultánea de múltiples discapacidades. Ninguno de los 35 trabajos revisados implementa un sistema móvil de mensajería que adapte dinámicamente el formato de cada mensaje al perfil sensorial del receptor combinando TTS, STT, *image captioning* y OCR en una única plataforma nativa móvil, que es precisamente la contribución central del presente trabajo.

Brecha 2 — Fragmentación tecnológica: los componentes de IA existen de forma aislada pero no han sido integrados en un sistema coherente con privacidad garantizada. La literatura de IA para la accesibilidad demuestra que los componentes individuales han alcanzado madurez técnica notable: la TTS neuronal de Ji *et al.* [36] y Tan *et al.* [8] produce voz de calidad comparable a la humana; el STT de Baevski *et al.* [9] y Radford *et al.* [37] alcanza WER cercana a la transcripción humana en condiciones de ruido real; los modelos de *image captioning* de Ming *et al.* [38], Dognin *et al.* [10] y Safiya y Pandian [39] generan descripciones de utilidad comparable a la humana; y el OCR de Mukherjee *et al.* [40] supera el 95 % de precisión en texto impreso estándar. Sin embargo, ninguno de estos trabajos combina los cuatro componentes —TTS, STT, *captioning* y OCR— en una arquitectura de mensajería con cifrado asimétrico extremo a extremo. La privacidad es especialmente crítica para poblaciones con discapacidad que comparten información sensible en sus comunicaciones, pero está ausente en toda la literatura de sistemas CAA revisada, incluyendo Guerrero-Ulloa *et al.* [22], Costanzo *et al.* [30], Mateos-Sanchez *et al.*

[31] y Tomczak *et al.* [32].

Brecha 3 — Escasez de evidencia empírica de aceptación tecnológica en poblaciones de discapacidad múltiple y heterogénea. La mayoría de los trabajos que evalúan sistemas inclusivos se limitan a un único perfil de discapacidad o emplean muestras de conveniencia no representativas. Costanzo *et al.* [30] evalúan Talkitt exclusivamente con niños con síndrome de Down. Mateos-Sanchez *et al.* [31] se circunscriben a personas con discapacidad intelectual. Bleakley *et al.* [33] trabajan con 11 adultos con tartamudez. Murad *et al.* [27] y Kothadiya *et al.* [29] evalúan su RALS con usuarios sordos sin incluir personas con discapacidad visual ni del habla. Kim *et al.* [16] se concentran exclusivamente en usuarios con discapacidad auditiva. Incluso los trabajos de revisión sistemática —Weichbroth [3], Ara *et al.* [20], Chemnad y Othman [34]— llaman la atención sobre la escasez de estudios con usuarios reales con discapacidades múltiples. Los sistemas de mensajería revisados —BellChat [22], Yeratziotis *et al.* [24], Stefanov *et al.* [23]— carecen de evaluación con el instrumento TAM o no reportan resultados cuantitativos de aceptación. Esta brecha impide conocer si las soluciones propuestas son efectivamente adoptadas por los usuarios a los que van dirigidas, lo que representa un obstáculo para su transferencia tecnológica y su adopción en contextos reales.

Brecha 4 — Ausencia de metodologías de desarrollo sistemático y dirigido por pruebas para sistemas de mensajería accesible. Ara *et al.* [20] identifican que los procesos de *testing* iterativo son la fase del ciclo de desarrollo donde la investigación ha aportado mayor valor en accesibilidad, pero ningún trabajo revisado aplica una metodología de desarrollo formal orientada a la verificación sistemática de la accesibilidad. Los prototipos de mensajería inclusiva —BellChat [22], Stefanov *et al.* [23], GlassMessaging [26]— no describen ninguna metodología de desarrollo reproducible. Los sistemas CAA evaluados —Talkitt [30], CapacitaBOT [31]— se presentan como productos terminados sin documentar el proceso de desarrollo. La revisión de Bercaru y Popescu [2] y el marco de Ballantyne *et al.* [17] proponen directrices de evaluación, pero no metodologías de desarrollo que incorporen la accesibilidad como requisito verificable desde la primera iteración. En particular, la metodología TDDM4IoT [11] ha sido aplicada en contextos de IoT distribuido, pero no ha sido adaptada al desarrollo de aplicaciones móviles de mensajería inclusiva, lo que constituye una brecha metodológica con impacto directo en la reproducibilidad y calidad de los artefactos software desarrollados en este dominio.

Brecha 5 — Cobertura insuficiente de perfiles de discapacidad del habla y disfluencias en sistemas de mensajería con entrada de voz. Los sistemas que incorporan reconocimiento de voz como modalidad de entrada —GlassMessaging [26], BellChat [22], Stefanov *et al.* [23], los sistemas RALS de Saleem *et al.* [27] y Adewole *et al.* [28]— son evaluados exclusivamente con hablantes con habla típica o con usuarios sordos que se comunican mediante signos, pero no con personas que presentan disfluencias, habla atípica o trastornos motores del habla. Bleakley *et al.* [33] documentan que los sistemas STT comerciales fallan sistemáticamente para personas con tartamudez, y Radford *et al.* [37] reconocen

que Whisper exhibe rendimiento heterogéneo según el patrón de habla del usuario. Costanzo *et al.* [30] demuestran que el entrenamiento personalizado del modelo STT con datos del propio usuario mejora significativamente la precisión para habla ininteligible, pero este paradigma no ha sido integrado en ningún sistema de mensajería móvil. Tomczak *et al.* [32] identifican la mensajería electrónica asíncrona como la alternativa comunicativa más efectiva para personas con TEA, cuya interacción verbal directa con sistemas STT en tiempo real puede resultar estresante o ineficaz, sin que ningún sistema existente ofrezca adaptación automática del modo de entrada según el perfil de disfluencia. Esta brecha compromete la inclusividad real de todos los sistemas que incorporan entrada por voz como modalidad principal de acceso para usuarios con discapacidad del habla.

En conjunto, las cinco brechas identificadas evidencian que el campo carece de un sistema que (i) atienda simultáneamente los tres perfiles de discapacidad sensorial —visual, auditiva y del habla— en una única plataforma móvil; (ii) integre coherentemente los componentes de IA maduros —TTS, STT, *image captioning* y OCR— con protección criptográfica de extremo a extremo; (iii) cuente con evidencia empírica de aceptación tecnológica obtenida con poblaciones heterogéneas de discapacidad múltiple; (iv) haya sido desarrollado mediante una metodología reproducible que incorpore la accesibilidad como criterio de calidad verificable desde el inicio; y (v) adapte el modo de entrada de voz al perfil de habla individual del usuario. El presente trabajo aborda de forma directa las cinco brechas identificadas.

III. MATERIALES Y MÉTODOS

Esta sección describe, en primer lugar, los materiales empleados —plataformas, instrumentos y componentes de inteligencia artificial— y, en segundo lugar, los métodos aplicados tanto para el desarrollo del sistema como para su evaluación técnica y con usuarios. La investigación adoptó un paradigma mixto [41]: cuantitativo para la medición de métricas de rendimiento de la API de conversión (latencia media, tasa de error) y para la cuantificación de la aceptación tecnológica mediante el Modelo de Aceptación Tecnológica (TAM) [42]; y cualitativo para el análisis de las barreras de accesibilidad identificadas durante las sesiones de observación directa con usuarios. El tipo de investigación es aplicada y proyectiva [41], orientada al diseño, implementación y evaluación de un artefacto software que resuelve un problema técnico y social específico en el dominio de la comunicación inclusiva.

III-A. Materiales

Esta subsección describe los componentes de hardware, software, APIs de inteligencia artificial, el marco normativo de accesibilidad y el instrumento de evaluación de aceptación tecnológica que constituyeron los recursos del estudio.

III-A1. Infraestructura de Hardware y Despliegue: El sistema fue desplegado sobre una infraestructura híbrida en dos nodos complementarios. El **Nodo de IA** corresponde a una instancia en Amazon Web Services (AWS) con sistema operativo Windows Server, asignada a la API de inteligencia

Tabla I
STACK TECNOLÓGICO DEL SISTEMA DE MENSAJERÍA INCLUSIVA

Componente	Tecnología	Justificación
Interfaz móvil	React Native	Multiplataforma; accesibilidad nativa TalkBack/VoiceOver
Backend REST	Spring Boot (Java)	Microservicios, ORM, escalabilidad horizontal
API de IA	Django (Python)	Ecosistema ML/PNL, modelos pre-entrenados
Mensajería RT	WebSocket + RabbitMQ	Entrega en tiempo real; garantía de orden
Persistencia	PostgreSQL	Relacional, ACID, código abierto
Contenedores	Docker + Nginx	Portabilidad, aislamiento, proxy inverso
Nube (IA)	AWS Windows Server	CPU/RAM para inferencia de modelos
Cifrado	Clave asimétrica	Confidencialidad extremo a extremo

artificial (Django/Python) dada su mayor demanda de CPU y memoria RAM para la inferencia de modelos de visión y lenguaje. El **Nodo de backend** es un servidor CentOS administrado por la Universidad Técnica Estatal de Quevedo (UTEQ), que aloja la API REST (Spring Boot/Java), el bróker de mensajería RabbitMQ y la base de datos PostgreSQL. Nginx funcionó como servidor web y proxy inverso en ambos nodos; la contenerización mediante Docker garantizó la portabilidad y el aislamiento de los servicios entre entornos de desarrollo y producción. Las pruebas técnicas de la API se ejecutaron desde un dispositivo móvil Android conectado a una red WiFi estándar (802.11n, potencia de señal −55 dBm).

III-A2. Stack Tecnológico: La Tabla I resume los componentes software del sistema, la tecnología seleccionada para cada uno y la justificación técnica de la elección. React Native fue seleccionado para la interfaz móvil por su capacidad de generar componentes de interfaz nativos para Android e iOS desde una única base de código, lo que reduce el coste de mantenimiento y asegura la compatibilidad con los servicios de accesibilidad nativos de cada plataforma (TalkBack en Android, VoiceOver en iOS). Spring Boot fue seleccionado para el backend por su soporte nativo de arquitecturas de microservicios, su gestión de transacciones y su escalabilidad horizontal. Django fue seleccionado para la API de IA por la madurez de su ecosistema en procesamiento de lenguaje natural y visión por computador, y por su interoperabilidad con los modelos pre-entrenados utilizados en los módulos TTS, STT e *image captioning*.

III-A3. Componentes de Inteligencia Artificial: Los módulos de conversión accesible integraron los siguientes componentes de IA. Para **Text-to-Speech (TTS)**, se integraron dos motores en paralelo: Edge-TTS (Microsoft Neural TTS, multilingüe, sin restricciones de membresía) y SAPI5 (Microsoft Speech API 5, procesamiento local). La selección dual permitió comparar calidad y latencia entre un motor en la nube y uno local. Para **Speech-to-Text (STT)**, se empleó una API de

reconocimiento automático del habla basada en transformers de aprendizaje profundo [9], [37]. Para **descripción de imágenes** (*image captioning*), se integraron modelos de visión-lenguaje pre-entrenados mediante llamadas a API, coherentes con el estado del arte en accesibilidad visual [10], [39]. Para **Reconocimiento Óptico de Caracteres (OCR)**, se utilizaron modelos de visión por computador con precisión superior al 95 % en texto impreso estándar [40]. Para la **navegación por comandos de voz**, se empleó similitud del coseno [43] como métrica de proximidad semántica, con corrección en cascada mediante el modelo de lenguaje Llama 1B y un diccionario derivado de los patrones fonéticos de los comandos registrados.

III-A4. Marco Normativo de Accesibilidad: El marco de evaluación de accesibilidad se construyó a partir de tres fuentes normativas complementarias: las WCAG 2.1 [5] en sus niveles de conformidad A y AA, las directrices de accesibilidad móvil de W3C y el conjunto de directrices para aplicaciones Android e iOS sistematizadas por Ballantyne *et al.* [17] y Acosta-Vargas *et al.* [18]. A partir de estas fuentes se definieron 18 criterios verificables —identificados mediante el procedimiento de evaluación combinada automatizada y manual propuesto por Acosta-Vargas *et al.* [18]— organizados según el principio POUR de las WCAG 2.1: (i) **Perceptibilidad:** transcripción de mensajes de audio y vídeo, textos alternativos en imágenes, velocidad de voz sintetizada configurable y contraste de color mínimo de 4.5:1 para texto normal (criterio WCAG 1.4.3), validado mediante el algoritmo de luminancia relativa W3C implementado en Python; (ii) **Operabilidad:** tamaño de objetivo táctil mínimo de 48×48 dp, orientación de pantalla adaptable y navegación completa por comandos de voz; (iii) **Comprensibilidad:** sugerencias de error informativas, idioma de la interfaz declarado explícitamente y consistencia de iconos y etiquetas; y (iv) **Robustez:** compatibilidad verificada con TalkBack y VoiceOver, y marcado semántico de todos los controles interactivos. La herramienta de evaluación automatizada fue *Accessibility Scanner* de Google, aplicada sobre las siete pantallas principales del sistema.

III-A5. Instrumento de Evaluación de Aceptación Tecnológica: La aceptación tecnológica se midió mediante el TAM original propuesto por Davis [42], ampliamente validado en estudios de aplicaciones móviles de accesibilidad [44]. El cuestionario comprendió 12 ítems (PTAM001–PTAM012) en escala Likert de 5 puntos (1 = totalmente en desacuerdo; 5 = totalmente de acuerdo), organizados en cuatro constructos: **utilidad percibida** (PTAM001: la aplicación facilita mi comunicación con personas que no comparten mi discapacidad; PTAM002: el sistema reduce el tiempo que necesito para enviar y recibir mensajes; PTAM003: las funciones de conversión de mensajes satisfacen mis necesidades comunicativas; PTAM004: el sistema es útil para mi vida cotidiana); **facilidad de uso percibida** (PTAM005: la interfaz de la aplicación es clara y fácil de entender; PTAM006: aprender a usar las funciones principales requirió poco esfuerzo; PTAM007: la navegación por voz es intuitiva y predecible; PTAM008: el proceso de conversión de mensajes ocurre de forma transparente y sin pasos adicionales); **intención de uso** (PTAM009: utilizaría esta aplicación en lugar de las plataformas de men-

sajería actuales; PTAM010: recomendaría esta aplicación a personas con discapacidades similares a la mía); y **satisfacción global** (PTAM011: la experiencia general con el sistema es satisfactoria; PTAM012: el sistema cumple con mis expectativas de accesibilidad e inclusión). El cuestionario fue administrado en formato Google Forms adaptado con soporte TTS para usuarios con discapacidad visual. Los datos se analizaron con R Studio (paquetes *psych* y *ggplot2*) y Microsoft Excel.

III-B. Métodos

Esta subsección describe el proceso metodológico en dos dimensiones: el método de desarrollo del sistema y el método de evaluación, que comprende el protocolo de pruebas técnicas y el protocolo del estudio con usuarios.

III-B1. Marco de Desarrollo: TDDM4IoTS: El sistema fue desarrollado mediante la metodología TDDM4IoTS (*Test-Driven Development Methodology for Internet of Things-based Systems*), propuesta por Guerrero-Ulloa *et al.* [11]. TDDM4IoTS integra los fundamentos del desarrollo guiado por pruebas (TDD), la ingeniería dirigida por modelos (MDE) y los principios de las metodologías ágiles Scrum y XP en once fases iterativas, diseñadas específicamente para sistemas distribuidos que combinan componentes de software y hardware heterogéneos. Su elección sobre metodologías convencionales responde a tres razones: (1) la Fase 5 (*Generación de Pruebas*) incorpora la accesibilidad como criterio verificable antes de la generación del código, lo que supera el modelo reactivo de las metodologías convencionales donde las pruebas de accesibilidad son actividades *post-hoc*; (2) su carácter iterativo permite la incorporación de hallazgos de las pruebas con usuarios en iteraciones sucesivas sin requerir reestructuración arquitectónica; y (3) su diseño es agnóstico respecto a las herramientas, permitiendo a los desarrolladores seleccionar las tecnologías más adecuadas a los requisitos de cada entregable [11].

La Tabla II describe las once fases de TDDM4IoTS tal como fueron aplicadas al desarrollo del sistema de mensajería inclusiva, con los entregables obtenidos en cada fase y las decisiones de diseño que produjeron.

III-B2. Diseño del Sistema: Arquitectura y Módulos: El sistema adopta una arquitectura de microservicios en tres capas desacopladas. La **capa de presentación** corresponde a la interfaz móvil en React Native. La **capa de negocio** comprende dos servicios independientes: la API REST en Spring Boot, que gestiona la autenticación, el enrutamiento de mensajes y el cifrado; y la API de IA en Django, que concentra los modelos de conversión accesible. La **capa de persistencia** corresponde a la base de datos PostgreSQL. La comunicación en tiempo real entre la capa de negocio y los clientes móviles se gestiona mediante WebSocket con RabbitMQ como bróker de mensajería, que garantiza la entrega en orden y la tolerancia a fallos transitorios de conectividad. Para mensajes multimedia cuyo tamaño supera el límite de trama de WebSocket (64 KB), se adoptó HTTP con *multipart/form-data* como protocolo alternativo, decisiones formalizadas en la Fase 7 de TDDM4IoTS.

El módulo de conversión inteligente opera en tres pasos: (1) el backend Spring Boot recibe el mensaje, lo descifra con

Tabla II
APLICACIÓN DE TDDM4IoTS AL SISTEMA DE MENSAJERÍA INCLUSIVA:
FASES, ENTREGABLES Y DECISIONES DE DISEÑO

F.	Fase	Entregable	Decisión de diseño
1	Análisis preliminar	Lista de cotejo (18 criterios WCAG 2.1); análisis tecnológico	Selección de Edge-TTS + SAPI5; infraestructura AWS + UTEQ
2	Diseño de capa tecnológica	Arquitectura de micro-servicios en tres capas	Separación API REST / API IA en nodos distintos
3	Análisis de requisitos	5 casos de uso con diagramas UML	Definición de 5 flujos principales y perfiles de usuario
4	Modelos	Diagrama de clases, estados, actividad, base de datos	Modelo relacional PostgreSQL; estructura de mensajes polimórficos
5	Generación de pruebas	Pruebas unitarias/integración API; cuestionario TAM; protocolo de accesibilidad	Criterio de aceptación: tasa de error = 0 en conversión
6	Generación de software	API REST (Spring Boot), API IA (Django), app móvil (React Native)	WebSocket + RabbitMQ para tiempo real
7	Refinamiento de modelos	Actualización arquitectónica multimedia	HTTP <i>multipart/form-data</i> para mensajes >64 KB
8	Refinamiento de software	Código refactorizado (<i>clean code</i>)	Eliminación de identificadores duplicados en listas virtualizadas
9	Despliegue	Sistema en producción	Docker + Nginx en dos nodos; variables de entorno
10	Evaluación de entregables	Informe de conformidad con requisitos	Validación final de 18 criterios WCAG 2.1
11	Retroalimentación	Registro de incidencias y mejoras	Corrección de 48 de 75 advertencias de accesibilidad

la clave privada del emisor y lo redirige a la API Django según su tipo MIME (texto, audio, imagen o vídeo); (2) la API Django aplica la transformación al perfil sensorial declarado por el receptor: TTS si el receptor tiene discapacidad visual, STT si tiene discapacidad auditiva, descripción por modelo visión-lenguaje más OCR si el mensaje es de tipo imagen y el receptor tiene discapacidad visual, o combinación de STT y TTS para la discapacidad del habla; y (3) el mensaje procesado se re-cifra con la clave del receptor y se envía mediante WebSocket. El cifrado de extremo a extremo se implementa mediante claves privadas asimétricas: cada usuario recibe en su registro una clave única almacenada localmente en el dispositivo móvil, de modo que el servidor nunca almacena texto plano.

El módulo de navegación por comandos de voz permite la operación completa de la interfaz móvil mediante instrucciones habladas. El audio transcrito mediante STT se compara con el catálogo de comandos registrados mediante similitud del coseno [43]. Si la puntuación de similitud es inferior al umbral $\theta = 0,60$ —establecido empíricamente en pruebas piloto— se activa un mecanismo de corrección en cascada: en primer lugar, mediante el modelo Llama 1B ajustado para corrección léxico-semántica; en segundo lugar,

mediante un diccionario derivado de las variaciones fonéticas más frecuentes de cada comando. Este diseño en cascada garantiza el reconocimiento robusto ante variaciones de acento, ruido ambiental y disfluencias leves, que son las principales fuentes de fallo documentadas en sistemas STT para entornos reales [33], [37].

III-B3. Protocolo de Pruebas Técnicas de la API: Las pruebas técnicas de rendimiento se diseñaron para caracterizar la latencia de cada módulo de conversión en condiciones de entrada variables y controladas. Para el **módulo TTS** se evaluaron los dos motores integrados —Edge-TTS y SAPI5— con textos de tres longitudes: corto (151 caracteres, equivalente a un mensaje breve), mediano (317 caracteres, equivalente a un párrafo) y largo (799 caracteres, equivalente a un mensaje extenso). Para el **módulo STT** se evaluaron tres archivos de audio con duraciones proporcionales a las mismas categorías de longitud. Para el **módulo de descripción de imágenes** se evaluaron cuatro resoluciones representativas del rango de cámaras móviles actuales: 640×427 , $1\,280 \times 853$, $1\,920 \times 1\,280$ y $6\,000 \times 4\,000$ píxeles. En cada condición se realizaron tres mediciones independientes y se reportó la media aritmética. Las métricas registradas fueron: latencia de procesamiento (en segundos, medida desde el envío de la solicitud hasta la recepción de la respuesta procesada), tamaño del mensaje de entrada (KB), tamaño del mensaje de salida (KB) y tasa de error (número de fallos de procesamiento sobre el total de solicitudes). La evaluación de accesibilidad se realizó en dos momentos: antes del despliegue (evaluación inicial) y tras la iteración de mejora de la Fase 11 de TDDM4IoTS (evaluación final), para cuantificar la reducción de advertencias por pantalla.

III-B4. Protocolo del Estudio con Usuarios:

III-B4a. Participantes.: La muestra comprendió $n = 25$ participantes con discapacidades sensoriales documentadas, seleccionados por muestreo intencional [41] en una clínica de diálisis de la ciudad de Quevedo (Ecuador), donde se concentra una población adulta con diagnósticos sensoriales heterogéneos. El muestreo intencional se justifica por la especificidad clínica de los criterios de inclusión y por la baja prevalencia de la población objetivo en contextos poblacionales generales [1]. Los criterios de inclusión fueron: (i) diagnóstico documentado de discapacidad visual, auditiva o del habla; (ii) edad igual o superior a 18 años; (iii) acceso a dispositivo móvil Android compatible; y (iv) firma del consentimiento informado. Los criterios de exclusión fueron: (i) presencia de multidiscapacidad que combinase simultáneamente los tres perfiles sensoriales, ya que la adaptación de mensajes para ese perfil compuesto está fuera del alcance de la versión evaluada; (ii) deterioro cognitivo que imposibilitase la comprensión del cuestionario; y (iii) ausencia de consentimiento informado por escrito. Los datos se recolectaron entre 2024 y 2025. El estudio fue conducido de conformidad con los principios de la Declaración de Helsinki [45] y contó con la aprobación del comité institucional correspondiente; todos los participantes otorgaron consentimiento informado escrito antes del inicio de las pruebas.

III-B4b. Procedimiento.: El protocolo de evaluación comprendió tres etapas secuenciales para cada participante.

En la **Etapla 1** (15 minutos), el facilitador presentó el sistema mediante una demostración estándar de las funcionalidades principales —envío de mensaje de texto, escucha de mensaje de audio, descripción de imagen recibida y navegación por voz— sin intervenir en las interacciones del participante. En la **Etapla 2** (20 minutos), el participante interactuó libremente con el sistema en su propio dispositivo móvil, completando cinco tareas predefinidas: (T1) registro y configuración del perfil de discapacidad; (T2) búsqueda de un contacto y envío de un mensaje de texto; (T3) escucha de un mensaje de audio recibido mediante TTS; (T4) recepción de una imagen y escucha de su descripción automática; y (T5) navegación a la pantalla de configuración exclusivamente mediante comandos de voz. Durante esta etapa, el facilitador registró los indicadores de observación directa: número de errores de interacción (toques en elementos incorrectos), número de solicitudes de ayuda al facilitador y número de toques erróneos en pantalla. En la **Etapla 3** (10 minutos), el participante completó el cuestionario TAM de 12 ítems de forma autónoma, asistido por el motor TTS en caso de discapacidad visual.

III-B4c. Análisis estadístico. La consistencia interna del cuestionario TAM se verificó mediante el coeficiente alfa de Cronbach. Para cada ítem se calcularon la media aritmética ($\bar{x}$), la desviación estándar (DE) y la distribución de frecuencias por nivel de la escala Likert. La estructura factorial del instrumento fue explorada mediante un gráfico HJ-Biplot, que permitió identificar clústeres de ítems con alta correlación interna y participantes con patrones de respuesta similares. Los datos de la evaluación de accesibilidad se presentaron como frecuencias absolutas de advertencias antes y después del proceso iterativo de mejora, con el porcentaje de reducción por pantalla. Todos los análisis se realizaron en R Studio (versión 4.3.1; paquetes `psych`, `ggplot2` y `BiplotR`) y Microsoft Excel.

IV. EVALUACIÓN Y RESULTADOS

Esta sección presenta los resultados de la evaluación en dos dimensiones complementarias: primero, las pruebas técnicas de rendimiento de la API de conversión multimodal; y segundo, la evaluación de accesibilidad y de aceptación tecnológica con usuarios reales. Los resultados se estructuran de forma que permitan juzgar, de manera separada e integrada, la viabilidad técnica del sistema y su utilidad percibida por la población destinataria.

IV-A. Rendimiento Técnico de la API de Conversión

La API de conversión fue sometida a pruebas de carga controladas para caracterizar la latencia, la estabilidad y la integridad del procesamiento en cada módulo. Todas las condiciones de prueba se ejecutaron desde un dispositivo móvil Android conectado a una red WiFi estándar (802.11n, −55 dBm), con tres repeticiones por condición, reportándose la media aritmética. El criterio de aceptación técnica definido en la Fase 5 de TDDM4IoT fue: tasa de error igual a cero para todas las condiciones de entrada.

Tabla III
RENDIMIENTO COMPARATIVO TTS (MEDIA DE 3 EJECUCIONES, ERROR = 0)

Métrica	Edge-TTS			SAPI5		
	Corto	Medio	Largo	Corto	Medio	Largo
Carga (s)	8.13	7.90	16.88	5.18	5.76	15.07
Latencia (s)	8.10	7.90	16.87	5.14	5.73	15.05
Envío (KB)	0.37	0.54	1.03	0.37	0.54	1.03
Resp.	0.16 MB	0.30 MB	0.75 MB	1.46 MB	2.93 MB	7.24 MB
Errores	0	0	0	0	0	0

IV-A1. Módulo de Síntesis de Voz (TTS): El módulo TTS integra dos motores en paralelo: Edge-TTS (Microsoft Neural TTS, procesamiento en nube) y SAPI5 (Microsoft SAPI5, procesamiento local mediante la librería `pyttsx3`). Se evaluaron tres categorías de texto cuya longitud reproduce los rangos de mensajes reales en aplicaciones de mensajería: corto (151 caracteres), mediano (317 caracteres) y largo (799 caracteres). La Tabla III presenta los resultados completos.

Ambos motores operaron con tasa de error cero en todas las condiciones, verificando el criterio de aceptación. SAPI5 presentó latencias inferiores a Edge-TTS en todos los niveles de longitud: 5.14 s versus 8.10 s para texto corto (37 % menor), 5.73 s versus 7.90 s para texto mediano (27 % menor) y 15.05 s versus 16.87 s para texto largo (11 % menor). Estas diferencias se explican por la ausencia de latencia de red en SAPI5, que ejecuta la síntesis localmente. En contrapartida, SAPI5 genera archivos de respuesta significativamente más voluminosos: 7.24 MB para texto largo frente a 0.75 MB de Edge-TTS, lo que puede comprometer la eficiencia en entornos con ancho de banda limitado. La latencia mínima observada (5.14 s en SAPI5 para texto corto) supera el umbral de 2 s que la literatura establece como óptimo para un flujo conversacional natural [8], lo que constituye la limitación técnica más crítica del sistema en su estado actual.

IV-A2. Módulo de Reconocimiento Automático del Habla (STT): El módulo STT emplea el modelo Whisper de reconocimiento automático del habla [37], ejecutado en el nodo AWS. Se evaluaron tres archivos de audio cuyas duraciones son representativas del comportamiento documentado de los usuarios en aplicaciones de mensajería por voz [46]: corto (equivalente a una instrucción breve), mediano (equivalente a un mensaje conversacional estándar) y largo (equivalente a un mensaje narrativo extendido). La Tabla IV presenta los resultados detallados.

La tasa de error fue cero en todas las condiciones, confirmando la estabilidad del modelo Whisper en el entorno de despliegue. La latencia crece de forma aproximadamente lineal con la duración del audio: 13.36 s para el audio corto, 20.51 s para el mediano (+53 %) y 54.99 s para el largo (+168 % respecto al corto). Los tamaños de envío y respuesta son prácticamente idénticos en todas las condiciones (diferencia < 1 %), lo que confirma la integridad del procesamiento y la ausencia de pérdida de datos durante la transmisión. La latencia del STT es considerablemente superior a la del TTS, lo que es coherente con la mayor carga computacional del reconocimiento de habla en comparación con la síntesis [9].

Tabla IV
RENDIMIENTO DEL MÓDULO STT POR DURACIÓN DEL AUDIO (ERROR = 0)

Métrica	Unidad	Corto	Mediano	Largo
Tiempo carga	s	13.361	20.512	55.000
Tiempo conex.	s	0.003	0.008	0.011
Latencia neta	s	13.361	20.509	54.990
Tam. envío	KB	60.382	233.50	1000
Tam. respuesta	KB	60.723	233.85	1000
Errores	—	0	0	0

Tabla V
RENDIMIENTO DEL MÓDULO POR RESOLUCIÓN (ERROR = 0)

Métrica	640×427	1280×853	1920×1280	6000×4000
Peso img.	44 KB	126 KB	254 KB	1.65 MB
Carga (s)	14.09	17.68	16.43	19.22
Conex. (s)	0.003	0.054	0.056	0.057
Latencia (s)	13.95	17.67	16.42	19.19
Envío (MB)	0.058	0.17	0.35	2.31
Resp. (MB)	0.12	0.24	0.41	2.37
Errores	0	0	0	0

IV-A3. Módulo de Descripción de Imágenes (Image Captioning): El módulo de descripción de imágenes emplea el modelo `blip-image-captioning-base` de Hugging Face. Se evaluaron cuatro resoluciones que cubren el rango típico de cámaras móviles actuales, desde imágenes de baja resolución (640×427 px, 72 DPI, 44 KB) hasta imágenes de alta resolución profesional (6 000×4 000 px, 72 DPI, 1.65 MB). La Tabla V presenta los resultados.

El sistema no registró errores en ninguna de las cuatro resoluciones evaluadas, evidenciando estabilidad ante imágenes de alta resolución. La latencia osciló entre 13.95 s (640×427 px) y 19.19 s (6 000×4 000 px), con una variación relativa del 37 % entre los extremos del rango de resolución, lo que indica una degradación de rendimiento moderada y aceptable a medida que aumenta el peso de la imagen. Notablemente, la imagen de 1 920×1 280 px presentó una latencia (16.42 s) inferior a la de 1 280×853 px (17.67 s), lo que sugiere variabilidad en los tiempos de inferencia del modelo relacionada con el contenido semántico de la imagen más que con la resolución per se, en consonancia con lo documentado por Dognin *et al.* [10] y Safiya y Pandian [39].

IV-A4. Módulo de Procesamiento de Vídeo: El módulo de vídeo gestiona la transmisión de archivos multimedia de gran tamaño mediante HTTP con `multipart/form-data`, protocolo adoptado en la Fase 7 de TDDM4IoTS para superar el límite de trama de 64 KB de WebSocket. Se evaluaron tres duraciones representativas: vídeo corto (4 min, 9.22 MB), mediano (17 min, 48.9 MB) y largo (30 min, 76.9 MB), todos a resolución 360p. Los tiempos de carga escalaban linealmente con la duración: 3.91 min, 20.29 min y 34.00 min respectivamente, con latencias equivalentes al tiempo de carga y tasa de error cero en todos los casos. Los tamaños de envío y respuesta fueron prácticamente idénticos (diferencia media

Tabla VI
REDUCCIÓN DE ADVERTENCIAS DE ACCESIBILIDAD POR PANTALLA TRAS LA APLICACIÓN DEL CICLO ITERATIVO DE MEJORA DE TDDM4IoTS (FASES 5 Y 11).

Pantalla	Inicial	Final	Reducción	%
Principal	11	2	9	81.8
Perfil de usuario	21	8	13	61.9
Configuraciones	9	2	7	77.8
Mensajería	21	13	8	38.1
Cámara	4	0	4	100.0
Foto	2	0	2	100.0
Vídeo	7	2	5	71.4
Total	75	27	48	64.0

< 0,2 %), confirmando la integridad de la transmisión. La latencia del vídeo, expresada en minutos, excede la de los demás módulos en un orden de magnitud, lo cual era esperado dada la naturaleza del protocolo HTTP para archivos de gran tamaño.

IV-B. Evaluación de Accesibilidad

La evaluación de accesibilidad se realizó en dos momentos mediante la herramienta *Accessibility Scanner* de Google [18] sobre las siete pantallas principales del sistema, en consonancia con el protocolo de evaluación combinada automatizada propuesto por Acosta-Vargas *et al.* [18]. La evaluación inicial —correspondiente a la Fase 5 de TDDM4IoTS— precedió al despliegue; la evaluación final —correspondiente a la Fase 11— se realizó tras la iteración de mejora. La Tabla VI presenta la comparación.

El proceso iterativo eliminó 48 de las 75 advertencias iniciales, alcanzando una reducción global del 64.0 %. Las advertencias resueltas correspondieron principalmente a cuatro categorías de no conformidad con las WCAG 2.1: (i) elementos táctiles cuyo tamaño era inferior al mínimo de 48×48 dp (criterio de operabilidad); (ii) relaciones de contraste de color por debajo de 4.5:1 (criterio WCAG 1.4.3); (iii) texto no expuesto en las etiquetas de accesibilidad de los elementos (criterio de robustez); y (iv) descripciones de elementos ambiguas o ausentes. Las pantallas de cámara y foto alcanzaron eliminación total de advertencias (100 %), mientras que las pantallas de configuraciones y principal obtuvieron reducciones del 77.8 % y 81.8 %, respectivamente. La pantalla de mensajería registró la menor reducción (38.1 %, de 21 a 13 advertencias), por una razón de carácter arquitectónico: la reutilización de plantillas de lista virtualizada en React Native genera identificadores de accesibilidad duplicados que el sistema operativo Android interpreta como elementos redundantes, los cuales no son resolubles sin una refactorización con identificadores únicos dinámicos por elemento de lista. Esta limitación es estructural y su resolución completa queda propuesta como línea de trabajo futuro. El resultado obtenido contrasta favorablemente con los niveles de incumplimiento superiores al 60 % documentados por Chen *et al.* [6] en las plataformas de mensajería comerciales más extendidas.

Tabla VII
RESULTADOS DEL CUESTIONARIO TAM ($n = 25$, ESCALA LIKERT 1–5).
UP = UTILIDAD PERCIBIDA; FUP = FACILIDAD DE USO PERCIBIDA;
IU = INTENCIÓN DE USO; SG = SATISFACCIÓN GLOBAL.

Ítem	Constructo	$\bar{x}$	DE	Nivel 5 (%)
PTAM001	UP	4.48	1.00	72
PTAM002	UP	4.76	0.60	84
PTAM003	UP	4.48	0.77	—
PTAM004	UP	4.52	0.77	—
PTAM005	FUP	4.56	0.77	—
PTAM006	FUP	4.52	0.87	—
PTAM007	FUP	3.56	1.36	—
PTAM008	FUP	3.96	1.21	—
PTAM009	IU	4.20	1.00	—
PTAM010	IU	4.16	1.07	—
PTAM011	SG	3.72	1.21	—
PTAM012	SG	3.48	1.23	—
Global	—	4.28	0.95	—

IV-C. Aceptación Tecnológica: Resultados del TAM

La aceptación tecnológica se cuantificó mediante el cuestionario TAM de 12 ítems administrado a los $n = 25$ participantes. La Tabla VII presenta las medias ($\bar{x}$) y desviaciones estándar (DE) por ítem, con la asignación a los cuatro constructos del TAM [42].

IV-C1. Utilidad Percibida: El constructo de utilidad percibida (PTAM001–PTAM004) obtuvo la media más alta del instrumento ($\bar{x}$ de construto = 4,56). El ítem PTAM002 (“el sistema reduce el tiempo que necesito para enviar y recibir mensajes”) alcanzó la valoración más alta de todo el cuestionario ($\bar{x} = 4,76$; DE = 0,60), con el 84 % de participantes en el nivel máximo de acuerdo, lo que indica que la función de conversión automática de mensajes es percibida como la aportación de mayor valor práctico. El ítem PTAM001 ($\bar{x} = 4,48$; DE = 1,00) obtuvo el 72 % de respuestas en el nivel máximo, reflejando que la aplicación facilita la comunicación con personas sin la misma discapacidad. La DE relativamente elevada de PTAM001 (1.00) indica mayor heterogeneidad en la percepción de este beneficio entre los participantes, lo que podría estar relacionada con la variabilidad de los perfiles de discapacidad de la muestra.

IV-C2. Facilidad de Uso Percibida: El constructo de facilidad de uso percibida (PTAM005–PTAM008) presentó mayor dispersión interna. Los ítems PTAM005 ($\bar{x} = 4,56$; DE = 0,77) y PTAM006 ($\bar{x} = 4,52$; DE = 0,87) reflejan una valoración positiva de la claridad de la interfaz y del bajo esfuerzo de aprendizaje de las funciones principales. En contraste, PTAM007 ($\bar{x} = 3,56$; DE = 1,36) obtuvo la segunda valoración más baja del instrumento, con la mayor variabilidad observada (rango completo 1–5). Este ítem evalúa la intuitividad de la navegación por voz, cuya curva de aprendizaje resultó más pronunciada de lo esperado, en consonancia con los hallazgos de Bleakley *et al.* [33] sobre las limitaciones de los sistemas STT comerciales para usuarios con patrones de habla heterogéneos. PTAM008 ($\bar{x} = 3,96$; DE = 1,21)

evalúa la transparencia del proceso de conversión de mensajes, y su valoración intermedia indica que algunos participantes percibieron el proceso como más complejo de lo deseable.

IV-C3. Intención de Uso: Los ítems de intención de uso (PTAM009–PTAM010) obtuvieron medias de 4.20 y 4.16, respectivamente, con desviaciones estándar de 1.00 y 1.07. Estos valores indican una disposición positiva mayoritaria a utilizar el sistema como alternativa a las plataformas de mensajería convencionales y a recomendarlo a pares con discapacidades similares, si bien la presencia de valores en la escala inferior (niveles 1 y 2) en una proporción de participantes sugiere que subsisten reservas asociadas a la curva de aprendizaje documentada en PTAM007.

IV-C4. Satisfacción Global: El constructo de satisfacción global (PTAM011–PTAM012) presentó las valoraciones más bajas del instrumento: PTAM011 ($\bar{x} = 3,72$; DE = 1,21) y PTAM012 ($\bar{x} = 3,48$; DE = 1,23). En PTAM012 (“el sistema cumple con mis expectativas de accesibilidad e inclusión”), el 20 % de los participantes seleccionó el nivel 1 de la escala y el 28 % seleccionó el nivel 1 en PTAM011, los porcentajes de rechazo más altos del instrumento. Estos resultados indican que, si bien las funcionalidades de conversión son valoradas positivamente, las expectativas globales de accesibilidad de la población participante superan al estado actual del sistema, lo que es coherente con el 38.1 % de advertencias residuales en la pantalla de mensajería documentado en la evaluación de accesibilidad.

IV-C5. Análisis Multivariante: HJ-Biplot: El análisis HJ-Biplot sobre la matriz de respuestas TAM reveló dos patrones estructurales relevantes. En primer lugar, los ítems PTAM001–PTAM006 forman un clúster de alta correlación interna, con vectores que apuntan en la misma dirección del espacio biplot, lo que indica que los participantes percibieron de forma coherente y conjunta las dimensiones de utilidad percibida y facilidad de uso para las funciones principales. En segundo lugar, los vectores de PTAM007 y PTAM012 son aproximadamente ortogonales al clúster principal, lo que revela que estos ítems capturan varianza independiente del resto del instrumento, asociada a las dimensiones de gestión de la navegación por voz y satisfacción con la cobertura de accesibilidad, respectivamente. El análisis de proyección de participantes evidenció que un subgrupo de usuarios se posiciona en el cuadrante opuesto a los vectores de PTAM007 y PTAM012, representando a los participantes con mayor dificultad percibida en estas dimensiones; este subgrupo coincidió, en la observación directa, con los participantes que registraron más errores de interacción. La media global del instrumento fue $\bar{x} = 4,28$ (DE = 0,95), superando el umbral de aceptación positiva ($\bar{x} > 4,0$) establecido en estudios TAM en contextos de accesibilidad móvil [44].

IV-C6. Observación Directa: La sesión de observación directa registró los indicadores conductuales definidos en el protocolo de evaluación: 7 errores de interacción (toques en elementos incorrectos), 2 solicitudes de ayuda al facilitador y 15 toques erróneos totales. Los tres indicadores se concentraron mayoritariamente en la pantalla de mensajería y en la pantalla de cámara durante las tareas T2 y T4, en concordancia con la mayor densidad de elementos interactivos

Tabla VIII
SÍNTESIS DE RESULTADOS POR DIMENSIÓN DE EVALUACIÓN Y BRECHA ATENDIDA.

Dimensión	Resultado principal	Brecha atendida
Rendimiento API	Tasa de error = 0 en TTS, STT, <i>captioning</i> y vídeo; latencia TTS mínima: 5.14 s	Brechas 1 y 2
Accesibilidad	Reducción del 64 % en advertencias WCAG 2.1 (48/75); 100 % en cámara y foto	Brecha 4
Aceptación TAM	$\bar{x}_{global} = 4,28$; UP = 4,56; FUP = 4,15; IU = 4,18; SG = 3,60	Brecha 3
Observación	8 % solicitudes de ayuda; errores concentrados en mensajería	Brechas 1 y 5

en esas pantallas y con el número residual de advertencias de accesibilidad documentado en la Tabla VI. El bajo número de solicitudes de ayuda (2 sobre 25 participantes, 8 %) indica que la mayoría de los usuarios fueron capaces de completar las tareas predefinidas de forma autónoma, lo que respalda los valores positivos de utilidad percibida y facilidad de uso del TAM para las funciones principales.

IV-D. Síntesis de Resultados

La Tabla VIII ofrece una visión integrada de los resultados obtenidos en las tres dimensiones evaluadas, relacionando cada resultado con la brecha identificada en la sección II que aborda.

V. DISCUSIÓN

Esta sección interpreta los resultados obtenidos en el marco de la literatura revisada, articula las implicaciones de los hallazgos para el campo de la interacción hombre-máquina inclusiva, identifica las limitaciones del sistema y reflexiona sobre el alcance social del trabajo.

V-A. Interpretación de los Resultados Técnicos

Los cuatro módulos de conversión del sistema —TTS, STT, descripción de imágenes y procesamiento de vídeo— operaron con tasa de error cero en todas las condiciones evaluadas, lo que valida la estabilidad de la arquitectura de microservicios propuesta y satisface el criterio de aceptación definido en la Fase 5 de TDDM4IoTS. Este resultado es relevante porque ninguno de los sistemas de mensajería inclusiva revisados en la literatura —BellChat [22], el prototipo de Stefanov *et al.* [23] ni GlassMessaging [26]— reporta evaluaciones de robustez API con condiciones de entrada variable, lo que impide la comparación directa de tasas de error pero resalta la contribución metodológica de disponer de evidencia cuantificada bajo un protocolo controlado.

La latencia TTS mínima observada fue 5.14 s (SAPI5, texto corto), valor que excede el umbral de 2 s que Tan *et al.* [8] identifican como óptimo para mantener el flujo conversacional en sistemas TTS neuronales de alta calidad. Esta limitación no es exclusiva del sistema propuesto: la revisión PRISMA de Bercaru y Popescu [2] documenta que la latencia de inferencia sigue siendo la barrera de despliegue más crítica de los modelos TTS neuronales en entornos de producción real, y que solo las implementaciones con caché predictiva o modelos no autorregresivos logran latencias inferiores a 2 s. La ventaja de SAPI5 sobre Edge-TTS en latencia neta (37 % menor para texto corto) se explica por la ausencia de latencia de red en el procesamiento local; no obstante, este beneficio se revierte en escenarios con ancho de banda móvil limitado, donde los archivos de respuesta de SAPI5 —7.24 MB para texto largo frente a 0.75 MB de Edge-TTS— representan una penalización de transferencia significativa. Este *trade-off* entre latencia de inferencia y volumen de datos de respuesta no había sido documentado en el contexto de sistemas de mensajería inclusiva móvil y constituye un hallazgo operacionalmente relevante para futuras implementaciones.

La latencia del módulo STT escaló de 13.36 s para audio corto a 54.99 s para audio largo, con integridad de transmisión perfecta en todos los casos (diferencia entre envío y respuesta inferior al 1 %). Este comportamiento es coherente con la arquitectura de Whisper [37], cuyo mecanismo de atención global sobre la secuencia completa de audio determina que el coste computacional sea proporcional a la duración. Baeviski *et al.* [9] demuestran que los modelos STT basados en aprendizaje autosupervisado —como wav2vec 2.0, al que Whisper es conceptualmente cercano— alcanzan WER comparable a la transcripción humana, pero sus latencias de inferencia en producción varían notablemente según el hardware de despliegue. El nodo AWS utilizado representó la solución mínima viable dada la infraestructura disponible; la reducción de latencia STT mediante aceleración GPU dedicada o modelos destilados (*Whisper Tiny/Small*) constituye la línea de mejora de mayor impacto práctico identificada.

La variabilidad no monótona observada en la latencia del módulo de descripción de imágenes —la resolución 1920×1280 px registró menor latencia (16.42 s) que la resolución 1280×853 px (17.67 s)— es consistente con los hallazgos de Dognin *et al.* [10], quienes documentan que en el conjunto VizWiz la dificultad semántica de la imagen —no su resolución— es el predictor primario del tiempo de inferencia en modelos de *image captioning* basados en atención visual. Safiya y Pandian [39] corroboran esta observación al reportar que el modelo VGG16-LSTM exhibe tiempos de inferencia variables en imágenes con alta densidad de objetos, independientemente de su tamaño en píxeles. Estos resultados tienen implicaciones de diseño: en una aplicación móvil de mensajería inclusiva, la predicción de latencia de descripción no puede basarse exclusivamente en metadatos de tamaño de imagen, sino que requiere un estimador de complejidad semántica que anticipe los tiempos de respuesta para gestionar las expectativas del usuario.

V-B. Interpretación de los Resultados de Accesibilidad

La reducción global del 64.0 % en advertencias de accesibilidad (de 75 a 27) tras la aplicación del ciclo iterativo de TDDM4IoTS coloca al sistema propuesto en una posición notablemente superior respecto a las plataformas comerciales de referencia. Chen *et al.* [6] documentan tasas de incumplimiento superiores al 60 % en criterios WCAG 2.1 fundamentales para WhatsApp, Telegram, Messenger e Instagram, valores que representan el escenario *baseline* con el que el sistema propuesto compete. Huang *et al.* [19] confirman que estos patrones de incumplimiento son especialmente severos en los criterios de tamaño de objetivo táctil y contraste de color para usuarios con discapacidades cognitivas, precisamente las dos categorías más frecuentes entre las 48 advertencias resueltas en el proceso iterativo de este trabajo.

La reducción del 100 % en las pantallas de cámara y foto válida que la metodología de desarrollo adoptada —en particular, la Fase 5 de TDDM4IoTS que define las pruebas de accesibilidad antes de la generación del código— es efectiva para eliminar barreras en pantallas de diseño relativamente simple. Este resultado concuerda con la propuesta de Ara *et al.* [20] de que el *testing* iterativo desde fases tempranas del ciclo de desarrollo es la intervención con mayor impacto en la conformidad WCAG. Por el contrario, la pantalla de mensajería —la de mayor densidad funcional del sistema— sólo alcanzó una reducción del 38.1 %, lo que expone una limitación arquitectónica del patrón de lista virtualizada de React Native que genera identificadores de accesibilidad duplicados. Esta limitación no es exclusiva del sistema propuesto: Da Silva *et al.* [12] identificaron que las pantallas de conversación de WhatsApp concentran el mayor número de barreras para usuarios con discapacidad visual, y Swati *et al.* [14] documentaron el mismo patrón en Facebook Messenger. El problema es, por tanto, estructural al paradigma de lista de mensajes virtualizada y no resuelto en ninguna implementación reportada en la literatura.

La evaluación de accesibilidad fue realizada exclusivamente con herramientas automatizadas (*Accessibility Scanner*), en concordancia con la metodología de Acosta-Vargas *et al.* [18], quienes demuestran que los métodos automatizados detectan el espectro de barreras de tipo estructural con alta cobertura. Sin embargo, los propios autores advierten que el enfoque combinado —automatizado más inspección manual experta— incrementa la cobertura de detección en más de un 35 %. La ausencia de inspección manual experta en el presente estudio constituye, por tanto, una limitación metodológica reconocida que puede haber subestimado el número real de barreras presentes, especialmente en las dimensiones de comprensibilidad y robustez, cuya evaluación automática es parcial incluso en las herramientas más avanzadas [20].

V-C. Interpretación de los Resultados de Aceptación Tecnológica

La media global del cuestionario TAM ($\bar{x} = 4,28$; $DE = 0,95$) supera el umbral de aceptación positiva $\bar{x} > 4,0$ establecido en estudios TAM en contextos de accesibilidad

móvil [44], lo que constituye evidencia de que los usuarios de la muestra perciben el sistema como una alternativa tecnológicamente aceptable a las plataformas convencionales. Este resultado respalda directamente el paradigma de Davis [42], que postula que la utilidad percibida es el predictor dominante de la intención de uso, y es coherente con el patrón documentado por Mateos-Sanchez *et al.* [31] en CapacitaBOT, donde las funcionalidades de conversión de mensajes con IA fueron las mejor valoradas por los usuarios con discapacidad intelectual.

El constructo de utilidad percibida obtuvo la media de constructo más alta ($\bar{x}_{UP} = 4,56$), con PTAM002 como el ítem mejor valorado de todo el instrumento ($\bar{x} = 4,76$; 84 % en nivel 5). Este resultado indica que la reducción del tiempo de comunicación gracias a la conversión automática de mensajes es la aportación de mayor valor práctico percibida por los participantes, lo que valida el argumento central de Elshahar *et al.* [21] de que la velocidad conversacional —no la precisión de la conversión— es el factor crítico de usabilidad en las plataformas CAA. Paralelamente, los ítems PTAM003 ($\bar{x} = 4,48$) y PTAM004 ($\bar{x} = 4,52$), que evalúan la satisfacción con las funciones de conversión y la utilidad cotidiana, confirman que el diseño multimodal del sistema responde a necesidades comunicativas reales, en línea con lo documentado por Chang *et al.* [25] para sistemas de participación urbana multimodal.

La facilidad de uso percibida presentó la mayor dispersión interna del instrumento. Los ítems PTAM005 ($\bar{x} = 4,56$) y PTAM006 ($\bar{x} = 4,52$) reflejan una valoración positiva de la claridad de la interfaz y el bajo esfuerzo de aprendizaje para las funciones principales, consistente con los principios de diseño universal [4]. Por el contrario, PTAM007 ($\bar{x} = 3,56$; $DE = 1,36$), que evalúa la intuitividad de la navegación por voz, obtuvo la segunda valoración más baja del instrumento y la mayor variabilidad. Este resultado resuena directamente con los hallazgos de Bleakley *et al.* [33] sobre altavoces inteligentes: los sistemas de reconocimiento de voz comerciales presentan barreras críticas para usuarios con habla atípica o disfluencias, relacionadas con umbrales de detección de fin de enunciado demasiado cortos y la incapacidad de gestionar repeticiones y prolongaciones propias de la tartamudez. Aunque el sistema propuesto incorpora un mecanismo de corrección en cascada basado en similitud del coseno y Llama 1B, la curva de aprendizaje de los comandos de voz en usuarios no familiarizados con este paradigma de interacción sigue siendo un obstáculo que requiere intervención de diseño específica. La heterogeneidad de la DE en PTAM007 sugiere que la dificultad de la navegación por voz varía significativamente según el perfil de discapacidad del usuario, lo que es coherente con la recomendación de Costanzo *et al.* [30] de implementar modelos STT con entrenamiento personalizado por usuario para habla atípica.

Los constructos de intención de uso (IU: $\bar{x}_{PTAM009} = 4,20$; $\bar{x}_{PTAM010} = 4,16$) indican una disposición positiva mayoritaria a adoptar el sistema en la vida cotidiana. No obstante, la presencia de valoraciones en los niveles inferiores de la escala en una proporción de participantes sugiere que la intención de uso está condicionada por la resolución de las

dificultades asociadas a PTAM007. Este patrón de dependencia entre facilidad de uso e intención de uso es consistente con el modelo TAM original [42] y ha sido documentado en aplicaciones CAA por Kim *et al.* [16], quienes observaron que la ausencia de estándares de evaluación específicos para discapacidad auditiva produce diseños que comprometen la adopción real, incluso cuando la utilidad percibida es alta.

El constructo de satisfacción global presentó las medias más bajas del instrumento (PTAM011: $\bar{x} = 3,72$; PTAM012: $\bar{x} = 3,48$), con un 20 % y un 28 % de participantes en el nivel 1, respectivamente. La interpretación más plausible de estos valores es que las expectativas globales de accesibilidad e inclusión de la población participante —personas con discapacidades sensoriales que han experimentado la exclusión digital de forma cotidiana— son sistemáticamente más altas que las de cualquier población de referencia general. Este fenómeno ha sido descrito por Weichbroth [3] como el “efecto de las expectativas elevadas en poblaciones con discapacidad”: los usuarios con alta dependencia de herramientas de accesibilidad aplican estándares de exigencia más estrictos que los usuarios sin discapacidad. En consecuencia, la baja puntuación en satisfacción global no refleja necesariamente un fracaso del sistema, sino la distancia que aún separa al estado actual del sistema del ideal de inclusión total que los participantes demandan, en consonancia con las limitaciones residuales de accesibilidad documentadas en la Tabla VI.

El análisis HJ-Biplot reveló que los ítems PTAM001–PTAM006 forman un clúster de alta correlación interna, evidenciando que los participantes percibieron las dimensiones de utilidad y facilidad de uso para las funciones principales de forma coherente y conjunta. Los vectores ortogonales de PTAM007 y PTAM012 indican que la navegación por voz y la satisfacción global capturan varianza independiente del resto del instrumento, asociada a perfiles de usuario específicos. Este patrón es teóricamente consistente con la reformulación del TAM propuesta por Davis [42], en la que la facilidad de uso modera el efecto de la utilidad percibida sobre la intención de uso, pero con un componente de satisfacción global que refleja experiencias acumuladas más allá de la interacción inmediata.

V-D. Implicaciones para el Diseño de Sistemas de Mensajería Inclusiva

Los resultados del presente estudio permiten articular cuatro implicaciones concretas para el diseño de sistemas de mensajería inclusiva impulsados por IA.

La primera implicación es que la **integración multimodal** de TTS, STT, *image captioning* y OCR en una plataforma móvil única es técnicamente viable con tecnologías de código abierto disponibles, y produce niveles de aceptación tecnológica positivos ($\bar{x}_{TAM} = 4,28$) en poblaciones de discapacidad heterogénea. Este hallazgo no tenía precedente documentado en la literatura, que se había limitado a sistemas unimodales [22] o de perfil único [23], [24].

La segunda implicación es que el **cifrado asimétrico de extremo a extremo** es compatible con el flujo de conversión multimodal sin degradar la tasa de error, lo que disipa la

preocupación —implícita en la brecha identificada— de que la privacidad y la accesibilidad son objetivos en conflicto en sistemas de mensajería. Ninguno de los sistemas CAA revisados —incluyendo Talkitt [30], CapacitaBOT [31] y Bell-Chat [22]— había reportado una implementación de privacidad equivalente.

La tercera implicación es que el **módulo de comandos de voz** mediante similitud del coseno con corrección en cascada reduce, pero no elimina, la barrera de la curva de aprendizaje para la navegación por voz (PTAM007: $\bar{x} = 3,56$). El diseño de un proceso de *onboarding* accesible que guíe al usuario en la internalización de los comandos disponibles es una condición necesaria para que el sistema alcance su potencial de accesibilidad plena para usuarios con discapacidad visual severa.

La cuarta implicación concierne a la **metodología de desarrollo**. La aplicación de TDDM4IoTS [11] con accesibilidad como criterio verificable desde la Fase 5 produjo una reducción del 64 % en advertencias WCAG 2.1, resultado que contrasta con la ausencia total de evaluación de accesibilidad en los ciclos de desarrollo de los sistemas CAA revisados [26], [30], [31]. Este dato sugiere que la incorporación de pruebas de accesibilidad como requisito de aceptación —en lugar de actividades *post-hoc*— es la intervención de mayor impacto en la calidad de accesibilidad del artefacto final, en consonancia con la recomendación central de Ara *et al.* [20].

V-E. Limitaciones del Estudio y Trabajo Futuro

El presente estudio presenta cuatro limitaciones que deben tenerse en cuenta al interpretar sus resultados.

La primera es el **tamaño muestral**: $n = 25$ participantes, si bien justificado por la especificidad clínica de los criterios de inclusión y el carácter proyectivo de la investigación [41], no permite generalizar los resultados a la diversidad de perfiles de discapacidad sensorial ni a otros contextos geográficos y culturales. La ampliación del estudio con muestras estratificadas por tipo de discapacidad y rango de edad es la línea de trabajo futuro de mayor prioridad para incrementar la generalizabilidad de los hallazgos.

La segunda limitación es la **latencia TTS**: con valores mínimos de 5.14 s, el sistema no alcanza aún el umbral conversacional de 2 s [8]. La optimización mediante modelos TTS no autorregresivos (FastSpeech2, VITS) ejecutados localmente en el dispositivo móvil, o mediante caché predictiva de segmentos de voz frecuentes, es la mejora técnica de mayor impacto identificada.

La tercera limitación es la **pantalla de mensajería con accesibilidad residual** (38.1 % de reducción vs. 100 % en otras pantallas), cuya causa es arquitectónica: el patrón de lista virtualizada en React Native genera identificadores de accesibilidad duplicados que ningún ciclo de mejora puede resolver sin refactorizar la arquitectura de identificadores únicos dinámicos por elemento.

La cuarta limitación es la **ausencia de reconocimiento de lenguaje de señas**, lo que excluye a usuarios sordos cuya lengua materna no es el español escrito sino la lengua de señas. La integración de un módulo RALS —como los

propuestos por Saleem *et al.* [27] y Kothadiya *et al.* [29]— es la extensión funcional más significativa para ampliar la cobertura del sistema a este colectivo.

V-F. Alineación con los Objetivos de Desarrollo Sostenible

Los resultados del presente trabajo se alinean con al menos dos de los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de las Naciones Unidas. En relación con el ODS 10 (Reducción de las Desigualdades), el sistema demuestra que la tecnología móvil con IA puede reducir las asimetrías comunicativas que marginan a 124,801 personas con discapacidades sensoriales en Ecuador —cifra que la OMS escala al 15 % de la población mundial [1]— de la comunicación digital autónoma. En relación con el ODS 9 (Industria, Innovación e Infraestructura), el sistema propone una arquitectura de microservicios desplegable sobre infraestructura híbrida de bajo coste (servidor institucional más instancia en nube), lo que reduce la barrera de adopción institucional en contextos de recursos limitados como el de la UTEQ. La compatibilidad entre accesibilidad, privacidad e infraestructura asequible que demuestra el sistema constituye un modelo de referencia transferible a otros contextos de inclusión digital en países en desarrollo.

VI. CONCLUSIÓN

Este artículo ha presentado el diseño, implementación y evaluación empírica de un sistema de mensajería móvil inclusiva potenciado por inteligencia artificial, concebido para atender simultáneamente los perfiles sensoriales visual, auditivo y del habla mediante la orquestación integrada de módulos TTS, STT, descripción automática de imágenes y OCR, con cifrado asimétrico de extremo a extremo y navegación completa por comandos de voz. Los hallazgos permiten formular cuatro conclusiones sustantivas y cinco líneas de investigación futura que avanzan el estado del arte en interacción hombre-máquina inclusiva.

La **primera conclusión** concierne a la viabilidad técnica de la integración multimodal con privacidad garantizada. Los cuatro módulos de conversión —TTS, STT, *image captioning* y vídeo— registraron tasa de error cero en la totalidad de las condiciones de prueba, con integridad de transmisión verificada en cada condición (diferencia entre tamaño de envío y respuesta inferior al 1 % en STT y al 0.2 % en vídeo). La coexistencia del flujo de conversión accesible con el cifrado asimétrico de extremo a extremo, sin degradar la tasa de error, demuestra por primera vez en la literatura de mensajería inclusiva que la privacidad y la accesibilidad no son objetivos en conflicto en una arquitectura móvil distribuida. La latencia TTS mínima de 5.14 s (SAPI5, texto corto) constituye la limitación técnica principal al superar el umbral conversacional de 2 s; su resolución mediante modelos TTS no autorregresivos o caché predictiva de segmentos representa la mejora de mayor urgencia para versiones futuras del sistema.

La **segunda conclusión** concierne a la aceptación tecnológica positiva en una población de discapacidad heterogénea. El cuestionario TAM de 12 ítems, aplicado a $n = 25$ participantes con discapacidades visuales, auditivas y del habla, produjo

una media global de $\bar{x} = 4,28$ ($DE = 0,95$), que supera el umbral de aceptación positiva $\bar{x} > 4,0$ establecido en la literatura para contextos de accesibilidad móvil [44]. El constructo de utilidad percibida alcanzó la media más alta del instrumento ($\bar{x}_{UP} = 4,56$), con el ítem de reducción del tiempo de comunicación (PTAM002: $\bar{x} = 4,76$; 84 % en nivel 5) como la aportación de mayor valor práctico percibida por la población destinataria. La curva de aprendizaje de la navegación por voz (PTAM007: $\bar{x} = 3,56$; $DE = 1,36$) y la brecha entre las expectativas de inclusión total y el estado actual del sistema (PTAM012: $\bar{x} = 3,48$) representan las dos dimensiones de mejora prioritarias desde la perspectiva del usuario. El bajo número de solicitudes de ayuda durante las sesiones de interacción libre (2 de 25 participantes, 8 %) confirma que la mayoría de los usuarios completan las tareas predefinidas de forma autónoma, lo que respalda la validez ecológica de los resultados del TAM.

La **tercera conclusión** concierne a la eficacia del ciclo iterativo de TDDM4IoT para la mejora sistemática de la accesibilidad. La aplicación de la metodología [11] con la accesibilidad como criterio de aceptación verificable desde la Fase 5 —anterior a la generación del código— produjo una reducción global del 64.0 % en advertencias WCAG 2.1 (de 75 a 27), con eliminación total en las pantallas de cámara y foto (100 %) y reducciones superiores al 70 % en configuraciones (77.8 %) y pantalla principal (81.8 %). Este resultado contrasta con las tasas de incumplimiento superiores al 60 % documentadas en las plataformas de mensajería comerciales de referencia [6] y valida que la incorporación de pruebas de accesibilidad como requisito formal de aceptación —en lugar de actividades *post-hoc*— es la intervención de mayor impacto en la calidad de accesibilidad del artefacto. La limitación residual en la pantalla de mensajería (38.1 %) responde a una causa arquitectónica identificada —identificadores de accesibilidad duplicados generados por el patrón de lista virtualizada de React Native— con protocolo de resolución definido, lo que la convierte en una deuda técnica trazable.

La **cuarta conclusión** concierne a la resolución de la fragmentación tecnológica documentada en la literatura. Los componentes de IA para la accesibilidad —TTS neuronal, STT basado en transformadores, *image captioning* y OCR— que la literatura ha desarrollado de forma aislada [8], [9], [37], [38], [40] son integrables en una arquitectura de mensajería móvil coherente, estable y con privacidad garantizada mediante infraestructura híbrida de bajo coste institucional. Esta integración, ausente en todos los sistemas revisados, establece un modelo de referencia transferible para el desarrollo de aplicaciones de comunicación inclusiva en contextos con restricciones de infraestructura, con implicaciones directas para el cumplimiento del ODS 10 (Reducción de Desigualdades) y el ODS 9 (Industria, Innovación e Infraestructura) de la Agenda 2030 de las Naciones Unidas.

Los hallazgos configuran cinco líneas de investigación futura de alta prioridad. La primera es la optimización de la latencia TTS mediante arquitecturas no autorregresivas —FastSpeech2 o VITS— ejecutadas localmente en el dispositivo móvil, o mediante caché predictiva de segmentos de voz basada en patrones de mensajería frecuentes, con el objetivo

de alcanzar el umbral conversacional de 2 s establecido en la literatura [8]. La segunda es el diseño de un flujo de *onboarding* accesible que incluya calibración personalizada de comandos de voz al perfil de disfluencia del usuario, siguiendo el paradigma de entrenamiento adaptativo de Costanzo *et al.* [30], para reducir la barrera de aprendizaje documentada en PTAM007. La tercera es la integración de reconocimiento de lenguaje de señas como modalidad adicional de entrada y salida, tomando como referentes los modelos LSTM–GRU de Kothadiya *et al.* [29] y los sistemas multilingües de Saleem *et al.* [27]. La cuarta es la refactorización arquitectónica de la pantalla de mensajería mediante identificadores de accesibilidad únicos dinámicos por elemento de lista, con el objetivo de eliminar las 13 advertencias residuales y elevar la satisfacción global del sistema (PTAM012: $\bar{x} = 3,48$). La quinta es la ampliación del estudio a muestras estratificadas por tipo de discapacidad, rango de edad y condiciones de conectividad móvil (redes 4G/LTE de bajo ancho de banda), para incrementar la generalizabilidad de los resultados e identificar factores de moderación de la aceptación tecnológica específicos a cada perfil sensorial.

AGRADECIMIENTOS

Los autores agradecen a la Universidad Técnica Estatal de Quevedo (UTEQ) por el apoyo técnico, financiero e institucional. De igual forma, expresan su gratitud a los 25 participantes del estudio, cuya colaboración fue fundamental para la validación empírica del sistema propuesto.

REFERENCIAS

- [1] World Health Organization and World Bank, *World Report on Disability*. Geneva, Switzerland: WHO Press, 2011. [Online]. Available: <https://www.who.int/publications/i/item/9789241564182>
- [2] V. Bercaru and N. Popescu, "A systematic review of accessibility techniques for online platforms: Current trends and challenges," *Applied Sciences*, vol. 14, no. 22, p. 10337, 2024.
- [3] P. Weichbroth, "Usability of mobile applications: A systematic literature study," *IEEE Access*, vol. 8, pp. 55 563–55 577, 2020.
- [4] M. F. Story, "Maximizing usability: The principles of universal design," in *Assistive Technology*, 1998, vol. 10, no. 1, pp. 4–12.
- [5] World Wide Web Consortium, "Web content accessibility guidelines (WCAG) 2.1," W3C, Tech. Rep., 2018, w3C Recommendation. [Online]. Available: <https://www.w3.org/TR/WCAG21/>
- [6] S. Chen, C. Chen, L. Fan, M. Fan, X. Zhan, and Y. Liu, "Accessible or not? an empirical investigation of android app accessibility," *IEEE Transactions on Software Engineering*, vol. 48, no. 10, pp. 3954–3968, 2022.
- [7] P. Acosta-Vargas, J. Guaña-Moya, J. Jadán-Guerrero, C. Alvites-Huamán, and L. Salvador-Ullauri, "Towards accessibility assessment with a combined approach for native mobile applications," in *Lecture Notes in Networks and Systems*, vol. 265. Springer, 2021, pp. 234–241.
- [8] X. Tan, T. Qin, F. Soong, and T. Liu, "A survey on neural speech synthesis," *arXiv preprint*, 2021, arXiv:2106.15561.
- [9] A. Baevski, Y. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, pp. 12 449–12 460.
- [10] P. Dognin, I. Melnyk, Y. Mroueh, I. Padhi, M. Rigotti, J. Ross, Y. Schiff, R. A. Young, and B. Belgodere, "Image captioning as an assistive technology: Lessons learned from vizwiz 2020 challenge," *Journal of Artificial Intelligence Research*, vol. 73, pp. 437–459, 2021.
- [11] G. Guerrero-Ulloa, M. J. Hornos, and C. Rodríguez-Domínguez, "TDDM4IoT: A test-driven development methodology for Internet of Things (IoT)-based systems," in *Communications in Computer and Information Science*, vol. 1193. Springer, 2020, pp. 41–55.
- [12] C. F. da Silva, S. B. L. Ferreira, and J. F. M. Ramos, "WhatsApp accessibility from the perspective of visually impaired people," in *Proceedings of the 15th Brazilian Symposium on Human Factors in Computing Systems*. ACM, 2016, pp. 1–10.
- [13] W. Zahida, V. Effendy, and A. Hadikusuma, "Improving messenger accessibility for elderly users using user centered design (UCD) methods (study case: WhatsApp)," in *2021 International Conference on Software Engineering & Computer Systems and 4th International Conference on Computational Science and Information Management (ICSECS-ICOCOSIM)*. IEEE, 2021, pp. 273–278.
- [14] M. A. Swati, T. M. Madni, U. I. Janjua, and I. Ahmad, "Accessibility of social media application for blinds," in *2021 4th International Conference on Computing and Information Sciences (ICCIS)*. IEEE, 2021, pp. 1–6.
- [15] R. Rumini and A. I. Astrid, "Evaluating the usability of heuristics within Telegram using the linear regression method," in *2019 4th International Conference on Information Technology, Information Systems and Electrical Engineering (ICITISEE)*. IEEE, 2019, pp. 469–473.
- [16] H. Kim, H. Hwang, S. Gwak, J. Yoon, and K. Park, "Improving communication and promoting social inclusion for hearing-impaired users: Usability evaluation and design recommendations for assistive mobile applications," *PLOS ONE*, vol. 19, no. 7, p. e0305726, 2024.
- [17] M. Ballantyne, A. Jha, A. Jacobsen, J. S. Hawker, and Y. N. El-Glaly, "Study of accessibility guidelines of mobile applications," in *Proceedings of the 17th International Conference on Mobile and Ubiquitous Multimedia*. ACM, 2018, pp. 305–315.
- [18] P. Acosta-Vargas, J. Guaña-Moya, J. Jadán-Guerrero, C. Alvites-Huamán, and L. Salvador-Ullauri, "Towards accessibility assessment with a combined approach for native mobile applications," in *Lecture Notes in Networks and Systems*, vol. 265. Springer, 2021, pp. 234–241.
- [19] M. Huang, G. McGrew, and C. Bodine, "Social media apps: A paradigm for examining usability of mobile apps for working-age adults with mild-moderate cognitive disabilities," *ACM Transactions on Accessible Computing*, vol. 18, no. 1, pp. 1–38, 2025.
- [20] J. Ara, C. Sik-Lanyi, and A. Kelemen, "Accessibility engineering in web evaluation process: A systematic literature review," *Universal Access in the Information Society*, vol. 23, no. 2, pp. 653–686, 2024.
- [21] Y. Elshahar, S. Hu, K. Bouazza-Marouf, D. Kerr, and A. Mansor, "Augmentative and alternative communication (AAC) advances: A review of configurations for individuals with a speech disability," *Sensors*, vol. 19, no. 8, p. 1911, 2019.
- [22] G. Guerrero-Ulloa, M. J. Hornos, and C. Rodríguez-Domínguez, "Bell-Chat: Una aplicación web inclusiva para personas con discapacidades visuales y auditivas," in *Proceedings of the XVI Multi-Conference on Computer Science and Information Systems*, 2021, ISBN: 978-989-758-534-0.
- [23] T. Stefanov, S. Varbanova, M. Stefanova, and I. Alinski, "Mobile app prototype supporting people with special needs," *TEM Journal*, pp. 1871–1880, 2024.
- [24] A. Yeratziotis, A. Achilleos, S. Koumou, G. Zampas, R. A. Thibodeau, G. Geratziotis, G. A. Papadopoulos, I. Iasonas, and C. Kronis, "Making social media applications inclusive for deaf end-users with access to sign language," *Multimedia Tools and Applications*, vol. 82, no. 29, pp. 46 185–46 215, 2023.
- [25] I. Chang, J. Castillo, and H. Montes, "Technology-based social innovation: Smart city inclusive system for hearing impairment and visual disability citizens," *Sensors*, vol. 22, no. 3, p. 848, 2022.
- [26] N. Janaka, J. Gao, L. Zhu, S. Zhao, L. Lyu, P. Xu, M. Nabokow, S. Wang, and Y. Ong, "GlassMessaging: Towards ubiquitous messaging using OHMDs," *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, vol. 7, no. 3, p. 100, 2023.
- [27] M. I. Saleem, A. Siddiqui, S. Noor, M.-A. Luque-Nieto, and P. Otero, "A novel machine learning based two-way communication system for deaf and mute," *Applied Sciences*, vol. 13, no. 1, p. 453, 2023.
- [28] M. Papatsimouli, P. Sarigiannidis, and G. F. Fragulis, "A survey of advancements in real-time sign language translators: Integration with IoT technology," *Technologies*, vol. 11, no. 4, p. 83, 2023.
- [29] D. Kothadiya, C. Bhatt, K. Sapariya, K. Patel, A.-B. Gil-González, and J. M. Corchado, "DeepSign: Sign language detection and recognition using deep learning," *Electronics*, vol. 11, no. 11, p. 1780, 2022.
- [30] F. Costanzo, E. Fucà, C. Caciolo, D. Ruà, S. Smolley, D. Weissberg, and S. Vicari, "Talkitt: Toward a new instrument based on artificial intelligence for augmentative and alternative communication in children with Down syndrome," *Frontiers in Psychology*, vol. 14, p. 1176683, 2023.
- [31] M. Mateos-Sanchez, A. Casado Melo, L. Sánchez Blanco, and A. M. Fermoso García, "Chatbot, as educational and inclusive tool for people

- with intellectual disabilities,” *Sustainability*, vol. 14, no. 3, p. 1520, 2022.
- [32] M. T. Tomczak, J. M. Szulc, and M. Szczerska, “Inclusive communication model supporting the employment cycle of individuals with autism spectrum disorders,” *International Journal of Environmental Research and Public Health*, vol. 18, no. 9, p. 4696, 2021.
 - [33] A. Bleakley, D. Rough, A. Roper, S. Lindsay, M. Porcheron, M. Lee, S. A. Nicholson, B. R. Cowan, and L. Clark, “Exploring smart speaker user experience for people who stammer,” in *Proceedings of the 24th International ACM SIGACCESS Conference on Computers and Accessibility (ASSETS)*. ACM, 2022, pp. 1–17.
 - [34] K. Chemnad and A. Othman, “Digital accessibility in the era of artificial intelligence—bibliometric analysis and systematic review,” *Frontiers in Artificial Intelligence*, vol. 7, p. 1349668, 2024.
 - [35] J. Madake, S. Bhatlawande, A. Solanke, and S. Shilaskar, “A qualitative and quantitative analysis of research in mobility technologies for visually impaired people,” *IEEE Access*, vol. 11, pp. 82 496–82 520, 2023.
 - [36] S. Ji, J. Zuo, M. Fang, Z. Jiang, F. Chen, X. Duan, B. Huai, and Z. Zhao, “TextrolSpeech: A text style control speech corpus with codec language text-to-speech models,” in *ICASSP 2024 – 2024 IEEE International Conference on Acoustics, Speech and Signal Processing*. IEEE, 2024, pp. 10 301–10 305.
 - [37] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” in *Proceedings of the 40th International Conference on Machine Learning (ICML)*, vol. 202. PMLR, 2023, pp. 28 492–28 518.
 - [38] Y. Ming, N. Hu, C. Fan, F. Feng, J. Zhou, and H. Yu, “Visuals to text: A comprehensive review on automatic image captioning,” *IEEE/CAA Journal of Automatica Sinica*, vol. 9, no. 8, pp. 1339–1365, 2022.
 - [39] K. M. Safiya and R. Pandian, “A real-time image captioning framework using computer vision to help the visually impaired,” *Multimedia Tools and Applications*, vol. 83, pp. 59 413–59 438, 2024.
 - [40] S. Mukherjee, H. Tyagi, P. Tyagi, N. Singh, and S. Bhardwaj, “OCR using Python and its application,” *Journal of Advanced Zoology*, vol. 44, no. S-3, pp. 1083–1092, 2023.
 - [41] R. Hernández Sampieri, C. Fernández Collado, and P. Baptista Lucio, *Metodología de la Investigación*, 6th ed. Mexico City, Mexico: McGraw-Hill Education, 2014.
 - [42] F. D. Davis, “Perceived usefulness, perceived ease of use, and user acceptance of information technology,” *MIS Quarterly*, vol. 13, no. 3, pp. 319–340, 1989.
 - [43] A. R. Lahitani, A. E. Permanasari, and N. A. Setiawan, “Cosine similarity to determine similarity measure: Study case in online essay assessment,” in *2016 4th International Conference on Cyber and IT Service Management*. IEEE, 2016, pp. 1–6.
 - [44] A. I. Julianto, H. A. D. Rimbawa, and Y. D. W. Asnar, “Study and analysis of end-to-end encryption message security using Diffie-Hellman key exchange encryption,” *International Journal of Progressive Sciences and Technologies*, vol. 42, no. 1, p. 173, 2023.
 - [45] World Medical Association, “Declaration of Helsinki: Ethical principles for medical research involving human subjects,” *JAMA*, vol. 310, no. 20, pp. 2191–2194, 2013.
 - [46] F. H. F. Botelho, “Accessibility to digital technology: Virtual barriers, real opportunities,” *Assistive Technology*, vol. 33, no. sup1, pp. 27–34, 2021.