

La brecha de medición del uso de la inteligencia artificial en educación

Protocolo de investigación para un estudio multinivel con elicitación indirecta en escuela, colegio y universidad

4 de agosto de 2026 — Versión 1.0

Resumen del protocolo

Este protocolo define un estudio transversal multinivel destinado a estimar la magnitud del desajuste entre el uso de inteligencia artificial generativa que los estudiantes declaran y el que efectivamente realizan, en tres niveles educativos de un mismo territorio: educación primaria (escuela), educación secundaria (colegio) y educación superior (universidad). El estudio incorpora un experimento de listas (*unmatched count technique*) embebido en la encuesta, lo que permite estimar la prevalencia de uso no declarado sin exigir acceso a registros institucionales de actividad. La contribución central no es descriptiva sino metodológica: se busca demostrar que las conclusiones sustantivas del campo sobre efectos pedagógicos de la IA dependen del instrumento de medición empleado, y que el sesgo de deseabilidad social varía sistemáticamente según el nivel educativo y el clima normativo de la institución.

Contenido

1	Planteamiento: el problema no es el uso, es la medición	3
2	Vacíos de conocimiento que este estudio aborda	3
3	Preguntas de investigación e hipótesis	4
3.1	Preguntas	4
3.2	Hipótesis	4
4	Marco teórico	4
5	Diseño metodológico	5
5.1	Tipo de diseño	5
5.2	Contexto y muestra	5
5.3	Capas de medición	5

5.4	Diseño de las listas	6
5.5	Adaptación por nivel educativo: una restricción que debe respetarse	6
5.6	Capa conductual: diseño oportunista	6
6	Plan de análisis	7
7	Consideraciones éticas	7
8	Riesgos y mitigaciones	9
9	Estrategia de publicación	9
10	Cronograma	9
11	Limitaciones anticipadas	9

1 Planteamiento: el problema no es el uso, es la medición

La literatura sobre inteligencia artificial generativa en educación se encuentra en un estado de saturación descriptiva. Existen decenas de revisiones sistemáticas que sintetizan efectos sobre rendimiento, motivación y compromiso, y prácticamente todas coinciden en un mismo señalamiento metodológico: la evidencia disponible se apoya de forma predominante en datos de autorreporte (Alfarwan, 2025). Ese señalamiento se ha repetido tantas veces que ha dejado de leerse como una limitación y ha pasado a leerse como una convención aceptada del campo.

El supuesto implícito de esa convención es que el autorreporte, aunque imperfecto, produce un error aleatorio y por tanto no compromete las inferencias. Ese supuesto es falso en este dominio específico. El uso de IA en tareas académicas es un comportamiento socialmente sancionado en la mayoría de las instituciones, y los comportamientos socialmente sancionados producen error sistemático, no aleatorio. La evidencia empírica reciente lo confirma con una magnitud que invalida buena parte de las estadísticas de adopción publicadas: en una encuesta a 338 estudiantes universitarios, aproximadamente el 60 % declaró usar IA mientras que el 90 % atribuyó ese uso a sus pares, y el análisis cualitativo de las explicaciones de los propios estudiantes identificó la deseabilidad social como el motor principal de esa discrepancia (Ling et al., 2026).

La consecuencia es de primer orden. Si el uso de IA está medido con error sistemático descendente, entonces todo estudio que lo emplee como variable independiente — para predecir rendimiento, autorregulación, pensamiento crítico o descarga metacognitiva — está estimando coeficientes sesgados por atenuación diferencial. Esto afecta directamente a la línea de investigación más activa del campo, que documenta que el apoyo de IA mejora el desempeño de corto plazo en la tarea pero puede inducir dependencia tecnológica y “pereza metacognitiva”, deteriorando la capacidad de autorregulación (Fan et al., 2025), y a los instrumentos que se están construyendo sobre esa base conceptual (Dizon et al., 2026).

2 Vacíos de conocimiento que este estudio aborda

1. **Vacío de estimación.** No existe una cuantificación de la brecha entre uso declarado y uso real que emplee técnicas de elicitación indirecta validadas en contextos educativos hispanohablantes. La única evidencia sólida disponible procede de un único campus universitario estadounidense (Ling et al., 2026), cuyos propios autores advierten que la magnitud y la dirección del error dependen del contexto normativo.
2. **Vacío de nivel educativo.** La investigación sobre IA generativa en educación escolar se concentra en secundaria y en profesorado en formación, con muy escasa producción sobre educación primaria (Alfarwan, 2025). No existe ningún estudio que estime la brecha de medición de forma comparable en primaria, secundaria y superior dentro de un mismo sistema educativo.
3. **Vacío psicométrico.** Las comparaciones de medias latentes entre grupos exigen invarianza escalar como precondition, y los instrumentos existentes de uso de IA no la han establecido. Cualquier comparación entre niveles educativos que omita esta verificación es interpretativamente inválida.

3 Preguntas de investigación e hipótesis

3.1 Preguntas

- PI 1 ¿Cuál es la magnitud de la brecha entre la prevalencia de uso de IA estimada por interrogación directa y la estimada por elicitación indirecta, en cada uno de los tres niveles educativos?
- PI 2 ¿Varía sistemáticamente esa brecha según el nivel educativo, el clima normativo institucional percibido y el rendimiento académico previo?
- PI 3 ¿Cambian las conclusiones sustantivas sobre la relación entre uso de IA y descarga metacognitiva cuando el predictor se mide por vía directa frente a la vía indirecta?

La PI 3 es la que confiere al estudio valor para una revista de alto impacto. Las dos primeras producen una estimación local; la tercera produce una advertencia metodológica generalizable a todo el campo.

3.2 Hipótesis

- H 1 La prevalencia estimada por elicitación indirecta será significativamente superior a la estimada por interrogación directa en los tres niveles.
- H 2 La brecha será mayor en instituciones con políticas prohibitivas explícitas que en instituciones con políticas permisivas o ambiguas, por incremento de la sanción social percibida.
- H 3 La brecha será mayor en niveles educativos con evaluación de mayor consecuencia (universidad y colegio) que en primaria.
- H 4 La asociación entre uso de IA y descarga metacognitiva será de mayor magnitud cuando el predictor se corrija por deseabilidad social, por reducción del sesgo de atenuación.

4 Marco teórico

El estudio articula tres cuerpos teóricos. El primero es la teoría del sesgo de deseabilidad social en investigación por encuesta, que establece que los encuestados subdeclaran comportamientos socialmente reprobados y sobredeclaran los socialmente valorados, y que fundamenta el desarrollo de técnicas de interrogación indirecta como alternativa a la pregunta directa (Coutts and Jann, 2011).

El segundo es la teoría de la descarga cognitiva y metacognitiva aplicada al aprendizaje asistido por IA, que sostiene que la delegación de procesos de monitoreo, evaluación y regulación a un agente externo reduce el compromiso cognitivo interno y, sostenida en el tiempo, deteriora la capacidad de autorregulación del aprendiz (Fan et al., 2025; Dizon et al., 2026). Este cuerpo aporta la variable dependiente sustantiva del estudio.

El tercero es el marco del clima normativo institucional, que permite tratar la política de IA de cada institución no como un dato de contexto sino como un moderador teóricamente relevante de la magnitud del sesgo de respuesta. Esta articulación es la que convierte el estudio en algo

distinto de una réplica: la brecha de medición se modela como un fenómeno con estructura, no como ruido.

5 Diseño metodológico

5.1 Tipo de diseño

Estudio transversal, comparativo entre niveles educativos, con un experimento de encuesta embebido de asignación aleatoria individual. El componente experimental es el experimento de listas o *unmatched count technique* (UCT), en el cual los participantes se asignan aleatoriamente a un grupo de control que recibe una lista de reactivos no sensibles y a un grupo de tratamiento que recibe la misma lista más el reactivo sensible, y en ambos casos se solicita únicamente el número total de reactivos aplicables, nunca cuáles (Hinsley et al., 2019).

5.2 Contexto y muestra

Tabla 1: Estructura de la muestra por nivel educativo.

Nivel	Rango etario	<i>N</i> objetivo	Rol en el diseño
Universidad	18 años o más	600	Núcleo inferencial; brazo UCT completo
Colegio (secundaria)	13–17 años	600	Núcleo inferencial; brazo UCT completo
Escuela (primaria)	9–12 años	300	Componente descriptivo; sin brazo UCT

El tamaño muestral responde a una restricción específica del método: el estimador de diferencia de medias del UCT genera intervalos de confianza sensiblemente más anchos que los de una pregunta directa, por lo que requiere muestras considerablemente mayores para alcanzar la misma precisión (Hinsley et al., 2019). Las cifras de la tabla constituyen un objetivo preliminar que debe confirmarse mediante simulación de potencia antes del trabajo de campo, asumiendo una prevalencia declarada base del 60 % y una brecha mínima detectable de 15 puntos porcentuales.

5.3 Capas de medición

Tabla 2: Operacionalización del constructo “uso de IA” en capas independientes.

Capa	Instrumento	Constructo capturado
Capa 1	Autorreporte directo de frecuencia y tipo de uso	Uso declarado
Capa 2a	Estimación del uso de los pares	Norma percibida; indicador indirecto de sub-declaración
Capa 2b	Experimento de listas (UCT)	Prevalencia corregida por deseabilidad social
Capa 3	Corroboración conductual oportunist	Uso observado (opcional; véase § 5.6)

La inclusión simultánea de la pregunta directa y del experimento de listas no es redundante: permite ejecutar las pruebas de placebo que verifican los supuestos identificadores del método,

en particular la ausencia de efectos de diseño y la ignorabilidad de la asignación al tratamiento (Imai, 2011).

5.4 Diseño de las listas

La construcción de las listas sigue tres reglas derivadas de las guías de buena práctica del método (Hinsley et al., 2019): los reactivos no sensibles deben ser temáticamente próximos pero no correlacionados entre sí; la lista debe incluir al menos un reactivo de prevalencia alta y uno de prevalencia baja para evitar efectos de techo y de piso; y el número de reactivos no debe exceder cinco para no comprometer la carga cognitiva de la tarea.

Tabla 3: Ejemplo de lista para el nivel universitario (versión a pilotear).

Grupo	Reactivos presentados
Control	(1) He entregado un trabajo después de la fecha límite. (2) He utilizado un traductor automático para una tarea. (3) He estudiado a partir de apuntes de un compañero. (4) He cursado una asignatura completa sin comprar el libro de texto.
Tratamiento	Los cuatro reactivos anteriores más: (5) He entregado como propio un texto generado sustancialmente por una herramienta de IA sin declararlo.

5.5 Adaptación por nivel educativo: una restricción que debe respetarse

La tarea del UCT exige que el participante comprenda que informar un total no revela cuáles reactivos aplican. Esa comprensión metarrepresentacional no puede asumirse por debajo de los trece años aproximadamente, y su ausencia produce estimaciones no interpretables en lugar de estimaciones sesgadas. Por esa razón el brazo UCT se restringe a colegio y universidad.

Para el nivel de escuela primaria se sustituye por tres fuentes convergentes: autorreporte directo con formato simplificado y vocabulario adaptado, estimación del uso de los compañeros de clase, e informe docente sobre uso observado en el aula. Este componente se reporta como descriptivo y como generador de hipótesis, y se declara explícitamente como tal en el manuscrito. Presentarlo de otro modo constituiría exactamente el tipo de sobreextensión inferencial que el estudio pretende denunciar.

5.6 Capa conductual: diseño oportunista

Dado que el acceso a registros institucionales de actividad aún debe negociarse, la capa conductual se diseña como componente opcional y no como dependencia crítica. Si la negociación prospera, se incorporarán registros agregados de la plataforma institucional o donaciones voluntarias de historiales de conversación bajo consentimiento específico. Si no prospera, el estudio conserva íntegra su validez, porque la contribución central descansa en el contraste entre las capas 1 y 2. Esta decisión de arquitectura es deliberada: elimina el principal riesgo de inviabilidad del proyecto.

6 Plan de análisis

1. **Estimación de prevalencia.** Estimador de diferencia de medias entre grupo de tratamiento y grupo de control para obtener la prevalencia del reactivo sensible en cada nivel, con intervalos de confianza por *bootstrap*.
2. **Pruebas de supuestos.** Verificación de ausencia de efectos de diseño mediante comparación de las distribuciones de conteo, y pruebas de placebo no paramétricas aprovechando la pregunta directa (Imai, 2011).
3. **Modelado multivariante.** Regresión no lineal para el UCT según el estimador de Imai (2011), con nivel educativo, clima normativo, sexo, rendimiento previo y alfabetización en IA como covariables.
4. **Brecha como variable dependiente.** Modelado de la diferencia entre estimación indirecta y estimación directa por institución, con clima normativo como predictor principal.
5. **Invarianza de medición.** Análisis factorial confirmatorio multigrupo con contraste secuencial configural, métrico y escalar entre colegio y universidad, como precondition para cualquier comparación de medias latentes.
6. **Análisis de consecuencia sustantiva.** Reestimación del modelo uso de IA → descarga metacognitiva con el predictor medido de ambas formas, y contraste formal de la diferencia entre coeficientes.

Todo el análisis se preinscribirá en un repositorio público antes de la recolección de datos, con especificación previa de las reglas de decisión. En un estudio cuya tesis es que el campo mide mal, la preinscripción no es un adorno metodológico sino un requisito de coherencia argumental.

7 Consideraciones éticas

El estudio involucra menores de edad en dos de los tres niveles, lo que exige aprobación de comité de ética institucional, consentimiento informado de padres o tutores y asentimiento del menor documentado por separado. El instrumento indaga sobre un comportamiento potencialmente sancionable por reglamento institucional, por lo que la protección del participante es una obligación estructural del diseño, no un trámite: el UCT se selecciona precisamente porque hace imposible atribuir el comportamiento sensible a un individuo concreto.

Se establecen tres garantías adicionales. Ningún dato se compartirá con las instituciones en forma desagregada ni permitirá identificar cursos con menos de treinta respondientes. Ningún resultado se comunicará de manera que pueda fundamentar sanciones disciplinarias. Y el reporte institucional se limitará a estimaciones agregadas acompañadas de recomendaciones de política, nunca de listados.

Tabla 4: Riesgos principales del proyecto y estrategias de mitigación.

Riesgo	Mitigación
El UCT no reduce el sesgo, resultado documentado en parte de la literatura	Incorporar pregunta directa y pruebas de placebo; preinscribir el hallazgo nulo como resultado publicable
Muestra insuficiente para la precisión requerida	Simulación de potencia previa; muestreo por conglomerados con aulas completas
Denegación de acceso institucional	Capa conductual diseñada como opcional; el núcleo inferencial no depende de ella
Falta de comparabilidad entre niveles	Contraste formal de invarianza escalar antes de comparar medias latentes
Sesgo de selección por autoselección voluntaria	Aplicación en horario de clase con tasa de respuesta documentada por aula

Tabla 5: Revistas objetivo, en orden de prioridad.

Revista	Posición	Argumento de ajuste
<i>Computers & Education</i>	Q1	Contribución transversal a la comunidad educativa, no restringida a una asignatura
<i>British Journal of Educational Technology</i>	Q1	Cubre el rango completo de educación y formación; sede del debate sobre descarga metacognitiva
<i>Int. Journal of Educational Technology in Higher Education</i>	Q1, acceso abierto	Alta visibilidad y decisión editorial rápida; verificar cargo por procesamiento
<i>Education and Information Technologies</i>	Q1–Q2	Alternativa realista con buena aceptación de estudios multinivel

8 Riesgos y mitigaciones

9 Estrategia de publicación

Los cuartiles y factores de impacto deben verificarse en la edición vigente del *Journal Citation Reports* antes de la decisión final, dado que numerosas fuentes secundarias difunden métricas desactualizadas. Se recomienda que, una vez elegida la revista, las referencias del manuscrito privilegien trabajos publicados en ella, conforme a la política editorial del proyecto.

10 Cronograma

Tabla 6: Cronograma estimado.

Mes	Actividad	Producto
1–2	Revisión focalizada y preinscripción	Protocolo registrado
2–3	Construcción y pilotaje cognitivo de listas	Instrumento validado
3–4	Aprobación ética y acuerdos institucionales	Dictamen y convenios
4–6	Trabajo de campo en los tres niveles	Base de datos
6–8	Análisis y verificación de supuestos	Resultados
8–10	Redacción y envío	Manuscrito

11 Limitaciones anticipadas

El diseño es transversal y por tanto no permite inferencia causal sobre la evolución del uso ni sobre sus efectos. La elicitación indirecta reduce pero no elimina el sesgo de deseabilidad social, y existe evidencia de que su desempeño varía según el modo de administración y el contexto (Coutts and Jann, 2011; Hinsley et al., 2019). El componente de educación primaria carece de brazo experimental y no admite comparación inferencial con los otros dos niveles. Finalmente, la validez externa está acotada a un sistema educativo particular, lo que hace de la replicación multiterritorial la extensión natural del proyecto.

Referencias

- Alfarwan, A. (2025). Generative AI use in K-12 education: A systematic review. *Frontiers in Education*, 10:1647573.
- Coutts, E. and Jann, B. (2011). Sensitive questions in online surveys: Experimental results for the randomized response technique (RRT) and the unmatched count technique (UCT). *Sociological Methods & Research*, 40(1):169–193.
- Dizon, J. I. W. T., Mendoza, N. B., Gasevic, D., and Ganotice, F. A. (2026). Assessing AI-driven metacognitive offloading: Initial development and validation of the Metacognitive Laziness Scale. *ECNU Review of Education*, 9(2):1–12.
- Fan, Y., Tang, L., Le, H., Shen, K., Tan, S., Zhao, Y., Shen, Y., Li, X., and Gašević, D. (2025). Beware of metacognitive laziness: Effects of generative artificial intelligence on learning motivation, processes, and performance. *British Journal of Educational Technology*, 56(2):489–530.
- Hinsley, A., Keane, A., St. John, F. A. V., Ibbett, H., and Nuno, A. (2019). Asking sensitive questions using the unmatched count technique: Applications and guidelines for conservation. *Methods in Ecology and Evolution*, 10:308–319.
- Imai, K. (2011). Multivariate regression analysis for the item count technique. *Journal of the American Statistical Association*, 106(494):407–416.
- Ling, Y., Kale, A., and Imas, A. (2026). Underreporting of AI use: The role of social desirability bias. In *Proceedings of the 2026 CHI Conference on Human Factors in Computing Systems*, New York, NY, USA. Association for Computing Machinery.