

UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO
Facultad de Ciencias de la Computación — Carrera de Software

PROTOCOLO DE INVESTIGACIÓN

Descarga cognitiva con inteligencia artificial generativa en la escritura académica

Calidad del texto, retención del aprendizaje y detectabilidad experta: un
estudio aleatorizado multi-sitio

Investigador principal

Ing. Gleiston Cicerón Guerrero Ulloa, PhD.

Versión del protocolo

Versión 1.0 — documento previo al registro y a la recolección de datos

Quevedo, Ecuador

Índice general

1. Presentación del protocolo	1
1.1. Qué problema aborda este estudio	1
1.2. Tres aportaciones que este diseño permite reclamar	1
1.3. Cómo leer este documento	2
2. Marco teórico e hipótesis	3
2.1. Cuatro mecanismos que explican lo que esperamos observar	3
2.1.1. Delegar el trabajo mental a una herramienta externa (descarga cognitiva)	3
2.1.2. Lo que cuesta más se aprende mejor (dificultades deseables)	3
2.1.3. Producir es recordar (efecto de generación)	3
2.1.4. Confundir facilidad con dominio (ilusiones metacognitivas de fluidez)	3
2.2. Preguntas de investigación	4
2.3. Hipótesis	4
3. Diseño experimental	6
3.1. Tipo de diseño	6
3.2. Los tres grupos	6
3.3. Participantes y criterios de elegibilidad	6
3.4. Procedimiento de asignación aleatoria equilibrada	7
3.5. Condiciones de administración	7
3.6. Rotación de los temas entre grupos	7
3.7. Verificación previa de la dificultad de los temas	8
3.8. Unidad de análisis	9
3.9. Estructura del estudio: campus, carreras e instituciones	9
3.9.1. Campus y carreras dentro de la UTEQ	9
3.9.2. Incorporación de instituciones externas	10
3.9.3. Distribución de los participantes	10
4. Variables e instrumentos	11
4.1. Mapa general de variables	11
4.2. Calidad del manuscrito	11

4.3. Acuerdo entre evaluadores	12
4.4. Retención y transferencia	12
4.5. Esfuerzo mental y carga de trabajo	12
4.6. Calibración metacognitiva	13
4.7. Integridad de las referencias citadas	13
4.8. Datos de proceso	13
4.9. Subestudio de detección experta	14
4.9.1. Sensibilidad y especificidad	14
4.9.2. Discriminación y criterio de decisión	14
4.9.3. Curva ROC y área bajo la curva (AUC)	15
5. Plan de análisis estadístico	16
5.1. Preparación de los datos	16
5.2. Modelo principal	16
5.3. Contraste principal de retención	17
5.4. Pruebas de equivalencia	17
5.5. Análisis de mediación	17
5.6. Análisis del subestudio de detección	17
5.7. Tamaños de efecto y presentación de resultados	18
5.8. Datos faltantes	18
5.9. Programas	18
6. Tamaño muestral y potencia	19
6.1. Qué significa el tamaño del efecto	19
6.2. Procedimiento de cálculo	19
6.3. Meta de reclutamiento	19
7. Ética, ciencia abierta y gestión de datos	20
7.1. Aprobación ética y consentimiento	20
7.2. Separación respecto de la calificación del curso	20
7.3. Protección de datos	20
7.4. Registro previo del estudio	20
7.5. Materiales abiertos	21
8. Cronograma y viabilidad	22

9. Limitaciones y estrategia de publicación	23
9.1. Limitaciones anticipadas y cómo se abordan	23
9.2. Ajuste al perfil editorial	23
A. Consentimiento informado	24
1. Datos de identificación del participante	24
2. En qué consiste este estudio	24
3. Qué implica su participación	24
4. Qué datos se recogen	25
5. Autorización para solicitar su rendimiento académico previo	25
6. Efecto sobre sus calificaciones	25
7. Confidencialidad y protección de sus datos	25
8. Carácter voluntario y derecho de retiro	26
9. Riesgos, beneficios e información final	26
10. A quién dirigirse	26
11. Declaración del participante	26
B. Rúbrica analítica de calidad del manuscrito	27
C1. Calidad de la tesis y de la argumentación	27
C2. Uso e integración de la evidencia	27
C3. Precisión conceptual y dominio del contenido	28
C4. Estructura, coherencia y claridad expositiva	28
C5. Originalidad y voz propia	29
C. Formulario del revisor	30
Sección 1. Puntuación por criterio	30
Sección 2. Recomendación editorial simulada	30
Sección 3. Juicio sobre el origen del texto	30
D. Ficha de predicción de calificación	32
E. Escala de esfuerzo mental	33
F. Cuestionario de carga de trabajo NASA-TLX	34
G. Estructura de la prueba diferida	35

H. Plantilla de verificación de referencias	36
I. Registro de proceso y de interacción con la herramienta	37
J. Ficha de línea base	38
K. Guión de administración de la sesión	39
Referencias	40

CAPÍTULO 1

Presentación del protocolo

1.1 Qué problema aborda este estudio

La incorporación de la inteligencia artificial generativa a la escritura académica plantea una pregunta que las encuestas de percepción no pueden responder: cuando un estudiante delega en una herramienta generativa la elaboración de un texto, obtiene un producto de mejor apariencia, pero ¿conserva el conocimiento que habría construido al escribirlo por su cuenta? La distinción importa porque el rendimiento inmediato y el aprendizaje duradero no son la misma cosa, y las condiciones que mejoran el primero con frecuencia deterioran el segundo (Bjork et al., 2013).

Este protocolo describe un experimento diseñado para responder esa pregunta con evidencia causal, no correlacional. El estudio compara el desempeño de estudiantes universitarios que escriben con asistencia de inteligencia artificial generativa frente a quienes escriben sin ella, mide lo que retienen semanas después, registra el esfuerzo mental que invirtieron, contrasta la confianza que declaran con su desempeño real y, finalmente, somete todos los textos al juicio ciego de revisores con experiencia editorial en revistas indexadas.

1.2 Tres aportaciones que este diseño permite reclamar

Primera: evidencia causal sobre retención, no sobre percepción. La literatura acumula estudios de aceptación y de satisfacción, y las síntesis disponibles señalan que la asistencia generativa mejora el desempeño inmediato y reduce el esfuerzo mental percibido (Deng et al., 2024). Lo que aún falta es determinar qué ocurre cuando la herramienta se retira. El presente diseño incorpora un grupo de control que nunca utiliza la herramienta, lo que hace posible aislar ese efecto.

Segunda: la brecha entre confianza y competencia. El estudio mide, para cada estudiante y en cada sesión, la calificación que anticipa y la que realmente obtiene. Esa diferencia permite cuantificar si la fluidez del texto producido con asistencia genera una sensación de dominio que los resultados no respaldan.

Tercera: la capacidad real de detección de revisores expertos. Como el equipo investigador conoce con certeza qué textos se produjeron con asistencia generativa y cuáles no, es posible calcular con precisión cuántos aciertos y cuántos errores comete un revisor experimentado al emitir ese juicio. La evidencia disponible sugiere que la combinación de juicio académico y software detector dista de ser fiable (Perkins et al., 2024), y este estudio aporta una medición rigurosa con verdad de base conocida.

1.3 Cómo leer este documento

El capítulo 2 presenta el marco teórico y enuncia las hipótesis una por una. El capítulo 3 detalla la estructura experimental y los procedimientos de asignación, contrabalanceo y administración. El capítulo 4 define cada variable y remite al anexo con el instrumento correspondiente, listo para aplicar. El capítulo 5 especifica el plan de análisis, y el capítulo 6 el cálculo del tamaño muestral. Los capítulos finales cubren ética, ciencia abierta, cronograma, limitaciones y estrategia de publicación. Los anexos contienen todos los formularios en formato aplicable.

Cada término técnico se introduce primero en lenguaje llano y se acompaña del nombre especializado entre paréntesis, seguido del procedimiento concreto con el que se obtiene.

CAPÍTULO 2

Marco teórico e hipótesis

2.1 Cuatro mecanismos que explican lo que esperamos observar

2.1.1 Delegar el trabajo mental a una herramienta externa (descarga cognitiva)

Las personas reducen sistemáticamente la carga de una tarea trasladando parte del procesamiento a recursos externos: una libreta, una calculadora, un buscador o, ahora, un modelo generativo (Risko and Gilbert, 2016). La descarga cognitiva es adaptativa y con frecuencia deseable, pero tiene un costo característico: aquello que se delega tiende a no quedar codificado en la memoria de quien delega. Este es el mecanismo central del estudio y explica por qué esperamos disociación entre calidad del producto y retención del contenido.

2.1.2 Lo que cuesta más se aprende mejor (dificultades deseables)

Determinadas condiciones vuelven el aprendizaje más lento y trabajoso en el momento y, precisamente por ello, producen mejor retención y mejor transferencia a largo plazo (Bjork et al., 2013). La asistencia generativa elimina buena parte de esas dificultades: suprime la búsqueda del argumento, la formulación tentativa y la reescritura. La predicción que se deriva es directa: mejor desempeño inmediato, peor desempeño diferido.

2.1.3 Producir es recordar (efecto de generación)

La información que una persona produce por sí misma se recuerda mejor que la información equivalente que simplemente lee (Slamecka and Graf, 1978). Escribir un argumento propio deja huella en la memoria; revisar un argumento ya redactado por un tercero, mucho menos. Este mecanismo justifica que la variable dependiente no sea solo el texto entregado, sino también el conocimiento evaluado semanas después sin acceso a materiales.

2.1.4 Confundir facilidad con dominio (ilusiones metacognitivas de fluidez)

Cuando una tarea se experimenta como fácil y fluida, las personas interpretan esa fluidez como evidencia de haber aprendido, y ajustan a la baja el esfuerzo posterior (Bjork et al., 2013). Un texto generativo produce prosa pulida sin fricción aparente, de modo que cabe esperar una sobreestimación sistemática del propio desempeño. Esta es la base de la medida de calibración descrita en la sección 4.6.

2.2 Preguntas de investigación

- PI1.** ¿Difiere la calidad de un texto académico producido con asistencia de inteligencia artificial generativa respecto de uno producido sin ella, cuando ambos se juzgan a ciegas con la misma rúbrica?
- PI2.** ¿Se deteriora el desempeño autónomo posterior de quienes escribieron previamente con asistencia generativa, cuando deben producir un texto sin ninguna herramienta de IA?
- PI3.** ¿Se traduce el uso previo de asistencia generativa en menor retención y menor transferencia del contenido trabajado, evaluadas semanas después?
- PI4.** ¿Modifica la asistencia generativa el esfuerzo mental invertido y la precisión con la que el estudiante juzga su propio desempeño?
- PI5.** ¿Con qué exactitud identifican revisores con experiencia editorial los textos producidos con asistencia generativa, y a qué costo en acusaciones erróneas?

2.3 Hipótesis

Cada hipótesis se enuncia con dirección explícita, se asocia a una variable operacionalizada y se contrasta con una prueba definida de antemano. Se registran antes de recolectar cualquier dato, siguiendo la lógica de separación entre predicción y análisis exploratorio (Nosek et al., 2018).

- H1.** En las sesiones con herramienta disponible, los textos producidos con asistencia generativa obtendrán puntuaciones de calidad iguales o superiores a los producidos sin ella. Si la diferencia no resulta significativa, se aplicará una prueba de equivalencia para sostener que ambas condiciones producen calidad comparable, y no meramente que no se halló diferencia.
- H2.** En la sesión final, realizada por todos los participantes sin ninguna herramienta de IA, el grupo con uso sostenido previo obtendrá puntuaciones de calidad inferiores al grupo de control que nunca utilizó la herramienta.
- H3.** En la prueba diferida a libro cerrado, el grupo con uso sostenido previo obtendrá menor puntuación que el grupo de control, tanto en preguntas de recuerdo como, con mayor magnitud, en preguntas de transferencia.
- H4.** El esfuerzo mental reportado será menor en las sesiones realizadas con asistencia generativa que en las realizadas sin ella.
- H5.** La sobreestimación del propio desempeño será mayor en las sesiones realizadas con asistencia generativa, medida como diferencia con signo entre calificación anticipada y obtenida.
- H6.** La relación entre la condición experimental y el desempeño diferido estará mediada por el esfuerzo mental invertido durante las sesiones de producción: a menor esfuerzo invertido, menor retención posterior.
- H7.** El grupo con exposición intermedia a la herramienta obtendrá resultados de retención situados entre el grupo de uso sostenido y el grupo de control, configurando un patrón de dosis y respuesta.

- H8.** Los revisores expertos discriminarán los textos asistidos por encima del azar, pero su exactitud global quedará por debajo del umbral exigible para fundamentar decisiones sancionatorias, y la proporción de textos humanos erróneamente señalados no será despreciable.
- H9.** La proporción de referencias bibliográficas no verificables será mayor en los textos producidos con asistencia generativa.

CAPÍTULO 3

Diseño experimental

3.1 Tipo de diseño

El estudio es un experimento aleatorizado con tres grupos y medidas repetidas (diseño mixto: el factor grupo varía entre participantes y el factor sesión varía dentro de cada participante). La asignación de cada estudiante a su grupo se realiza por sorteo, lo que permite atribuir causalmente las diferencias observadas a la condición experimental y no a características previas de los participantes.

En la literatura metodológica cada grupo de un experimento se denomina *brazo*. En este documento se emplea la palabra *grupo* por claridad, y se señala aquí la equivalencia para facilitar la lectura de la bibliografía especializada.

3.2 Los tres grupos

Tabla 3.1. Estructura de los tres grupos a lo largo de las tres sesiones de producción.

Grupo	Sesión 1	Sesión 2	Sesión 3
A — Uso sostenido	Con IAGen	Con IAGen	Sin IA
B — Control puro	Sin IA	Sin IA	Sin IA
C — Alternado	Con IAGen	Sin IA	Sin IA

El grupo B es el elemento que confiere validez al estudio. Sin un grupo que nunca utilice la herramienta, en la sesión final todos los participantes compartirían la misma historia de exposición y la comparación quedaría vacía: solo podría contrastarse el orden de las condiciones, no su presencia o ausencia. Con el grupo B, la comparación A frente a B en la sesión 3 constituye la prueba causal principal de la hipótesis H2, y el grupo C aporta el término intermedio que permite examinar si el efecto crece con la dosis de exposición.

3.3 Participantes y criterios de elegibilidad

Participan estudiantes de tercer nivel de carreras de computación y de áreas afines. Se incluye a quienes estén matriculados en las asignaturas participantes, otorguen consentimiento informado y asistan a la sesión de línea base. Se excluye a quienes no completen al menos dos de las tres sesiones de producción, y se registra como abandono a quienes no se presenten a la prueba diferida, sin eliminar sus datos previos del análisis.

3.4 Procedimiento de asignación aleatoria equilibrada

La asignación aleatoria estratificada consiste en sortear a cada estudiante hacia un grupo, uno por uno, garantizando que los tres grupos queden equilibrados en aquellas características que podrían influir en el resultado. El procedimiento es el siguiente:

- Paso 1.** Dos semanas antes de la primera sesión, todos los participantes redactan en clase un texto argumentativo breve de 500 palabras sobre un tema común, sin acceso a ninguna herramienta. Ese texto se califica con la rúbrica del Anexo B y constituye la **calificación de partida** (línea base).
- Paso 2.** Se registra también el promedio acumulado del estudiante y su nivel de uso previo de herramientas generativas, recogido con la ficha del Anexo J. El promedio acumulado se solicita a las autoridades de cada institución únicamente respecto de los participantes que lo hayan autorizado de forma expresa en el consentimiento informado; para quienes no otorguen esa autorización, la estratificación se realiza solo con la calificación de partida, sin que ello afecte su participación en el estudio.
- Paso 3.** Se ordena a los participantes según una puntuación combinada de calificación de partida y promedio acumulado, y se los divide en tres bloques de igual tamaño: tercio superior, intermedio e inferior. Cada bloque constituye un **estrato**.
- Paso 4.** Dentro de cada estrato se sortea la asignación a los grupos A, B y C mediante una semilla aleatoria fija y documentada, generada con el programa estadístico R. La semilla se declara en el registro previo del estudio, de modo que la asignación sea reproducible por terceros.
- Paso 5.** Una persona ajena al equipo de aplicación custodia la tabla de asignación y entrega a cada aplicador únicamente la lista de la sesión que le corresponde administrar.

Este procedimiento evita que un grupo quede accidentalmente compuesto por los mejores escritores, que es la primera objeción que un revisor plantea ante un experimento educativo.

3.5 Condiciones de administración

Todos los participantes reciben el material de trabajo **el mismo día de la sesión**, en el momento de iniciarla. No existe entrega anticipada para ningún grupo. Esta decisión es deliberada y responde a un requisito de validez interna: si un grupo dispusiera del material con anticipación y otro no, el tiempo de preparación quedaría mezclado con la herramienta utilizada, y ante cualquier diferencia observada sería imposible determinar cuál de las dos causas la produjo. Al igualar el acceso al material, la única diferencia sistemática entre grupos es la herramienta, que es exactamente lo que el estudio pretende evaluar.

3.6 Rotación de los temas entre grupos

Cada sesión trabaja un tema distinto. Si todos los grupos abordaran los temas en el mismo orden, la dificultad propia de cada tema quedaría confundida con el momento de la sesión, y una caída en la sesión 3 podría deberse tanto a la ausencia de la herramienta como a que ese

Tabla 3.2. Condiciones idénticas para todos los grupos en cada sesión de producción.

Elemento	Especificación
Entrega del material	El mismo día, al inicio de la sesión, para los tres grupos
Lugar	Laboratorio de cómputo supervisado, con grupos en salas separadas
Duración	120 minutos de reloj, idénticos para todos
Material de referencia	El mismo conjunto de artículos científicos para todos los grupos
Producto solicitado	Ensayo argumentativo de 1200 a 1500 palabras, con referencias
Condición sin IA	Procesador de texto sin conexión, sin acceso a servicios de IA
Condición con IAGen	Acceso a una herramienta generativa designada, con registro obligatorio de la conversación completa
Control de contaminación	Dispositivos institucionales, navegación restringida por perfil y declaración de honor firmada

tema era simplemente más difícil. El contrabalanceo mediante **cuadrado latino** resuelve ese problema: se construye una tabla en la que cada tema aparece exactamente una vez en cada sesión y una vez en cada grupo.

Tabla 3.3. Rotación de temas en cuadrado latino. Cada tema ocupa una sola vez cada posición temporal y cada grupo.

Grupo	Sesión 1	Sesión 2	Sesión 3
A	Tema X	Tema Y	Tema Z
B	Tema Y	Tema Z	Tema X
C	Tema Z	Tema X	Tema Y

3.7 Verificación previa de la dificultad de los temas

Antes de fijar los tres temas definitivos se ejecuta un estudio piloto de dificultad con el siguiente procedimiento: se seleccionan seis temas candidatos del ámbito disciplinar; ocho docentes del área califican cada uno de 1 a 10 en dificultad conceptual, disponibilidad de fuentes en acceso abierto y familiaridad esperada del estudiantado; un grupo reducido de estudiantes que no participará en el experimento redacta un esquema breve sobre dos temas al azar, y se cronometra el tiempo empleado. Se retienen los tres temas cuyas puntuaciones medias resulten más próximas entre sí, y la tabla completa de puntuaciones se reporta en el artículo como evidencia de equiparación.

3.8 Unidad de análisis

La unidad de análisis es el **estudiante**, no el equipo. Cada participante entrega un texto individual en cada sesión y responde individualmente todos los instrumentos. Esta decisión es determinante para la viabilidad estadística: si el producto fuera colectivo, con doce equipos el número real de casos sería doce y el estudio carecería de capacidad para detectar cualquier efecto, por grande que fuese.

3.9 Estructura del estudio: campus, carreras e instituciones

El estudio se despliega en tres niveles anidados que conviene distinguir con precisión, porque cumplen funciones metodológicas distintas y no son intercambiables entre sí.

Tabla 3.4. Niveles de la estructura del estudio y función de cada uno.

Nivel	Contenido previsto	Función metodológica
Institución	UTEQ y las universidades nacionales y extranjeras que se incorporen mediante convenio	Sustenta la generalización de los hallazgos más allá de una sola institución
Campus	Campus central “Manuel Haz Álvarez” y campus “La María”	Aporta variación de contexto dentro de una misma institución; actúa como factor de bloqueo
Carrera	Carreras participantes en cada campus	Aporta variación disciplinar; actúa como factor de bloqueo y de agrupamiento

3.9.1 Campus y carreras dentro de la UTEQ

En la Universidad Técnica Estatal de Quevedo el estudio se ejecuta con estudiantes de distintas carreras distribuidas entre el campus central “Manuel Haz Álvarez” y el campus “La María”. Esta distribución aporta variación real de contexto formativo y disciplinar, y permite comprobar si el efecto observado se mantiene en poblaciones estudiantiles con perfiles distintos.

Conviene, no obstante, precisar el alcance de esa variación. Dos campus de una misma universidad comparten normativa académica, calendario, plantilla docente en buena parte y criterios de admisión, de modo que **no constituyen dos instituciones a efectos de replicación**. El campus y la carrera fortalecen la validez interna del estudio, porque permiten verificar que el efecto no depende de un contexto particular, pero no sustituyen la incorporación de instituciones externas, que es lo que sostiene el argumento de generalización ante una revista de primer nivel. El protocolo trata ambos elementos como complementarios y no como alternativos.

3.9.2 Incorporación de instituciones externas

Se gestionará la colaboración de otras universidades, nacionales y extranjeras, mediante convenio específico. Cada institución que se incorpore aplica el protocolo, la rúbrica, los temas, la guía del estudiante y el cronograma sin modificación alguna, obtiene la aprobación de su propio comité de ética y designa un coordinador responsable de la fidelidad de la aplicación. La incorporación de al menos una institución extranjera es especialmente valiosa, porque añade variación de sistema educativo y de contexto lingüístico-académico, y convierte los hallazgos en evidencia transcultural.

3.9.3 Distribución de los participantes

Cada institución, cada campus y cada carrera aportan estudiantes a los tres grupos. El sorteo descrito en la sección 3.4 se ejecuta **dentro de cada combinación de institución, campus y carrera**: en cada una de esas unidades se ordena a sus propios participantes por calificación de partida, se los divide en tercios y dentro de cada tercio se los asigna al azar a los grupos A, B y C.

Esta decisión no es organizativa sino metodológica. Si una carrera constituyera íntegramente un grupo y otra carrera el grupo restante, la disciplina y la condición experimental quedarían completamente superpuestas, y ante cualquier diferencia observada resultaría imposible determinar si la produjo la herramienta o el hecho de tratarse de poblaciones con formación distinta. Lo mismo ocurriría si un campus o una institución coincidieran con un grupo. El diseño quedaría irremediablemente invalidado.

Tabla 3.5. Reparto de participantes según el número de instituciones, para la meta de reclutamiento de 225 participantes.

Instituciones	Por grupo en cada una	Total por institución	Total del estudio
2	38	114	228
3	25	75	225
4	19	57	228

El reparto no exige simetría perfecta. Una institución puede aportar 90 participantes y otra 130, y una carrera más estudiantes que otra, sin comprometer el análisis, siempre que dentro de cada unidad los tres grupos queden equilibrados en tamaño y en calificación de partida. Lo que debe protegerse es el balance interno de cada unidad, no la igualdad entre unidades.

Como criterio operativo, ninguna combinación de campus y carrera debería aportar menos de nueve participantes, es decir tres por grupo, ya que por debajo de esa cifra el bloqueo pierde sentido y la unidad solo añade ruido. Cuando una carrera no alcance ese mínimo, se agrupará con otra afín del mismo campus, y esa agrupación se declarará en el registro previo antes de recolectar datos.

Los tamaños finalmente alcanzados por institución, campus, carrera y grupo se reportan en el artículo, junto con la comparación de las características de línea base entre grupos.

CAPÍTULO 4

Variables e instrumentos

4.1 Mapa general de variables

Tabla 4.1. Variables del estudio, instrumento asociado y momento de medición.

Variable	Tipo	Instrumento	Momento
Condición experimental	Independiente	Asignación aleatoria estratificada	Previo a la sesión 1
Calidad del manuscrito	Principal	Rúbrica analítica (Anexo B)	Cada sesión
Recomendación editorial	Principal	Formulario del revisor (Anexo C)	Cada sesión
Retención y transferencia	Principal	Prueba diferida (Anexo G)	2–4 semanas después
Esfuerzo mental	Secundaria	Escala de Paas (Anexo E)	Fin de cada sesión
Carga de trabajo percibida	Secundaria	NASA-TLX (Anexo F)	Fin de cada sesión
Calibración metacognitiva	Secundaria	Ficha de predicción (Anexo D)	Antes de entregar
Integridad referencial	Secundaria	Plantilla de verificación (Anexo H)	Posterior a cada sesión
Datos de proceso y prompts	Secundaria	Registro de proceso (Anexo I)	Durante cada sesión
Detección experta	Subestudio	Formulario del revisor (Anexo C)	Fase de evaluación
Calificación de partida	Covariable	Rúbrica analítica	Línea base

4.2 Calidad del manuscrito

La calidad se evalúa con una **rúbrica analítica**, es decir, una rúbrica que puntúa por separado cada criterio en lugar de emitir una impresión global única. El Anexo B contiene la rúbrica completa con sus descriptores de nivel, lista para aplicar.

El procedimiento de evaluación es doblemente ciego: cada texto se anonimiza, se le elimina cualquier marca de autoría, se le asigna un código alfanumérico y se distribuye en orden aleatorio, de modo que el revisor desconoce tanto la identidad del estudiante como el grupo y la sesión de procedencia. Cada texto es evaluado por un mínimo de tres revisores con experiencia acreditada como pares evaluadores en revistas indexadas. Antes de iniciar, los revisores participan en una sesión de calibración de dos horas en la que puntúan cinco textos de entrenamiento, discuten discrepancias y acuerdan la interpretación de los descriptores.

4.3 Acuerdo entre evaluadores

Dado que varias personas califican los mismos textos, es obligatorio demostrar que sus juicios son consistentes y no producto del azar. Se emplean dos índices complementarios.

Concordancia en puntuaciones numéricas (coeficiente de correlación intraclase, ICC)

El ICC es un valor entre 0 y 1 que expresa qué proporción de la variación observada en las puntuaciones corresponde a diferencias reales entre los textos y no a diferencias entre los criterios de los evaluadores. Se calcula con la función `ICC` del paquete `psych` de R, especificando modelo de efectos aleatorios de dos vías y definición de acuerdo absoluto. Se reporta la forma exacta empleada junto con su intervalo de confianza. Valores superiores a 0,75 indican fiabilidad buena y superiores a 0,90 fiabilidad excelente (Koo and Li, 2016).

Concordancia en juicios categóricos (alfa de Krippendorff)

Cuando la respuesta no es un número sino una etiqueta — por ejemplo, si el revisor considera que el texto fue producido con asistencia generativa o sin ella — el índice apropiado es el alfa de Krippendorff, que admite cualquier número de evaluadores, cualquier nivel de medición y la presencia de datos faltantes. Se calcula con el paquete `irr` de R. Valores iguales o superiores a 0,80 permiten sostener conclusiones firmes, y 0,67 constituye el mínimo tolerable (Hayes and Krippendorff, 2007).

4.4 Retención y transferencia

La retención se mide de dos formas complementarias. La primera es el desempeño en la sesión 3, realizada sin ninguna herramienta de IA. La segunda es una **prueba diferida** aplicada entre dos y cuatro semanas después de la última sesión, a libro cerrado y sin dispositivos, sobre los contenidos trabajados en las sesiones 1 y 2.

La prueba incluye dos bloques deliberadamente distintos. El bloque de recuerdo pregunta por contenidos tratados de forma directa. El bloque de **transferencia** plantea situaciones nuevas que exigen aplicar lo aprendido a un caso no visto: es en este bloque donde el efecto de la descarga cognitiva debería manifestarse con mayor magnitud, porque transferir requiere haber construido el conocimiento y no solo haberlo tramitado. La estructura completa figura en el Anexo G.

4.5 Esfuerzo mental y carga de trabajo

El esfuerzo mental invertido se mide con la escala de Paas, un instrumento de un solo ítem y nueve niveles que interroga directamente por el esfuerzo mental dedicado a la tarea recién concluida (Paas, 1992). Su brevedad es una virtud: se responde en menos de un minuto y admite aplicación repetida sin fatigar al participante. El instrumento figura en el Anexo E.

De forma complementaria se aplica el NASA-TLX, un cuestionario de seis dimensiones que descompone la carga de trabajo en exigencia mental, exigencia física, presión temporal, rendimiento percibido, esfuerzo y frustración (Hart and Staveland, 1988). El Anexo F contiene las seis escalas y el procedimiento de ponderación por comparaciones pareadas. Ambos

instrumentos se aplican inmediatamente al finalizar cada sesión, antes de que el participante abandone el laboratorio.

4.6 Calibración metacognitiva

La calibración metacognitiva es la correspondencia entre lo que una persona cree que ha logrado y lo que efectivamente logró. Justo antes de entregar su texto, cada participante anota en una ficha la calificación que espera obtener sobre 100 y su nivel de seguridad en esa estimación. El instrumento figura en el Anexo D.

A partir de esos datos se calculan dos indicadores. El **sesgo** es el promedio de la diferencia con signo entre la calificación anticipada y la obtenida: un valor positivo indica sobreestimación sistemática y un valor negativo, subestimación. La **precisión absoluta** es el promedio de esa misma diferencia sin considerar el signo, y expresa cuán afinado es el juicio del estudiante con independencia de la dirección del error. Formalmente:

$$\text{Sesgo} = \frac{1}{n} \sum_{i=1}^n (P_i - R_i) \quad \text{Precisión absoluta} = \frac{1}{n} \sum_{i=1}^n |P_i - R_i| \quad (4.1)$$

donde P_i es la calificación predicha y R_i la calificación real del participante i . La predicción teórica es que la asistencia generativa elevará el sesgo sin mejorar la retención, produciendo estudiantes más confiados y no más competentes.

4.7 Integridad de las referencias citadas

Se verifica cada referencia de cada texto entregado con la plantilla del Anexo H. Dos asistentes, trabajando de forma independiente y ciega a la condición, comprueban que el identificador digital resuelva correctamente y que autores, título, revista, año, volumen y páginas se correspondan entre sí y con la obra real. Se calculan dos indicadores por texto: la proporción de referencias plenamente verificables y la **tasa de alucinación**, entendida como la proporción de referencias inexistentes o con campos fabricados. Este indicador es enteramente objetivo y de alto interés editorial.

4.8 Datos de proceso

Se registran el tiempo efectivo dedicado a la tarea, el historial de versiones del documento y, en la condición con asistencia, la transcripción íntegra de la conversación con la herramienta. El Anexo I especifica el formato de entrega. Estos datos permiten distinguir entre distintos modos de uso de la herramienta, desde la delegación completa hasta el uso como interlocutor crítico, y habilitan análisis posteriores sobre estrategias de interacción.

4.9 Subestudio de detección experta

Cada revisor, además de calificar la calidad, emite un juicio dicotómico sobre si el texto fue producido con asistencia generativa y declara su nivel de seguridad en una escala de 0 a 100. Como el equipo investigador conoce la condición real de cada texto — lo que en metodología se denomina **verdad de base** — es posible contrastar cada juicio con la realidad y construir la tabla de aciertos y errores que se presenta a continuación.

Tabla 4.2. Tabla de contingencia que ordena los juicios del revisor frente a la condición real del texto.

	Texto realmente asistido	Texto realmente sin IA
El revisor dice “con IA”	Verdadero positivo (VP)	Falso positivo (FP)
El revisor dice “sin IA”	Falso negativo (FN)	Verdadero negativo (VN)

4.9.1 Sensibilidad y especificidad

La **sensibilidad** es la proporción de textos realmente asistidos que el revisor identificó como tales; responde a la pregunta de cuántos casos reales se detectaron. La **especificidad** es la proporción de textos realmente escritos sin IA que el revisor dejó pasar correctamente; responde a cuántos estudiantes inocentes no fueron señalados. Se calculan así:

$$\text{Sensibilidad} = \frac{VP}{VP + FN} \quad \text{Especificidad} = \frac{VN}{VN + FP} \quad (4.2)$$

Ambas se reportan con intervalos de confianza del 95 %. En un contexto disciplinario, la especificidad tiene mayor peso ético que la sensibilidad: señalar erróneamente a un estudiante honesto es un error más grave que dejar pasar un caso.

4.9.2 Discriminación y criterio de decisión

Sensibilidad y especificidad dependen conjuntamente de dos cosas distintas que conviene separar: cuánto distingue realmente el revisor, y cuán dispuesto está a acusar. La teoría de detección de señales separa ambos componentes.

El índice d' (que se lee “de prima”) mide la capacidad genuina de distinguir entre los dos tipos de texto, con independencia de la disposición a acusar. Un valor próximo a cero significa que el revisor está esencialmente adivinando; valores superiores a 1 indican discriminación real. El índice de criterio, c , mide esa disposición: un valor negativo describe a un revisor propenso a acusar y uno positivo a un revisor indulgente. Dos revisores pueden discriminar igual de bien y aun así uno acusar al doble de estudiantes que el otro. Ambos se calculan a partir de las tasas de aciertos y falsas alarmas:

$$d' = z(\text{Sensibilidad}) - z(\text{tasa de falsos positivos}) \quad (4.3)$$

$$c = -\frac{1}{2} [z(\text{Sensibilidad}) + z(\text{tasa de falsos positivos})] \quad (4.4)$$

donde $z(\cdot)$ es la función inversa de la distribución normal estándar.

4.9.3 Curva ROC y área bajo la curva (AUC)

Los revisores no emiten solo un juicio dicotómico: declaran además cuán seguros están. Esa información adicional permite construir una medida de exactitud global que no depende del umbral que cada revisor haya elegido.

Qué es una curva ROC

La sigla ROC corresponde a *receiver operating characteristic*, “característica operativa del receptor”, denominación heredada de los operadores de radar de la Segunda Guerra Mundial, que debían decidir si una señal en pantalla correspondía a un avión o a ruido. La curva se construye recorriendo todos los umbrales posibles de seguridad: para cada umbral se calcula qué proporción de textos asistidos sería detectada y qué proporción de textos humanos sería acusada erróneamente, y se representa el primer valor frente al segundo. El resultado es una curva que describe el comportamiento del revisor bajo cualquier grado de severidad, en lugar de un único punto.

Qué es el AUC

El AUC (*area under the curve*, “área bajo la curva”) es el área que queda bajo esa curva y resume la exactitud global en un solo número entre 0,5 y 1. Tiene una interpretación probabilística directa y muy intuitiva: es la probabilidad de que, tomados al azar un texto asistido y un texto humano, el revisor otorgue mayor sospecha al texto asistido (Hanley and McNeil, 1982). Un AUC de 0,5 equivale exactamente a lanzar una moneda; 1,0 representa discriminación perfecta. Se calcula con el paquete pROC de R a partir de las puntuaciones de seguridad, y se reporta con su intervalo de confianza.

Tabla 4.3. Criterios de interpretación del AUC adoptados en este estudio.

Valor de AUC	Lectura
0,50 – 0,60	Indistinguible del azar
0,60 – 0,70	Discriminación débil, insuficiente para cualquier decisión
0,70 – 0,80	Discriminación moderada, admisible solo como indicio
0,80 – 0,90	Discriminación buena
0,90 – 1,00	Discriminación excelente

Los mismos textos se procesan adicionalmente con al menos dos detectores automáticos disponibles, calculando para ellos los mismos indicadores. La comparación entre juicio humano experto y detección automática, ambos contrastados contra la misma verdad de base, constituye una contribución directamente relevante para las políticas institucionales de integridad académica.

CAPÍTULO 5

Plan de análisis estadístico

5.1 Preparación de los datos

Antes de cualquier contraste se depura la base: se verifican rangos admisibles, se documentan y conservan los valores atípicos sin eliminarlos salvo error de registro comprobado, y se examina el patrón de datos faltantes. El código de depuración y análisis se versiona en un repositorio público junto con los datos anonimizados.

5.2 Modelo principal

El análisis central emplea **modelos mixtos**, también llamados multinivel, que son una extensión de la regresión capaz de reconocer que los datos están anidados: cada estudiante produce tres textos, cada tema posee su propia dificultad y cada revisor su propia severidad. El modelo separa esas fuentes de variación en lugar de confundirlas con el efecto de la condición experimental. La especificación, en la notación del paquete `lme4` de R, es la siguiente:

```
calidad ~ grupo * sesion + institucion + campus
      + calificacion_base + (1|estudiante) + (1|tema)
      + (1|revisor) + (1|carrera)
```

Los términos entre paréntesis son los **efectos aleatorios**: instruyen al modelo para que ajuste por el hecho de que un revisor determinado califica más duro, un tema determinado resulta más difícil y cada estudiante parte de un nivel propio. Los valores p se obtienen mediante aproximación de Satterthwaite con el paquete `lmerTest`.

La institución y el campus se incorporan como **efectos fijos** y no como efectos aleatorios. La razón es técnica: la estimación fiable de la varianza de un efecto aleatorio requiere del orden de cinco o más agrupaciones, y este estudio contempla dos o tres. Con ese número, tratar la sede como efecto aleatorio produciría estimaciones inestables y errores típicos poco confiables. Si el estudio llegara a ampliarse a cinco o más instituciones, la especificación se revisaría para incorporarlas como efecto aleatorio, y ese cambio quedaría declarado en una enmienda al registro previo. La carrera, en cambio, sí se modela como efecto aleatorio siempre que participen cinco o más; con menos de cinco se incorpora también como efecto fijo. El criterio aplicado se declara en el registro previo una vez conocido el número definitivo de carreras participantes.

Se estima además un modelo complementario que incluye las interacciones entre grupo e institución, entre grupo y campus, y entre grupo y carrera. Su propósito no es contrastar una hipótesis principal, sino verificar que el efecto de la condición experimental se reproduce en los distintos contextos institucionales. La ausencia de interacción significativa constituye

evidencia de replicación y es precisamente el argumento que sostiene la relevancia del estudio más allá de una sola institución.

5.3 Contraste principal de retención

La hipótesis H2 se contrasta con un **análisis de covarianza** (ANCOVA) sobre las puntuaciones de la sesión 3, comparando los grupos y descontando la calificación de partida de cada estudiante. De este modo, lo que se compara es el desempeño ajustado por el nivel previo, y no diferencias heredadas de la composición de los grupos. Se reporta la diferencia de medias ajustadas con su intervalo de confianza del 95 % y el tamaño del efecto correspondiente.

5.4 Pruebas de equivalencia

Las pruebas estadísticas convencionales pueden rechazar la ausencia de efecto, pero no pueden afirmar que dos condiciones sean equivalentes. Cuando la calidad inmediata no difiera significativamente entre condiciones, se aplicará el procedimiento de dos pruebas unilaterales (TOST) para sostener la equivalencia de manera positiva (Lakens et al., 2018). El procedimiento exige declarar de antemano cuál es la diferencia mínima que se consideraría relevante en la práctica; este estudio la fija en 5 puntos sobre 100 de la rúbrica, magnitud que corresponde aproximadamente a un nivel de diferencia en un criterio. El cálculo se realiza con el paquete `TOSTER` de R.

Este contraste es estratégicamente importante. Demostrar que la calidad es estadísticamente equivalente y que, a pesar de ello, la retención cae, constituye un resultado mucho más robusto y más difícil de refutar que una simple diferencia de medias.

5.5 Análisis de mediación

La hipótesis H6 se examina mediante un modelo de mediación multinivel en el que el esfuerzo mental reportado actúa como variable intermedia entre la condición experimental y el desempeño diferido. Se estima con el paquete `mediation` de R, con 5000 remuestreos bootstrap para los intervalos de confianza del efecto indirecto.

5.6 Análisis del subestudio de detección

Se calculan sensibilidad, especificidad, d' , criterio c y AUC por revisor y de forma agregada, con intervalos de confianza del 95 %. La probabilidad de que un texto sea señalado se modela mediante regresión logística mixta con efectos aleatorios por revisor y por texto, incluyendo como predictores la condición real, la calidad del texto y la experiencia editorial del revisor. Se contrasta formalmente la exactitud del juicio humano frente a la de los detectores automáticos.

5.7 Tamaños de efecto y presentación de resultados

Todo contraste se acompaña del tamaño del efecto con intervalo de confianza del 95 %. No se reportarán conclusiones basadas únicamente en la significación estadística. Los resultados exploratorios se etiquetan explícitamente como tales y se distinguen de los contrastes preespecificados.

5.8 Datos faltantes

Los modelos mixtos utilizan toda la información disponible sin exigir casos completos. Para las variables con datos faltantes se aplicará imputación múltiple por ecuaciones encadenadas con el paquete `mice`, generando veinte conjuntos imputados, y se reportará un análisis de sensibilidad comparando los resultados con y sin imputación.

5.9 Programas

El análisis se ejecuta en R con los paquetes `lme4`, `lmerTest`, `emmeans`, `psych`, `irr`, `pROC`, `TOSTER`, `mediation` y `mice`. El cálculo de potencia se realiza con G*Power (Faul et al., 2007).

CAPÍTULO 6

Tamaño muestral y potencia

6.1 Qué significa el tamaño del efecto

La d de **Cohen** expresa la magnitud de una diferencia en unidades comparables entre estudios: se obtiene dividiendo la diferencia entre las medias de dos grupos por la desviación típica combinada de ambos. Por convención, 0,20 corresponde a un efecto pequeño, 0,50 a uno mediano y 0,80 a uno grande. Fijar el objetivo en $d = 0,50$ significa diseñar el estudio para poder detectar una diferencia de magnitud mediana, que es la mínima con relevancia educativa práctica en este ámbito.

6.2 Procedimiento de cálculo

El cálculo se ejecuta en G*Power con los siguientes parámetros: familia de pruebas t ; prueba de diferencia de medias entre dos grupos independientes; análisis a priori; contraste bilateral; $d = 0,50$; nivel de significación $\alpha = 0,05$; potencia $1 - \beta = 0,80$; razón de asignación igual a 1. El programa devuelve 64 participantes por grupo.

Tabla 6.1. Escenarios de potencia para el contraste principal entre dos grupos.

d objetivo	Potencia	n por grupo	N total (3 grupos)
0,40	0,80	99	297
0,50	0,80	64	192
0,50	0,90	86	258
0,60	0,80	45	135

6.3 Meta de reclutamiento

Adoptando $d = 0,50$ con potencia de 0,80 y previendo una pérdida del 15 % entre la primera sesión y la prueba diferida, la meta de reclutamiento se fija en **225 participantes** distribuidos entre las sedes, con un mínimo aceptable de 180. Alcanzar esa cifra exige la participación de varias carreras de ambos campus y probablemente de más de una cohorte, además de las instituciones externas que se incorporen. Conviene señalar que el diseño de medidas repetidas y la inclusión de la calificación de partida como covariable incrementan la potencia efectiva por encima de la estimación conservadora de la tabla anterior.

CAPÍTULO 7

Ética, ciencia abierta y gestión de datos

7.1 Aprobación ética y consentimiento

El protocolo se somete a la aprobación del comité de ética institucional de cada universidad participante antes de iniciar el reclutamiento. Todos los participantes firman el consentimiento informado del Anexo A, que explica los objetivos, los procedimientos, el carácter voluntario de la participación y el derecho a retirarse en cualquier momento sin consecuencia alguna. Dicho documento incorpora una autorización diferenciada y opcional para que el equipo solicite a las autoridades universitarias el promedio académico del participante, de modo que quien no desee otorgarla pueda participar igualmente en el estudio.

7.2 Separación respecto de la calificación del curso

El experimento se desacopla por completo de la evaluación académica real. Ningún estudiante ve afectada su nota por el grupo que le correspondió en el sorteo. Los participantes reciben un reconocimiento equivalente por su participación, con independencia de su desempeño y de su condición. Al concluir el estudio se realiza una sesión informativa en la que se explica el propósito, se comunican los resultados agregados y se ofrece a todos los grupos formación en uso crítico de herramientas generativas.

7.3 Protección de datos

Los textos se anonimizan antes de la evaluación mediante códigos alfanuméricos. La tabla que vincula códigos con identidades se custodia por separado, cifrada, bajo responsabilidad de una persona ajena al equipo evaluador, y se destruye al cerrar el estudio. Los datos publicados no contienen información que permita identificar a ningún participante.

7.4 Registro previo del estudio

El protocolo se registra en el Open Science Framework antes de recolectar el primer dato. El registro previo consiste en depositar públicamente hipótesis, diseño, instrumentos y plan de análisis en un documento con marca temporal certificada, lo que permite distinguir con nitidez entre lo que se predijo y lo que se descubrió después (Nosek et al., 2018). El procedimiento operativo es el siguiente: se crea el proyecto en la plataforma, se completa una plantilla de registro, se adjunta este documento y los anexos, y se congela el registro, que puede mantenerse en acceso restringido hasta la publicación. El enlace se declara en la carta de presentación del manuscrito.

7.5 Materiales abiertos

Al publicar se depositan en un repositorio público los datos anonimizados, la rúbrica, los instrumentos, el código de análisis y las transcripciones de las conversaciones con la herramienta generativa, previa eliminación de cualquier dato identificable.

CAPÍTULO 8

Cronograma y viabilidad

Tabla 8.1. Cronograma de ejecución por fases.

Mes	Actividad	Producto
1	Pilotaje de temas y ajuste de la rúbrica	Informe de equiparación de temas
1–2	Aprobación ética y registro previo	Dictamen y registro con marca temporal
2	Sesión de línea base y asignación aleatoria	Tabla de asignación custodiada
3–4	Sesiones 1, 2 y 3 de producción	Corpus de textos codificados
5	Prueba diferida	Base de retención y transferencia
5–6	Calibración y evaluación por revisores	Puntuaciones y juicios de detección
6	Verificación de referencias	Indicadores de integridad referencial
7	Análisis estadístico	Resultados y figuras
8–9	Redacción y envío del manuscrito	Manuscrito y materiales abiertos

La partida de costo más significativa es la remuneración de los revisores externos. Con tres revisores por texto y un corpus estimado en torno a 675 textos, el volumen de evaluación exige un panel de al menos doce revisores y una planificación cuidadosa de la carga individual, que no debería superar los sesenta textos por persona para preservar la calidad del juicio.

CAPÍTULO 9

Limitaciones y estrategia de publicación

9.1 Limitaciones anticipadas y cómo se abordan

Tabla 9.1. Limitaciones previstas y decisiones de diseño que las atenuan.

Limitación	Tratamiento
Contaminación entre grupos	Salas separadas, dispositivos institucionales con perfil restringido y declaración de honor
Efecto de novedad de la herramienta	Registro del uso previo declarado en la línea base e inclusión como covariable
Generalización limitada a la escritura argumentativa	Se declara explícitamente el alcance y se propone replicación en otros géneros
Evolución rápida de los modelos generativos	Se documentan versión exacta y fecha de acceso de la herramienta empleada
Motivación diferencial por desacople de la nota	Reconocimiento equivalente para todos y verificación del esfuerzo mediante datos de proceso
Ventana de la prueba diferida	Se fija y se preregistra el intervalo exacto, idéntico para todos los grupos

9.2 Ajuste al perfil editorial

El manuscrito derivado de este protocolo se orienta a una revista de primer nivel en tecnología educativa. Tres rasgos del diseño atienden de forma directa los criterios editoriales habituales en ese ámbito. En primer lugar, el objeto de estudio es un mecanismo cognitivo de alcance general y no la evaluación de una herramienta concreta en un curso particular. En segundo lugar, la estructura multi-sitio y multidisciplinar sustenta la relevancia más allá de una sola institución. En tercer lugar, el registro previo, los materiales abiertos y el reporte de tamaños de efecto con intervalos de confianza responden a los estándares metodológicos que hoy se exigen.

La redacción del manuscrito debe hacer explícita, ya desde la introducción, la relevancia para la comunidad educativa amplia, y evitar toda formulación que presente el trabajo como un estudio de caso institucional.

APÉNDICE A

Consentimiento informado

Este documento se emite por duplicado: un ejemplar para el participante y otro para el archivo del proyecto. Se entrega con anterioridad a la primera sesión, de modo que el participante disponga de tiempo para leerlo y formular preguntas.

CONSENTIMIENTO INFORMADO PARA PARTICIPANTES

Proyecto EAES — Escritura Académica y Aprendizaje en Educación Superior

1. Datos de identificación del participante

Universidad: _____
Campus: _____
Carrera: _____
Año o nivel: _____
Apellidos: _____
Nombres: _____
Cédula / pasaporte /
DNI / ID: _____
Correo institucional: _____

2. En qué consiste este estudio

El Proyecto EAES estudia cómo los estudiantes universitarios elaboran textos académicos y qué factores influyen en lo que aprenden durante ese proceso. La investigación se desarrolla simultáneamente en varias carreras y universidades, y es conducida por docentes investigadores de las instituciones participantes.

3. Qué implica su participación

- Asistirá a **tres sesiones de trabajo de dos horas** cada una, en laboratorio supervisado, en las que redactará un ensayo a partir de material entregado el mismo día.
- Asistirá a una **sesión posterior de evaluación de aproximadamente cuarenta minutos**, entre dos y cuatro semanas después de la última sesión de trabajo.

- Responderá **cuestionarios breves** sobre el esfuerzo que le demandó cada tarea, que no toman más de cinco minutos.
- Las **condiciones y herramientas de trabajo de cada sesión se asignan al azar**. Usted no elige el grupo que le corresponde ni las herramientas de las que dispondrá en cada sesión.

4. Qué datos se recogen

Los textos que usted produzca, sus respuestas a los cuestionarios, el registro del tiempo dedicado a cada tarea, el historial de versiones de su documento, su rendimiento académico previo y, en las sesiones en que disponga de alguna herramienta digital de apoyo, el registro de su interacción con ella. No se recogen imágenes, grabaciones de audio ni datos ajenos a la actividad académica descrita.

5. Autorización para solicitar su rendimiento académico previo

Para conformar grupos de trabajo comparables entre sí, el equipo investigador necesita distribuir a los participantes de manera equilibrada según su rendimiento académico previo. Con ese único fin se solicitará a las autoridades de su universidad su **promedio acumulado** hasta el período académico inmediato anterior.

☐ **Autorizo** que el equipo investigador solicite a las autoridades de mi universidad mi promedio acumulado, exclusivamente para la conformación equilibrada de los grupos de trabajo de este estudio.

☐ **No autorizo** esta solicitud. *(Puede igualmente participar en el estudio; en ese caso la asignación a los grupos se realizará únicamente con base en el texto de referencia inicial.)*

6. Efecto sobre sus calificaciones

Ninguno. Su participación, su desempeño dentro del estudio y el grupo que le corresponda por sorteo no afectan de ningún modo su calificación en ninguna asignatura. Los textos que elabore en este estudio no forman parte de la evaluación de su curso.

7. Confidencialidad y protección de sus datos

A cada participante se le asigna un código. Desde ese momento, toda la información del estudio se maneja únicamente mediante ese código. Quienes evalúen sus textos desconocerán su identidad, su universidad, su campus, su carrera y el grupo al que usted pertenece.

La tabla que vincula códigos con identidades se custodia cifrada, bajo responsabilidad de una persona ajena al equipo evaluador, y se destruye al concluir el estudio. Los datos que se publiquen no permitirán identificar a ningún participante. Sus datos no se utilizarán para

ninguna finalidad distinta de la descrita en este documento, ni se transferirán a terceros ajenos al equipo investigador.

8. Carácter voluntario y derecho de retiro

Su participación es enteramente voluntaria. Puede negarse a participar o retirarse en cualquier momento, sin necesidad de explicar el motivo y sin consecuencia alguna de tipo académico o de otra naturaleza. Si decide retirarse, puede solicitar además la eliminación de los datos que hubiera aportado hasta ese momento.

9. Riesgos, beneficios e información final

El estudio no implica riesgos previsibles para usted. Al concluir la investigación se realizará una **sesión informativa** en la que se explicará en detalle el propósito completo del estudio, se comunicarán los resultados obtenidos y se ofrecerá a todos los participantes, sin distinción de grupo, formación sobre escritura académica y uso responsable de herramientas digitales de apoyo. Una vez conocido ese propósito, usted podrá solicitar el retiro de sus datos.

10. A quién dirigirse

Investigador principal: Gleiston Cicerón Guerrero Ulloa

Correo de contacto: gguerrero@uteq.edu.ec

Comité de ética / trámite: _____

11. Declaración del participante

He leído este documento en su totalidad, he tenido la oportunidad de formular preguntas y estas han sido respondidas de forma satisfactoria. Comprendo en qué consiste el estudio, qué datos se recogen, con qué finalidad se utilizan y que puedo retirarme en cualquier momento sin consecuencia alguna. Recibo un ejemplar firmado de este documento.

☐ **Acepto participar** en el Proyecto EAES en los términos descritos en este documento.

Firma del participante

Fecha (día / mes / año)

Firma del investigador o persona responsable

Fecha (día / mes / año)

APÉNDICE B

Rúbrica analítica de calidad del manuscrito

Cada criterio se puntúa de 0 a 4. La puntuación total sobre 100 se obtiene aplicando los pesos de la tabla B.1 mediante la fórmula $\text{Total} = \sum_j \left(\frac{\text{nivel}_j}{4} \times \text{peso}_j \right)$.

Tabla B.1. Criterios y pesos de la rúbrica.

Código	Criterio	Peso
C1	Calidad de la tesis y de la argumentación	25
C2	Uso e integración de la evidencia	25
C3	Precisión conceptual y dominio del contenido	25
C4	Estructura, coherencia y claridad expositiva	15
C5	Originalidad y voz propia	10
Total		100

C1. Calidad de la tesis y de la argumentación

Nivel	Descriptor
4	La tesis es explícita, delimitada y discutible. La argumentación progresa de forma encadenada, anticipa objeciones relevantes y las responde con razones.
3	La tesis es clara y la argumentación es sólida, aunque no considera objeciones o las trata de manera superficial.
2	Hay una tesis identificable, pero la argumentación es enumerativa más que encadenada y algunos pasos quedan sin justificar.
1	La tesis es vaga o se confunde con el tema. El texto describe en lugar de argumentar.
0	No hay tesis reconocible ni estructura argumentativa.

C2. Uso e integración de la evidencia

Nivel	Descriptor
4	Las fuentes se integran al servicio del argumento, se contrastan entre sí y se citan con precisión. Se distingue con claridad lo aportado por las fuentes de lo aportado por el autor.
3	Las fuentes son pertinentes y están bien citadas, pero se yuxtaponen más que dialogar entre sí.
2	Se citan fuentes de forma ornamental, sin que sostengan realmente las afirmaciones.
1	Las citas son escasas, imprecisas o no corresponden a lo afirmado.
0	No hay evidencia citada, o las referencias no existen.

C3. Precisión conceptual y dominio del contenido

Nivel	Descriptor
4	Los conceptos se emplean con exactitud técnica, se definen cuando corresponde y se establecen relaciones correctas entre ellos. No hay errores conceptuales.
3	El manejo conceptual es correcto, con imprecisiones menores que no comprometen el argumento.
2	Se emplean los términos adecuados, pero con definiciones imprecisas o relaciones mal establecidas.
1	Hay errores conceptuales que afectan partes sustantivas del texto.
0	El contenido es erróneo o ajeno al tema solicitado.

C4. Estructura, coherencia y claridad expositiva

Nivel	Descriptor
4	La organización responde a la lógica del argumento. Las transiciones son explícitas y la redacción es precisa y económica.
3	El texto está bien organizado y se lee con fluidez, con alguna sección desproporcionada.
2	La organización es convencional pero rutinaria, y hay pasajes redundantes.
1	La secuencia es confusa y obliga a releer para seguir el hilo.
0	No hay organización discernible.

C5. Originalidad y voz propia

Nivel	Descriptor
4	El texto aporta una perspectiva, un ejemplo o una articulación propia que no proviene directamente de las fuentes, con una voz reconocible.
3	Hay elaboración personal, aunque el enfoque sigue de cerca el de las fuentes.
2	El texto reorganiza correctamente material ajeno sin aportar elaboración propia.
1	El texto es una paráfrasis extendida de las fuentes.
0	No hay elaboración propia alguna.

APÉNDICE C

Formulario del revisor

Código del texto: _____ Código del revisor: _____ Fecha: _____

Sección 1. Puntuación por criterio

Criterio	Nivel (0–4)	Observación
C1. Tesis y argumentación	_____	_____
C2. Uso de la evidencia	_____	_____
C3. Precisión conceptual	_____	_____
C4. Estructura y claridad	_____	_____
C5. Originalidad y voz propia	_____	_____

Sección 2. Recomendación editorial simulada

Si este texto llegara a su escritorio como manuscrito sometido a una revista, ¿qué recomendaría?

- ☐ 1. Rechazar
- ☐ 2. Revisión mayor
- ☐ 3. Revisión menor
- ☐ 4. Aceptar

Sección 3. Juicio sobre el origen del texto

3.1. ¿Considera que este texto fue elaborado con asistencia de inteligencia artificial generativa?

☐ Sí ☐ No

3.2. Indique su nivel de seguridad en ese juicio, de 0 (ninguna seguridad) a 100 (certeza absoluta): _____

3.3. Señale los indicios en los que basó su juicio (puede marcar varios):

☐ Uniformidad excesiva del registro y del ritmo de las oraciones

- ☐ Ausencia de errores menores propios de la escritura humana
- ☐ Generalidad en los ejemplos o falta de anclaje concreto
- ☐ Estructura excesivamente simétrica entre secciones
- ☐ Referencias que no logré verificar
- ☐ Vocabulario atípico para el nivel formativo esperado
- ☐ Otro: _____

3.4. Tiempo empleado en la evaluación de este texto: _____ minutos

APÉNDICE D

Ficha de predicción de calificación

Esta ficha se completa **antes** de entregar el texto y no influye en ninguna calificación.

Código del participante: _____ **Sesión:** _____ **Fecha:** _____

1. ¿Qué calificación cree que obtendrá este texto, en una escala de 0 a 100? _____

2. ¿Cuánta seguridad tiene en esa estimación, de 0 a 100? _____

3. ¿Cuánto cree que recordará de este contenido dentro de un mes?

☐ Muy poco ☐ Poco ☐ Algo ☐ Bastante ☐ Mucho

4. Si tuviera que explicar oralmente este contenido sin consultar el texto, ¿con qué facilidad cree que podría hacerlo, de 0 a 100? _____

APÉNDICE E

Escala de esfuerzo mental

Se aplica inmediatamente al finalizar cada sesión, antes de que el participante abandone el laboratorio. Adaptación al español del instrumento de un solo ítem propuesto por Paas (1992).

Código del participante: _____ **Sesión:** _____

Instrucción: En la tarea que acaba de realizar, invertí un esfuerzo mental de:

Nivel	Descripción
1	Esfuerzo mental extremadamente bajo
2	Esfuerzo mental muy bajo
3	Esfuerzo mental bajo
4	Esfuerzo mental algo bajo
5	Esfuerzo mental ni alto ni bajo
6	Esfuerzo mental algo alto
7	Esfuerzo mental alto
8	Esfuerzo mental muy alto
9	Esfuerzo mental extremadamente alto

Marque un solo nivel: _____

APÉNDICE F

Cuestionario de carga de trabajo NASA-TLX

Adaptación al español del instrumento de [Hart and Staveland \(1988\)](#). Cada dimensión se puntúa sobre una escala de 0 a 100, en incrementos de 5.

Dimensión	Pregunta	Puntuación
Exigencia mental	¿Cuánta actividad mental requirió la tarea (pensar, decidir, buscar, recordar)?	_____
Exigencia física	¿Cuánta actividad física requirió la tarea?	_____
Presión temporal	¿Cuánta presión de tiempo sintió durante la tarea?	_____
Rendimiento	¿Cuán satisfecho está con su desempeño? (0 = perfecto; 100 = fracaso)	_____
Esfuerzo	¿Cuánto tuvo que esforzarse para alcanzar su nivel de desempeño?	_____
Frustración	¿Cuán inseguro, desanimado, irritado o estresado se sintió?	_____

Ponderación. Tras responder las seis escalas, el participante recibe quince tarjetas con todas las parejas posibles de dimensiones y en cada una señala cuál contribuyó más a la carga de la tarea. El número de veces que se elige cada dimensión constituye su peso, y el índice global se obtiene como la media ponderada de las seis puntuaciones. Si el tiempo de aplicación resultara crítico, se admite la variante no ponderada, que promedia las seis dimensiones sin comparaciones pareadas; la decisión se declara en el registro previo.

APÉNDICE G

Estructura de la prueba diferida

Se aplica entre dos y cuatro semanas después de la última sesión de producción, en formato presencial, a libro cerrado, sin dispositivos y con una duración de cuarenta minutos. Cubre los contenidos de las sesiones 1 y 2, no los de la sesión 3.

Tabla G.1. Composición de la prueba diferida.

Bloque	Ítems	Puntos	Naturaleza de las preguntas
Reconocimiento	10	20	Opción múltiple sobre hechos y definiciones tratados
Recuerdo libre	4	20	Respuesta breve sin claves de recuperación
Comprensión	3	24	Explicar con palabras propias una relación entre conceptos
Transferencia	3	36	Aplicar lo aprendido a un caso nuevo no tratado en las sesiones
Total		100	

Los ítems de transferencia concentran el mayor peso porque es en ellos donde el mecanismo de descarga cognitiva debería manifestarse con mayor claridad: aplicar conocimiento a una situación nueva exige haberlo construido, no haberlo tramitado. Las respuestas abiertas se califican con una guía de corrección cerrada, por dos correctores independientes y ciegos a la condición, y se reporta el ICC correspondiente.

APÉNDICE H

Plantilla de verificación de referencias

Se completa una fila por cada referencia de cada texto entregado. Dos asistentes verifican de forma independiente y ciega a la condición; las discrepancias se resuelven por consenso con un tercer verificador.

N.º	Referencia tal como aparece	DOI resuelve	Autores coinciden	Revista y año coinciden	Clasificación
1		Sí / No	Sí / No	Sí / No	
2		Sí / No	Sí / No	Sí / No	
3		Sí / No	Sí / No	Sí / No	

Clasificación de cada referencia. *Verificada*: todos los campos correctos y coherentes entre sí. *Imprecisa*: la obra existe, pero uno o más campos son erróneos. *Inexistente*: no se localiza la obra en ninguna base indexada. *Atribución errónea*: la obra existe pero no sostiene la afirmación a la que se asocia.

Indicadores derivados. Proporción de referencias verificadas sobre el total; tasa de alucinación, entendida como la proporción de referencias inexistentes; y tasa de atribución errónea. Los tres se calculan por texto y se analizan como variables dependientes.

APÉNDICE I

Registro de proceso y de interacción con la herramienta

Al finalizar cada sesión, cada participante entrega los siguientes elementos en una carpeta identificada con su código.

Elemento	Especificación
Texto final	Archivo en formato PDF y en formato editable
Historial de versiones	Exportación del historial del procesador de texto empleado
Tiempo en tarea	Registro automático de inicio, pausas y cierre de la sesión
Transcripción de la interacción	Solo en condición con herramienta: exportación íntegra de la conversación, sin edición
Declaración de uso	Descripción breve, en no más de cinco líneas, de cómo utilizó la herramienta
Herramienta y versión	Nombre exacto del servicio, versión del modelo y fecha de acceso

Las transcripciones se codifican posteriormente según el modo de uso predominante: delegación completa de la redacción, generación de borrador seguida de reescritura sustantiva, uso como interlocutor para clarificar conceptos, o uso limitado a corrección de estilo. Esta codificación se realiza por dos codificadores independientes y su acuerdo se reporta mediante el alfa de Krippendorff.

APÉNDICE J

Ficha de línea base

Código del participante: _____ **Sede:** _____ **Fecha:** _____

1. Nivel y carrera que cursa: _____

2. Promedio acumulado: _____

3. ¿Con qué frecuencia ha utilizado herramientas de inteligencia artificial generativa para tareas académicas durante el último semestre?

☐ Nunca ☐ Alguna vez ☐ Mensualmente ☐ Semanalmente ☐ A diario

4. Indique las herramientas que ha utilizado: _____

5. ¿Ha recibido formación formal sobre uso de estas herramientas? ☐ Sí ☐ No

6. ¿Cuántos trabajos escritos de más de mil palabras ha elaborado en su formación universitaria? _____

Texto de partida. A continuación dispone de cuarenta minutos para redactar un texto argumentativo de aproximadamente 500 palabras sobre el tema entregado, sin acceso a ninguna herramienta digital de asistencia. Este texto se emplea únicamente para equilibrar los grupos y no forma parte de su calificación.

APÉNDICE K

Guión de administración de la sesión

Este guión garantiza que las sesiones se apliquen de forma idéntica en todos los campus, carreras e instituciones participantes. El aplicador marca cada paso a medida que lo ejecuta y firma al cierre.

Minuto	Acción del aplicador	Verificado
0–5	Verificar asistencia contra la lista de la sesión y asignar puestos	☐
5–10	Comprobar el perfil del equipo según la condición de la sala	☐
10–15	Leer en voz alta las instrucciones estándar y recoger la declaración de honor	☐
15	Entregar el material del tema y los artículos de referencia	☐
15–135	Supervisar la producción; registrar cualquier incidencia	☐
135–140	Entregar la ficha de predicción de calificación y recogerla	☐
140–145	Recibir textos, historiales y transcripciones	☐
145–155	Aplicar la escala de esfuerzo mental y el NASA-TLX	☐
155–160	Cerrar la sesión, sellar la carpeta y firmar el acta	☐

Instrucciones estándar que se leen en voz alta. “Dispone de dos horas para elaborar un ensayo argumentativo de entre mil doscientas y mil quinientas palabras sobre el tema que acaba de recibir, apoyándose en los artículos entregados. Debe incluir referencias. En esta sala, [dispone / no dispone] de una herramienta de inteligencia artificial generativa; [debe exportar la conversación completa al finalizar / no está permitido el uso de ningún servicio de inteligencia artificial]. Su trabajo en esta sesión no afecta de ninguna manera su calificación en la asignatura. Si tiene dudas sobre el procedimiento, levante la mano.”

Incidencias. Cualquier interrupción, fallo técnico o abandono se anota en el acta con hora exacta y se reporta al coordinador de la institución el mismo día.

Bibliografía

- Bjork, R. A., Dunlosky, J., and Kornell, N. (2013). Self-regulated learning: Beliefs, techniques, and illusions. *Annual Review of Psychology*, 64:417–444.
- Deng, R., Jiang, M., Yu, X., Lu, Y., and Liu, S. (2024). Does ChatGPT enhance student learning? a systematic review and meta-analysis of experimental studies. *Computers & Education*, 227:105224.
- Faul, F., Erdfelder, E., Lang, A.-G., and Buchner, A. (2007). G*Power 3: A flexible statistical power analysis program for the social, behavioral, and biomedical sciences. *Behavior Research Methods*, 39(2):175–191.
- Hanley, J. A. and McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1):29–36.
- Hart, S. G. and Staveland, L. E. (1988). Development of NASA-TLX (task load index): Results of empirical and theoretical research. In Hancock, P. A. and Meshkati, N., editors, *Human Mental Workload*, volume 52 of *Advances in Psychology*, pages 139–183. North-Holland, Amsterdam.
- Hayes, A. F. and Krippendorff, K. (2007). Answering the call for a standard reliability measure for coding data. *Communication Methods and Measures*, 1(1):77–89.
- Koo, T. K. and Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *Journal of Chiropractic Medicine*, 15(2):155–163.
- Lakens, D., Scheel, A. M., and Isager, P. M. (2018). Equivalence testing for psychological research: A tutorial. *Advances in Methods and Practices in Psychological Science*, 1(2):259–269.
- Nosek, B. A., Ebersole, C. R., DeHaven, A. C., and Mellor, D. T. (2018). The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606.
- Paas, F. G. W. C. (1992). Training strategies for attaining transfer of problem-solving skill in statistics: A cognitive-load approach. *Journal of Educational Psychology*, 84(4):429–434.
- Perkins, M., Roe, J., Postma, D., McGaughan, J., and Hickerson, D. (2024). Detection of GPT-4 generated text in higher education: Combining academic judgement and software to identify generative AI tool misuse. *Journal of Academic Ethics*, 22(1):89–113.
- Risko, E. F. and Gilbert, S. J. (2016). Cognitive offloading. *Trends in Cognitive Sciences*, 20(9):676–688.
- Slamecka, N. J. and Graf, P. (1978). The generation effect: Delineation of a phenomenon. *Journal of Experimental Psychology: Human Learning and Memory*, 4(6):592–604.