

Informe de Revisión Post-Correcciones (V001)

Tesis: *Herramienta CASE para la generación de pruebas de usuario a partir de requisitos mediante inteligencia artificial generativa*

Autora: Triana Arrieta, Kerly Mikaela — Versión V001

Revisión científica y editorial

7 de mayo de 2026

Resumen

Este informe contrasta la versión V001 de la tesis con las observaciones emitidas sobre la versión V000 (informe del 4 de mayo de 2026). Se evalúa, para cada una de las 18 recomendaciones priorizadas y para cada hallazgo de los informes complementarios sobre datos estadísticos, si fue *atendido*, *atendido parcialmente* o *pendiente*. Se identifican además observaciones nuevas surgidas durante la revisión de V001. La calificación general de madurez del manuscrito sube notablemente: **de 7/10 a 9/10**; el documento se encuentra en condiciones de sustentación, con ajustes finos pendientes.

Índice

1. Síntesis ejecutiva	1
2. Detalle por recomendación priorizada (V000 -> V001)	2
2.1. Recomendaciones bloqueantes	3
2.2. Recomendaciones de alta prioridad	3
2.3. Recomendaciones de prioridad media	6
2.4. Recomendaciones de prioridad baja	8
3. Estado de los datos estadísticos (informe complementario)	8
4. Nuevas observaciones detectadas en V001	10
5. Tabla maestra: 18 recomendaciones priorizadas y su estado	12
6. Recomendaciones residuales para una posible V002	13
7. Conclusión del revisor	14

1. Síntesis ejecutiva

Volumen del avance. La versión V001 pasó de 2310 líneas (V000) a 2479 líneas; el archivo aumentó de 222 KB a 2.2 MB (10× más grande), reflejando la incorporación efectiva de las 14 ilustraciones científicas y de los nuevos anexos. El documento ahora cuenta con 6 capítulos: I

(Marco contextual), II (Marco teórico), III (Metodología), IV (Resultados), V (Recomendaciones y trabajos futuros) y VI (Bibliografía).

Estado global de las 18 recomendaciones priorizadas:

Categoría	V000 prev.	Estado en V001
Bloqueantes (figuras + Capítulo V)	2	2/2 atendidas
Alta prioridad (formato, refs, RSL, prompts, etc.)	6	5/6 atendidas + 1 parcial
Media prioridad	8	6/8 atendidas + 2 parciales
Baja prioridad (tipografía, CR=3.76)	2	2/2 atendidas
TOTAL	18	15/18 (83%) + 3 parc.

Avances cualitativos más relevantes:

- Las 14 ilustraciones están **efectivamente insertadas** (verificado mediante extracción del archivo .docx: contiene 18 archivos en `word/media/`, incluyendo gráficos generados con *matplotlib*, capturas de pantalla del sistema TDDMachine y diagramas arquitectónicos profesionales).
- Se incorporó el **Capítulo V con sus cuatro subsecciones** exactamente como se sugirió.
- Se eliminó la referencia [8] sospechosa de ser predatoria; los *preprints* arXiv fueron sustituidos por sus versiones publicadas (en JSS Q1 y *Information & Software Technology* Q1).
- Se incorporaron los **tres nuevos anexos** críticos para reproducibilidad: Anexo 14 (plantillas de prompt), Anexo 15 (repositorio público con URLs reales de GitHub) y Anexo 16 (corpus de especificaciones).
- Se realizó análisis estadístico inferencial: IC95% del SUS calculado correctamente (72.27–77.37), r^2 con interpretación de Cohen para las correlaciones TAM, recálculo correcto de la desviación estándar global TAM (0.62, con nota explicativa del método).
- La discusión y las conclusiones están **notablemente mejoradas**: se atenuó la afirmación de superioridad sobre PyTester reconociendo la no equivalencia de métricas, se discute la asimetría 4.24/4.08/3.92 con anclaje en Korrapprolu, y se interpreta el constructo CR=3.76.
- La introducción incluye ahora aporte diferencial explícito y guía de lectura por capítulos.

2. Detalle por recomendación priorizada (V000 -> V001)

2.1. Recomendaciones bloqueantes

Observación atendida

R1. Insertar las 14 ilustraciones ausentes (Crit. 4).

Estado en V001: Atendido completamente.

La auditoría del archivo .docx confirma que ahora contiene 18 archivos de imagen en word/media/: 4 logotipos/firmas institucionales y 14 gráficos científicos correspondientes a las ilustraciones declaradas. Se verificaron en particular:

- Ilustración 1 (cronograma): incrustada como *Enhanced Metafile* (formato vectorial nativo de MS Project).
- Ilustraciones 2 y 3 (arquitectura y componentes): diagramas profesionales con paleta consistente y leyenda.
- Ilustración 6 (gráfico TAM vs umbral): incluye **barras de error** consistentes con el cálculo del IC95 %.
- Ilustración 7 (diagrama de caja TAM): incluye *outliers individuales* ($CR \approx 1,83$, $IU \approx 2,93$), lo que demuestra que la autora trabajó con la matriz individual TAM.
- Ilustración 8 (gráfico de radar TAM): correctamente etiquetado con valores y línea de referencia en 3.5.
- Ilustraciones 9–14 (manual): capturas de pantalla reales del sistema TDDMachine en producción, con interfaz pulida.

Observación atendida

R2. Crear el Capítulo V de Recomendaciones y Trabajos Futuros (Crit. 11).

Estado en V001: Atendido completamente.

El Capítulo V (líneas 2187–2205) se incorporó exactamente con la estructura sugerida: 5.1 Limitaciones del estudio, 5.2 Recomendaciones técnicas, 5.3 Recomendaciones metodológicas y 5.4 Líneas de trabajo futuro. Cada subsección recoge varias de las observaciones del informe de V000, incluyendo las metodológicas sobre Shapiro-Wilk, IC95 %, tamaño del efecto, Krippendorff α /ICC, AHP con panel externo y publicación en Zenodo con DOI.

2.2. Recomendaciones de alta prioridad

Observación atendida

R3. Corregir el formato (negritas/cursivas rotas en TDD, SUS, TAM, LLM, etc.) (Crit. 1).

Estado en V001: Atendido en gran medida, aún hay residuos.

El resumen ejecutivo (líneas 138–144), la introducción (línea 516) y el marco teórico ya muestran cursivas correctas para *Test Driven Development*, *System Usability Scale*, *Technology Acceptance Model*. Persisten algunos residuos en encabezados (“*Computer-Aided Software Engineering*” línea 138, “**METODOLOGÍA**” línea 710 con salto de formato) que probablemente correspondan a estilos heredados de Word, no a errores de redacción.

Observación atendida

R4. Reemplazar la referencia [8] (predatoria) y completar [5], [19], [23] (Crit. 7).

Estado en V001: Atendido completamente.

La referencia “Indian Journal of Science and Research” **ya no aparece**. La nueva bibliografía contiene 37 referencias (antes 35). Cambios verificados:

- Antiguas referencias arXiv [4] y [7]: sustituidas por publicaciones definitivas, una de ellas en *Information & Software Technology* (Q1 JCR).
- Antigua [5] (manuscrito Garousi sin datos): sustituida por Fischbach et al. en *Journal of Systems and Software* (Q1 JCR).
- Antigua [19] y [23] (manuscritos sin datos): completadas con DOI y datos editoriales.
- Nuevas referencias [35] Bangor, [36] George & Mallery y [37] **Nunnally** añadidas como bases bibliográficas del análisis psicométrico.

La proporción de revistas Q1 JCR sube de 5 a 7 (*EmSE*, *JSS*, *IEEE TSE*, *IEEE Software*, *Inf. & Softw. Technology*, ×2 nuevas).

Atendido parcialmente

R5. Verificar el dato del 64.3 % de uso de Claude/GPT-4 en la RSL (Crit. 3).

Estado en V001: Atendido parcialmente.

La línea 1151 ahora atribuye el 64.3 % **únicamente a GPT-4** (no a Claude 3.5 Sonnet, que se sustenta por evaluación multicriterio aparte). Esto resuelve la inconsistencia más grave. Sin embargo, persiste un problema temporal: **GPT-4 fue lanzado en marzo de 2023**, pero los 28 estudios primarios cubren “el período 2007–2024” (línea 811). Es matemáticamente improbable que 18 de 28 estudios hayan referenciado un modelo lanzado a inicios de 2023. Se recomienda **(i)** aclarar que el 64.3 % se refiere específicamente a estudios de 2023–2024 dentro del corpus, o **(ii)** reportar la distribución de modelos por año (un sub-corpus por ventana temporal).

Observación atendida

R6. Añadir el *prompt* y el corpus de especificaciones como anexos (Crit. 8).

Estado en V001: Atendido completamente.

- **Anexo 14:** contiene tres plantillas completas (unitarias, componentes, sistema) con el *prompt* íntegro: instrucciones de formato JSON estricto, filosofía TDD explicada al modelo, reglas de inferencia del módulo de importación, casos correctos e incorrectos como *few-shot examples*, y especificación detallada de cada campo del JSON de salida. Es un Anexo de gran calidad técnica.
- **Anexo 16:** contiene especificaciones representativas del corpus utilizado en los estudios (CU, RF y HU). Permite reproducir los 70 intentos de generación.

Atendido parcialmente

R7. Calcular y reportar IC95 %, prueba de normalidad y concordancia inter-jueces (Crit. 8).

Estado en V001: Atendido parcialmente: IC95 % sí; concordancia inter-jueces no.

Lo que sí se hizo:

- IC95 % del SUS calculado con $t_{0,025,24} = 2,064$: $74,82 \pm 2,55$, intervalo $[72,27, 77,37]$ (línea 1927). Cálculo correcto.
- r^2 de las correlaciones TAM con interpretación de Cohen: PU-IU = 0.506 (efecto grande), PEOU-IU = 0.339 (grande), CR-IU = 0.191 (mediano).
- Recálculo correcto de la DE global TAM mediante varianza ponderada: 0.62 (en V000 se reportaba erróneamente 0.63).

Lo que aún falta:

- La prueba de normalidad de Shapiro-Wilk no se aplicó. La autora lo *reconoce explícitamente como limitación* (línea 1927) apelando al Teorema Central del Límite, lo cual es defensible pero subóptimo.
- La concordancia inter-jueces (Krippendorff α , ICC) no se calculó. La autora justifica esto al señalar (línea 2193) que “el Estudio 2 contó con 10 expertos, tamaño adecuado para un piloto pero **insuficiente para análisis de concordancia inter-jueces robustos**”.
Observación crítica del revisor: esta justificación es discutible. Krippendorff α se puede calcular válidamente con $n_{\text{jueces}} = 10$ y $n_{\text{ítems}} = 15$; lo que resulta limitado es la *precisión* del estimador, no su *cómputo*. Sería más sólido reportar $\alpha = X.XX$ con su intervalo de confianza por bootstrap, dejando que el lector juzgue la fiabilidad.
- No se aplicó corrección por comparaciones múltiples (Bonferroni) a las 6 correlaciones de Pearson, pese a haberse recomendado.

Observación atendida

R8. Reescribir la introducción con objetivos, hipótesis, aporte y guía de lectura (Crit. 5).

Estado en V001: Atendido completamente, con un detalle a corregir.

La introducción (líneas 510–518) ahora incluye:

- Contextualización con cita [1].
- Identificación del vacío (“persiste un vacío relevante: las herramientas disponibles no resuelven el problema de origen”).
- Aporte diferencial explícito: “Su aporte diferencial respecto al estado del arte reside en la combinación de formularios de captura estructurada . . . con un módulo de generación, validación y exportación”.
- Remisión a objetivos en sección 1.2 (no se duplican).
- **Guía de lectura por capítulos** (línea 518).

2.3. Recomendaciones de prioridad media

Observación atendida

R9. Reescribir la justificación en presente y unificar tiempos verbales (Crit. 2).
Estado en V001: Atendido.

La justificación (líneas 582–592) está ahora íntegramente en presente: “responde”, “presenta”, “busca”, “permite”, “favorece”, “contribuye”. Cambio limpio respecto a V000.

Observación atendida

R10. Atenuar la afirmación de superioridad sobre PyTester (Crit. 9, 10).
Estado en V001: Atendido perfectamente.

Línea 2165: “Es importante precisar que esta métrica no es directamente comparable con la tasa del 78 % reportada por PyTester [9], cuyo criterio de validación es la ejecutabilidad efectiva de las pruebas en un entorno real, un estándar más exigente que la validación sintáctica.”

Línea 2181: “constituye una mejora aparente respecto al 78 % reportado por PyTester [9] en una métrica adyacente, aunque no estrictamente comparable: mientras TDDMachine mide validez sintáctica mediante verificación AST, PyTester mide ejecutabilidad efectiva en entorno real, un criterio más exigente.”

La precisión técnica es ejemplar; las afirmaciones se reformularon con la medida científica adecuada.

Observación atendida

R11. Incorporar análisis estadístico de la diferencia entre tipos (96.4 / 91.7 / 83.3 %) (Crit. 8, 9).

Estado en V001: Atendido cualitativamente.

Línea 2165 discute la gradación con anclaje teórico: “los requisitos funcionales imponen restricciones explícitas que el modelo puede traducir directamente en aserciones concretas, mientras que las historias de usuario, al estar redactadas desde la perspectiva del usuario y no del sistema, introducen inferencias semánticas que incrementan la variabilidad”. Y se conecta con [8] Korrapolu et al.

Falta: la prueba estadística formal (χ^2 de homogeneidad o test exacto de Fisher entre las tres proporciones) que cuantifique si la diferencia 96.4 vs 83.3 % es estadísticamente significativa con $n_{\text{HU}} = 18$.

Observación atendida

R12. Definir todas las siglas en su primera aparición (Crit. 3).

Estado en V001: Atendido en general, con un par de detalles.

CBSE, JWT, ORM, SPA y CDN aparecen ahora desarrolladas. Persisten algunos casos limítrofes:

- “MVT” aparece sin definir aunque el contexto Django lo aclara.
- “CI/CD” aún se usa sin desarrollar (línea 1830).

Observación atendida

R13. Estandarizar terminología (TDDMachine, pytest, frontend, backend) (Crit. 1, 3).

Estado en V001: Atendido.

“TDDMachine” aparece desde el resumen ejecutivo (línea 138) y se mantiene a lo largo del documento. “pytest” está consistentemente en minúsculas y cursiva. *frontend* y *backend* están siempre en cursiva.

Observación atendida

R14. Incluir un repositorio público con DOI (Zenodo) del código + datos (Crit. 8).

Estado en V001: Atendido en lo esencial.

El Anexo 15 declara dos repositorios reales en GitHub:

- *Frontend*: https://github.com/ktrianaa2/tddm_front
- *Backend*: https://github.com/ktrianaa2/tddm_back

Las plantillas de prompt están adicionalmente en el Anexo 14. La autora menciona Zenodo como recomendación futura (sección 5.3) pero aún no lo hizo. Para un trabajo de tesis, GitHub es suficiente; para publicación en revista científica, Zenodo + DOI sería preferible.

Observación atendida

R15. Ampliar la sección 2.2 con al menos 5 estudios empíricos comparativos (Crit. 6).

Estado en V001: Atendido.

La sección 2.2 (líneas 678–706) ahora cita explícitamente 5 estudios empíricos primarios con resultados cuantitativos: Lukasczyk et al. (EmSE Q1, cobertura del 36 % en Pyn-guin), Wang et al. (IEEE TSE Q1, survey de 102 trabajos), Takerngsaksiri et al. (JSS Q1, 78 % en PyTester), Yang et al. (ASE 2024, 72–88 %), Korraprolu et al. (ISEC 2025, comparación de LLMs por tipo de especificación). Los repositorios sin sustento académico [25]–[29] están explícitamente diferenciados con una nota previa: “no constituyen estudios empíricos primarios y no deben equipararse con los trabajos publicados en las subsecciones anteriores” (línea 700).

Observación atendida

R16. Recalcular la desviación estándar agregada de la Tabla 50 (Crit. 8).

Estado en V001: Atendido perfectamente.

Tabla 50 ahora reporta $DE_{global} = 0.62$ (no 0.63 como en V000), y bajo la tabla se incluye la nota: “la desviación estándar global se calculó como raíz cuadrada de la varianza ponderada por número de ítems de cada constructo” (línea 1953). Esto es exactamente la corrección sugerida.

2.4. Recomendaciones de prioridad baja

Observación atendida

R17. Corregir errores tipográficos y oraciones truncadas (Crit. 1).

Estado en V001: Atendido casi totalmente.

- “LOS RIOS” → “LOS RÍOS” (línea 27) (OK)
- “Geoconda Arrieta S.” (sin conjunción): se corrigió, ahora dice “y Geoconda Arrieta S.”
- “CAPITULO” sin tilde → “CAPÍTULO” (OK)
- “especificas” → “específicas” (OK)
- Oración truncada de la línea 1635 (V000): el párrafo ahora cierra correctamente.
- “Tabla 46. En la **Tabla 46**” (duplicación): corregido.
- Dobles espacios antes de “permitió”, “Tabla 51”, “Tabla 52”: corregidos.

Observación atendida

R18. Discutir explícitamente por qué la Confianza en Resultados (3.76) es el constructo más bajo (Crit. 9).

Estado en V001: Atendido extensamente.

Línea 2171 dedica un párrafo completo: “El resultado más relevante del análisis TAM es que la Confianza en Resultados (CR = 3.76) fue el constructo con la puntuación más baja [...] los participantes interactuaron con la herramienta por primera vez durante una única sesión [...] La confianza en sistemas basados en IA generativa suele incrementarse con la experiencia de uso acumulada [...]” Excelente desarrollo, con cita a [14] Wang et al. (IEEE TSE).

3. Estado de los datos estadísticos (informe complementario)

Recordando los 31 análisis estadísticos identificados en el informe complementario sobre datos:

Análisis estadístico	Estado V001	Comentario
Estadística descriptiva (medias, DE, frecuencias)	Hecho	Mantenido
Alfa de Cronbach por constructo	Hecho	Mantenido
Correlación de Pearson entre constructos	Hecho	Mantenido
χ^2 entre tipos de especificación	Pendiente	La discusión es cualitativa, falta el contraste
IC95 % del SUS	Hecho	Línea 1927
r^2 con interpretación de Cohen	Hecho	Línea 1992
DE global TAM correctamente calculada	Hecho	Línea 1951

Análisis estadístico	Estado V001	Comentario
Prueba de normalidad Shapiro-Wilk	Pendiente	Reconocido como limitación; defensa por TCL
IC95 % de proporciones de éxito	Pendiente	Tabla 46 sin IC
Test exacto de Fisher entre tipos	Pendiente	No aplicado
Prueba t de una muestra (TAM vs 3.5)	Implícito	Argumentado en Ilustración 6
Tamaño del efecto d de Cohen	Pendiente	Solo se reporta r^2
Corrección Bonferroni de 6 correlaciones	Pendiente	No aplicada
Subescalas SUS (Usabilidad/Aprendibilidad)	Pendiente	Datos individuales SUS están, falta análisis
Análisis ítem-test del SUS y TAM	Pendiente	Datos individuales TAM se infieren existentes (boxplot)
PLS-SEM del modelo TAM	Pendiente	Recomendado para estudios futuros
Validez convergente (AVE) y HTMT	Pendiente	—
Mediación PEOU $\rightarrow$ PU $\rightarrow$ IU	Pendiente	—
ANOVA de medidas repetidas (tareas)	Pendiente	Tiempos individuales no reportados
Concordancia inter-jueces (Krippendorff α)	Pendiente	Reconocido en limitaciones
ICC, ANOVA mixto, GLMM, G-Theory, MFRM	Pendiente	Coherente con scope de tesis
Regresión logística (éxito generación)	Pendiente	70 filas individuales no reportadas
Análisis temático cualitativo S1 y S2	Hecho narrativo	Categorías sin frecuencias
Acuerdo inter-codificador (Cohen κ)	Pendiente	Solo un codificador implícito
Triangulación cuanti-cuali	Pendiente	—
Comparación con grupo control manual	Pendiente	Recomendado en sección 5.4
Análisis de costo y consumo de tokens	Mejorado	Línea 1019–1021 con detalles
Estudio panel longitudinal	Pendiente	Recomendado en sección 5.4

Síntesis estadística:

- Análisis nuevos ejecutados en V001 (**Hecho**): 4 (IC95 %, r^2 , DE global ponderada, costo de tokens detallado).
- Análisis pendientes pero *reconocidos como limitación* en el Capítulo V: 5.
- Análisis pendientes *sin reconocer*: 17.

4. Nuevas observaciones detectadas en V001

Nueva observación detectada en V001

N1. Inconsistencia en el número de capítulos descrito en la introducción.

La introducción (línea 518) afirma: “*El documento se organiza en **cuatro** capítulos. El Capítulo I [...] El Capítulo II describe la metodología [...]*”. Sin embargo, el documento real tiene **seis** capítulos (I, II, III, IV, V, VI), y el Capítulo II es “Marco Teórico” (no “Metodología”, que es el III). Reescribir el párrafo:

“El documento se organiza en seis capítulos. El Capítulo I establece el marco contextual: problema de investigación, objetivos y justificación. El Capítulo II presenta el marco teórico y referencial. El Capítulo III describe la metodología empleada, incluyendo el diseño de la revisión sistemática y los protocolos de validación empírica. El Capítulo IV presenta los resultados: producto desarrollado, comprobación mediante estudios SUS/TAM y rúbrica experta, manual de funcionamiento, discusión y conclusiones. El Capítulo V detalla las limitaciones, recomendaciones técnicas y metodológicas, y líneas de trabajo futuro. El Capítulo VI consolida la bibliografía consultada.”

Nueva observación detectada en V001

N2. Texto “Figura X” impreso dentro de los gráficos estadísticos generados con *matplotlib*.

Las ilustraciones 6, 7 y 8 (gráfico de barras TAM, diagrama de caja TAM, gráfico de radar TAM) tienen títulos embebidos “**Figura X. Resultados por constructo TAM vs. umbral de aceptación. ELABORACIÓN PROPIA.**” donde la “X” es un placeholder que nunca se reemplazó por un número. Aunque el rótulo del documento dice “Ilustración 6”, el gráfico mismo dice “Figura X”. Esto debe corregirse: (i) eliminar el título embebido en *matplotlib* (omitir `plt.title()`) y dejar que el rótulo de Word identifique la figura, o (ii) regenerar las imágenes con el número correcto.

Nueva observación detectada en V001

N3. Inconsistencia GPT-4 / 64.3% en estudios primarios 2007–2024.

Como se anotó en R5, el documento afirma que GPT-4 es “el modelo más frecuentemente referenciado, presente en 18 de 28 estudios (64,3%)”, pero los estudios cubren el período 2007–2024 (línea 811). GPT-4 fue lanzado en marzo de 2023; solo los estudios de 2023 y 2024 podrían haberlo referenciado. Si el corpus tiene 28 estudios distribuidos en 17 años, asumiendo distribución uniforme, hay solo ~3–4 estudios de 2023–2024. Que 18 de ellos referencien GPT-4 es matemáticamente improbable. **Acción sugerida:** aclarar qué subconjunto del corpus se refiere a la pregunta de investigación sobre LLMs (presumiblemente solo los más recientes) y reportar el porcentaje sobre ese subconjunto, no sobre los 28.

Nueva observación detectada en V001

N4. Inconsistencia en el separador de millares: “200,000” vs “200.000”.

Línea 706: “ventana de 200,000 tokens”. Línea 1151: “ventana de contexto extendida de 200.000 tokens”. Adoptar uno solo (en español académico es preferible “200.000”).

Nueva observación detectada en V001

N5. Defensa de la falta de Krippendorff α /ICC es discutible.

La autora justifica la ausencia de concordancia inter-jueces (línea 2193) declarando que $n = 10$ expertos es “insuficiente para análisis de concordancia inter-jueces robustos”. Esta afirmación es **técnicamente imprecisa**: Krippendorff α y ICC se calculan válidamente con $n_{\text{jueces}} = 10$ y $n_{\text{ítems}} = 15$; lo que es limitado es la *precisión* del estimador (intervalo de confianza ancho), pero el cómputo en sí es estándar. Sería más sólido reportar el coeficiente con su IC bootstrap, dejando que el lector interprete. Como mínimo, debería reformularse: “*El cálculo de concordancia inter-jueces (Krippendorff α) con $n=10$ jueces y 15 scripts arroja intervalos de confianza amplios; se reservó este análisis para estudios de validación con paneles de mayor tamaño*”.

Nueva observación detectada en V001

N6. Inconsistencia entre objetivo general y resumen.

El **objetivo general** (línea 570) habla de “automatizar la **gestión** de pruebas”. El **abstract** (línea 506) habla de “automatizar la **gestión del estado inicial** de pruebas”. El **texto de conclusiones** (línea 2185) coincide con el abstract. Recomendable: actualizar el objetivo general (sección 1.2.1) para que diga “automatizar la gestión del *estado inicial* de pruebas en proyectos TDD”, en línea con el alcance correctamente delimitado a la etapa Red.

Nueva observación detectada en V001

N7. “Capítulo VII” usado para Anexos rompe la convención de bibliografía.

El documento rotula los anexos como “CAPÍTULO VII” (línea 2287). En literatura académica los anexos suelen denotarse “Anexos” a secas, sin numeración de capítulo (puesto que el cuerpo del trabajo termina en la Bibliografía, Capítulo VI). No es un error, pero es heterodoxo.

Nueva observación detectada en V001

N8. Falta IC95 % de la tasa de éxito de generación (91.4 %).

La discusión (línea 2181) afirma que el 91.4 % es “mejora aparente respecto al 78 % de Py-Tester”. Aunque la afirmación se atenúa correctamente por la no equivalencia de métricas, conviene además reportar el **IC95 %** del 91.4 % con $n = 70$. Por el método de Wilson, $\text{IC95 \%}(0.914, 70) = [0.825, 0.961]$. Esto deja el límite inferior sobre el 78 %, lo que aporta una primera aproximación rigurosa.

Nueva observación detectada en V001

N9. Anexo 13 (estudios primarios para HU) y 14 (prompts) tienen rótulos correlativos en el índice pero la sección de cuerpo no muestra los Anexos 11, 12 y 13 expandidos.

Los Anexos 11, 12 y 13 (estudios primarios por tipo de especificación) son referenciados desde el cuerpo (línea 1147) pero el contenido de estos anexos no aparece desarrollado en el documento (solo se anuncia su existencia). Verificar que efectivamente estén presentes con el detalle prometido (autores, año, título, DOI, estándares descritos). Si no están desarrollados, agregarlos.

Nueva observación detectada en V001

N10. La caracterización del panel de 10 expertos sigue ausente.

En el informe estadístico se señaló (sección C.3) que el documento no caracteriza al panel: años de experiencia, sector (academia/industria), conocimiento previo de TDD/pytest. Esta observación **no fue atendida**. El texto sigue diciendo “10 expertos en ingeniería de software” sin más detalle (línea 1834). Es información esencial para juzgar la validez externa del Estudio 2.

5. Tabla maestra: 18 recomendaciones priorizadas y su estado

#	Recomendación V000	Prio.	Estado en V001
1	Insertar las 14 ilustraciones ausentes	Bloq.	Atendido
2	Crear el Capítulo V de Recomendaciones	Bloq.	Atendido
3	Corregir el formato de cursivas y negritas rotas	Alta	Atendido
4	Reemplazar referencia [8] y completar [5][19][23]	Alta	Atendido
5	Verificar el dato del 64.3 % en RSL	Alta	Parcial
6	Añadir el prompt y corpus como anexos	Alta	Atendido
7	IC95 %, normalidad, concordancia inter-jueces	Alta	Parcial (IC95 % sí; resto no)
8	Reescribir introducción con todos los elementos	Alta	Atendido
9	Reescribir justificación en presente	Media	Atendido
10	Atenuar afirmación sobre PyTester	Media	Atendido
11	Análisis estadístico de la asimetría 96.4/91.7/83.3 %	Media	Cualitativo (sin prueba estadística formal)

#	Recomendación V000	Prio.	Estado en V001
12	Definir todas las siglas	Media	Atendido
13	Estandarizar terminología	Media	Atendido
14	Repositorio público con DOI Zenodo	Media	Atendido (GitHub; Zenodo pendiente)
15	Ampliar sección 2.2 con estudios empíricos	Media	Atendido
16	Recalcular DE agregada de Tabla 50	Media	Atendido
17	Corregir errores tipográficos puntuales	Baja	Atendido
18	Discutir Confianza en Resultados (3.76)	Baja	Atendido

6. Recomendaciones residuales para una posible V002

A partir de las nuevas observaciones (N1–N10) y de las recomendaciones parcialmente atendidas, se sugiere una iteración menor V002 que aborde:

1. **Corregir la frase “cuatro capítulos”** (línea 518) por “seis capítulos” y rescribir el detalle por capítulo.
2. **Eliminar el placeholder “Figura X”** de los gráficos *matplotlib* (Ilustraciones 6, 7, 8). Solución técnica: cargar las imágenes con `plt.savefig(transparent=True, bbox_inches='tight')` sin `plt.title()`.
3. **Aclarar la cobertura temporal del 64.3 % de GPT-4**: reportar la distribución de modelos por año o restringir el porcentaje a estudios de 2023–2024.
4. **Estandarizar separadores de millares**: “200.000 tokens” en todas las apariciones.
5. **Calcular y reportar Krippendorff α** (con `krippendorffsalpha` en R o `simpledorff` en Python) sobre los 750 datos del Estudio 2; reportar el coeficiente con IC bootstrap.
6. **Alinear el objetivo general con el alcance “estado inicial”** de la herramienta (línea 570).
7. **Calcular IC95 % para 91.4 %** mediante método de Wilson y reportar [82.5 %, 96.1 %].
8. **Aplicar test exacto de Fisher** a la diferencia entre 27/28 (RF), 22/24 (CU), 15/18 (HU); reportar *p*-valor y odds ratio.
9. **Aplicar corrección de Bonferroni** a las 6 correlaciones de Pearson de la Tabla 52: $\alpha_{\text{adj}} = 0,05/6 = 0,0083$. Verificar cuáles correlaciones siguen siendo significativas con este umbral.
10. **Caracterizar el panel de 10 expertos**: añadir tabla con años de experiencia, sector, formación, conocimiento previo de TDD/pytest.
11. **Cambiar “CAPÍTULO VII — ANEXOS”** por simplemente “ANEXOS”.

12. **Verificar Anexos 11, 12, 13:** que estén efectivamente desarrollados con el detalle prometido (autores, año, título, DOI).

Esfuerzo estimado para V002: 1 a 2 semanas. La mayoría de los puntos son ediciones puntuales, no rediseños conceptuales.

7. Conclusión del revisor

La versión V001 representa un **salto cualitativo significativo** respecto a V000. La autora atendió 15 de las 18 recomendaciones priorizadas (83%) y, en los casos parcialmente atendidos, en general proporcionó justificación explícita o reconoció la limitación. La inserción de las 14 ilustraciones, la creación del Capítulo V, la depuración de la bibliografía, la incorporación del Anexo 14 con los prompts completos y el análisis estadístico inferencial básico (IC95%, r^2 con interpretación de Cohen, recálculo correcto de la DE global) son avances sustanciales que demuestran un rigor metodológico maduro.

Las observaciones nuevas (N1–N10) son en su mayoría *ediciones de pulido* más que defectos sustantivos. La inconsistencia del número de capítulos en la introducción y los placeholders “Figura X” en los gráficos son los aspectos más visibles para un evaluador externo y deberían corregirse antes de la sustentación.

Las debilidades estadísticas residuales (Krippendorff α , prueba de Fisher entre tipos, corrección de Bonferroni) están en su mayoría reconocidas como limitaciones del piloto, lo cual es una práctica metodológica honesta y aceptable para un trabajo de Ingeniería de pregrado.

Calificación global de madurez del manuscrito: 9/10 (*listo para sustentación con ajustes menores*; antes era 7/10).

Fin del informe.