

Informe de Revisión Crítica

Tesis: *Herramienta CASE para la generación de pruebas de usuario a partir de requisitos mediante inteligencia artificial generativa*

Autora: Triana Arrieta, Kerly Mikaela — Versión V000

Revisión científica y editorial

4 de mayo de 2026

Resumen

El presente informe contiene una revisión sistemática del documento de tesis indicado, organizada según los once criterios solicitados. Se utiliza la regla de *arrastre de observaciones*: las limitaciones detectadas en una sección anterior se incorporan a las recomendaciones de la sección posterior. La revisión se basa en la lectura íntegra del manuscrito (2310 líneas, 54 tablas, 14 ilustraciones, 12 anexos y 35 referencias bibliográficas).

Índice

1. Resumen ejecutivo	2
2. Criterio 1 — Ortografía y aspectos editoriales	3
2.1. Hallazgos sistemáticos	3
2.2. Errores ortográficos y de tipografía detectados	3
2.3. Inconsistencias terminológicas	4
3. Criterio 2 — Tiempos verbales por sección	4
3.1. Diagnóstico general	4
3.2. Hallazgos por sección	4
4. Criterio 3 — Términos técnicos e idioma	5
4.1. Uso correcto y bien justificado	5
4.2. Términos no definidos en su primera aparición	5
4.3. Anglicismos crudos sin necesidad	6
4.4. Errores conceptuales puntuales	6
5. Criterio 4 — Referenciación de elementos visuales y tabulares	7
5.1. Inventario	7
5.2. Hallazgos críticos	7
5.3. Tablas correctamente referenciadas	7
5.4. Errores específicos en referencias	7
5.5. Otros problemas en tablas	8
6. Criterio 5 — Completitud de la introducción	8
6.1. Estructura observada	8
6.2. Elementos esperados y su presencia	8

7. Criterio 6 — Calidad del estado del arte (estudios primarios)	9
7.1. Estructura del marco referencial (sección 2.2)	9
7.2. Carácter de las fuentes	9
7.3. Estudios primarios empíricos identificados	9
7.4. Cobertura temporal	10
8. Criterio 7 — Calidad científica de las referencias	10
8.1. Análisis de las 35 referencias bibliográficas	10
8.2. Resumen cuantitativo	11
9. Criterio 8 — Reproducibilidad metodológica y análisis estadístico	12
9.1. Reproducibilidad de la metodología	12
9.2. Materiales no completamente especificados	12
9.3. Análisis estadístico	13
10. Criterio 9 — Resultados y discusión	14
10.1. Presentación de resultados	14
10.2. Debilidades en la presentación	14
10.3. Calidad de la discusión (sección 4.4)	14
11. Criterio 10 — Conclusiones vinculadas a objetivos	15
11.1. Estructura	15
11.2. Aspectos a mejorar	15
12. Criterio 11 — Recomendaciones y trabajos futuros	16
12.1. Hallazgo crítico	16
12.2. Limitaciones identificadas en el documento (insumo para la sección faltante)	16
12.3. Estructura sugerida para la nueva sección	17
13. Síntesis priorizada de recomendaciones	17
14. Comentario final	18

1. Resumen ejecutivo

El documento presenta un trabajo tecnológico sólido en su concepción, con un alcance bien delimitado (etapa *Red* del ciclo TDD), una arquitectura coherente (React 18 + Django 4.2 + PostgreSQL 15 + API de Claude 3.5 Sonnet) y dos estudios empíricos complementarios (SUS/TAM con 25 participantes y rúbrica experta con 10 evaluadores). Sin embargo, presenta debilidades importantes que deben subsanarse antes de la sustentación: **(i)** *todas* las ilustraciones (14) carecen de archivo gráfico — únicamente se incluye el rótulo y la fuente, sin la figura misma; **(ii)** hay contradicciones internas en el reporte; **(iii)** la bibliografía mezcla fuentes de calidad alta (IEEE TSE Q1, JSS Q1, EmSE Q1) con un *preprint* arXiv sin revisión por pares y al menos una referencia presumiblemente predatoria (*Indian Journal of Science and Research*); **(iv)** no existe sección formal de *Recomendaciones* / *Trabajos futuros* pese a que el índice y el ámbito académico del documento la requieren; **(v)** hay inconsistencias terminológicas (TDDMachine vs. “herramienta CASE”; *frontend/backend* en cursiva o redonda; “PyTest” vs. “pytest”) y errores tipográficos sistemáticos (espacios duplicados en negrita en cursiva).

Calificación global de madurez del manuscrito (orientativa): 7/10 (*requiere revisión mayor antes de sustentación*).

2. Criterio 1 — Ortografía y aspectos editoriales

2.1. Hallazgos sistemáticos

Hallazgo crítico

A lo largo del documento aparecen artefactos de procesamiento de Word que rompen la cursiva o la negrita en mitad de los términos técnicos en inglés, generando expresiones como “*Test **Driven Development***”, “*Computer-Aided **Software Engineering***” o “*System **Usability Scale***”. Esto afecta a prácticamente **todas** las apariciones de TDD, SUS, TAM, LLM y CASE en el texto. Es un defecto editorial generalizado.

2.2. Errores ortográficos y de tipografía detectados

- **Línea 107:** “LOS RIOS” debe escribirse “LOS RÍOS” (acento perdido respecto a la portada de la línea 19).
- **Línea 117:** “Ph.D.” aparece con espaciado y negritas inconsistentes (“**Ph.D.**”); estandarizar como “Ph.D.” a lo largo del documento.
- **Línea 127:** “*A mis padres, Samuel Triana G. Geoconda Arrieta S.,*” — falta la conjunción “y” entre ambos nombres.
- **Línea 502 y siguientes:** “CAPITULO II” y “CAPÍTULO III” alternan con y sin tilde; debe ser siempre “CAPÍTULO”.
- **Línea 576:** “CAPITULO II” (sin tilde).
- **Línea 686:** encabezado mal numerado: “METODOLOGÍA” tiene un salto de formato dentro de la palabra; corregir en el original.
- **Línea 726:** “Cadenas de búsqueda **especificas**” — debe ser “específicas” (esdrújula con tilde).
- **Línea 854:** “Diagrama de arquitectura general del sistema” — correcto, pero la **Ilustración 2** no está incluida (ver Criterio 4).
- **Línea 1635:** oración truncada: “[...] o incompatibilidad confirmada En la **Tabla 39**” — falta el punto y se corta el párrafo. Reescribir como: “[...] o incompatibilidad confirmada. En la Tabla 39 se presentan los resultados...”
- **Línea 855:** “4.1.5” aparece dos veces como referencia cruzada en la misma frase con espaciado distinto.
- **Línea 947:** “\$1.485 USD” usa punto como separador de miles, pero la Tabla 2 (línea 949) y el cuerpo del texto (línea 975) usan “\$1,485 USD”. Unificar al estilo anglosajón o al estilo hispano, pero no mezclar.
- **Línea 1117:** “200.000 tokens” — el modelo Claude 3.5 Sonnet tiene una ventana de contexto de 200,000 tokens; el formato es correcto en español, pero el resto del documento alterna “1,485” y “1,485”. Estandarizar.
- **Línea 1799:** “Tabla 46 . En la **Tabla 46**” — el rótulo aparece duplicado de manera consecutiva; revisar la generación automática de referencias.
- **Línea 1891:** “el cuestionario cualitativo permitió” — doble espacio antes de “permitió”.

- **Línea 1917 y 1935:** “Tabla 51” y “Tabla 52” aparecen con doble espacio antes de la siguiente palabra.

2.3. Inconsistencias terminológicas

- **TDDMachine vs. “herramienta CASE”:** a partir de la sección 3.1.1 se introduce el nombre propio *TDDMachine*, pero ni el resumen, ni el abstract, ni la introducción, ni el planteamiento del problema lo mencionan. **Recomendación:** introducir el nombre del artefacto desde el resumen ejecutivo y mantenerlo consistente.
- **“pytest” vs. “PyTest” vs. “Pytest”:** la documentación oficial del *framework* de pruebas Python lo escribe en minúsculas (*pytest*). El documento alterna las tres formas de manera arbitraria (cf. líneas 140 vs. 1338 vs. 1709). **Adoptar siempre “pytest”.**
- **“frontend” / “backend”:** aparecen unas veces en cursiva (correcto, por ser anglicismos) y otras en redonda (líneas 921, 943). Unificar siempre en cursiva.
- **“testing” / “pruebas”:** el documento alterna ambos términos. En español académico se prefiere “pruebas de software”; reservar “*testing*” (en cursiva) para nombres propios como “*testing* automatizado”.
- **Comillas tipográficas vs. rectas:** la mayoría son rectas (“ ”); en español académico deben ser angulares (« ») o, en su defecto, tipográficas dobles (“ ”). Unificar.

3. Criterio 2 — Tiempos verbales por sección

3.1. Diagnóstico general

La norma estándar en escritura científica es: **introducción y marco teórico en presente** (verdades aceptadas), **metodología y resultados en pasado simple** (lo que el autor hizo), **discusión y conclusiones en presente** (interpretación de los hallazgos), **trabajo futuro en condicional / futuro simple**. El documento no aplica esta convención de manera uniforme.

3.2. Hallazgos por sección

Observación importante

Justificación (sección 1.3, líneas 564–574): se redacta íntegramente en *pretérito perfecto simple* (“respondió”, “buscó”, “permitió”, “favoreció”, “contribuyó”). La justificación, por su naturaleza argumentativa, debe escribirse en **presente**: “el presente proyecto *responde* a la creciente necesidad...”, “la propuesta tecnológica *busca* desarrollar...”, “la aplicación práctica *favorece*...”. Sólo la *conclusión* puede pasar a pretérito.

Observación importante

Pronóstico (sección 1.1.1, líneas 528–534): se utiliza el condicional simple (“continuaría aumentando”, “seguiría siendo”, “perpetuaría”) que es correcto, pero alternado con el subjuntivo imperfecto (“si no se resolviera”, “de no ser resuelto”). **Mantener un único tiempo** a lo largo de los tres párrafos.

Observación importante

Marco teórico (Capítulo II): predomina correctamente el presente, pero hay deslices puntuales al pretérito (“*ha mostrado resultados prometedores*”, “*Estudios recientes han explorado*”, línea 640) que son aceptables. Sin embargo, se recomienda eliminar los pretéritos perfectos compuestos en favor del presente cuando sea posible.

Hallazgo crítico

Metodología (Capítulo III): la sección debería estar uniformemente en *pretérito* (lo que se hizo), pero presenta saltos al *presente*: “*La cadena de búsqueda se construyó utilizando...*” (correcto, línea 712) seguido de “*Las cadenas se estructuraron...*” (correcto), pero también “*Cada criterio recibe un peso porcentual...*” (línea 831, debe ser “recibió”) y “*El sistema debe completar la generación...*” (en las tablas de RNF). Los *requisitos no funcionales* sí pueden estar en presente porque son especificaciones permanentes, pero el resto de la metodología debe estar en pretérito.

Hallazgo crítico

Resultados (Capítulo IV): mayoritariamente en pretérito (correcto), pero los *Hallazgos cualitativos* (líneas 1893–1897, 2019–2025) saltan al presente (“*los expertos coinciden...*”, “*la mayoría valora positivamente...*”). Si la observación se limita al estudio realizado, debe ser pretérito (“coincidieron”, “valoró”). Si se generaliza al universo, el presente sería válido, pero esa generalización no está justificada con $n=10$ y $n=25$.

Aspecto positivo

Conclusiones (sección 4.5): los tres párrafos centrales utilizan correctamente el pretérito (“*permitió obtener*”, “*demonstró ser técnicamente viable*”, “*produjo scripts*”). Es la sección con mejor consistencia verbal del documento.

4. Criterio 3 — Términos técnicos e idioma

4.1. Uso correcto y bien justificado

Aspecto positivo

Los términos técnicos centrales están bien empleados: *Test Driven Development*, *System Usability Scale*, *Technology Acceptance Model*, *árbol sintáctico abstracto (AST)*, *Component-Based Software Engineering (CBSE)*, *coeficiente Alfa de Cronbach*, *coeficiente de correlación de Pearson*. La definición de cada acrónimo aparece en la primera mención (excepto las observaciones a continuación).

4.2. Términos no definidos en su primera aparición

- **CBSE:** aparece por primera vez en la línea 859 sin definición. Se desarrolla más tarde (*Component-Based Software Engineering*), pero la primera mención debe contener la forma extendida.

- **MVT (*Model-View-Template*)**: línea 841 — definir; lectores no familiarizados con Django pueden confundirlo con MVC.
- **JWT**: línea 1232 — definir como *JSON Web Token* en su primera aparición.
- **PICOC**: línea 712 — aunque se desglosa, conviene mencionar que es una variante del marco PICO de revisiones sistemáticas.
- **CDN**: línea 917 — definir *Content Delivery Network*.
- **CI/CD**: línea 1788 — definir *Continuous Integration / Continuous Deployment*.
- **ODS**: línea 572 — aunque se infiere, indicar “Objetivos de Desarrollo Sostenible (ODS) de la ONU”.
- **ORM**: línea 1771 — definir *Object-Relational Mapping*.
- **SPA**: línea 1715 — definir *Single-Page Application*.

4.3. Anglicismos crudos sin necesidad

- “*overhead*” (líneas 530, 604, 622, 658) — sustituir por “sobrecoste”, “coste adicional” o “carga adicional”.
- “*wrappers*” (línea 861) — traducir como “envoltorios” (que ya aparece) y dejar el término inglés solo entre paréntesis en la primera mención.
- “*webhooks*” (línea 917) — explicar la primera vez (“ganchos web”).
- “*backoff* exponencial” (línea 925) — preferible “espera exponencial” (que ya se usa en otra parte).
- “*commit*” (línea 1792) — en español: “confirmación”.

4.4. Errores conceptuales puntuales

Observación importante

Línea 1117: “Claude 3.5 Sonnet (Anthropic) y GPT-4 (OpenAI) fueron reportados en 18 de 28 estudios (64,3 %) como modelos de preferencia”. Este dato es metodológicamente sospechoso: *Claude 3.5 Sonnet* fue lanzado en junio de 2024 y *GPT-4* en marzo de 2023. Es matemáticamente imposible que el 64 % de 28 estudios primarios (cuyas fechas pueden remontarse a 2007–2024 según los anexos) hayan usado un modelo lanzado a mediados de 2024. La revisión sistemática no puede cubrir tantos años *y* contener solamente modelos recientes. Aclarar el rango temporal exacto de los estudios primarios y verificar los porcentajes; lo más probable es que se haya confundido el corpus de la RSL con un corpus de *benchmarks* comparativos.

Observación importante

Línea 1917: “*quienes establecen como aceptable un coeficiente $\alpha \geq 0,70$* ”. La cita correcta es George & Mallery (*SPSS for Windows*); además, el umbral 0.70 también lo establece Nunnally (1978), referencia más canónica que conviene incluir.

Observación importante

Línea 1462: “*Claude 3.5 Sonnet*” aparece en el RNF; en otras secciones se escribe “Claude Sonnet 3.5” (línea 967), “Claude 3.5 Sonnet” (línea 1117) y “Claude (Anthropic)” (línea 925). El nombre oficial del modelo es “Claude 3.5 Sonnet”. Estandarizar.

5. Criterio 4 — Referenciación de elementos visuales y tabulares

5.1. Inventario

El documento contiene, según los índices: **14 ilustraciones** y **54 tablas**. He auditado cada elemento contra el cuerpo del texto.

5.2. Hallazgos críticos

Hallazgo crítico

Las 14 ilustraciones carecen de archivo gráfico. En el cuerpo del documento aparecen únicamente los rótulos “Ilustración *N*” seguidos de “Elaborado por: Autor”, sin la imagen entre ambos. Esto es inaceptable en una versión final: *ningún* diagrama, captura de pantalla o gráfico está realmente incluido. Verificar que se trata de una versión incompleta o, en caso contrario, incorporar las 14 figuras antes de la sustentación.

5.3. Tablas correctamente referenciadas

Las 54 tablas *sí* están todas referenciadas en el texto, en algunos casos con doble referencia (descriptiva y de cierre). Aspecto positivo destacable.

5.4. Errores específicos en referencias

- **Tabla 1** (línea 726): el cuerpo se anuncia (“En la Tabla 1 se presentan...”) pero a continuación se inserta el contenido sin que el rótulo de la tabla aparezca centrado/numerado de manera visible. Verificar el estilo de tabla en el procesador.
- **Ilustración 1 (Cronograma)** (línea 929): se menciona “Cronograma de actividades” pero no se incluye el diagrama de Gantt esperado.
- **Ilustración 2 y 3** (Arquitectura y Componentes): líneas 1694, 1719 — se menciona en el texto pero no se inserta el diagrama UML/C4.
- **Ilustraciones 4 y 5** (módulos): líneas 1729, 1757 — son capturas de pantalla esenciales para un manual de funcionamiento; ausentes.
- **Ilustraciones 6, 7 y 8** (TAM): líneas 1958, 1966, 1974 — son las *visualizaciones estadísticas* que sustentan la sección 4.2.5. Su ausencia hace ininteligibles los párrafos de análisis que siguen a cada rótulo.
- **Ilustraciones 9–14** (Manual): líneas 2045–2115 — el manual de funcionamiento sin las capturas de pantalla pierde casi todo su valor pedagógico.

- **Tabla 7 a Tabla 9:** en el texto se menciona “El detalle de cada estudio seleccionado analizado se encuentra en el Anexo 10” (línea 1139). Pero la tabla 8 remite al Anexo 11 (línea 1161) y la 9 al Anexo 12 (línea 1185). Esta correspondencia es correcta, pero conviene declararla explícitamente al inicio de la sección 4.1.1 para evitar confusiones.

5.5. Otros problemas en tablas

- **Tabla 2** (línea 951): los costos de software listan “React 18” bajo la categoría “Software - IDE y Editores” — categoría incorrecta, debería ir bajo “*Frontend* - Bibliotecas”.
- **Tabla 39, 40, 41:** las pesos en porcentajes (25 %, 20 %, etc.) deben totalizar 100 %; en la tabla 39 suman correctamente, pero conviene verificar las tres y reportar el total al pie.
- **Tablas 47–49:** la columna “Clasificación” del puntaje SUS aplica los rangos de Bangor pero éstos deben citarse en el pie de tabla (no sólo en el texto que las sigue).
- **Tabla 50:** la última fila “Promedio global” presenta la desv. est. como 0.63 (suma simple), cuando la *desviación estándar agregada* debe calcularse a partir de la varianza ponderada, no como promedio aritmético de desviaciones. Recalcular.

6. Criterio 5 — Completitud de la introducción

6.1. Estructura observada

La introducción (líneas 492–500) consta de cuatro párrafos: contexto, problema (TDD), tecnología (IA generativa) y propuesta. **Es muy breve** (alrededor de 480 palabras) para una tesis de Ingeniería.

6.2. Elementos esperados y su presencia

Elemento	Presente	Comentario
Contextualización del área (pruebas de SW)	Sí	Párrafo 1
Identificación del vacío de investigación	Parcial	No se cuantifica el vacío con datos
Justificación de la metodología elegida	No	No se menciona TDD como elección
Objetivo general	No	Está sólo en la sección 1.2
Objetivos específicos	No	Sólo en la sección 1.2
Hipótesis o preguntas de investigación	No	Sólo aparecen como RQ en la metodología
Aporte / contribución del trabajo	Insuficiente	Falta enunciado explícito
Estructura del documento	No	Esencial; no aparece
Limitaciones del trabajo	No	Aparecen sólo en discusión

Hallazgo crítico

La introducción carece de cuatro elementos canónicos: **(i)** enunciado del objetivo general, **(ii)** preguntas de investigación o hipótesis, **(iii)** aporte específico de este trabajo respecto al estado del arte (*¿qué hace TDDMachine que ningún otro hace?*), y **(iv)** la guía de lectura del documento (un párrafo final del tipo “el capítulo I presenta..., el capítulo II revisa...”).

Recomendación

Reestructurar la introducción siguiendo el esquema CARS (*Create A Research Space*) de Swales: (1) establecer el territorio (presente), (2) identificar el nicho (vacío), (3) ocupar el nicho (objetivo + aporte). Añadir un quinto párrafo con la estructura del documento por capítulos.

7. Criterio 6 — Calidad del estado del arte (estudios primarios)

7.1. Estructura del marco referencial (sección 2.2)

El marco referencial (líneas 660–680) es **breve** (aproximadamente 350 palabras) y se divide en tres subsecciones: *frameworks* académicos, herramientas de análisis texto-a-pruebas y prototipos *open source*. Discute brevemente *ChatUniTest* [25], *TestSpark* [26], *Pynguin* [27], *PyTester* [10], *PyTestAI* [28], *Test Case Generation Agent* [29], *UnitGenAI* [30], *AutoGen Test Generator* [31] y *RAG Test Case Generator* [32].

7.2. Carácter de las fuentes

Observación importante

Las referencias [28], [29], [30], [31] y [32] son repositorios de GitHub, no estudios científicos. Aunque su mención puede ser legítima como “estado del arte tecnológico”, no son estudios empíricos primarios y no deberían computarse al lado de *ChatUniTest* (publicado en FSE 2024) o *Pynguin* (ISSTA 2022). Diferenciar claramente, por ejemplo, en una tabla comparativa, “herramientas con sustento académico” vs. “prototipos comunitarios”.

7.3. Estudios primarios empíricos identificados

Sí hay estudios primarios empíricos correctamente citados en el marco teórico (no en el referencial):

- 2 Lukasczyk *et al.*, *Empirical Software Engineering* (Q1 JCR) — estudio empírico sobre *Pynguin*.
- 9 Korraprolu *et al.*, ISEC 2025 — estudio comparativo de LLMs.
- 10 Takerngsaksiri *et al.*, *Journal of Systems and Software* (Q1 JCR) — estudio empírico de *PyTester*.
- 16 Wang *et al.*, *IEEE Transactions on Software Engineering* (Q1 JCR) — *survey* con 102 trabajos analizados.

- 17 Ghafari *et al.*, ESEM 2020 — mapeo empírico sobre TDD.
- 22 Yang *et al.*, ASE 2024 — evaluación empírica de LLMs en pruebas unitarias.

Aspecto positivo

La presencia de [2], [10], [16] y [22] es excelente: son estudios empíricos primarios en revistas/congresos top-tier directamente relevantes al problema.

Hallazgo crítico

Sin embargo, el **marco referencial** (sección 2.2) cita mayoritariamente *frameworks* y prototipos, y no estudios empíricos. La diferencia entre marco *teórico* y marco *referencial* en este documento es difusa. **Recomendación:** en la sección 2.2, presentar al menos 5 estudios empíricos comparativos (no solo herramientas) que evalúen LLM-based test generation, con su muestra, métrica y resultado. Por ejemplo: Yang *et al.* 2024 [22] reporta tasas de éxito específicas que deben confrontarse con el 91.4 % obtenido por TDDMachine. Esto refuerza enormemente la sección 4.4 (Discusión).

7.4. Cobertura temporal

La RSL declara haber analizado 28 estudios primarios. La cobertura temporal aparente (a partir de los Anexos 10–12) va de **2007 a 2024**. Esto es problemático para un trabajo cuyo objeto central es la generación con LLMs (tecnología post-2020). Conviene reportar histograma de años y justificar por qué se incluyen estudios de 2007 que no podían tratar este problema.

8. Criterio 7 — Calidad científica de las referencias

8.1. Análisis de las 35 referencias bibliográficas

He clasificado cada referencia por tipo de fuente y, para las publicadas en revista, por cuartil JCR/SJR (datos verificados al 2024–2025).

[N]	Fuente	Calidad
[1]	ACM Conf. (<i>Internet of Things</i>)	Conferencia ACM, sin cuartil JCR — aceptable
[2]	<i>Empirical Software Engineering</i> (Springer)	Q1 JCR / Q1 SJR
[3]	Springer Lecture Notes (libro)	Capítulo de libro — aceptable
[4]	arXiv preprint	Sin revisión por pares
[5]	Manuscrito Garousi <i>et al.</i>	Faltan datos de publicación
[6]	Springer Lecture Notes (libro)	Capítulo de libro
[7]	arXiv preprint	Sin revisión por pares
[8]	<i>Indian J. of Science and Research</i>	Posible revista predatoria

[N]	Fuente	Calidad
[9]	ACM ISEC	Conferencia revisada
[10]	<i>Journal of Systems and Software</i>	Q1 JCR / Q1 SJR
[11]	<i>Software: Practice and Experience</i>	Q2 JCR / Q1 SJR
[12]	Libro Springer (Juristo & Moreno)	Libro — acceptable
[13]	IEEE QSIC 2013	Conferencia IEEE
[14]	DOI ACM 2024 (datos truncados)	Conferencia ACM
[15]	FOSE 2007 (Bertolino)	Conferencia clásica
[16]	<i>IEEE Trans. Software Engineering</i>	Q1 JCR (IF 6.78)
[17]	ACM/IEEE ESEM 2020	Conferencia top
[18]	<i>J. of Software Eng. Research & Dev.</i>	SJR Q3-Q4
[19]	Manuscrito Santos <i>et al.</i> 2018	Faltan datos de publicación
[20]	<i>Electronics</i> (MDPI)	Q2 JCR / Q1–Q2 SJR
[21]	ICSE Companion 2024	Conferencia top
[22]	ACM ASE 2024	Conferencia top (CORE A*)
[23]	Baqar & Khanda 2025	Faltan datos de publicación
[24]	<i>IEEE Software</i>	Q1–Q2 JCR
[25]	ACM FSE 2024 (<i>ChatUniTest</i>)	Conferencia top
[26]	ICSE Companion 2024 (<i>TestSpark</i>)	Conferencia top
[27]	ACM 2022 (<i>Penguin</i>)	Conferencia ISSTA — top
[28]–[32]	Repositorios GitHub	No académicos
[33]	<i>Technological & Economic Dev.</i>	SJR Q1–Q2
[34]	Saaty 1980 (libro)	Libro clásico
[35]	<i>Information & Software Tech.</i>	Q1 JCR

8.2. Resumen cuantitativo

- Revistas Q1 JCR: 5 ([2], [10], [16], [24], [35])
- Revistas Q2 JCR: 2 ([11], [20])
- Conferencias top (CORE A/A*): 8
- Capítulos de libro / libros: 5
- Preprints arXiv (sin pares): 2 ([4], [7])
- Repositorios GitHub: 5 ([28]–[32])
- Revistas posiblemente predatorias o sin trazabilidad: 4 ([5], [8], [19], [23])

Hallazgo crítico

La referencia [8] “**Indian Journal of Science and Research**” es altamente sospechosa de ser una publicación predatoria: no figura en JCR ni en SJR, y la URL ijsronline.org muestra los signos típicos (claim de *impact factor* no validado, publicación rápida, ausencia de indexación reconocida). **Se recomienda eliminarla** y sustituirla por una referencia equivalente de fuentes Q1–Q2 (existen abundantes *surveys* sobre *manual vs. automated testing* en IEEE/ACM).

Hallazgo crítico

Las referencias [4], [5], [7], [19] y [23] carecen de datos editoriales completos o son *preprints* arXiv. Aunque arXiv es válido para fuentes recientes, debe (i) verificarse si el preprint ya tiene versión publicada y citar la versión revisada, (ii) indicar explícitamente “preprint, no revisado por pares” cuando se cite, y (iii) no superar el 10 % de las referencias totales (aquí superan el 14 %).

Observación importante

Las cinco referencias a repositorios de GitHub [28]–[32] son aceptables como *evidencia de existencia de prototipos comunitarios*, pero no como sustento científico de afirmaciones. Si se mantienen, agruparlas como “Software Repositories” al final de la bibliografía y diferenciarlas tipográficamente.

9. Criterio 8 — Reproducibilidad metodológica y análisis estadístico

9.1. Reproducibilidad de la metodología

Aspecto positivo

Aspectos altamente reproducibles: las cadenas de búsqueda de la RSL (Tabla 1), los criterios de inclusión/exclusión, el estándar ISO/IEC/IEEE 29148:2018 para los requisitos, la matriz multicriterio (Tablas 39–41), y los anexos 4 (SUS), 5 (TAM), 8 (rúbrica) y 9 (cuestionario cualitativo). El protocolo de tareas (Anexo 3) está bien detallado. La declaración explícita del modelo Claude 3.5 Sonnet, los parámetros (*ventana 200k tokens*) y el SDK utilizado permite reproducir el módulo de generación.

9.2. Materiales no completamente especificados

Observación importante

Falta el *prompt* estructurado. El módulo *PromptBuilder* es el corazón del trabajo, pero su *plantilla de prompt* no se incluye en ningún anexo. Sin ella, los resultados (91.4 % de éxito, 4.08/5.0) son irreproducibles. **Añadir Anexo: “Plantilla del prompt enviado a Claude 3.5 Sonnet por tipo de especificación”.**

Observación importante

Falta el conjunto de especificaciones de prueba. Los 70 intentos de generación se hicieron sobre 28 RF, 24 CU y 18 HU. Estas especificaciones concretas no están en los anexos. **Añadir Anexo con el corpus de especificaciones utilizadas.**

Observación importante

Faltan los 15 scripts evaluados por los expertos. El Estudio 2 evalúa “5 unitarias + 5 integración + 5 sistema”; sin los scripts, la evaluación de 4.08/5.0 no puede replicarse.

Observación importante

Repositorio del código. En toda tesis de software es práctica recomendada incluir el enlace a un repositorio público (GitHub/Zenodo con DOI) que contenga el código fuente, los *prompts*, los *datasets* y los *notebooks* de análisis estadístico. No se menciona ninguno.

9.3. Análisis estadístico

Aspecto positivo

Aciertos: se reporta $n=25$ (S1) y $n=10$ (S2); se calcula media, desviación estándar, mínimo y máximo (Tablas 47–53); se aplica Alfa de Cronbach por constructo y para el instrumento global (Tabla 51); se calcula la matriz de correlaciones de Pearson con niveles de significación (Tabla 52); y se justifica el umbral 0.70 con la referencia [23].

Hallazgo crítico

Carencias estadísticas:

1. **No se reporta intervalo de confianza** para ninguna de las medias TAM ni para el SUS global (74.82). Para $n=25$ y desviación estándar 6.18, el IC95 % del SUS es aproximadamente $74,82 \pm 2,55$.
2. **No se realiza prueba de normalidad** (Shapiro-Wilk) antes de aplicar Pearson; para $n=25$ esto puede comprometer la validez de las correlaciones reportadas, sobre todo si los datos están sesgados.
3. **No se reporta tamaño del efecto.** Pearson da significación pero no magnitud práctica; reportar r^2 o el d de Cohen entre subgrupos.
4. **Acuerdo entre expertos no medido.** Los 10 expertos evaluaron 15 scripts pero no se calcula *concordancia inter-jueces* (Kendall W , Krippendorff α , ICC), lo cual es esencial para validar una rúbrica con múltiples evaluadores.
5. **La desviación estándar agregada** de la fila “Promedio global” de la Tabla 50 (0.63) parece calculada como promedio de desviaciones, lo cual es estadísticamente incorrecto.
6. **Tamaños muestrales pequeños.** $N=25$ y $n=10$ son adecuados para estudio piloto pero deben acompañarse de un cálculo de potencia post-hoc o un reconocimiento explícito como limitación.
7. **Comparación 91.4 % vs. 78 % (línea 2135).** La afirmación “superior al 78 % reportado por PyTester” carece de prueba estadística (test exacto de Fisher o χ^2) y de control por confounders (tipo de especificación, dificultad, etc.).

10. Criterio 9 — Resultados y discusión

10.1. Presentación de resultados

Aspecto positivo

La sección 4 está bien estructurada: producto desarrollado (4.1), comprobación (4.2), manual (4.3), discusión (4.4) y conclusiones (4.5). Las tablas son numerosas y descriptivas. Los hallazgos cualitativos por categorías (positivos, dificultades, sugerencias) son una práctica adecuada.

10.2. Debilidades en la presentación

Hallazgo crítico

Las ilustraciones que sustentan los resultados estadísticos están ausentes (cf. Criterio 4). Los párrafos analíticos de las líneas 1956–1978 hacen referencia a “el gráfico de radar refleja...”, “el diagrama de caja confirma...” que son afirmaciones vacías sin la imagen.

Observación importante

Tabla 50 (TAM): dice $n=25$ pero la fila “Promedio global” muestra 16 ítems, lo que confunde. El $n=25$ es de *participantes*, no de ítems. Reescribir el rótulo.

Observación importante

Tabla 47 (caracterización): la suma del 60 % + 40 % (género) y de los demás bloques es correcta, pero falta declarar cómo se manejaron los datos faltantes (si los hubo) y si se ofreció una opción “otro” o “prefiero no responder”.

10.3. Calidad de la discusión (sección 4.4)

Aspecto positivo

La discusión está **estructurada por objetivos específicos** (3 párrafos, uno por objetivo), lo cual es excelente. Compara los resultados con *Pynguin*, *EvoSuite*, *ChatUniTest*, *TestSpark* y *PyTester*. Reconoce limitaciones (línea 2127).

Hallazgo crítico

Limitaciones de la discusión:

1. No discute los resultados frente a *estudios empíricos comparativos* (los benchmarks publicados en [16], [22]). Sólo se compara con *herramientas*.
2. La afirmación de superioridad sobre PyTester (91.4 % vs 78 %, línea 2135) compara métricas *no equivalentes*: la métrica de Pytester es la tasa de pruebas *ejecutables* mientras que la métrica de TDDMachine es *sintácticamente válida (AST)*. Son criterios distintos. Atenuar la afirmación.
3. No se discute por qué la *Confianza en Resultados* (3.76) es el constructo TAM más bajo. Es el hallazgo más interesante y debería desarrollarse.
4. No se discute la diferencia entre los tres tipos de especificación (96.4 % RF, 91.7 % CU, 83.3 % HU). Es una tendencia clara que merece análisis.
5. No se confronta el SUS de 74.82 con benchmarks publicados de herramientas de *testing* (típicamente 65–75 según Bangor).

11. Criterio 10 — Conclusiones vinculadas a objetivos

11.1. Estructura

Las conclusiones (líneas 2129–2137) presentan **tres párrafos, uno por objetivo específico**, antecedidos por un encabezado que recuerda el objetivo general. Esta estructura cumple con las buenas prácticas.

Aspecto positivo

Cada conclusión cita explícitamente la referencia del trabajo relacionado con el que se contrasta el resultado: [4], [9], [10], [20], [25] y [26]. Esto vincula la conclusión con el estado del arte, cumpliendo el criterio 10 solicitado por el revisor.

11.2. Aspectos a mejorar

Observación importante

El objetivo general no se concluye explícitamente. Las tres conclusiones particulares (una por OE) están bien, pero falta un párrafo final que sintetice el cumplimiento del **objetivo general**: “*En conjunto, los tres módulos validan...*” (línea 2137) está, pero conviene escribir explícitamente “El objetivo general — desarrollar una aplicación web que automatice la gestión de pruebas... — ha sido cumplido mediante...”.

Observación importante

La conclusión 2 (línea 2135) afirma “este resultado es superior al 78 % reportado por PyTester [10]”. Como ya se anotó, las métricas no son equivalentes (*válido sintácticamente* vs. *ejecutable*). Reescribir como: “*este resultado constituye una mejora aparente respecto al 78 % reportado por PyTester [10] en una métrica adyacente, aunque no estrictamente comparable*”.

Recomendación

Añadir un párrafo final con el **aporte original** sintetizado en una frase: “*La principal contribución de este trabajo es . . . , lo que diferencia a TDDMachine de . . . y abre la posibilidad de . . .*”.

12. Criterio 11 — Recomendaciones y trabajos futuros

12.1. Hallazgo crítico

Hallazgo crítico

No existe sección de Recomendaciones / Trabajos Futuros. El índice del documento (líneas 156–310) salta directamente de *Conclusiones* (4.5) a *Bibliografía*. Las menciones a trabajos futuros aparecen *intercaladas* en la discusión (línea 2127, párrafo final) y en la sección 4.2.5 (línea 1980), pero no están agrupadas en un capítulo dedicado. Esto incumple el formato académico estándar y lo solicitado en el criterio 11 de la revisión.

12.2. Limitaciones identificadas en el documento (insumo para la sección faltante)

A partir del análisis de los criterios 1–10, la sección de *Recomendaciones* debería incorporar al menos los siguientes puntos, derivados **por arrastre** de los hallazgos previos:

1. **Limitación derivada del Criterio 4 (figuras ausentes):** en una próxima iteración se debe verificar la integridad gráfica del documento generado y construir un sistema de *checklist* pre-entrega.
2. **Limitación derivada del Criterio 6 (estado del arte limitado):** ampliar la revisión sistemática para incluir mayor número de estudios empíricos comparativos publicados en 2024–2025.
3. **Limitación derivada del Criterio 7 (referencias):** sustituir las referencias presumiblemente predatorias y los *preprints* sin versión publicada por fuentes Q1–Q2 verificadas.
4. **Limitación derivada del Criterio 8 (reproducibilidad):** publicar el repositorio de código, los *prompts*, el corpus de especificaciones, los scripts generados y los *notebooks* de análisis (con DOI Zenodo).
5. **Limitación derivada del Criterio 8 (estadística):** en futuros estudios, reportar IC95 %, normalidad, tamaño del efecto y concordancia inter-jueces (Krippendorff α o ICC).
6. **Limitación reconocida en línea 1980 (sesgo muestral):** la muestra de 25 estudiantes de un mismo semestre y carrera limita la generalización; ampliar a profesionales de diversas industrias.
7. **Limitación reconocida en línea 1980 (uso único):** medir aceptación tras uso sostenido (3–6 meses) en vez de única sesión.
8. **Limitación reconocida en línea 2127 (alcance Red):** extender el sistema para cubrir las etapas *Green* (sugerencia de implementación) y *Refactor* (sugerencia de refactorización), con experimentos controlados en pipelines CI/CD reales.

9. **Limitación derivada del Criterio 9 (Confianza en Resultados):** estudiar mecanismos para incrementar la confianza del usuario — *explainability*, métricas de cobertura visibles, comparación lado-a-lado con prueba de referencia, etc.
10. **Limitación derivada del Criterio 9 (asimetría por tipo):** investigar técnicas específicas (e.g., *Chain-of-Thought prompting*, *Few-Shot*) para mejorar la generación desde historias de usuario, donde la calidad fue inferior (3.92).
11. **Limitación derivada del módulo de generación:** comparar Claude 3.5 Sonnet con modelos abiertos (Llama 3, DeepSeek-Coder) para evaluar dependencia del proveedor y costos.
12. **Trabajo futuro técnico:** integrar la herramienta como *plugin* de IDE (VS Code, IntelliJ), siguiendo el camino de *TestSpark* [26].
13. **Trabajo futuro experimental:** *benchmark* público que mida la calidad del estado inicial Red contra implementaciones manuales de TDD por desarrolladores de distinta experiencia.
14. **Trabajo futuro metodológico:** aplicar AHP (Saaty [34]) con un panel externo de expertos para validar los pesos de la evaluación multicriterio (Tablas 39–41), tal como se reconoce en línea 833.

12.3. Estructura sugerida para la nueva sección

Recomendación

Crear el **Capítulo V — Recomendaciones y trabajos futuros**, ubicado entre la sección 4.5 y la bibliografía actual, con cuatro subsecciones:

- **5.1. Limitaciones del estudio** (recoge lo que está disperso en 4.4 y 4.2.5).
- **5.2. Recomendaciones técnicas** (mejoras al artefacto: prompt engineering avanzado, soporte a otros lenguajes/*frameworks* de pruebas, etc.).
- **5.3. Recomendaciones metodológicas** (cómo replicar mejor: AHP, normalidad, tamaño del efecto).
- **5.4. Líneas de trabajo futuro** (puntos 8–14 de la lista anterior).

13. Síntesis priorizada de recomendaciones

#	Recomendación	Crit.	Prioridad
1	Insertar las 14 ilustraciones ausentes y verificar que las capturas son legibles a escala impresa	4	Bloqueante
2	Crear el Capítulo V de Recomendaciones y Trabajos Futuros	11	Bloqueante
3	Corregir el formato (negritas/cursivas rotas en TDD, SUS, TAM, LLM, etc.) en todas las apariciones	1	Alta
4	Reemplazar la referencia [8] (probable predatoria) y las referencias sin datos editoriales completos ([5], [19], [23])	7	Alta

#	Recomendación	Crit.	Prioridad
5	Verificar el dato del 64.3 % de uso de Claude 3.5 Sonnet/GPT-4 en la RSL — inconsistencia temporal con la fecha de los estudios primarios	3	Alta
6	Añadir el <i>prompt</i> y el corpus de especificaciones como anexos para garantizar reproducibilidad	8	Alta
7	Calcular y reportar IC95 %, prueba de normalidad y concordancia inter-jueces (Krippendorff α /ICC)	8	Alta
8	Reescribir la introducción incluyendo objetivos, hipótesis, aporte y guía de lectura	5	Alta
9	Reescribir la justificación en presente y unificar el tiempo verbal en cada sección	2	Media
10	Atenuar la afirmación de superioridad sobre PyTester (métricas no equivalentes)	9, 10	Media
11	Incorporar análisis estadístico de la diferencia entre tipos de especificación (96.4 / 91.7 / 83.3 %)	8, 9	Media
12	Definir todas las siglas en su primera aparición (CBSE, JWT, MVT, CDN, CI/CD, ORM, SPA)	3	Media
13	Estandarizar terminología (TDDMachine, pytest, <i>frontend</i> , <i>backend</i>)	1, 3	Media
14	Incluir un repositorio público con DOI (Zenodo) del código + datos	8	Media
15	Ampliar la sección 2.2 con al menos 5 estudios empíricos comparativos	6	Media
16	Recalcular la desviación estándar agregada de la Tabla 50 con el método correcto	8	Media
17	Corregir errores tipográficos y oraciones truncadas (líneas 117, 502, 576, 686, 947, 1635, 1799, 1891)	1	Baja
18	Discutir explícitamente por qué la Confianza en Resultados (3.76) es el constructo más bajo	9	Baja

14. Comentario final

El proyecto subyacente es ambicioso, pertinente y técnicamente sólido. La autora ha cubierto un ciclo completo: revisión sistemática de literatura → especificación con estándares ISO/IEC/IEEE 29148 → evaluación multicriterio de tecnologías → implementación → dos estudios empíricos → discusión y conclusiones contrastadas con el estado del arte. La elección de circunscribir el alcance a la etapa *Red* del ciclo TDD es metodológicamente honesta y elimina la sobrepromesa típica de trabajos similares.

Sin embargo, el documento en su versión V000 **no está listo para sustentación** por las razones citadas (figuras ausentes, sección de recomendaciones inexistente, referencias problemáticas, formato inconsistente). Atendiendo las 18 recomendaciones priorizadas anteriores — en particular las cinco bloqueantes/alta prioridad — el manuscrito puede pasar de un nivel “borrador avanzado” a un nivel “defensa lista” en un plazo razonable de 2 a 4 semanas de trabajo.

Fin del informe.