

Informe de Análisis de Datos y Métodos Estadísticos

Tesis: *Herramienta CASE para la generación de pruebas de usuario a partir de requisitos mediante inteligencia artificial generativa*

Autora: Triana Arrieta, Kerly Mikaela — Versión V000

Revisión científica

4 de mayo de 2026

Resumen

Este informe inventaria los datos primarios reportados en el manuscrito, identifica qué análisis estadísticos pueden ejecutarse con esa información, señala los datos que faltan para completar un análisis estadístico riguroso del trabajo, indica qué pruebas o métodos requieren cada dato faltante y, para investigadores noveles, ofrece pasos concretos de recopilación. El análisis distingue tres bloques de datos: (i) la generación automática de scripts *pytest*, (ii) la usabilidad y aceptación tecnológica (Estudio 1, $n = 25$), y (iii) la calidad de pruebas evaluada por expertos (Estudio 2, $n = 10$).

Índice

1. Resumen ejecutivo	2
2. Inventario de datos disponibles en el manuscrito	2
2.1. Variables categóricas (sociodemográficas y de perfil)	2
2.2. Datos individuales SUS ($n=25$, completos)	3
2.3. Estadísticos descriptivos del estudio TAM	3
2.4. Coeficiente Alfa de Cronbach	4
2.5. Matriz de correlaciones de Pearson	4
2.6. Generación automática (Tabla 46)	4
2.7. Resultados de la rúbrica experta (Tabla 53)	4
3. Datos faltantes y métodos estadísticos asociados	5
3.1. Bloque A — Generación automática	5
3.2. Bloque B — Estudio 1 (Usabilidad y TAM)	6
3.3. Bloque C — Estudio 2 (Calidad por expertos)	9
3.4. Bloque D — Datos transversales no recopilados que serían valiosos	11
4. Tabla maestra: análisis estadísticos posibles vs. necesarios	12
5. Plan de recopilación priorizado	14
5.1. Datos que probablemente <i>ya se recopilaron</i> pero no fueron reportados	14
5.2. Datos que probablemente <i>no se recopilaron</i>	15
5.3. Cronograma sugerido (investigador neófito)	15
5.4. Software y formación recomendados	16

6. Observaciones sobre validez de los análisis ya reportados	16
6.1. Coherencia matemática de la Tabla 50	16
6.2. Verificabilidad de las correlaciones (Tabla 52)	16
7. Cierre	17

1. Resumen ejecutivo

El documento contiene **tres conjuntos de datos primarios** con grados de completitud distintos:

- **Bloque A — Generación automática (Tabla 46):** *datos agregados* de 70 intentos (28 RF + 24 CU + 18 HU). **Faltan los datos individuales** (par especificación-resultado) que permitirían inferencia estadística.
- **Bloque B — Estudio 1 SUS/TAM (Tablas 47–52):** *datos individuales SUS* están reportados completos para los 25 participantes (Tabla 49). Sin embargo, **las respuestas individuales por ítem TAM (16 ítems × 25 participantes = 400 valores)** y los **tiempos individuales por participante** no aparecen — solo agregados.
- **Bloque C — Estudio 2 expertos (Tablas 53–54):** solo medias por criterio y por tipo de prueba; **no se reportan las 750 evaluaciones individuales** (10 expertos × 15 scripts × 5 criterios) que son la materia prima para concordancia inter-jueces, generalizabilidad y modelos jerárquicos.

Conclusión preliminar: el trabajo dispone de los datos para análisis descriptivos (medias, desviaciones, frecuencias) y para algunas pruebas inferenciales básicas (correlaciones de Pearson, Alfa de Cronbach), pero **no** dispone de las matrices de datos individuales necesarias para análisis multivariante, modelos lineales generalizados, concordancia inter-jueces, intervalos de confianza por bootstrap o ecuaciones estructurales. La mayoría de estos datos fueron **recopilados pero no reportados**, lo que sugiere que su recuperación es factible si los archivos originales (cuestionarios completados, hojas de cálculo) se conservan.

2. Inventario de datos disponibles en el manuscrito

2.1. Variables categóricas (sociodemográficas y de perfil)

Tabla 47 (n=25) reporta cuatro variables categóricas con frecuencia y porcentaje:

Variable	Categorías y frecuencias	Tipo
Género	Masculino (15), Femenino (10)	Nominal binaria
Experiencia en desarrollo	<1 año (8), 1–2 años (12), >2 años (5)	Ordinal
Experiencia en <i>testing</i>	Ninguna (7), Básica (14), Avanzada (4)	Ordinal
Familiaridad IA generativa	Ninguna (3), Ocasional (18), Frecuente (4)	Ordinal

Datos disponibles

Lo que se puede hacer con estos datos: estadística descriptiva básica (frecuencias, porcentajes), pruebas de homogeneidad (χ^2 de bondad de ajuste contra una distribución esperada), tablas de contingencia bivariadas *si* se cruzaran con los puntajes SUS individuales (Tabla 49). Esto último **requiere reconstruir el dataset** cruzando el código del participante con su perfil — **el manuscrito no presenta esa correspondencia**.

2.2. Datos individuales SUS (n=25, completos)

Tabla 49 ofrece el puntaje SUS de cada participante (P01 a P25) con su clasificación. Es el **único dataset individual** reportado de manera completa.

Los 25 valores numéricos son:

{72,5, 80,0, 67,5, 75,0, 82,5, 65,0, 78,5, 70,0, 76,5, 62,5, 85,0, 71,5,
79,0, 68,0, 74,5, 83,5, 69,5, 77,5, 66,5, 81,0, 73,5, 78,0, 64,5, 84,0, 75,5}

Estadísticos reportados: $\bar{x} = 74,82$; $s = 6,18$; mín. = 62,5; máx. = 85,0.

Datos disponibles

Análisis ejecutables sobre este vector:

- Prueba de normalidad de Shapiro–Wilk (n=25 es adecuado).
- Intervalo de confianza al 95 % para la media: $\bar{x} \pm t_{0,975,24} \cdot s/\sqrt{n}$, lo que da $74,82 \pm 2,55$.
- Prueba t de una muestra contra el umbral 68 (Bangor): $H_0 : \mu = 68$ vs $H_1 : \mu > 68$.
- Prueba de Wilcoxon de los rangos con signo (alternativa no paramétrica) si la normalidad falla.
- Comparación con percentil 70 de la curva SUS de Bangor: prueba binomial de proporción.
- Bootstrap con 10 000 réplicas para IC95 % de la mediana y de los percentiles.

2.3. Estadísticos descriptivos del estudio TAM

Tabla 50 reporta solo agregados por constructo (no individuales):

Constructo	N.º ítems	Media	DE	Mín.	Máx.
Utilidad Percibida (PU)	5	4.14	0.56	3.20	5.00
Facilidad de Uso (PEOU)	4	4.02	0.63	3.00	5.00
Confianza en Resultados (CR)	4	3.76	0.71	2.50	5.00
Intención de Uso (IU)	3	4.08	0.60	3.00	5.00

Datos disponibles

Análisis ejecutables a partir solo de las medias y desviaciones:

- Comparación contra umbral 3.5: para cada constructo, prueba t de una muestra usando $\bar{x}$, s , $n = 25$.
- Cálculo del estadístico: e.g. para PU, $t = (4,14 - 3,5)/(0,56/\sqrt{25}) = 5,71$, $p < 0,001$.
- Tamaño del efecto d de Cohen: $d_{PU} = (4,14 - 3,5)/0,56 = 1,14$ (efecto muy grande).

2.4. Coeficiente Alfa de Cronbach

Tabla 51 reporta α por constructo y para el instrumento total: PU = 0.847; PEOU = 0.812; CR = 0.798; IU = 0.831; total = 0.883. Estos valores ya *son* análisis estadísticos completos, no datos crudos.

2.5. Matriz de correlaciones de Pearson

Tabla 52 entrega las correlaciones entre los cuatro constructos:

	PU	PEOU	CR	IU
PU	1.000	0.623*	0.548*	0.711**
PEOU	0.623*	1.000	0.491*	0.582*
CR	0.548*	0.491*	1.000	0.437*
IU	0.711**	0.582*	0.437*	1.000

2.6. Generación automática (Tabla 46)

Datos agregados de tasa de éxito por tipo de especificación:

Tipo	Intentos	Válidos	Errores	Éxito
Requisitos funcionales	28	27	1	96.4 %
Casos de uso	24	22	2	91.7 %
Historias de usuario	18	15	3	83.3 %
Total	70	64	6	91.4 %

Datos disponibles

Análisis ejecutables sobre Tabla 46:

- Intervalo de confianza al 95 % para cada proporción (método Wilson o Clopper-Pearson).
- Prueba χ^2 de homogeneidad para comparar las tres tasas: $H_0 : p_{RF} = p_{CU} = p_{HU}$.
- Prueba exacta de Fisher (recomendable por las celdas pequeñas: 1, 2, 3 errores).
- Prueba binomial de cada tasa contra un umbral teórico (e.g. $p_0 = 0,85$).
- Comparación dos a dos: RF vs HU mediante prueba z de proporciones o exacta de Fisher.

2.7. Resultados de la rúbrica experta (Tabla 53)

Solo medias y desviaciones por criterio (no individuales):

Criterio	Media	DE
Compleitud	4.2	0.45
Claridad	4.3	0.42
Trazabilidad	4.0	0.58
Viabilidad de ejecución	3.9	0.67
Cobertura de escenarios	4.0	0.61
Media global	4.08	0.55

3. Datos faltantes y métodos estadísticos asociados

3.1. Bloque A — Generación automática

A.1. Mapa especificación–resultado individual

Datos faltantes

Qué falta: la matriz de las 70 generaciones individuales con columnas: ID_especificación, tipo (RF/CU/HU), complejidad (cuantificable), longitud_prompt (tokens), resultado (válido/error), tipo_de_error, tiempo_de_respuesta_API (segundos), costo_tokens, intento_n.º (1, 2, 3 si hubo reintentos).

Método sugerido

Pruebas estadísticas que requieren estos datos:

- **Regresión logística binaria:** probabilidad de éxito = $f(\text{tipo, complejidad, longitud del prompt})$.
- **Modelo lineal mixto generalizado (GLMM)** si hay efectos por proyecto o por participante.
- **Test exacto de Fisher** y odds ratio entre tipos de especificación.
- **Análisis de supervivencia (Kaplan–Meier)** si interesa el tiempo hasta el primer éxito (con reintentos).
- **Curva ROC** si se quisiera definir un umbral de complejidad por encima del cual la generación es poco fiable.

A.2. Métricas de calidad de código a nivel script

Datos faltantes

Qué falta: para cada uno de los 64 scripts válidos, métricas objetivas de calidad: número de funciones de prueba, número de aserciones por función, complejidad ciclomática, longitud (LOC), número de *fixtures*, presencia de *mocks/stubs*, cobertura de ramas (si se ejecutaran), cumplimiento de PEP-8.

Método sugerido

Pruebas estadísticas que requieren estos datos:

- **ANOVA de un factor** (tipo de especificación) sobre cada métrica.
- **Kruskal–Wallis** (alternativa no paramétrica) para distribuciones sesgadas.
- **Análisis de componentes principales (PCA)** sobre el vector de métricas para reducir dimensionalidad.
- **Coefficiente de correlación** entre las métricas de calidad de código y las puntuaciones de la rúbrica experta (Tabla 53), lo que permitiría *validar la rúbrica* contra medidas objetivas.

Pasos para investigador neófito

Cómo obtenerlos (investigador neófito):

1. Recolectar los 70 archivos `.py` generados (deben estar en la base PostgreSQL del sistema).
2. Instalar `radon` (`pip install radon`) y ejecutar `radon cc archivo.py -s` para complejidad ciclomática y `radon raw archivo.py` para LOC.
3. Para conteo de aserciones y funciones, usar el módulo `ast` de Python (que ya emplea `PytestValidator`): contar nodos `ast.Assert` y `ast.FunctionDef` cuyo nombre comience por `test_`.
4. Para cumplimiento PEP-8: `flake8 archivo.py -count`.
5. Para cobertura de ramas (requeriría ejecutar): `pytest -cov=módulo -cov-branch` sobre código de producción ficticio o *stubs*.
6. Volcar todo a un archivo CSV con una fila por script.

3.2. Bloque B — Estudio 1 (Usabilidad y TAM)

B.1. Matriz individual de respuestas SUS por ítem

Datos faltantes

Qué falta: matriz de 25 filas (participantes) $\times$ 10 columnas (ítems SUS), con valores 1–5. La Tabla 49 ya entrega los puntajes *globales* pero no los ítems crudos.

Método sugerido

Pruebas estadísticas que se desbloquean:

- **Análisis ítem-por-ítem:** media de cada uno de los 10 ítems SUS, identificación del ítem más débil.
- **Subescalas de Lewis & Sauro:** cálculo separado de *Usabilidad* (8 ítems) y *Aprendizabilidad* (2 ítems: 4 y 10).
- **Alfa de Cronbach** del instrumento SUS aplicado al estudio.
- **Análisis factorial confirmatorio (CFA)** con $n = 25$, indicativo aunque no concluyente.

Pasos para investigador neófito

Cómo obtenerlos: si los cuestionarios SUS se aplicaron en formato digital (Google Forms, etc.), exportar el CSV con todas las respuestas. Si se aplicaron en papel, transcribir manualmente a una hoja de cálculo. Codificar la inversión de los ítems impares: para ítems 2, 4, 6, 8, 10 la puntuación se invierte como $5 - x$ antes de aplicar la fórmula SUS estándar.

B.2. Matriz individual de respuestas TAM por ítem

Datos faltantes

Qué falta: matriz de 25 filas $\times$ 16 columnas (PU1–PU5, PEOU1–PEOU4, CR1–CR4, IU1–IU3) con valores 1–5. Sin esta matriz, los Alfa de Cronbach y las correlaciones de Pearson reportadas (Tablas 51 y 52) **no son verificables** y los análisis adicionales son imposibles.

Método sugerido

Pruebas estadísticas adicionales que se desbloquean:

- **Modelo de ecuaciones estructurales (SEM)** del TAM clásico (Davis 1989): PEOU $\rightarrow$ PU $\rightarrow$ IU. Aunque $n = 25$ es bajo para SEM-CB (covariance-based), el método **PLS-SEM** (Partial Least Squares) tolera $n \geq 20$ y es estándar en investigación TAM.
- **Validez convergente y discriminante:** cálculo de AVE (*Average Variance Extracted*) y criterio de Fornell–Larcker.
- **Heterotrait–Monotrait Ratio (HTMT)** para validez discriminante.
- **Análisis ítem-test:** correlación de cada ítem con su constructo — detecta ítems mal formulados.
- **Regresión múltiple:** $IU = \beta_0 + \beta_1 PU + \beta_2 PEOU + \beta_3 CR + \varepsilon$.
- **Mediación:** efecto indirecto de PEOU sobre IU a través de PU (test de Sobel o bootstrap PROCESS).
- **Moderación:** efecto del perfil del participante (experiencia, género) sobre las relaciones del modelo.

Pasos para investigador neófito

Cómo obtenerlos: idéntico al SUS. Si se conservaron los formularios, exportar a CSV. Para PLS-SEM existe el software libre **SmartPLS** (versión 3 gratuita académica) o el paquete R **sempr**. Tutorial recomendado: *Hair et al. (2022) A Primer on PLS-SEM*.

B.3. Tiempos individuales por participante y por tarea

Datos faltantes

Qué falta: matriz 25×4 con el tiempo (en minutos) que cada participante empleó en cada una de las cuatro tareas. La Tabla 48 entrega solo agregados (media, DE, mín, máx por tarea).

Método sugerido

Pruebas estadísticas adicionales:

- **ANOVA de medidas repetidas:** las cuatro tareas son medidas repetidas dentro de cada participante; el ANOVA con corrección de Greenhouse–Geisser detecta diferencias significativas entre tareas.
- **Prueba de Friedman** (alternativa no paramétrica para medidas repetidas).
- **Correlación entre tiempo total y puntaje SUS:** ¿los participantes que tardan más perciben peor usabilidad? Pearson o Spearman.
- **Curva de aprendizaje:** regresión del tiempo en función del orden de la tarea.
- **Cluster *k*-means:** identificar perfiles de participantes (rápidos, lentos) y comparar su perfil sociodemográfico.

Pasos para investigador neófito

Cómo obtenerlos: (a) si se grabó la sesión: marcar manualmente los tiempos de inicio/fin de cada tarea con un cronómetro o usar el log del sistema (timestamp del primer y último evento por tarea); (b) si la herramienta registra eventos: extraer de la base de datos los timestamps de creación de proyecto, registro de RF, registro de HU y exportación; (c) si nada de esto se conservó, ya *no es posible* reconstruirlos — declararlo como limitación.

B.4. Datos cualitativos codificados

Datos faltantes

Qué falta: las respuestas textuales del cuestionario abierto (Anexo 6, 5 preguntas $\times$ 25 participantes = 125 respuestas) y su codificación temática. El manuscrito describe los hallazgos en tres categorías (positivos, dificultades, sugerencias) pero **sin frecuencias por código y sin las citas literales** (*verbatim*).

Método sugerido

Pruebas y técnicas:

- **Análisis temático** (Braun & Clarke 2006): codificación abierta, codificación axial, agrupamiento en categorías.
- **Tabla de frecuencias por código:** cuántos participantes mencionan cada tema; identifica los temas dominantes.
- **Acuerdo inter-codificador** (Cohen κ): si dos codificadores categorizan independientemente el corpus.
- **Triangulación cuanti–cuali:** cruzar categorías cualitativas con SUS bajos vs altos. ¿Los participantes que dieron SUS < 70 mencionan los mismos problemas?
- **Análisis de sentimiento** (opcional, `vaderSentiment` o `TextBlob` para español).
- **Nube de palabras** y co-ocurrencia de términos.

Pasos para investigador neófito

Cómo obtenerlos: (a) digitalizar las respuestas en una hoja de cálculo, una columna por pregunta; (b) usar software como *Atlas.ti*, *NVivo*, *MAXQDA* o, gratuitos, *Taguette* o *QualCoder*; (c) aplicar un libro de códigos: leer 5 transcripciones, identificar temas recurrentes, definir nombres de código, etiquetar las restantes 20; (d) contar frecuencias y exportar tabla.

3.3. Bloque C — Estudio 2 (Calidad por expertos)

C.1. Matriz de evaluaciones individuales

Datos faltantes

Qué falta: la matriz tridimensional $10 \times 15 \times 5 = 750$ evaluaciones (10 expertos $\times$ 15 scripts $\times$ 5 criterios). Es el dato más crítico ausente del documento. Sin esta matriz **no es posible** verificar si los expertos coincidieron o discreparon.

Método sugerido

Pruebas que requieren obligatoriamente esta matriz:

- **Concordancia inter-jueces:**
 - W de Kendall (escala ordinal, varios jueces).
 - Krippendorff α (la más robusta, admite datos perdidos).
 - Coeficiente de correlación intraclase (ICC), modelo (2, k) si los jueces son aleatorios.
- **ANOVA mixto bifactorial:** tipo de prueba (3 niveles: unitaria/integración/sistema) $\times$ criterio (5 niveles), con expertos como factor aleatorio.
- **Teoría de la generalizabilidad (G-Theory):** descompone la varianza en componentes (script, criterio, experto, interacciones) e indica el coeficiente G del diseño.
- **Análisis Many-Facet Rasch (MFRM, Linacre):** mide la severidad de cada experto y la dificultad de cada criterio.
- **Modelo lineal mixto:** $\text{puntuaje} \sim \text{tipo} + \text{criterio} + (1 \mid \text{experto}) + (1 \mid \text{script})$ con *lme4* en R.
- **Detección de outliers:** ¿hay un experto sistemáticamente más severo que el resto?

Pasos para investigador neófito

Cómo obtenerlos: si los 10 expertos enviaron rúbricas firmadas, transcribirlas a una hoja con la estructura:
`experto_id, script_id, tipo_prueba, completitud, claridad, trazabilidad, viabilidad, cobertura`
con $10 \times 15 = 150$ filas. Si se conserva una hoja por experto, basta concatenar.
Si las rúbricas se digitalizaron en Google Forms con escalas Likert ([] [] [] [] [] []), exportar directamente a CSV.
Si se usaron PDFs editables, los datos están en los campos del formulario y `pdfTk dump_data_fields` los extrae.

C.2. Comentarios cualitativos del cuestionario para expertos

Datos faltantes

Qué falta: las respuestas a las 10 preguntas abiertas del Anexo 9, contestadas por los 10 expertos (100 respuestas en total). El manuscrito (líneas 2017–2025) sintetiza en cuatro categorías sin frecuencias ni *verbatim*.

Método sugerido

Idéntico al apartado B.4: análisis temático, frecuencias por código, triangulación cuantitativa con las puntuaciones de la rúbrica.

Adicionalmente:

- **Síntesis comparativa entre expertos:** ¿los expertos con mayor experiencia hacen las críticas más detalladas?
- **Categorización de “debilidades técnicas”:** cubrir cobertura, casos extremos, especificidad de aserciones.

C.3. Caracterización del panel de expertos

Datos faltantes

Qué falta: el manuscrito declara que los 10 expertos tienen “experiencia comprobada en *testing* de software” (línea 903) pero **no caracteriza al panel:** años de experiencia, sector (academia/industria), nivel formativo, conocimiento previo de TDD, conocimiento previo de pytest, país de residencia. Esto es esencial para juzgar la validez externa del Estudio 2.

Método sugerido

- **Tabla descriptiva del panel,** análoga a la Tabla 47 del Estudio 1.
- **Análisis de moderación:** ¿los expertos con más experiencia puntúan más severamente?
- **Ponderación de las puntuaciones** por experiencia o por especialización en TDD.

Pasos para investigador neófito

Cómo obtenerlos: si la invitación (Anexo 7) incluyó un mini-formulario de perfil, los datos están; si no, enviar a posteriori un correo breve a los 10 expertos pidiendo: años_de_experiencia, sector, nivel_formativo (Lic./MSc./PhD), TDD_previo (sí/no), pytest_previo (sí/no), país.

3.4. Bloque D — Datos transversales no recopilados que serían valiosos

D.1. Línea base manual (control)

Datos faltantes

Qué falta: no hay grupo control. El estudio mide cuánto tarda un participante en *usar la herramienta* (42 min) pero no compara con el tiempo que tardaría un desarrollador en *escribir manualmente* las mismas pruebas.

Método sugerido

Estudio cuasi-experimental con dos grupos:

- **Grupo A (control):** n_a participantes escriben manualmente los *tests pytest* a partir de las mismas especificaciones.
- **Grupo B (tratamiento):** n_b participantes usan TDDMachine.
- Métricas comparables: tiempo, número de aserciones, cobertura, tasa de defectos.
- **Prueba estadística:** prueba t de Welch para muestras independientes, o Mann–Whitney U si no hay normalidad. Tamaño del efecto: d de Cohen.
- **Diseño *within-subjects*** (más potente): cada participante hace ambas tareas con *counterbalancing* (mitad empieza con A, mitad con B); se aplica prueba t pareada o Wilcoxon.

Pasos para investigador neófito

Cómo diseñarlo:

1. Definir un conjunto fijo de 5 especificaciones (3 RF, 1 CU, 1 HU) representativas.
2. Reclutar ≥ 30 desarrolladores (o 15 con *within-subjects*).
3. Asignación aleatoria a grupos (sortear con `random.seed` o `sample()` en R).
4. Cronometrar cada sesión.
5. Recoger los *tests* producidos y aplicarles las métricas del bloque A.2.
6. Comparar con prueba t y reportar IC95 % de la diferencia de medias.

D.2. Costo y consumo de la API

Datos faltantes

Qué falta: el costo total estimado en \$45 USD aparece en la Tabla 2, pero no se reportan los **tokens consumidos por solicitud** ni la **distribución de costos por tipo de especificación**.

Método sugerido

- Estadística descriptiva de tokens de entrada y salida por solicitud.
- Histograma del costo por generación.
- Regresión: $\text{costo} \sim \text{longitud del prompt} + \text{tipo} + \text{complejidad}$.
- Cálculo del costo marginal de un nivel adicional de calidad (e.g. regenerar para mejorar).

Pasos para investigador neófito

Cómo obtenerlos: la API de Anthropic devuelve en cada respuesta el campo `usage` con `input_tokens` y `output_tokens`. Si el módulo `ClaudeService` ya los almacena, basta consultarlos; si no, modificar el servicio para registrarlos en cada llamada y reproducir las 70 generaciones (al precio actual de Claude 3.5 Sonnet, eso costaría aproximadamente \$2–5 USD).

D.3. Datos longitudinales

Datos faltantes

Qué falta: todas las medidas se tomaron en **una sola sesión**. No hay datos de uso prolongado, curva de aprendizaje del usuario, evolución de la calidad de los *prompts* construidos por el usuario, etc.

Método sugerido

- **Estudio panel:** medir SUS y TAM en t_0 (primera sesión), t_1 (1 mes) y t_2 (3 meses).
- **ANOVA de medidas repetidas** para detectar cambio en el tiempo.
- **Modelos de crecimiento latente (LGM)** para modelar la trayectoria individual.
- **Análisis de retención:** % de usuarios que siguen activos a las 4, 8, 12 semanas.

4. Tabla maestra: análisis estadísticos posibles vs. necesarios

Análisis estadístico	Estado	Datos requeridos / observación
Estadística descriptiva (medias, DE, frecuencias)	Hecho	Tablas 47–53
Alfa de Cronbach por constructo	Hecho	Tabla 51
Correlación de Pearson entre constructos	Hecho	Tabla 52 (a verificar con datos crudos)
Prueba t de una muestra (SUS vs 68)	Pendiente	Datos disponibles (Tabla 49)
Prueba t de una muestra (TAM vs 3.5)	Pendiente	Datos agregados disponibles (Tabla 50)
Tamaño del efecto d de Cohen	Pendiente	Datos agregados disponibles
IC95 % de proporciones de éxito	Pendiente	Tabla 46
χ^2 de homogeneidad entre tipos	Pendiente	Tabla 46 (cuidado: n pequeños)
Test exacto de Fisher entre tipos	Pendiente	Tabla 46

Análisis estadístico	Estado	Datos requeridos / observación
Prueba de Shapiro–Wilk de normalidad	Pendiente	Tabla 49 (SUS)
Subescalas SUS (Usabilidad / Aprendizabilidad)	Falta dato	Matriz 25×10 ítems SUS
Análisis ítem-test del SUS y TAM	Falta dato	Matriz individual de ítems
PLS-SEM del modelo TAM	Falta dato	Matriz 25×16 ítems TAM
Validez convergente (AVE) y HTMT	Falta dato	Matriz individual TAM
Mediación PEOU $\rightarrow$ PU $\rightarrow$ IU	Falta dato	Matriz individual TAM
ANOVA de medidas repetidas (tareas)	Falta dato	Matriz 25×4 tiempos por tarea
Concordancia inter-jueces (Krippendorff α)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
Coefficiente de correlación intraclase (ICC)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
ANOVA mixto bifactorial (tipo $\times$ criterio)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
Modelo lineal mixto (lme4)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
Teoría de la generalizabilidad (G-Theory)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
Many-Facet Rasch Model (MFRM)	Falta dato	Matriz $10 \times 15 \times 5$ expertos
Regresión logística (éxito generación)	Falta dato	70 filas con covariables
GLMM con efectos aleatorios	Falta dato	70 filas con covariables
Análisis temático cualitativo (S1)	Falta dato	125 respuestas abiertas (Anexo 6)

Análisis estadístico	Estado	Datos requeridos / observación
Análisis temático cualitativo (S2)	Falta dato	100 respuestas abiertas (Anexo 9)
Acuerdo inter-codificador Cohen κ	Falta dato	Codificación independiente por 2 personas
Triangulación cuanti-cuali	Falta dato	Cruce SUS/TAM con códigos cualitativos
Comparación con grupo control manual	Falta dato	Estudio cuasi-experimental adicional
Análisis de costo y consumo de tokens	Falta dato	Logs de la API de Anthropic
Estudio panel longitudinal (3 puntos)	Falta dato	Re-medición a 1 y 3 meses

Resumen cuantitativo:

- Análisis ya ejecutados (**Hecho**): 3
- Análisis ejecutables con los datos del manuscrito (**Pendiente**): 7
- Análisis que requieren datos no reportados o no recopilados (**Falta dato**): 21

5. Plan de recopilación priorizado

5.1. Datos que probablemente *ya se recopilaron pero no fueron reportados*

Recomendación

Estos datos pueden estar en archivos físicos o digitales del autor; recuperarlos no requiere nuevo trabajo de campo:

1. **Matriz individual SUS** (25×10): el cálculo del puntaje SUS *requiere* los ítems individuales; la autora debe tenerlos.
2. **Matriz individual TAM** (25×16): idem; el cálculo de la media y de Alfa de Cronbach reportadas implica que los datos crudos existen.
3. **Matriz de evaluaciones expertas** ($10 \times 15 \times 5$): las medias reportadas se calcularon a partir de la rúbrica completada por cada experto.
4. **Respuestas a cuestionarios cualitativos** (Anexos 6 y 9): los participantes y expertos las entregaron.
5. **Logs del módulo de generación**: el sistema implementado los registra en la base de datos.

Acción: solicitar los archivos originales (Excel, Google Forms, PDF de cuestionarios) y consolidar en un *dataset* único.

5.2. Datos que probablemente *no se recopilaron*

Recomendación

Requieren nueva recolección:

1. **Tiempos individuales por tarea** (25×4): solo es recuperable si quedaron registrados en grabaciones o logs.
2. **Caracterización del panel de expertos**: contactar a los 10 expertos y enviar mini-cuestionario.
3. **Métricas objetivas de calidad de código**: ejecutar `radon`, `flake8`, conteo AST sobre los 64 scripts válidos almacenados en la BD.
4. **Línea base manual (grupo control)**: requiere un nuevo experimento.
5. **Datos longitudinales**: requieren re-contactar a la muestra a 1 y 3 meses.

5.3. Cronograma sugerido (investigador neófito)

Semana	Actividad	Esfuerzo
1	Recuperar y consolidar matrices individuales (SUS, TAM, expertos) en CSV	8–12 h
1–2	Verificar Alfa de Cronbach y correlaciones reportadas	4 h
2	Calcular IC95 %, d de Cohen, prueba t contra umbrales	4 h
2–3	Concordancia inter-jueces (Krippendorff α , ICC) en R	8 h
3	PLS-SEM en SmartPLS o <code>semnr</code> (R)	12 h
3–4	Análisis temático con Taguette o NVivo	16–20 h
4–5	Métricas objetivas de código (<code>radon</code> , <code>flake8</code>)	8 h
4–5	Re-contacto a expertos para caracterización del panel	4 h
5–8	Diseño y ejecución del estudio cuasi-experimental con grupo control	40–60 h
9–10	Re-medición longitudinal a 1 mes (si aplica)	8 h

5.4. Software y formación recomendados

Tarea	Software (libre)	Recurso de formación
Estadística general	R + RStudio, JASP	Field, <i>Discovering Statistics Using R</i>
PLS-SEM	SmartPLS (académico), seminr (R)	Hair et al., <i>A Primer on PLS-SEM</i>
Concordancia inter-jueces	irr, psych (R)	Hallgren (2012), <i>Computing Inter-Rater Reliability</i>
Modelos lineales mixtos	lme4, lmerTest (R)	Bates et al. (2015) en <i>J. Stat. Software</i>
G-Theory / MFRM	gtheory (R), Facets	Brennan, <i>Generalizability Theory</i>
Análisis cualitativo	Taguette, QualCoder	Braun & Clarke (2006)
Análisis textual	quanteda, tm (R)	Silge & Robinson, <i>Text Mining with R</i>
Métricas de código Python	radon, flake8, pylint	Documentación oficial

6. Observaciones sobre validez de los análisis ya reportados

Antes de avanzar con nuevos análisis, conviene verificar dos puntos sobre lo ya reportado:

6.1. Coherencia matemática de la Tabla 50

La fila “Promedio global” indica $DE = 0.63$ como “promedio” de las cuatro DEs (0.56, 0.63, 0.71, 0.60). Esto es **incorrecto**. La desviación estándar de un conjunto formado por la unión de subgrupos no es el promedio de las DEs; debe calcularse a partir de la varianza ponderada:

$$s_{\text{total}}^2 = \frac{\sum_i (n_i - 1) s_i^2 + \sum_i n_i (\bar{x}_i - \bar{x}_{\text{total}})^2}{(\sum_i n_i) - 1}$$

con n_i el número de observaciones en cada grupo. Recalcular con la matriz cruda.

6.2. Verificabilidad de las correlaciones (Tabla 52)

Las correlaciones reportadas (PU–IU $r = 0,711$, etc.) presuponen que los constructos se calculan como *promedio aritmético de los ítems*. Si la matriz individual está disponible:

- **Verificar** las correlaciones recalculándolas en R.
- **Aplicar Shapiro–Wilk** a cada constructo: si alguno no es normal, recalcular con Spearman ρ .
- **Reportar IC95 %** de cada correlación (transformación de Fisher).
- **Corrección por comparaciones múltiples**: con 6 correlaciones simultáneas, aplicar Bonferroni ($\alpha/6 = 0,0083$) o Holm.

7. Cierre

El manuscrito posee la **infraestructura adecuada** para un análisis estadístico robusto: dos estudios bien diseñados, instrumentos validados (SUS, TAM), una rúbrica con cinco criterios, un panel experto. Lo que le falta es *reportar los datos crudos y ejecutar los análisis multivariantes que la naturaleza del problema reclama*.

De los datos faltantes identificados, aproximadamente **el 70 % probablemente ya está en poder de la autora** (cuestionarios completados, rúbricas, logs del sistema) y solo requiere consolidación; el otro 30 % — línea base manual, métricas de código, datos longitudinales — requiere nueva recolección. El esfuerzo combinado para llegar a un nivel de análisis sólido se estima en 6 a 10 semanas de trabajo del autor con asesoría puntual en estadística.

Fin del informe.