

Análisis Crítico de la Versión Final del Proyecto de Titulación

“Aplicación Web para la Detección de Similitud mediante Inteligencia Artificial Generativa y Análisis de Eficiencia Algorítmica en Código Fuente de Software”

Informe de revisión científica y editorial
con opciones concretas de corrección

Mayo 2026

Resumen

El presente informe realiza un análisis exhaustivo de la versión final del documento de titulación elaborado por Rafael Alexander Navas Rivera. **Para cada observación se ofrecen opciones concretas de corrección**, incluyendo: redacciones alternativas, sustituciones de referencias bibliográficas con sus DOIs y cuartiles, código ejecutable para los análisis estadísticos faltantes (cuando los datos están disponibles), y guías paso a paso para implementar las correcciones. Las observaciones que no pueden corregirse con los datos existentes se identifican explícitamente como “solo se da a conocer”.

Índice

1	Convenciones del Informe	3
2	Valoración General	3
3	Análisis Ortográfico	3
3.1	Errores ortográficos detectados con corrección	4
4	Análisis Gramatical	5
4.1	Errores gramaticales con opciones de corrección	5
4.2	Uso del relativo “donde”	7
4.3	Uso incorrecto del gerundio	8
5	Análisis de Tiempos Verbales	10
6	Uso de Terminología Técnica	11
6.1	Inconsistencias terminológicas con opciones de corrección	11
7	Análisis de Referencias Bibliográficas	12
7.1	Referencias correctamente indexadas	12
7.2	Referencias cuestionables con propuestas de sustitución	13
8	Análisis Estadístico	16
8.1	Análisis estadístico incorrecto: ANOVA de precisión	16
8.2	Análisis estadísticos faltantes con datos disponibles	17
8.2.1	Verificación de supuestos paramétricos	17
8.2.2	Pruebas post-hoc para tiempos de respuesta	18

8.2.3	Tamaño del efecto	19
8.2.4	Análisis estratificado por lenguaje (ANOVA factorial)	20
8.2.5	Matrices de confusión	21
8.2.6	Análisis dimensional desagregado	22
8.2.7	Inconsistencia en la Tabla 12	22
8.2.8	Caracterización de los expertos	23
8.2.9	Acuerdo entre expertos	24
8.3	Análisis estadísticos faltantes que NO se pueden calcular con los datos disponibles	24
9	Análisis de la Sección de Resultados	26
9.1	Tabla 12: inconsistencia entre tabla y texto	26
9.2	Análisis dimensional faltante	26
9.3	Matrices de confusión	26
10	Análisis de la Introducción	27
11	Análisis de la Metodología	27
11.1	Contradicción APIs vs interfaces web	27
11.2	Justificación del tamaño muestral	28
12	Análisis de Conclusiones	29
13	Análisis de Recomendaciones	30
14	Análisis del Resumen Ejecutivo y Abstract	30
15	Análisis del Código Dublin	31
16	Cuadro Resumen de Observaciones y sus Correcciones	32
17	Conclusión del Análisis	32

1 Convenciones del Informe

Cómo leer este informe

A lo largo del documento se utilizan los siguientes tipos de cajas:

- **Caja verde:** aspectos positivos detectados en el documento.
- **Caja roja:** problemas que requieren corrección.
- **Caja azul:** sugerencias generales y reglas didácticas.
- **Caja amarilla:** advertencias y observaciones de menor severidad.
- **Caja morada:** opciones concretas de corrección con código y redacciones alternativas.

Cuando una observación admite varias opciones de corrección, se etiquetan como **Opción A**, **Opción B**, etc., para que el autor elija según su criterio. Cuando una observación no puede corregirse con los datos disponibles, se marca explícitamente como “**solo se da a conocer**”.

2 Valoración General

Avances significativos respecto a versiones anteriores

- La introducción ahora incluye el problema de investigación, objetivo general, novedad y metodología.
- Se ha agregado el párrafo de cierre del estado del arte con identificación explícita del vacío científico.
- Las anotaciones internas en mayúsculas fueron eliminadas.
- Se incluye nueva sección 4.1 “Síntesis de entrevistas”.
- Se incorpora la Tabla 2 con la estructura del conjunto de datos.
- Se justifica el tamaño muestral y la selección de 5 expertos.
- Tablas adicionales: 10 (precisión por modelo y lenguaje), 11 (estadísticos descriptivos), 12 (calidad por dimensión).
- Anexos nuevos (5, 6, 7, 8, 9) que documentan justificaciones, dataset, plantillas, script Python y resultados.
- Tribunal completo y certificado de plagio con porcentajes.

3 Análisis Ortográfico

3.1 Errores ortográficos detectados con corrección

Errores ortográficos persistentes con sus correcciones

Error 1: “optima” sin tilde

Ubicación: Sección 1.1 (Planteamiento del problema), párrafo 1.

Texto original: “...presentando soluciones con complejidad computacional poco *opti*ma...”

Corrección: “...presentando soluciones con complejidad computacional poco **óptima**...”

Error 2: “LOS RIOS” sin tilde

Ubicación: Bloque del tribunal en portada (segunda aparición).

Texto original: “QUEVEDO – LOS RIOS – ECUADOR”

Corrección: “QUEVEDO – LOS **RÍOS** – ECUADOR”

Error 3: “CAPITULO” sin tilde

Ubicación: Encabezados de los capítulos IV, V, VI y VII.

Texto original: “CAPITULO IV”, “CAPITULO V”, “CAPITULO VI”, “CAPITULO VII”

Corrección: “**CAPÍTULO** IV”, “**CAPÍTULO** V”, “**CAPÍTULO** VI”, “**CAPÍTULO** VII”

Error 4: “especifico” sin tilde

Ubicación: Sección 4.4.4.

Texto original: “Resumen y conclusión del primer objetivo *especifico*”

Corrección: “Resumen y conclusión del primer objetivo **específico**”

Error 5: oración inacabada en Capítulo IV

Ubicación: Inicio del módulo de comparación individual.

Texto original: “...permitiendo dos fragmentos de código fuente a un análisis comparativo...”

Opciones de corrección:

- **Opción A:** “...permitiendo **someter** dos fragmentos de código fuente a un análisis comparativo...”
- **Opción B:** “...permitiendo **exponer** dos fragmentos de código fuente a un análisis comparativo...”
- **Opción C** (reformulación completa): “...que aplica un análisis comparativo asistido por inteligencia artificial generativa a dos fragmentos de código fuente...”

Error 6: “Intel Corei5-10400” sin espacio

Ubicación: Anexo 3, tabla de hardware.

Texto original: “Intel Corei5-10400”

Corrección: “Intel **Core i5-10400**”

Error 7: “16 Gb” (gigabit) en lugar de “16 GB” (gigabyte)

Ubicación: Anexo 3, tabla de hardware.

Texto original: “16 *Gb*”

Corrección: “16 **GB**” (Gb = gigabit; GB = gigabyte. La memoria RAM se mide en GB).

Error 8: cita reemplaza palabra esperada

Ubicación: Sección 2.1.3.1.

Texto original: “...típicamente como función del tamaño de [25], [39].”

Corrección: “...típicamente como función del tamaño de **la entrada** [25], [39].”

4 Análisis Gramatical

4.1 Errores gramaticales con opciones de corrección

Errores gramaticales detectados

Error 1: Pregunta de investigación mal formulada

Ubicación: Sección Formulación de problema (Capítulo I).

Texto original: “¿De qué manera se la detección de similitudes en código fuente e identificar simultáneamente el código más eficiente algorítmicamente durante el proceso de comparación, reduciendo la sobrecarga docente en instituciones educativas con limitaciones presupuestarias?”

Problemas múltiples: falta de verbo principal, mezcla de sustantivo (“la detección”) con infinitivo (“identificar”), gerundio adverbial (“reduciendo”).

Opciones de corrección:

- **Opción A** (verbo modal explícito): “¿De qué manera se puede automatizar la detección de similitudes en código fuente y la identificación simultánea del código más eficiente algorítmicamente, con el fin de reducir la sobrecarga docente en instituciones educativas con limitaciones presupuestarias?”
- **Opción B** (forma directa): “¿Cómo automatizar la detección de similitudes en código fuente y la identificación del código más eficiente algorítmicamente para reducir la sobrecarga docente en instituciones educativas con limitaciones presupuestarias?”
- **Opción C** (estructura más simple): “¿Cómo desarrollar una herramienta accesible que detecte similitudes y evalúe la eficiencia algorítmica en código fuente, dirigida a docentes de programación en instituciones con limitaciones presupuestarias?”

Error 2: Falta de sujeto en sección 1.1

Ubicación: Sección 1.1, párrafo 3.

Texto original: “Este problema se intensifica considerando en los primeros pasos del desarrollo de habilidades de codificación típicamente implementan soluciones...”

Opciones de corrección:

- **Opción A:** “Este problema se intensifica al considerar que, en los primeros pasos del desarrollo de habilidades de codificación, **los estudiantes** típicamente implementan soluciones...”

- **Opción B:** “Este problema se intensifica porque, en los primeros pasos del desarrollo de habilidades de codificación, **los principiantes** típicamente implementan soluciones...”
- **Opción C** (más concisa): “El problema se intensifica porque los estudiantes principiantes típicamente implementan soluciones con patrones de codificación ineficientes...”

Error 3: Frase truncada en sección 2.2.6

Ubicación: Sección 2.2.6 (Ingeniería de prompts para LLMs), penúltimo párrafo.

Texto original: “Al realizar análisis dimensional paso a paso mediante CoT y verificar consistencia mediante, se maximiza...”

Corrección: “Al realizar análisis dimensional paso a paso mediante CoT y verificar consistencia mediante **CoVe**, se maximiza...”

Error 4: Gerundio al inicio en abstract

Ubicación: Resumen ejecutivo en español.

Texto original: “Ofreciendo una herramienta accesible que fortalece la integridad académica...”

Opciones de corrección:

- **Opción A:** “El sistema ofrece una herramienta accesible que fortalece la integridad académica...”
- **Opción B:** “De este modo, se ofrece una herramienta accesible que fortalece la integridad académica...”
- **Opción C:** “Como resultado, el sistema constituye una herramienta accesible que fortalece la integridad académica...”

Error 5: Tiempo verbal en sección 3.12

Ubicación: Sección 3.12 (Validación con usuarios expertos).

Texto original: “El instrumento de evaluación utilizará una escala de Likert de 1 a 5 [22]...”

Corrección: “El instrumento de evaluación **utilizó** una escala de Likert de 1 a 5 [22]... **Incluyó** preguntas abiertas para capturar sugerencias y limitaciones.”

(El verbo debe estar en pretérito porque la validación ya se ejecutó, según muestra la sección 4.7).

Error 6: Tiempo verbal en sección 3.2

Ubicación: Sección 3.2 (Tipo de investigación).

Texto original: “Se emplea un enfoque mixto (cuantitativo y cualitativo...)”

Corrección: “Se **empleó** un enfoque mixto (cuantitativo y cualitativo...)”

Error 7: Mezcla de tiempos verbales en sección 4.5

Ubicación: Capítulo IV, sección 4.5.

Texto original: “*Se implementó el módulo de comparación individual dentro del sistema web SimilCode. El sistema cuenta con un mecanismo de autenticación...*”

Opciones de corrección:

- **Opción A** (mantener pretérito): “*Se implementó el módulo de comparación individual dentro del sistema web SimilCode. El sistema **contó** con un mecanismo de autenticación...*”
- **Opción B** (mantener presente, ajustar primer verbo): “*El sistema web SimilCode integra el módulo de comparación individual. Cuenta con un mecanismo de autenticación...*”

4.2 Uso del relativo “donde”**Regla del uso de “donde”**

El relativo “**donde**” debe usarse exclusivamente con referente locativo (lugar físico). Para referentes abstractos (situaciones, momentos, entidades) debe usarse:

- “**en el cual**” / “**en la cual**” / “**en los cuales**” / “**en las cuales**” (referente expreso).
- “**en el que**” / “**en la que**” (formas más coloquiales).
- “**en que**” (en construcciones más concisas).

“Donde” usado fuera de contexto espacial con sus correcciones**Caso 1: Sección 1.1, párrafo 1**

Texto original: “...esta problemática se ha convertido en un problema que afecta la integridad académica y la calidad educativa, donde las instituciones educativas enfrentan dificultades...”

Corrección: “...la calidad educativa, **en el cual** las instituciones educativas enfrentan dificultades...”

Caso 2: Sección 1.1, párrafo 3

Texto original: “...ha generado un problema operativo considerable, donde los docentes deben invertir tiempo excesivo...”

Corrección: “...ha generado un problema operativo considerable, **en el cual** los docentes deben invertir tiempo excesivo...”

Caso 3: Sección 1.1, párrafo 4

Texto original: “...generando un círculo vicioso donde la capacidad de proporcionar retroalimentación efectiva...”

Corrección: “...lo cual genera un círculo vicioso **en el cual** la capacidad de proporcionar retroalimentación efectiva...”

Caso 4: Sección 1.3 (Justificación), párrafo 1

Texto original: “...una problemática crítica en el ámbito educativo actual, donde la detección de similitudes...”

Corrección: “...una problemática crítica en el ámbito educativo actual, **en el cual** la detección de similitudes...”

Caso 5: Sección 3.3.1

Texto original: “Se diseñó un protocolo experimental riguroso donde los cuatro modelos fueron sometidos a las mismas 120 pruebas estandarizadas.”

Corrección: “Se diseñó un protocolo experimental riguroso **en el cual** los cuatro modelos fueron sometidos a las mismas 120 pruebas estandarizadas.”

4.3 Uso incorrecto del gerundio

Reglas básicas del gerundio en español

- **Uso correcto:** simultaneidad o anterioridad respecto al verbo principal (“*Estudiando, aprendió*”).
- **Uso correcto:** indica modo o manera (“*Habló sonriendo*”).
- **Uso INCORRECTO:** gerundio de posterioridad (“*Estudió, aprobando el examen*”) → “*Estudió y aprobó el examen*”.
- **Uso INCORRECTO:** gerundio de consecuencia (“*Estudió mucho, aprobando con notas altas*”) → “*Estudió mucho, por lo que aprobó con notas altas*”.
- **Uso INCORRECTO:** gerundio adjetivo (“*una caja conteniendo libros*”) → “*una caja que contiene libros*”.
- **Uso INCORRECTO:** gerundio al inicio absoluto de oración (“*Ofreciendo una solución, se mejora...*”).

Gerundios detectados con opciones de corrección

Caso 1: Resumen ejecutivo

Texto original: “Ofreciendo una herramienta accesible que fortalece la integridad académica y promueve el desarrollo de competencias en programación eficiente.”

Opciones de corrección:

- **Opción A:** “El sistema ofrece una herramienta accesible que fortalece la integridad académica y promueve el desarrollo de competencias en programación eficiente.”
- **Opción B:** “De este modo, se ofrece una herramienta accesible que fortalece la integridad académica y promueve el desarrollo de competencias en programación eficiente.”
- **Opción C:** “Como resultado, el sistema constituye una herramienta accesible que fortalece la integridad académica y promueve el desarrollo de competencias en programación eficiente.”

Caso 2: Sección 1.3, párrafo 2

Texto original: “...transformando procesos tradicionalmente laboriosos en actividades automatizadas y precisas, mientras que reducirá significativamente el tiempo...”

Opciones de corrección:

- **Opción A:** “...que transforma procesos tradicionalmente laboriosos en actividades automatizadas y precisas, y reduce significativamente el tiempo...”
- **Opción B:** “Esta automatización transforma procesos tradicionalmente laboriosos en actividades automatizadas y precisas, y reduce significativamente el tiempo...”
- **Opción C:** “...lo cual transforma procesos tradicionalmente laboriosos en actividades automatizadas y precisas, además de reducir significativamente el tiempo...”

Caso 3: Sección 1.1, párrafo 4

Texto original: “...la sobrecarga docente continuará incrementándose sin herramientas tecnológicas de apoyo, conduciendo a deterioro en la calidad de enseñanza...”

Opciones de corrección:

- **Opción A:** “...sin herramientas tecnológicas de apoyo, lo cual conducirá a un deterioro en la calidad de enseñanza...”
- **Opción B:** “...sin herramientas tecnológicas de apoyo. Esta situación conducirá a un deterioro en la calidad de enseñanza...”
- **Opción C:** “...sin herramientas tecnológicas de apoyo, por lo que se producirá un deterioro en la calidad de enseñanza...”

Caso 4: Sección 1.3, último párrafo

Texto original: “...generando un círculo vicioso donde la capacidad de proporcionar retroalimentación efectiva...”

Opciones de corrección:

- **Opción A:** “...lo cual genera un círculo vicioso en el cual la capacidad de proporcionar retroalimentación efectiva...”
- **Opción B:** “...Como consecuencia, se genera un círculo vicioso en el que la capacidad de proporcionar retroalimentación efectiva...”
- **Opción C:** “...con la consecuente generación de un círculo vicioso en el cual la capacidad de proporcionar retroalimentación efectiva...”

Caso 5: Sección 4.1 (Síntesis de entrevistas)

Texto original: “Se condujeron entrevistas semiestructuradas con docentes de programación con experiencia mínima de tres años impartiendo asignaturas relacionadas.”

Opciones de corrección:

- **Opción A:** “Se condujeron entrevistas semiestructuradas con docentes de programación con experiencia mínima de tres años **que imparten** asignaturas relacionadas.”
- **Opción B:** “Se condujeron entrevistas semiestructuradas con docentes de programación con experiencia mínima de tres años **en la enseñanza de** asignaturas relacionadas.”

- **Opción C:** *“Se condujeron entrevistas semiestructuradas con docentes con experiencia mínima de tres años en cursos de programación.”*

Caso 6: Sección 3.10.1 (Ejecución del experimento)

Texto original: *“El proceso se realizó de manera secuencial para cada modelo, completando todos los 120 casos antes de proceder al siguiente modelo, minimizando así sesgos temporales...”*

Opciones de corrección:

- **Opción A:** *“El proceso se realizó de manera secuencial para cada modelo: se completaron todos los 120 casos antes de proceder al siguiente. Esto minimizó los sesgos temporales...”*
- **Opción B:** *“El proceso se realizó de manera secuencial para cada modelo. Se completaron los 120 casos para cada uno antes de proceder al siguiente, lo cual minimizó los sesgos temporales...”*

5 Análisis de Tiempos Verbales

Norma de tiempos verbales en escritura científica

- **Resumen:** pretérito perfecto simple (“se desarrolló”, “se evaluó”).
- **Introducción:** presente atemporal para hechos generales, pretérito para investigaciones previas.
- **Marco teórico:** presente atemporal.
- **Metodología:** pretérito (acciones ya realizadas).
- **Resultados:** pretérito (lo que se obtuvo).
- **Discusión:** presente y pretérito mezclados según corresponda.
- **Conclusiones:** presente o pretérito perfecto compuesto.

Inconsistencias detectadas con corrección directa

Caso 1: Capítulo IV (Requisitos)

Observación: el uso de “El sistema deberá permitir...” (futuro de obligación) es correcto en requisitos de software (norma ISO/IEC/IEEE 29148), pero su ubicación en el capítulo de Resultados puede crear confusión.

Opción de corrección: agregar al inicio de la sección 4.2 una oración aclaratoria que enmarque el cambio de tiempo verbal:

“A continuación se presenta la especificación de requisitos del sistema desarrollado, redactada conforme a la norma ISO/IEC/IEEE 29148:2018, la cual establece el uso del verbo modal ‘deberá’ (shall) para expresar obligatoriedad funcional. Los requisitos describen las capacidades que el sistema debe satisfacer.”

Caso 2: Mezcla en sección 4.5

Texto original: “Se implementó el módulo... El sistema cuenta con...”

Opción de corrección: ya cubierta en sección 3.1, Caso 7.

6 Uso de Terminología Técnica

6.1 Inconsistencias terminológicas con opciones de corrección

Términos no unificados

Caso 1: Inconsistencia 4 vs 5 dimensiones de similitud

Problema: el marco teórico (sección 2.1.1.2) menciona **cuatro categorías** (léxica, estructural, estilo, funcional), pero los resultados (sección 4.5) evalúan **cinco dimensiones** (léxica, estructural, estilo, funcional, sintáctica).

Opciones de corrección:

- **Opción A** (ampliar el marco teórico a 5 dimensiones): agregar al final de la sección 2.1.1.2 lo siguiente:

*“En el presente trabajo se incorpora adicionalmente una quinta dimensión: la **similitud sintáctica**, que evalúa la coincidencia de patrones gramaticales del lenguaje de programación independientemente de su semántica funcional. Esta dimensión complementa las cuatro categorías clásicas al capturar similitudes en el uso de constructos del lenguaje (declaraciones de variables, llamadas a métodos, expresiones condicionales) que pueden ser indicadores tempranos de copia con modificaciones superficiales.”*

- **Opción B** (reducir los resultados a 4 dimensiones): eliminar la dimensión sintáctica de los resultados y reportar solo las cuatro originales. **No recomendado** porque el sistema ya implementa las cinco.
- **Opción C** (clarificar que la sintáctica se desprende de la léxica/estructural): justificar en el marco teórico que la similitud sintáctica es un caso especial de la combinación entre léxica y estructural.

Caso 2: Versiones desactualizadas de modelos

Texto original (sección 2.1.2.2): “Las APIs comerciales de modelos como GPT-4 (desarrollado por OpenAI), Claude (de Anthropic) y Gemini (de Google)...”

Opción de corrección: “Las APIs comerciales de modelos como **GPT-5** (desarrollado por OpenAI), **Claude Opus 4.1** (de Anthropic), **Gemini 2.5 Pro** (de Google) y **DeepSeek-V3** (de DeepSeek AI)...”

(Aplicar la misma corrección en la introducción donde se mencionan estos modelos).

Caso 3: Lenguaje coloquial

Texto original (sección 2.1.2.1): “Los programadores pueden usar LLMs para generar código más rápidamente; sin embargo, esto facilita la vida solo si el código sigue reglas del lenguaje...”

Opciones de corrección:

- **Opción A:** “...sin embargo, esto resulta beneficioso únicamente si el código sigue las reglas del lenguaje...”
- **Opción B:** “...sin embargo, este beneficio se materializa únicamente cuando el código generado cumple las reglas del lenguaje...”
- **Opción C:** “...sin embargo, su efectividad depende de que el código respete las reglas del lenguaje...”

Caso 4: Sigla “IAGEN” no definida

Ubicación: Anexo 3.

Opción de corrección: definir la sigla en el cuerpo del documento la primera vez que aparezca, o eliminarla del Anexo 3 y usar “IA generativa” completo.

Sugerencia: en la introducción agregar al final de la primera mención: “...*inteligencia artificial generativa (IAGEN)*...”.

Caso 5: “Códigos” (plural)

Texto problemático: “revisar manualmente múltiples códigos fuente”.

Opción de corrección: “revisar manualmente múltiples **fragmentos de código fuente**” o “múltiples **archivos de código fuente**”.

7 Análisis de Referencias Bibliográficas

7.1 Referencias correctamente indexadas

Referencias en revistas de calidad

- IEEE Access (Q2 JCR) — Zhang & Saber 2025 [9].
- Sensors (Q2 JCR) — Yin et al. 2023 [42].
- Entropy (Q2 JCR) — Li et al. 2024 [41], Zenil 2020 [40].
- Applied Sciences (Q2 Scopus) — Lee et al. 2023 [14], Jošt et al. 2024 [43].
- ACM Transactions on Computing Education (Q1 SJR) — Keuning et al. 2019 [45].
- Computers and Education: AI (Q1 SJR) — Manorat et al. 2025 [7], Yilmaz & Karaoglan 2023 [36].
- PLoS ONE (Q1 JCR) — Kožuh et al. 2018 [26].
- Education Sciences (Q2 Scopus) — Zvieli-Girshin 2024 [25].
- International Journal of Educational Integrity (Q1 Scopus) — Guerrero-Dib et al. 2020 [6].

7.2 Referencias cuestionables con propuestas de sustitución

Referencias problemáticas con sustituciones propuestas

Referencia [3]: Página web del CONICET

Problema: no es referencia científica indexada.

Contexto en el documento: se cita junto con [4] al hablar sobre regulaciones de organismos.

Opciones de corrección:

- **Opción A** (eliminar): la referencia [3] aparece junto con [4] CACES; al ser ambas regulatorias, basta con [4]. Eliminar [3].
- **Opción B** (sustituir por estudio sobre integridad académica latinoamericano):
Bretag, T. (Ed.) (2016). *Handbook of Academic Integrity*. Springer Singapore. DOI: 10.1007/978-981-287-098-8 (Q1 Scopus).

Referencia [5]: Vera Paredes et al. (Ciencia y Educación)

Problema: revista local de baja indexación.

Opción de corrección: sustituir por una referencia indexada con tema similar:

Lepp, M. & Kaimre, J. (2025). “Does generative AI help in learning programming”. *Computers in Human Behavior Reports*, 18: 100642. DOI: 10.1016/j.chbr.2025.100642. (Q1 Scopus).

Nota: esta referencia ya aparece en el documento como [8]. Por tanto, simplemente **eliminar [5] y reasignar las citas a [8]**.

Referencia [10]: Sahoo et al. (arXiv preprint)

Problema: preprint no revisado por pares.

Opción de corrección: sustituir por la versión publicada o por otra revisión sistemática de prompt engineering:

Liu, P. et al. (2023). “Pre-train, Prompt, and Predict: A Systematic Survey of Prompting Methods in Natural Language Processing”. *ACM Computing Surveys*, 55(9). DOI: 10.1145/3560815. (Q1 JCR).

Nota: esta referencia ya está en el documento como [17]. **Eliminar [10] y reasignar las citas a [17]**.

Referencia [11]: Van Viet & Vinh (2024)

Problema: “Journal of Education for Sustainable Innovation” es revista de baja indexación.

Opción de corrección: sustituir por una revisión sistemática indexada de LLMs en ingeniería de software:

Hou, X. et al. (2024). “Large Language Models for Software Engineering: A Systematic Literature Review”. *ACM Transactions on Software Engineering and Methodology*, 33(8). DOI: 10.1145/3695988. (Q1 JCR).

Referencia [12]: Hernández (2015)

Problema: artículo en SciELO Argentina, descriptivo y antiguo (10 años), sin DOI.

Opción de corrección: eliminar la referencia. El contexto donde se cita es secundario y el argumento puede sostenerse con [4], [27] (regulaciones del CES y CACES).

Referencia [13]: Espinoza Freire (2020)

Problema: SciELO Cuba, baja indexación.

Opción de corrección: sustituir por una referencia internacional sobre integridad académica:

Curtis, G. J. & Vardanega, L. (2016). "Is plagiarism changing over time? A 10-year time-lag study". *Higher Education Research & Development*, 35(6): 1167-1179. DOI: 10.1080/07294360.2016.1161602. **(Q1 JCR)**.

Alternativa: Eaton, S. E. (2022). "New priorities for academic integrity". *International Journal for Educational Integrity*, 18: 30. DOI: 10.1007/s40979-022-00115-y. **(Q1 Scopus)**.

Referencia [15]: Zakeri et al. (arXiv)

Problema: preprint.

Opción de corrección: sustituir por la revisión sistemática ya publicada:

Lee, G. et al. (2023). "Review of Code Similarity and Plagiarism Detection Research Studies". *Applied Sciences*, 13(20): 11358. DOI: 10.3390/app132011358. **(Q2 Scopus)**.

Nota: esta referencia ya aparece como [14]. **Eliminar [15] y reasignar a [14].**

Referencia [16]: Férez Vergara y Vergara Ronquillo (2024)

Problema: capítulo de libro local en Dialnet.

Opción de corrección: sustituir por una referencia indexada sobre IA y ética académica:

Cotton, D. R. E., Cotton, P. A. & Shipway, J. R. (2024). "Chatting and cheating: Ensuring academic integrity in the era of ChatGPT". *Innovations in Education and Teaching International*, 61(2): 228-239. DOI: 10.1080/14703297.2023.2190148. **(Q1 Scopus)**.

Referencia [18]: Wei et al. (arXiv)

Problema: aunque la cita actual apunta a arXiv, esta versión **sí fue publicada** en NeurIPS 2022.

Opción de corrección: actualizar la cita al volumen formal:

Wei, J. et al. (2022). "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models". En *Advances in Neural Information Processing Systems (NeurIPS 2022)*, vol. 35, pp. 24824-24837. (NeurIPS es proceedings indexados Q1 en Scopus, conferencia A* CORE).

Referencia [37]: “globalgoals.org”

Problema: página web, no es referencia científica.

Opción de corrección: sustituir por la fuente oficial de la ONU con DOI institucional: United Nations (2015). *Transforming our world: the 2030 Agenda for Sustainable Development*. Resolution adopted by the General Assembly on 25 September 2015, A/RES/70/1. URL: <https://sustainabledevelopment.un.org/post2015/transformingourworld>

Alternativa académica: Sachs, J. D. et al. (2019). “Six Transformations to achieve the Sustainable Development Goals”. *Nature Sustainability*, 2: 805-814. DOI: 10.1038/s41893-019-0352-9. (Q1 JCR).

Referencia [38]: Jiang et al. (Journal of the ACM)

Problema: el DOI apunta a arXiv aunque se cita como “Journal of the ACM”.

Opción de corrección: verificar y corregir la cita. La versión publicada está en:

Jiang, J. et al. (2024). “A Survey on Large Language Models for Code Generation”. arXiv:2406.00515. (Si no está publicada, mantener la cita como arXiv y reconocerlo explícitamente).

Referencia [46]: Brown et al. (NeurIPS 2020)

Problema: la cita usa enlace a arXiv aunque la publicación es de NeurIPS.

Opción de corrección: actualizar la cita:

Brown, T. B. et al. (2020). “Language Models are Few-Shot Learners”. En *Advances in Neural Information Processing Systems (NeurIPS 2020)*, vol. 33, pp. 1877-1901.

Referencia [49]: Fisher (1925)

Problema: referencia centenaria.

Opción de corrección: sustituir por una referencia metodológica moderna:

Field, A. (2018). *Discovering Statistics Using IBM SPSS Statistics* (5th ed.). SAGE Publications. ISBN: 978-1526419521.

Alternativa para el contexto específico de pruebas no paramétricas: McKight, P. E. & Najab, J. (2010). “Kruskal-Wallis Test”. En *The Corsini Encyclopedia of Psychology*. Wiley. DOI: 10.1002/9780470479216.corpsy0491.

Referencia [52]: Almenara y Cejudo (2013)

Problema: revista Eduweb de bajo impacto.

Opción de corrección: sustituir por una referencia internacional sobre juicio de expertos:

Galicia Alarcón, L. A., Balderrama Trápaga, J. A. & Edel Navarro, R. (2017). “Content validity by experts judgment: Proposal for a virtual tool”. *Apertura*, 9(2): 42-53. DOI: 10.32870/Ap.v9n2.993. (Q3 Scopus).

Alternativa más rigurosa: Lynn, M. R. (1986). “Determination and quantification of content validity”. *Nursing Research*, 35(6): 382-385. DOI: 10.1097/00006199-198611000-00017. (Q1 JCR).

Referencias [1]=[23] y [2]=[24] duplicadas

Problema: misma fuente referenciada con dos números distintos.

Opción de corrección:

- Eliminar [23] y reasignar todas sus citas a [1].
- Eliminar [24] y reasignar todas sus citas a [2].
- Renumerar la bibliografía en consecuencia (las referencias [25] a [55] pasarán a ser [23] a [53]).

8 Análisis Estadístico

8.1 Análisis estadístico incorrecto: ANOVA de precisión

Problema crítico: ANOVA aplicado incorrectamente a la precisión

Texto original (sección 4.4.1): “El análisis ANOVA arrojó un valor F de 0 y un p -valor de 1...”

Problema: la precisión es una variable **binaria por caso** (acertó/no acertó). Como los 4 modelos evaluaron los **mismos** 120 casos, los datos son **pareados**. El ANOVA tradicional sobre proporciones agregadas no es la prueba adecuada y produce el resultado degenerado $F=0$, $p=1$.

Datos disponibles: el documento dispone de los aciertos/fallos por caso y modelo (Anexo 3 muestra la plantilla con campos VP, VN, FP, FN y el campo “Coincidencia” con valores 1=Sí, 0=No).

Opción de corrección: Q de Cochran + McNemar

Justificación de la prueba: la **Q de Cochran** es la extensión de la prueba de McNemar a más de dos grupos pareados con variable dependiente dicotómica. Es la prueba estadísticamente correcta para comparar las proporciones de aciertos entre los 4 modelos sobre los mismos 120 casos.

Estructura de datos requerida (extraíble del Anexo 3):

caso_id	claude	gpt5	gemini	deepseek
1	1	1	1	1
2	1	0	1	1
3	1	1	1	0
...				

Código Python para la corrección (puede integrarse al script del Anexo 8):

```
import pandas as pd
```

```

from statsmodels.stats.contingency_tables import cochrans_q
from statsmodels.stats.contingency_tables import mcnemar
from itertools import combinations

# Cargar matriz pivote: 120 filas (casos), 4 columnas (modelos)
df_pivot = df.pivot(index='caso_id', columns='modelo',
                    values='acerto')

# Q de Cochran (omnibus para los 4 modelos)
matriz = df_pivot.values
resultado_q = cochrans_q(matriz)
print(f'Q de Cochran: Q={resultado_q.statistic:.4f}, '
      f'p-valor={resultado_q.pvalue:.4f}')

# Si Q es significativo, post-hoc McNemar por pares
if resultado_q.pvalue < 0.05:
    modelos = df_pivot.columns
    for m1, m2 in combinations(modelos, 2):
        tabla = pd.crosstab(df_pivot[m1], df_pivot[m2])
        # Asegurar tabla 2x2
        if tabla.shape == (2, 2):
            res = mcnemar(tabla.values, exact=True)
            print(f'McNemar {m1} vs {m2}: '
                  f'estadístico={res.statistic}, '
                  f'p-valor={res.pvalue:.4f}')

```

Redacción sugerida para reemplazar el párrafo:

“Dado que la precisión es una variable binaria por caso (acierto o fallo de clasificación) y los cuatro modelos evaluaron los mismos 120 casos, se aplicó la prueba Q de Cochran como prueba omnibus para muestras pareadas con variable dicotómica. La prueba arrojó un estadístico $Q = [\text{valor calculado}]$ con $p\text{-valor} = [\text{valor calculado}]$, lo que indica que [no existen / existen] diferencias significativas entre los modelos en la dimensión de precisión. [Si Q es significativo: Las pruebas post-hoc de McNemar revelaron que las diferencias se concentran en [pares específicos]].”

8.2 Análisis estadísticos faltantes con datos disponibles

8.2.1 Verificación de supuestos paramétricos

Problema

La metodología afirma haber aplicado ANOVA a los tiempos de respuesta sin reportar la verificación de los supuestos paramétricos (normalidad y homocedasticidad).

Opción de corrección: Shapiro-Wilk y Levene

Datos disponibles: el Anexo 8 (script Python) y Anexo 9 (resultados estadísticos) deberían contener los 480 tiempos de respuesta.

Código Python a integrar al Anexo 8:

```

from scipy import stats

# Test de normalidad (Shapiro-Wilk) por modelo
print('=== Prueba de normalidad (Shapiro-Wilk) ===')
for modelo in df['modelo'].unique():
    datos = df[df['modelo']==modelo]['tiempo_respuesta']
    W, p = stats.shapiro(datos)
    interpretacion = 'Normal' if p > 0.05 else 'No normal'
    print(f'{modelo}: W={W:.4f}, p={p:.4f} [{interpretacion}]')

# Test de homocedasticidad (Levene)
print('\n=== Prueba de homocedasticidad (Levene) ===')
grupos = [df[df['modelo']==m]['tiempo_respuesta']
           for m in df['modelo'].unique()]
W, p = stats.levene(*grupos)
interpretacion = ('Varianzas iguales' if p > 0.05
                  else 'Varianzas distintas')
print(f'Levene: W={W:.4f}, p={p:.4f} [{interpretacion}]')

```

Redacción a agregar antes del ANOVA:

“Previo a la aplicación del ANOVA, se verificaron los supuestos paramétricos. La prueba de Shapiro-Wilk arrojó valores de $p = [valores]$ para los cuatro modelos, [indicando/no indicando] desviaciones significativas de la normalidad. La prueba de Levene arrojó un estadístico de [valor] con $p = [valor]$, [confirmando/rechazando] la igualdad de varianzas entre grupos. [Conclusión sobre la idoneidad del ANOVA o la necesidad de pruebas no paramétricas].”

8.2.2 Pruebas post-hoc para tiempos de respuesta

Problema

El ANOVA de tiempos de respuesta es significativo ($F=30.89$, $p \approx 0$), pero no se identifica qué pares de modelos difieren entre sí.

Opción de corrección: Tukey HSD o Games-Howell

Datos disponibles: las 480 mediciones de tiempo.

Código Python:

```

from statsmodels.stats.multicomp import pairwise_tukeyhsd
import scikit_posthocs as sp

# Si Levene NO rechazó la homocedasticidad: Tukey HSD
tukey = pairwise_tukeyhsd(
    endog=df['tiempo_respuesta'],
    groups=df['modelo'],
    alpha=0.05
)
print(tukey)

```

```
# Si Levene rechazó la homocedasticidad: Games-Howell
gh = sp.posthoc_games_howell(
    df, val_col='tiempo_respuesta', group_col='modelo'
)
print(gh)
```

Redacción a agregar tras el resultado del ANOVA:

“Dado que el ANOVA reveló diferencias significativas entre modelos, se aplicaron pruebas post-hoc de Tukey HSD para identificar qué pares de modelos difieren. Los resultados (Tabla X) muestran que Claude Opus 4.1 difiere significativamente de [GPT-5/Gemini/DeepSeek] ($p < 0.05$), mientras que [otros pares] no presentan diferencias significativas.”

8.2.3 Tamaño del efecto

Problema

Las pruebas estadísticas reportan F, H y p, pero no la magnitud del efecto. En muestras grandes, diferencias triviales pueden ser estadísticamente significativas sin ser prácticamente relevantes.

Opción de corrección: η^2 y ϵ^2

Datos disponibles: los datos del experimento.

Código Python:

```
import numpy as np

# Eta cuadrado para ANOVA (tiempos de respuesta)
def eta_squared(F, df_between, df_within):
    return (F * df_between) / (F * df_between + df_within)

# Para 4 modelos y 480 observaciones:
F = 30.8935
df_between = 4 - 1 # 3
df_within = 480 - 4 # 476
eta2 = eta_squared(F, df_between, df_within)
print(f'eta cuadrado (ANOVA tiempos): {eta2:.4f}')
```

```
# Epsilon cuadrado para Kruskal-Wallis (calidad)
def epsilon_squared(H, n):
    return H / (n - 1)

H = 11.4991
n = 480
eps2 = epsilon_squared(H, n)
print(f'epsilon cuadrado (Kruskal-Wallis calidad): {eps2:.4f}')
```

Interpretacion:

```
# eta2/epsilon2 < 0.01: trivial
# 0.01 - 0.06: pequeno
# 0.06 - 0.14: mediano
# > 0.14: grande
```

Redacción sugerida:

“Para evaluar la magnitud práctica de las diferencias, se calculó el tamaño del efecto. El ANOVA de tiempos de respuesta arrojó $\eta^2 = [\text{valor}]$, lo que representa un efecto [pequeño/mediano/grande] según los criterios de Cohen. El Kruskal-Wallis de calidad arrojó $\epsilon^2 = [\text{valor}]$, indicando un efecto [...].”

8.2.4 Análisis estratificado por lenguaje (ANOVA factorial)**Problema**

Las Tablas 10 y 11 desagregan algunos resultados por lenguaje, pero no se evalúa la **interacción** entre modelo y lenguaje mediante ANOVA factorial.

Opción de corrección: ANOVA factorial 4×2

Datos disponibles: las 480 mediciones con etiqueta de lenguaje.

Código Python:

```
import statsmodels.api as sm
from statsmodels.formula.api import ols

# ANOVA factorial 4 modelos x 2 lenguajes con interaccion
modelo = ols(
    'tiempo_respuesta ~ C(modelo) * C(lenguaje)',
    data=df
).fit()
tabla_anova = sm.stats.anova_lm(modelo, typ=2)
print(tabla_anova)

# Tamano del efecto eta2 parcial
ss_total = tabla_anova['sum_sq'].sum()
for factor in tabla_anova.index[:-1]:
    eta2_parcial = (tabla_anova.loc[factor, 'sum_sq'] /
                    ss_total)
    print(f'eta2 parcial {factor}: {eta2_parcial:.4f}')
```

Redacción sugerida:

“Para evaluar si el rendimiento de los modelos depende del lenguaje de programación, se aplicó un ANOVA factorial 4 (modelo) × 2 (lenguaje) con término de interacción. El efecto principal del modelo fue [significativo / no significativo] ($F=[\text{valor}]$, $p=[\text{valor}]$), el efecto principal del lenguaje fue [significativo / no significativo] ($F=[\text{valor}]$, $p=[\text{valor}]$), y la interacción modelo × lenguaje fue [significativa / no significativa] ($F=[\text{valor}]$, $p=[\text{valor}]$). [Interpretación: si la interacción es significativa, indica que las diferencias entre modelos varían según el lenguaje].”

8.2.5 Matrices de confusión

Problema

Las matrices de confusión se mencionan en la metodología (sección 3.8) pero no aparecen en el documento.

Opción de corrección: incluir 4 matrices de confusión

Datos disponibles: el Anexo 3 contiene los campos VP, VN, FP, FN para cada caso.

Código Python:

```
from sklearn.metrics import (confusion_matrix,
                             classification_report, matthews_corrcoef)
import seaborn as sns
import matplotlib.pyplot as plt

for modelo in ['claude', 'gpt5', 'gemini', 'deepseek']:
    df_m = df[df['modelo']==modelo]
    y_true = df_m['categoria_real']
    y_pred = df_m['categoria_predicha']

    cm = confusion_matrix(y_true, y_pred,
                          labels=['identico', 'funcional', 'estructural',
                                  'diferente'])

    plt.figure(figsize=(6,5))
    sns.heatmap(cm, annot=True, fmt='d', cmap='Blues',
                xticklabels=['identico', 'funcional',
                              'estructural', 'diferente'],
                yticklabels=['identico', 'funcional',
                              'estructural', 'diferente'])
    plt.title(f'Matriz de confusion - {modelo}')
    plt.xlabel('Categoria predicha')
    plt.ylabel('Categoria real')
    plt.savefig(f'cm_{modelo}.png', dpi=150)
    plt.close()

    # Metricas adicionales
    print(f'\n=== {modelo} ===')
    print(classification_report(y_true, y_pred))
    print(f'Matthews Correlation Coefficient: '
          f'{matthews_corrcoef(y_true, y_pred):.4f}')
```

Recomendación: incluir 4 figuras (una por modelo) con sus matrices de confusión y una tabla con **Accuracy, Precision, Recall, F1-Score y MCC** por modelo.

8.2.6 Análisis dimensional desagregado

Problema

Aunque se evalúan 5 dimensiones de similitud, no se presenta el desempeño de cada modelo en cada dimensión por separado.

Opción de corrección: tabla con 5 dimensiones por modelo

Datos disponibles: el prompt del Anexo 2 instruye a los modelos a generar un puntaje 0-100 por cada dimensión. Estos datos están en el Anexo 6 (justificaciones textuales) y deben extraerse al script del Anexo 8.

Código Python:

Tabla con medias por dimension y modelo
dimensiones = ['lexica', 'estructural', 'estilo',
 'funcional', 'sintactica']
tabla_dim = df.groupby('modelo')[dimensiones].agg(
 ['mean', 'std']
)
print(tabla_dim.round(2))

MANOVA: comparacion multivariada
from statsmodels.multivariate.manova import MANOVA

formula = ' + '.join(dimensiones) + ' ~ modelo'
manova = MANOVA.from_formula(formula, data=df)
print(manova.mv_test())

Tabla sugerida para incluir en los resultados:

“Tabla X. Puntuaciones de similitud por dimensión y modelo (media ± desviación estándar)”

Modelo	Léxica	Estructural	Estilo	Funcional	Sintáctica
Claude Opus 4.1	...	...	...	...	...
GPT-5	...	...	...	...	...
Gemini 2.5 Pro	...	...	...	...	...
DeepSeek-V3	...	...	...	...	...

8.2.7 Inconsistencia en la Tabla 12

Problema

La Tabla 12 muestra que Claude Opus 4.1 tiene puntuación total de 14.93. Sin embargo, el texto dice “Claude Opus 4.1 con 4.96”. La diferencia de escala (total 14.93 vs. promedio 4.96) no se explica.

Opción de corrección: aclarar las escalas

Análisis del problema: la Tabla 12 suma claridad (1-5) + completitud (0-4) + coherencia (1-5) = puntuación total (3-14). Pero el texto promedia las puntuaciones individuales en escala 1-5.

Opciones de corrección:

- **Opción A** (mantener Tabla 12 con suma y aclarar): agregar nota al pie de la Tabla 12: *“La puntuación total se obtiene como la suma de las tres dimensiones (rango posible 3-14)”*.

Y reformular el texto del párrafo posterior: *“Las puntuaciones globales en escala normalizada [0-1], obtenidas dividiendo la puntuación total por el máximo (14), fueron: Claude Opus 4.1 con 0.99, Gemini 2.5 Pro con 0.99, GPT-5 con 0.97 y DeepSeek-V3 con 0.97”*.

- **Opción B** (cambiar Tabla 12 a promedio en escala 1-5): reemplazar la columna “Puntuación Total” por “Promedio”, donde Promedio = (Claridad + Completitud $\times$ (5/4) + Coherencia)/3.

Esto requiere normalizar la dimensión de completitud (que tiene escala 0-4) a escala 1-5.

- **Opción C** (eliminar la columna total y dejar las tres dimensiones desagregadas): el lector puede comparar las dimensiones por separado.

8.2.8 Caracterización de los expertos**Problema**

La Tabla 14 identifica los expertos solo como “Experto 1, 2, 3, 4, 5” sin perfil profesional.

Opción de corrección: tabla de caracterización de expertos

Datos a recoger: si no se han recogido durante la validación, contactar a los 5 expertos para obtener:

- Años de experiencia docente.
- Nivel académico (PhD, MSc, Ingeniero).
- Asignaturas de programación que imparte.
- Experiencia previa con herramientas de detección de similitudes.

Tabla sugerida (a agregar antes de la Tabla 14):

Tabla X. Perfil profesional de los expertos evaluadores

Experto	Años exp.	Nivel	Especialidad
1	...	...	...
2	...	...	...
3	...	...	...
4	...	...	...
5	...	...	...

8.2.9 Acuerdo entre expertos

Problema

No se calcula el coeficiente de acuerdo entre los 5 expertos.

Opción de corrección: ICC y W de Kendall

Datos disponibles: las 90 puntuaciones (5 expertos $\times$ 18 ítems del cuestionario).

Código Python:

```
import pingouin as pg

# Coeficiente de Correlacion Intraclass
icc = pg.intraclass_corr(
    data=df_expertos_largo,
    targets='item',
    raters='experto',
    ratings='puntuacion'
)
print(icc)

# Alfa de Cronbach del cuestionario
alpha = pg.cronbach_alpha(data=df_expertos[items_18])
print(f'Alfa de Cronbach: {alpha[0]:.4f}')
```

Redacción sugerida a agregar tras la Tabla 14:

“Para evaluar la consistencia entre los 5 expertos, se calculó el coeficiente de correlación intraclase (ICC), obteniéndose un valor de [valor] (IC 95%: [...]) que indica un acuerdo [pobre/moderado/bueno/excelente] según los criterios de Koo y Li (2016). El alfa de Cronbach del cuestionario completo fue de [valor], lo que sugiere [una confiabilidad aceptable/buena/excelente] del instrumento de evaluación.”

8.3 Análisis estadísticos faltantes que NO se pueden calcular con los datos disponibles

Solo se da a conocer: análisis que requieren nuevos datos

Los siguientes análisis estadísticos serían deseables para fortalecer el rigor del estudio, pero **requieren la recolección de datos adicionales** y por lo tanto no se ofrecen como “opciones de corrección” inmediatas:

1. Acuerdo inter-evaluador del ground truth (kappa de Cohen)

Datos faltantes: clasificaciones independientes de los 120 pares por al menos 2-3 evaluadores adicionales (no solo el autor).

Solo se da a conocer: para fortalecer la validez del *ground truth*, sería necesario reclutar 2 evaluadores expertos que clasifiquen independientemente los 120 pares en las 4 categorías y calcular el kappa de Cohen (≥ 0.61 aceptable). Sin estos datos, el ground truth depende

exclusivamente del juicio del autor.

2. Variabilidad intra-modelo (ICC de respuestas repetidas)

Datos faltantes: cada caso fue consultado **una sola vez** por cada modelo. No hay réplicas para evaluar la estabilidad de las respuestas de los LLMs (que son probabilísticos).

Solo se da a conocer: dado que los LLMs no son determinísticos, idealmente deberían repetirse las consultas (al menos 3-5 veces) sobre una submuestra de 30 casos. Sin estos datos, no se puede afirmar que las diferencias entre modelos son robustas a la variabilidad estocástica de las respuestas.

3. Validación inter-evaluador de la rúbrica de calidad (ICC)

Datos faltantes: las 480 justificaciones fueron evaluadas por el autor solo. No hay segundo evaluador para calcular el acuerdo en la aplicación de la rúbrica.

Solo se da a conocer: se sugiere para futuras versiones que una submuestra de 60-80 justificaciones sea reevaluada por un segundo evaluador para calcular el ICC y validar la confiabilidad de la rúbrica.

4. Análisis de potencia estadística a priori

Datos faltantes: el tamaño muestral ($n=120$) se justifica por una referencia [47] sobre fine-tuning de LLMs, lo cual es metodológicamente discutible.

Solo se da a conocer: lo apropiado habría sido un análisis de potencia a priori con G*Power para determinar el tamaño muestral mínimo. Con los datos actuales se puede hacer un **análisis de potencia post-hoc** (ver opción más abajo) pero no a priori.

5. Estudio longitudinal de adopción

Datos faltantes: el sistema fue evaluado en condiciones controladas, no en uso real.

Solo se da a conocer: el sistema no se ha probado durante un semestre académico completo. Para evaluar la utilidad práctica real, se requeriría un estudio longitudinal con métricas de uso continuado.

6. Análisis de costo-beneficio cuantitativo

Datos faltantes: el documento argumenta sobre limitaciones presupuestarias pero no presenta cálculos de costo de las APIs.

Solo se da a conocer: sería deseable cuantificar el costo por consulta de cada API (USD/consulta), el costo total del experimento, y proyectar el costo institucional para uso regular.

7. Análisis cualitativo profundo de las entrevistas

Datos faltantes: la sección 4.1 ofrece una síntesis de los temas pero no incluye análisis temático sistemático con citas representativas.

Solo se da a conocer: se podría enriquecer la presentación cualitativa con análisis temático (Braun & Clarke, 2006), incluyendo tabla de códigos, categorías y temas emergentes con citas representativas anonimizadas.

Opción de corrección viable con datos existentes: análisis de potencia post-hoc

Aunque el análisis de potencia a priori no es posible (los datos ya se recolectaron), **sí es posible** calcular la potencia post-hoc para reportar:

Código Python:

```
from statsmodels.stats.power import FTestAnovaPower

# Calcular tamaño del efecto f de Cohen a partir de eta2
eta2 = 0.163 # Sustituir por el valor calculado
f_cohen = (eta2 / (1 - eta2)) ** 0.5

# Potencia observada
analisis = FTestAnovaPower()
potencia = analisis.solve_power(
    effect_size=f_cohen,
    k_groups=4,
    nobs=480,
    alpha=0.05
)
print(f'Tamaño del efecto f de Cohen: {f_cohen:.4f}')
print(f'Potencia observada: {potencia:.4f}')
```

Redacción sugerida:

*“El análisis de potencia post-hoc, calculado con G*Power para un ANOVA de un factor con 4 grupos y n total = 480, indicó una potencia observada de [valor] para detectar efectos del tamaño obtenido (f de Cohen = [valor]). Esta potencia [supera/no supera] el umbral convencional de 0.80, lo que respalda la robustez de las conclusiones inferenciales.”*

9 Análisis de la Sección de Resultados

9.1 Tabla 12: inconsistencia entre tabla y texto

(Ya cubierta en sección 7.2.6 de este informe)

9.2 Análisis dimensional faltante

(Ya cubierta en sección 7.2.5 de este informe)

9.3 Matrices de confusión

(Ya cubierta en sección 7.2.4 de este informe)

10 Análisis de la Introducción

Avances importantes

La introducción ha sido reestructurada incluyendo problema científico, objetivo general, contribución/novedad y metodología.

Aspectos por mejorar con opciones de corrección

Caso 1: Falta el párrafo de estructura del documento

Opción de corrección: agregar al final de la introducción el siguiente párrafo:

Texto sugerido:

“El presente documento se organiza en seis capítulos. El Capítulo I presenta la contextualización del problema, los objetivos y la justificación de la investigación. El Capítulo II desarrolla el marco conceptual y referencial sobre detección de similitud, IA generativa y eficiencia algorítmica. El Capítulo III describe la metodología, incluyendo el diseño experimental, los instrumentos y el tratamiento estadístico de los datos. El Capítulo IV expone los resultados y la discusión, integrando la evaluación comparativa de modelos de IA, la implementación de los módulos del sistema SimilCode y la validación con expertos. El Capítulo V presenta las conclusiones y recomendaciones. Los Capítulos VI y VII contienen, respectivamente, la bibliografía y los anexos.”

Caso 2: Versiones desactualizadas de modelos

Texto original: “Los modelos de lenguaje grandes como GPT-4, Claude, Gemini y DeepSeek...”

Opción de corrección: “Los modelos de lenguaje grandes como **GPT-5**, **Claude Opus 4.1**, **Gemini 2.5 Pro** y **DeepSeek-V3**...”

11 Análisis de la Metodología

11.1 Contradicción APIs vs interfaces web

Problema crítico

La sección 3.10.1 contiene contradicciones internas:

Texto 1 (configuración del entorno): “Se accedió a las interfaces de chat web de los cuatro modelos...”

Texto 2 (ejecución del experimento): “...se enviaba el prompt estandarizado junto con el par de códigos a comparar a la **API** del modelo correspondiente. Se registró el **timestamp** de envío y recepción...”

¿Se usaron interfaces web (medición manual con cronómetro) o APIs programáticas (timestamps automáticos)?

Opciones de corrección: aclarar el método

Opción A (si efectivamente se usaron interfaces web manuales): reescribir la sección de ejecución eliminando las menciones a APIs y timestamps:

“Para cada caso de prueba se accedió a la interfaz web del modelo correspondiente, se ingresó el prompt estandarizado junto con el par de códigos a comparar, y se midió el tiempo de respuesta mediante cronómetro digital desde el envío hasta la generación completa. Las respuestas fueron copiadas y almacenadas en documentos de texto para su posterior análisis. El proceso se realizó de manera secuencial para cada modelo.”

Opción B (si efectivamente se usaron APIs programáticas): reescribir la sección de configuración eliminando las menciones a interfaces web:

“Las consultas se realizaron mediante las APIs oficiales de cada proveedor (Anthropic Claude API, OpenAI API, Google AI API y DeepSeek AI API). Para cada caso de prueba, un script Python enviaba el prompt estandarizado junto con el par de códigos y registraba el timestamp de envío y de recepción de la respuesta completa. Los parámetros de generación (temperatura, max_tokens) se mantuvieron constantes entre modelos para garantizar comparabilidad.”

Opción C (método mixto, si efectivamente se usó así): aclarar qué se hizo con cada modelo:

“Las consultas se realizaron mediante [interfaz web/API] para los modelos [X y Y], y mediante [interfaz web/API] para los modelos [Z y W]. La heterogeneidad de métodos se debe a [justificación: por ejemplo, disponibilidad de API, costos, etc.]. Los tiempos se midieron mediante [cronómetro digital / timestamps de la API].”

Recomendación: revisar los datos crudos en el Anexo 9 para determinar cuál fue el método real, y elegir la Opción A o B.

11.2 Justificación del tamaño muestral

Problema

La referencia [47] (Holovko & Aliksieiev 2025) trata sobre fine-tuning de LLMs para análisis de estilo de código, no sobre evaluación comparativa de modelos. Justificar el tamaño muestral con esta referencia es metodológicamente discutible.

Opción de corrección: análisis de potencia a priori reportado a posteriori

Texto sugerido para reemplazar la justificación actual:

“El tamaño muestral de 120 casos por modelo (480 mediciones totales) se determinó considerando dos criterios complementarios: (i) el equilibrio entre las cuatro categorías de similitud, asignando 30 casos por categoría (15 en C# y 15 en Java) para asegurar representación balanceada; y (ii) el tamaño suficiente para detectar diferencias de magnitud media (f de Cohen ≥ 0.25) entre modelos con potencia estadística de 0.80 y nivel de significancia $\alpha = 0.05$, según el análisis de potencia realizado con G*Power [referencia G*Power]. Adicionalmente, este tamaño se encuentra dentro del rango utilizado en estudios comparativos de LLMs en tareas de análisis de código [referencia adicional].”

Referencia recomendada para citar G*Power: Faul, F., Erdfelder, E., Buchner, A. & Lang, A.-G. (2009). “Statistical power analyses using G*Power 3.1”. *Behavior Research Methods*, 41(4): 1149-1160. DOI: 10.3758/BRM.41.4.1149. (Q1 JCR).

12 Análisis de Conclusiones

Carencias detectadas

Caso 1: No se referencian trabajos relacionados

Opción de corrección: agregar referencias a las conclusiones para vincular hallazgos con literatura previa.

Texto original (conclusión 1): “...la evaluación comparativa demostró que la precisión de detección ha alcanzado un nivel de madurez equivalente entre los modelos actuales, con un 98.3 % en todos los casos.”

Versión mejorada: “...la evaluación comparativa demostró que la precisión de detección ha alcanzado un nivel de madurez equivalente entre los modelos actuales, con un 98.3 % en todos los casos. Este hallazgo extiende la tendencia documentada por Zhang & Saber [9] hacia modelos generalistas no entrenados específicamente en código, contradiciendo parcialmente la suposición de que se requiere fine-tuning para alcanzar precisión competitiva.”

Caso 2: No se cuantifica el aporte

Texto original (conclusión 2): “...se demostró la viabilidad técnica de construir un módulo de comparación individual...”

Versión mejorada: “...se demostró la viabilidad técnica de construir un módulo de comparación individual que evalúa similitud en cinco dimensiones independientes con tiempos promedio de 19.08 segundos por análisis, alcanzando una precisión del 98.3 % y una calidad de justificación de 4.96/5.00 en la evaluación del modelo seleccionado (Claude Opus 4.1)...”

Caso 3: Falta conclusión sobre validación con expertos

Opción de corrección: agregar una conclusión adicional:

Texto sugerido:

“La validación con cinco expertos en docencia de programación arrojó una valoración global de 4.60/5.00, con puntuaciones máximas en utilidad práctica (4.80), precisión de resultados (4.60) y comprensibilidad de las justificaciones (4.60). Este resultado confirma que SimilCode satisface los requisitos funcionales identificados durante el levantamiento de necesidades y que su adopción en contextos académicos reales es viable desde la perspectiva del usuario final.”

Caso 4: Falta una conclusión global

Opción de corrección: agregar como conclusión final:

Texto sugerido:

“En conjunto, este trabajo aporta tres contribuciones diferenciadas al campo de la educación en programación con apoyo de IA: (i) evidencia empírica comparativa entre cuatro modelos de IA generativa actuales en tareas de análisis de código, (ii) un enfoque multidimensional de detección de similitud que supera las limitaciones de los métodos sintácticos tradicionales, y (iii) la integración del análisis automatizado de eficiencia algorítmica en notación Big O dentro del mismo flujo de evaluación, funcionalidad no documentada en la literatura revisada. SimilCode constituye una herramienta accesible y de bajo costo orientada a instituciones educativas con limitaciones presupuestarias, contribuyendo así al ODS 4 sobre educación de calidad.”

13 Análisis de Recomendaciones

Recomendaciones que faltan

Considerando las limitaciones identificadas en este análisis, deberían añadirse las siguientes recomendaciones:

Opciones de redacción de recomendaciones adicionales

Recomendación 4: Mediciones automáticas

“Se recomienda implementar las mediciones de tiempo de respuesta mediante APIs programáticas con timestamps al milisegundo, en lugar de cronometraje manual con interfaces web, para incrementar la precisión y reproducibilidad de las mediciones temporales en futuros estudios.”

Recomendación 5: Validación inter-evaluadores del ground truth

“Se recomienda que la construcción de futuros datasets de evaluación incluya la clasificación independiente por al menos dos evaluadores expertos, con cálculo del coeficiente kappa de Cohen para validar la consistencia del ground truth establecido.”

Recomendación 6: Estudio longitudinal de adopción

“Se recomienda realizar un estudio longitudinal de adopción del sistema durante al menos un semestre académico completo, con métricas de uso continuado, satisfacción de usuarios y comparación de eficiencia docente antes y después de la implementación.”

Recomendación 7: Evaluación de variabilidad intra-modelo

“Se recomienda que futuros estudios incorporen mediciones repetidas (al menos 3-5 réplicas por consulta) para evaluar la estabilidad de las respuestas de los LLMs mediante el coeficiente de correlación intraclase, dado que estos modelos son inherentemente probabilísticos.”

Recomendación 8: Modelos open-source ejecutables localmente

“Se recomienda explorar la integración de modelos open-source ejecutables localmente (como Llama 3, Qwen-Coder o Mistral) para reducir la dependencia de APIs externas y los costos asociados al uso intensivo del sistema en instituciones con limitaciones presupuestarias.”

Recomendación 9: Compatibilidad con LMS

“Se recomienda extender el sistema mediante integraciones con sistemas de gestión del aprendizaje (LMS) como Moodle y Canvas, mediante el estándar LTI (Learning Tools Interoperability), para facilitar la adopción institucional y el flujo de trabajo docente.”

14 Análisis del Resumen Ejecutivo y Abstract

Aspectos por mejorar

Caso 1: Gerundio inicial

(Ya cubierto en sección 4.3, Caso 1).

Caso 2: Falta de resultados cuantitativos

Opción de corrección: integrar los resultados cuantitativos clave en el resumen.

Texto sugerido a agregar al resumen:

“Los resultados muestran que los cuatro modelos alcanzaron una precisión equivalente del 98.3 % en la clasificación de similitud, mientras que Claude Opus 4.1 superó significativamente a los demás en tiempo de respuesta (19.08 s frente a 23.15-25.73 s; ANOVA $F=30.89$, $p < 0.001$) y en calidad de justificaciones (4.96/5.00; Kruskal-Wallis $H=11.50$, $p=0.009$). El sistema desarrollado fue validado con cinco expertos, obteniendo una valoración global de 4.60/5.00.”

Caso 3: Asimetría entre resumen español e inglés

Texto a agregar al resumen español (para hacerlo equivalente al abstract en inglés):

“Se concluye que la aplicación reduce significativamente la carga de trabajo docente, ofreciendo una herramienta accesible que fortalece la integridad académica y promueve el desarrollo de competencias en programación eficiente.”

Caso 4: Palabras clave incompletas

Palabras clave originales: “Detección de similitud en código, inteligencia artificial generativa, análisis de eficiencia algorítmica, aplicación web, educación en programación.”

Palabras clave sugeridas (más términos técnicos centrales):

“Detección de similitud en código, inteligencia artificial generativa, modelos de lenguaje grandes (LLMs), análisis de eficiencia algorítmica, notación Big O, ingeniería de prompts, Chain-of-Thought, aplicación web, educación en programación.”

15 Análisis del Código Dublin

Campos vacíos

El Código Dublin tiene varios campos vacíos.

Opción de corrección: completar el Código Dublin

Plantilla sugerida con valores propuestos:

Campo	Valor sugerido
Título	Aplicación Web para la Detección de Similitud mediante Inteligencia Artificial Generativa y Análisis de Eficiencia Algorítmica en Código Fuente de Software
Autor	Rafael Alexander Navas Rivera
Palabras claves	Detección de similitud en código; IA generativa; LLMs; Big O; ingeniería de prompts; aplicación web; educación en programación
Fecha de publicación	[día] de [mes] de 2025
Editorial	Quevedo: UTEQ, 2025
Resumen	[Pegar el resumen ejecutivo en español, máximo 300 palabras]
Abstract	[Pegar el resumen ejecutivo en inglés, máximo 300 palabras]
Descripción	108 hojas: 29 x 21 cm + CD-ROM 6162
URI	[Asignado por el repositorio institucional UTEQ tras publicación]

16 Cuadro Resumen de Observaciones y sus Correcciones

Resumen ejecutivo de observaciones, severidad y tipo de corrección disponible

Observación	Severidad	Tipo de corrección
Pregunta de investigación con error gramatical	Crítica	3 opciones de redacción
Frase truncada en sección 2.2.6	Crítica	Corrección directa
Frase truncada en sección 4.2	Crítica	3 opciones de redacción
ANOVA de precisión incorrecto	Crítica	Sustituir por Q de Cochran (código provisto)
Inconsistencia 4 vs 5 dimensiones	Crítica	3 opciones de armonización
Contradicción APIs vs interfaces web	Crítica	3 opciones (A, B o C) según método real
Referencias [1]=[23] y [2]=[24] duplicadas	Alta	Eliminar y reasignar citas
Inconsistencia Tabla 12 (escala 14.93 vs 4.96)	Alta	3 opciones de aclaración
Verificación supuestos estadísticos	Alta	Código provisto (Shapiro-Wilk, Levene)
Pruebas post-hoc no reportadas	Alta	Código provisto (Tukey HSD/Games-Howell)
Tamaño del efecto no reportado	Alta	Código provisto (η^2 , ϵ^2)
Análisis dimensional desagregado	Alta	Código provisto (MANOVA y tabla)
Caracterización de expertos faltante	Alta	Plantilla de tabla provista
Acuerdo entre expertos no calculado	Alta	Código provisto (ICC, Cronbach)
Matrices de confusión no presentadas	Alta	Código provisto (sklearn)
Tildes faltantes	Media	Correcciones directas
Tiempos verbales inconsistentes	Media	Correcciones directas
Versiones desactualizadas (GPT-4)	Media	Corrección directa
“Donde” fuera de contexto espacial	Media	5 correcciones directas
Inicio con gerundio	Media	Múltiples opciones por caso
Conclusiones sin referencias	Media	Versiones mejoradas provistas
Falta conclusión sobre expertos	Media	Texto sugerido
Falta conclusión global	Media	Texto sugerido
Recomendaciones insuficientes	Media	6 recomendaciones adicionales
Código Dublin incompleto	Media	Plantilla con valores sugeridos
Falta estructura del documento (intro)	Media	Texto sugerido
Justificación tamaño muestral discutible	Media	Texto sugerido + ref. G*Power
Referencias cuestionables (varias)	Media	Sustituciones con DOI y cuartil
“big o” en Figura 9	Baja	Corrección directa
“16 Gb” debería ser “16 GB”	Baja	Corrección directa
“Intel Corei5-10400” falta espacio	Baja	Corrección directa
Frases excesivamente largas	Baja	Sugerencia de división
Acuerdo inter-evaluador ground truth	Crítica	Solo se da a conocer (faltan datos)
Variabilidad intra-modelo	Alta	Solo se da a conocer (faltan datos)
Validación inter-evaluador rúbrica	Alta	Solo se da a conocer (faltan datos)
Estudio longitudinal	Media	Solo se da a conocer (faltan datos)
Análisis de costo-beneficio	Media	Solo se da a conocer (faltan datos)
Análisis temático profundo entrevistas	Media	Solo se da a conocer (faltan datos)

17 Conclusión del Análisis

La versión final del proyecto presenta avances sustanciales respecto a versiones anteriores. Este informe ha proporcionado, para cada observación detectada:

- **Opciones de corrección concretas** cuando son realizables con los datos y materiales disponibles, incluyendo:
 - Redacciones alternativas etiquetadas como Opción A, B, C, etc.
 - Sustituciones de referencias bibliográficas con DOIs y cuartiles indicados.
 - Código Python ejecutable para los análisis estadísticos faltantes.
 - Plantillas de tablas para datos a recoger.
 - Textos sugeridos para incorporar en distintas secciones.
- **Identificación explícita** de las observaciones que no pueden corregirse con los datos existentes, marcadas como “solo se da a conocer”, con explicación de qué datos serían necesarios para abordarlas.

Recomendación general: priorizar la atención de las observaciones críticas (errores gramaticales graves, ANOVA incorrecto, contradicción metodológica, inconsistencias de datos) antes de la entrega final. Los análisis estadísticos adicionales (verificación de supuestos, post-hoc, tamaño del efecto, matrices de confusión, análisis dimensional) son altamente recomendables y **ya cuentan con código ejecutable provisto en este informe**, por lo que su implementación es directa.

Las observaciones señaladas como “solo se da a conocer” representan oportunidades de fortalecimiento futuro del trabajo y pueden incorporarse como recomendaciones explícitas para investigaciones posteriores.