

Informe complementario:

Análisis del recogimiento de datos
para la consecución de los objetivos

Trabajo de Integración Curricular:
“Sistema de diagnóstico de cardiopatías mediante un modelo
de aprendizaje automático”

Autora: Angélica Michelle Tenecela Intriago | Director: Ing. Ariosto E. Vicuña Pino, MSc
Universidad Técnica Estatal de Quevedo — Carrera de Software — 2025

Documento independiente que complementa el informe general
de revisión científica y editorial.

Nota preliminar

Este informe complementario se entrega como documento independiente, separado del informe general de revisión científica y editorial. Su objetivo único es auditar el **diseño y calidad del recogimiento de datos** del proyecto, contrastando los datos efectivamente recogidos con los datos que cada objetivo del trabajo *exigía* para considerarse alcanzado, y evaluando si el análisis estadístico aplicado a esos datos es el apropiado en cada caso.

El proyecto involucra **cuatro tipos distintos de datos**, cada uno con su propio propósito metodológico:

- 1. **Datos cualitativos del levantamiento de requerimientos** (observación, entrevistas, formularios) — soportan el Objetivo Específico 1.
- 2. **Datos clínicos secundarios para el entrenamiento del modelo** (*dataset* público) — soportan el Objetivo Específico 2.
- 3. **Datos técnicos de funcionamiento del sistema integrado** (rendimiento, pruebas funcionales) — soportan el Objetivo Específico 3.
- 4. **Datos perceptuales de aceptación tecnológica** (cuestionario TAM) — transversales al Objetivo General.

1 Mapeo entre objetivos, datos y análisis

La trazabilidad entre objetivos, datos y análisis estadísticos permite identificar si el diseño del proyecto era adecuado para responder a las preguntas de investigación. La siguiente tabla resume el contraste entre lo necesario y lo aplicado:

Objetivo	Datos requeridos	Datos recogidos	Análisis aplicado vs. requerido
OE1 — Módulo de administración de datos clínicos	Necesidades reales del personal médico y administrativo	Observación, entrevistas, formularios	Análisis cualitativo declarado pero <i>no presentado</i> . Falta análisis temático o codificación.

Objetivo	Datos requeridos	Datos recogidos	Análisis aplicado vs. requerido
OE2 — Modelo predictivo	Conjunto clínico balanceado, con variable objetivo	<i>Heart Disease</i> combinado (UCI), 1 190 instancias	Estadística descriptiva, validación cruzada $k = 10$, métricas (AUC, F_1). Falta IC, prueba pareada, validación externa.
OE3 — Integración del modelo en la web	Tiempos de respuesta, errores, comportamiento bajo carga	6 <i>endpoints</i> , 15 usuarios virtuales, 90 s	Percentiles P95/P99. Falta justificación de la carga, IC, distribución completa.
General — Sistema validado	Percepción de utilidad y facilidad de uso	TAM con $n = 5$, escala Likert 1–5	Promedios aritméticos. Falta alfa de Cronbach, ítems del cuestionario, pruebas no paramétricas.

2 Tipo 1 — Datos cualitativos para los requerimientos (OE1)

El Capítulo III del documento original enuncia tres fuentes para el levantamiento: (i) observación directa, (ii) análisis documental de formularios, y (iii) entrevistas semiestructuradas a personal administrativo, estratégico y a un cardiólogo. La auditoría del recogimiento es la siguiente:

Datos cualitativos sin sistematización:

- No se reporta el **tamaño muestral** cualitativo: ¿una visita o varias?, ¿un cardiólogo o varios?, ¿cuántas horas de observación?, ¿cuántas entrevistas en total?
- No se especifican **criterios de inclusión/exclusión** para los informantes clave (años de experiencia mínima, especialidad cardiológica certificada, rol institucional).
- No se aplicó ningún **método sistemático de análisis cualitativo** (análisis temático de Braun & Clarke, codificación abierta de Strauss, análisis de contenido de Krippendorff). El documento simplemente afirma que se “sintetizó la información” sin describir el procedimiento.
- No se reporta el principio de **saturación teórica** (cuándo se decidió detener la recolección de información cualitativa).
- No se acompañan **citas verbatim** (*verbatim quotes*) de los entrevistados que sustenten las decisiones de diseño, lo cual es práctica estándar en investigación cualitativa.

Análisis estadístico aplicable: en investigación cualitativa pura no se requiere análisis estadístico inferencial, pero sí **registro reproducible de la cadena de evidencia**. La técnica mínima esperada habría sido:

- **Matriz de codificación** (códigos → categorías → temas).
- **Cuantificación complementaria:** frecuencia de menciones de cada problema operativo (e.g., “5/5 entrevistados mencionaron tiempos de espera”).
- **Triangulación entre fuentes:** ¿coinciden observación, formularios y entrevistas?

3 Tipo 2 — Datos clínicos secundarios para el modelo (OE2)

El *dataset* usado se identifica como “Heart Failure” en el texto pero corresponde realmente al *Heart Disease combinado* de cinco fuentes (Cleveland, Hungría, Suiza, Long Beach VA y Stalog) con 1190 instancias y 11 variables clínicas. Se trata de **datos secundarios públicos**, no recolectados específicamente para este proyecto.

3.1 Suficiencia y representatividad

Atributo de calidad de datos	Estado en el manuscrito
Cantidad ($n = 1\,190$)	Aceptable para clasificación binaria con 11 variables.
Representatividad demográfica	Limitada: 76,39 % varones, 23,61 % mujeres. El propio autor lo reconoce en R1 (Recomendaciones).
Representatividad geográfica	Comprometida: ninguna fuente latinoamericana, mucho menos ecuatoriana. Generalización al sistema de salud objetivo no demostrada .
Antigüedad temporal	Crítico no discutido: los <i>datasets</i> originales (Cleveland, Hungary, Switzerland, Long Beach VA) fueron recolectados entre 1980 y 1988 y no se han actualizado. La práctica clínica cardiológica, los criterios diagnósticos y los rangos de referencia han evolucionado significativamente en cuatro décadas.
Variable objetivo	Binaria balanceada (52,86 % vs. 47,14 %) — adecuada.
Variables predictoras	11 variables clínicas estándar; falta información sobre tabaquismo, antecedentes familiares, IMC, consumo de alcohol — listados en el Capítulo II como factores de riesgo importantes.
Calidad de los registros	Detectados 13 valores negativos en <i>oldpeak</i> , 0 mg/dL en colesterol y 0 mmHg en presión arterial. Documentación apropiada pero la limpieza no se evaluó por subgrupo (¿afecta más a una clase?).

Hallazgo crítico no discutido: el modelo se entrena con datos cardiológicos de hace 35–45 años, recolectados en cuatro países industrializados (Estados Unidos, Hungría, Suiza), y se propone su uso clínico en Ecuador en 2025. Esto conlleva tres riesgos:

1. **Cambio de distribución temporal** (*temporal data drift*): los rangos clínicos, los protocolos diagnósticos y la prevalencia de comorbilidades han cambiado.
2. **Desplazamiento poblacional** (*population shift*): la genética, dieta, prevalencia de obesidad y diabetes en población ecuatoriana difiere de la estadounidense/europea de los años 80.
3. **Sesgo de selección clínica:** la sección 4.1.9 advierte que los datos corresponden a “*pacientes que acudieron a evaluación cardiológica*” (no población general), por lo que el modelo no es válido como tamiz primario en atención primaria.

La justificación del uso del *dataset* debe incluir, mínimo, una discusión de estas tres limitaciones y una recomendación explícita de **recalibración local** con datos ecuatorianos antes de cualquier uso clínico real.

3.2 Análisis estadístico aplicado vs. requerido

Análisis	Aplicado	Requerido pero ausente
Estadística descriptiva univari- ada	Sí (Tablas 34–35)	—
Análisis de distribución	Parcial (asimetría repor- tada)	Histogramas y boxplots (no se presentan).
Análisis bivariado	No aplicado	Matriz de correlación entre variables predictoras; análisis de asociación variable-clase (<i>chi-cuadrado</i> para categóri- cas, <i>t-test</i> o Mann–Whitney para numéricas).
Análisis de balance entre sub- grupos	No aplicado	Distribución de la clase posi- tiva por sexo, edad, etc.
Validación cruzada	10- <i>fold</i>	Reportar si fue <i>stratified</i> CV; reportar SD entre <i>folds</i> .
Comparación pareada de mod- elos	No aplicado	Test de DeLong pareado para AUC; test de Friedman entre <i>folds</i> .
Intervalos de confianza	No reportado	IC _{95 %} por DeLong (anunciado, nunca calculado).
Tamaño del efecto	No reportado	Diferencias de AUC con <i>effect size</i> .

La afirmación “*Random Forest* superó al resto de modelos” (Cap. IV) presenta diferencias numéricas pero **ninguna prueba estadística** respalda la palabra “superó”. La diferencia entre RF (AUC 0,963) y XGBoost (0,956) podría no ser estadísticamente significativa con $n = 119$ (10 % del conjunto en cada *fold*). Sin la prueba de DeLong pareada, la conclusión de selección es estadísticamente débil. La diferencia podría también deberse a una sola corrida con una semilla afortunada.

4 Tipo 3 — Datos técnicos del sistema integrado (OE3)

4.1 Diseño de las pruebas de rendimiento

La sección 4.2.1 reporta el escenario: **15 usuarios virtuales concurrentes durante 90 segundos**, ejecutados con Artillery. La auditoría del diseño es:

Justificación de la carga insuficiente:

- **¿Por qué 15 usuarios?** El texto afirma que “*representan la demanda estimada en una jornada de atención clínica de alta concurrencia*”, pero **no se citan datos del centro** (número promedio de consultas simultáneas, picos históricos, tamaño de la plantilla médica, número de consultorios activos).
- **¿Por qué 90 segundos?** Una prueba de carga de 90 s es demasiado corta para detectar problemas como *memory leaks*, degradación progresiva, fugas de conexiones a base de datos. El estándar en la industria son pruebas de **carga sostenida (*soak test*) de mínimo 30 min.**
- No se reporta **rampa de carga (*ramp-up*)**: ¿los 15 usuarios entraron de golpe o gradualmente?
- No hay prueba de **estrés** (incrementar carga hasta el punto de ruptura) ni de **pico (*spike test*)**.
- No se reporta el **escenario de fallo** (¿qué pasa si la API de Python cae?). El texto menciona el manejo de excepciones pero no se prueba.

4.2 Análisis estadístico aplicado vs. requerido

Análisis	Aplicado	Requerido pero ausente
Tendencia central	Tiempo promedio (Tabla 38)	—
Percentiles altos	P95, P99 (Tabla 38)	Falta P50 (mediana) y P99.9.
Variabilidad	No reportada	Desviación estándar, varianza, IQR.
Distribución completa	No reportada	Histograma de tiempos por <i>endpoint</i> .
Detección de <i>outliers</i>	No reportada	Análisis de valores extremos: ¿hubo solicitudes de 5 s aisladas que no aparecen en P99?
Errores y disponibilidad	No reportados	Tasa de error 4xx/5xx, <i>throughput</i> en req/s.
Comparativa con/sin modelo	No reportada	Comparar latencia con y sin la llamada a la API de IA.

La afirmación “*Si cumple*” en la última columna de la Tabla 38 es binaria: cumple o no cumple. Pero un *endpoint* de predicción con P99 de 1,47 s frente a un umbral de 1,5 s tiene un margen de tan solo 30 ms. Esto significa que **en producción real cualquier degradación menor (saturación de red, GC de Python, latencia de PostgreSQL) pondría el sistema fuera del SLA**. El reporte debería discutir este margen y proponer un umbral de seguridad.

4.3 Pruebas de aceptación funcional

Los 17 casos de prueba de la Tabla 39 (numerada 40 en el manuscrito) cubren los 14 requerimientos funcionales. Sin embargo:

- **Cobertura aparente del 100 %:** los 17 casos están todos “Aprobado”. Esto debería levantar una alerta metodológica: en una prueba de aceptación realista **siempre** aparecen al menos algunos casos parcialmente aprobados o con observaciones. Un 100 % perfecto sugiere o bien una ejecución poco crítica, o bien que los criterios de aceptación se relajaron al ejecutar.
- No se reporta el **ambiente** de pruebas (¿producción real?, ¿*staging*?), ni la **versión** del sistema probado.
- No se incluye la **guía de prueba** (*test script*) que se usó para cada CP-XX. Sin la guía paso a paso, la prueba no es reproducible.

5 Tipo 4 — Datos de aceptación tecnológica (TAM)

La evaluación TAM se aplicó a $n = 5$ usuarios mediante un cuestionario en escala Likert de 5 puntos con 4 constructos $\times$ 4 ítems = 16 ítems totales. Esta es la sección de recolección de datos primarios más débil del proyecto.

5.1 Problemas de diseño del instrumento

El instrumento TAM no se presenta.

- **Los 16 ítems del cuestionario nunca aparecen en el manuscrito** (ni en el cuerpo, ni en anexos — los anexos están vacíos). Sin esos enunciados es **imposible replicar el estudio**.
- No se cita la **fuentes bibliográfica** del cuestionario. Si es una adaptación, ¿de qué autores (Davis 1989; Venkatesh & Davis 2000; Venkatesh *et al.* 2003)? Si es una creación propia, ¿qué proceso siguió?
- No se reporta ningún **piloto previo** para depurar los ítems.

5.2 Problemas de diseño muestral

- **Tamaño muestral $n = 5$ sin justificación.** Para una validación de instrumento Likert se recomiendan al menos 5 a 10 participantes **por ítem** (regla de Tinsley & Tinsley) — es decir, 80–160 participantes para 16 ítems.
- **Muestreo por conveniencia:** cinco usuarios de un solo centro de cardiología. No es probabilístico ni representativo.
- **No hay grupo de control** ni medición *pre/post* (la aceptación se mide solo después del uso, sin contraste).
- **Sesgo de cortesía y deseabilidad social:** los usuarios fueron evaluados “inmediatamente al concluir la sesión de pruebas”, en presencia probable del autor del sistema. Este diseño favorece respuestas positivas.

5.3 Problemas de análisis estadístico

Análisis	Aplicado	Requerido pero ausente
Promedio aritmético por constructo	Sí (Tablas 41–42)	—
Alfa de Cronbach	No calculado	Esencial para validar la consistencia interna de cada constructo (umbral mínimo $\alpha \geq 0,70$).
Análisis factorial	No aplicable con $n = 5$	Con muestra adecuada se haría AFE/AFC.
Estadística descriptiva más allá del promedio	No	Mediana, moda, desviación estándar; los datos Likert son ordinales , no necesariamente apropiados para promedio aritmético sin verificar normalidad.
Pruebas no paramétricas	No aplicadas	Wilcoxon para comparar contra el umbral 4,00; Kruskal–Wallis entre roles.
Coefficiente de concordancia	No reportado	Kendall's W o Krippendorff's α entre evaluadores.
Reportar n por grupo	Sí (Tabla 42)	—

El uso del promedio aritmético sobre escala Likert con $n = 5$ es metodológicamente cuestionable:

- Las escalas Likert producen datos **ordinales**; aplicar promedio asume distancias iguales entre categorías (debate clásico Stevens vs. Velleman & Wilkinson). Lo *usual* en literatura TAM es reportar también mediana y moda.
- Con $n = 5$, decir que el constructo CMP obtuvo 3,94 “superando el umbral 3,75” es estadísticamente vacío: el rango muestral entre los cinco usuarios no permite distinguir esa diferencia de 0,19 del ruido.
- Comparar grupos (médicos $n = 2$, enfermeros $n = 2$, administrativo $n = 1$) y derivar conclusiones (“los enfermeros confían menos en el modelo”) con $n_i \leq 2$ es estadísticamente inválido. Cualquier afirmación comparativa requiere reformularse como descriptiva sin generalización.

6 Aspectos éticos y legales del recogimiento

Hallazgo grave: ningún tratamiento ético/legal del recogimiento de datos.

- No se reporta **aprobación por comité de ética** institucional o universitario, requerido para investigación con seres humanos (médicos y administradores entrevistados, usuarios participantes en TAM).
- No se reporta **consentimiento informado** firmado por los participantes.
- No se discute la **Ley Orgánica de Protección de Datos Personales (LOPD)** del Ecuador (2021), que clasifica los datos de salud como *categoría especial de datos sensibles* y exige bases legales explícitas para su tratamiento.
- No se mencionan **políticas de anonimización** o **seudonimización** para los datos clínicos que el sistema almacenará en producción real (los datos del *dataset* público son anónimos pero el sistema operará con datos identificables).
- No se reportan los **rangos clínicos exactos** usados para validar las entradas en la API (sección 3.1.3 promete validación biológica pero no documenta los umbrales).

La omisión es especialmente delicada porque el sistema está concebido para uso clínico real en un centro de cardiología.

7 Trazabilidad: ¿los datos recogidos alcanzan los objetivos?

Objetivo	Datos sufi- cientes	Análisis sufi- ciente	Brechas críticas
OE1 (módulo)	Parcial	Insuficiente	Sin sistematización cualitativa, sin matriz de trazabilidad.
OE2 (modelo)	Parcial	Insuficiente	Datos antiguos y geográficamente externos; sin pruebas pareadas; sin IC ₉₅ %.
OE3 (integración)	Insuficiente	Insuficiente	Carga no justificada; sin SD ni distribución completa; sin pruebas de estrés.
General	Insuficiente	Inadecuado	TAM con $n = 5$ y sin alfa de Cronbach.

Veredicto integrador: desde el punto de vista del recogimiento de datos, el proyecto presenta **evidencia sustantiva para describir lo realizado** (productos, métricas, percepciones) pero **evidencia insuficiente para inferir generalización** (validación externa, pruebas estadísticas, muestras representativas). En lenguaje de investigación, el trabajo logra mostrar que “el sistema funciona en este caso” pero no que “el sistema funcionará en otros casos”. Esta distinción debe explicitarse en una sección de limitaciones del Capítulo I, no únicamente en las recomendaciones.

8 Recomendaciones específicas sobre el recogimiento de datos

Aplicando el principio de arrastre desde las observaciones anteriores, se proponen las siguientes acciones para fortalecer la dimensión de datos del proyecto. Las recomendaciones se agrupan por tipo de dato auditado.

Sobre los datos cualitativos (OE1):

1. Documentar y anexar **guion de observación** y **guion de entrevistas semiestructuradas** con todas sus preguntas.
2. Incluir un **cuadro de informantes** con cargo, especialidad, años de experiencia y duración de cada entrevista, manteniendo confidencialidad por código.
3. Aplicar **análisis temático** (Braun & Clarke) o **análisis de contenido** (Krippendorff) sobre las entrevistas, presentando matriz de codificación.
4. Incorporar **citas verbatim** representativas que justifiquen los requerimientos derivados.

Sobre los datos clínicos (OE2):

1. Reportar **año exacto de recolección** de cada *subset* del UCI *Heart Disease* y discutir explícitamente la **vigencia temporal** del modelo.
2. Realizar **análisis bivariado** (correlaciones, chi-cuadrado, Mann–Whitney) antes del modelado.
3. Calcular el **intervalo de confianza al 95 %** de DeLong para el AUC y reportarlo en la Tabla 36 junto al puntaje.
4. Aplicar **prueba pareada de DeLong** entre los cuatro modelos para sustentar la elección de RF.
5. Validar el modelo en el **subgrupo femenino** para detectar sesgo de género.
6. Plan de **recalibración con datos locales** ecuatorianos antes de uso clínico real.

Sobre los datos técnicos (OE3):

1. Justificar el escenario de carga (15×90 s) con **datos del centro** (consultas/día, picos esperados).
2. Realizar **soak test** de mínimo 30 minutos.
3. Reportar **distribución completa** (histograma) y **desviación estándar** de tiempos por *endpoint*.
4. Incluir **prueba de estrés** hasta el punto de ruptura.
5. Documentar las **guías de prueba** (*test scripts*) de los 17 casos funcionales.

Sobre los datos perceptuales (TAM):

1. Anexar el **cuestionario completo** con sus 16 ítems y la fuente bibliográfica de cada uno.
2. Calcular **alfa de Cronbach** para cada constructo (UP, FUP, IU, CMP).
3. Aumentar n al menos a 30–40 participantes para análisis descriptivo robusto, idealmente 80+ para validación de instrumento.
4. Reportar **mediana y moda** además del promedio.
5. Aplicar **prueba de Wilcoxon** de una muestra para contrastar contra el umbral teórico (4,00 y 3,75).
6. Reformular el cuestionario para minimizar **sesgo de cortesía**: aplicación anónima sin presencia del autor.

Sobre los aspectos éticos y legales:

1. Tramitar y reportar **aprobación de comité de ética** de la UTEQ.
2. Anexar **formato de consentimiento informado** firmado por los participantes (anonimizados).
3. Incluir una sección sobre **cumplimiento de la LOPDP** para los datos clínicos identificables del sistema en producción.
4. Documentar los **rangos clínicos exactos** de validación de la API.
5. Detallar la estrategia de **anonimización** de datos identificables en producción.

Cierre: este informe complementario aborda específicamente la dimensión de recogimiento de datos del proyecto. Las recomendaciones aquí formuladas son independientes del informe general de revisión científica y editorial, pero se articulan con él bajo el mismo principio de arrastre: cada brecha identificada en una sección anterior alimenta la recomendación correspondiente en la sección posterior, de modo que la corrección sistemática del documento eleve simultáneamente el rigor cualitativo, cuantitativo, técnico y ético del trabajo.