



UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

**FACULTAD DE CIENCIAS DE LA COMPUTACION Y DISEÑO
DIGITAL**

CARRERA DE SOFTWARE

Trabajo de Integración
Curricular previa la obtención
del Grado Académico de
Ingeniero/a de Software.

PROYECTO TECNOLÓGICO:

**“SISTEMA DE DIAGNÓSTICO DE CARDIOPATÍAS MEDIANTE UN
MODELO DE APRENDIZAJE AUTOMÁTICO”**

AUTOR:

ANGÉLICA MICHELLE TENECELA INTRIAGO

DIRECTOR:

ING. ARIOSTO EUGENIO VICUÑA PINO, MSC

QUEVEDO – LOS RÍOS – ECUADOR

2025



DECLARACIÓN DE AUTORÍA Y CESIÓN DE DERECHOS

Yo, **ANGÉLICA MICHELLE TENECELA INTRIAGO**, declaro que la investigación aquí descrita es de mi autoría; que no ha sido previamente presentado para ningún grado o calificación profesional; y, que he consultado las referencias bibliográficas que se incluyen en este documento.

La Universidad Técnica Estatal de Quevedo, puede hacer uso de los derechos correspondientes a este documento, según lo establecido por la Ley de Propiedad Intelectual, por su Reglamento y por la normatividad institucional vigente.

ANGÉLICA MICHELLE TENECELA INTRIAGO

C.I: 1351547888



CERTIFICACIÓN DE CULMINACIÓN DEL PROYECTO TECNOLÓGICO

El suscrito, **Ariosto Eugenio Vicuña Pino**, Docente de la Universidad Técnica Estatal de Quevedo, certifica que el estudiante **Angélica Michelle Tenecela Intriago**, realizó el Proyecto Tecnológico de grado titulado “**Sistema de diagnóstico de cardiopatías mediante un modelo de aprendizaje automático**” previo a la obtención del título de **Ingeniero de Software**, bajo mi dirección, habiendo cumplido con las disposiciones reglamentarias establecidas para el efecto.


Ing. Ariosto Eugenio Vicuña Pino, MSc

DIRECTOR DEL PROYECTO TECNOLÓGICO



CERTIFICADO DEL REPORTE DE LA HERRAMIENTA DE PREVENCIÓN DE COINCIDENCIA Y/O PLAGIO ACADÉMICO

El suscrito, **Ariosto Eugenio Vicuña Pino**, mediante el presente cumpla en presentar a usted, el informe del Proyecto Tecnológico titulado “**Sistema de diagnóstico de cardiopatías mediante un modelo de aprendizaje automático**” Presentado por el estudiante **Angélica Michelle Tenecela Intriago**, egresado de la Carrera de **Ingeniería de Software**, que fue revisado bajo mi dirección según resolución del Consejo Directivo de la Facultad de Ciencias de la Computación y Diseño Digital, que se ha desarrollado de acuerdo al Reglamento de la Unidad de Integración Curricular de la Universidad Técnica Estatal de Quevedo y cumple con el requerimiento de análisis del sistema COMPILATIO el cual avala los niveles de originalidad en un% y similitud ...%, del trabajo investigativo. Valido este documento para que el estudiante siga con los trámites pertinentes, de acuerdo como lo establece el Reglamento.



Ing. Ariosto Eugenio Vicuña Pino, MSc

DIRECTOR DEL PROYECTO TECNOLÓGICO



UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO
FACULTAD DE CIENCIAS DE LA COMPUTACIÓN Y DISEÑO DIGITAL
CARRERA DE SOFTWARE

PROYECTO TECNOLÓGICO

Título:

“Sistema de diagnóstico de cardiopatías mediante un modelo de aprendizaje automático”

Presentado al Consejo Directivo de la Facultad de Ciencias de la Computación y Diseño Digital como requisito previo a la obtención del título de Ingeniero de Software

Aprobado por:

PRESIDENTE DEL TRIBUNAL

Ing. Guerrero Ulloa Gleistón, PhD

MIEMBRO DEL TRIBUNAL

Ing. Iván Fredy Jaramillo Chuqui, PhD

MIEMBRO DEL TRIBUNAL

Ing. Efraín Evaristo Diaz Macias, MSc

QUEVEDO – LOS RIOS – ECUADOR

2025

AGRADECIMIENTO

DEDICATORIA

RESUMEN EJECUTIVO Y PALABRAS CLAVES

ABSTRACT AND KEYWORDS

Tabla De Contenido

DECLARACIÓN DE AUTORÍA Y CESIÓN DE DERECHOS	ii
CERTIFICACIÓN DE CULMINACIÓN DEL PROYECTO TECNOLÓGICO	iii
CERTIFICADO DEL REPORTE DE LA HERRAMIENTA DE PREVENCIÓN DE COINCIDENCIA Y/O PLAGIO ACADÉMICO	iv
AGRADECIMIENTO	vi
DEDICATORIA	vii
RESUMEN EJECUTIVO Y PALABRAS CLAVES	viii
ABSTRACT AND KEYWORDS	ix
CÓDIGO DUBLIN.....	xvi
INTRODUCCIÓN.....	1
CAPÍTULO I	3
MARCO CONTEXTUAL DEL PROYECTO TECNOLÓGICO.....	3
1.1 Planteamiento de investigación.....	4
1.1.1 Planteamiento del problema	4
1.1.2 Formulación del problema.....	5
1.1.3 Sistematización del problema.....	6
1.2 Objetivos.....	6
1.2.1 Objetivo general	6
1.2.2 Objetivos específicos.....	6
1.3 Justificación	6
MARCO TEÓRICO DEL PROYECTO TECNOLÓGICO	8
2.1. Marco conceptual.....	9
2.1.1. Enfermedades cardiovasculares.....	9
2.1.2. Aprendizaje Automático para la Predicción de Enfermedades Cardiovasculares.....	15
2.1.3 Metodología de Prototipado para el Desarrollo de Software	19

2.2.	Marco referencial	22
2.2.1.	Aplicaciones de aprendizaje automático en el Diagnóstico de Cardiopatías	22
2.2.2.	Preprocesamiento y Selección de Características.....	23
2.2.3.	Evaluación del Modelo y Métricas de Rendimiento	24
2.2.4.	Interpretabilidad y Transparencia del Modelo	24
	METODOLOGÍA DE LA INVESTIGACION	25
3.1	Marco de fases de desarrollo del proyecto tecnológico.	26
3.1.1	Desarrollo del módulo de gestión de pacientes	26
3.1.2	Desarrollo del modelo predictivo	30
3.1.3	Integración del modelo predictivo con la aplicación web	33
3.2	Cronograma.....	36
3.3	Recursos, presupuesto y financiamiento.....	36
3.3.1	Recursos humanos	36
3.3.2	Recursos tecnológicos	37
3.3.3	Presupuesto consolidado.....	38
3.4	Instrumentos para el seguimiento y control	38
3.4.1	Instrumentos de planificación y control de avance	38
3.4.2	Instrumentos de control de versiones y despliegue	39
3.4.3	Instrumentos de prueba y validación	39
3.4.4	Instrumentos de comunicación y coordinación	39
3.5	Indicadores de evaluación.....	39
3.5.1	Indicadores de evaluación del modelo predictivo	39
3.5.2	Indicadores de evaluación funcional del sistema	42
3.5.3	Indicadores de evaluación de usabilidad	42
	RESULTADOS	44
4.1	Producto tecnológico desarrollado.....	45
4.1.1	Requerimientos.....	45

4.1.2	Casos de uso	53
4.1.3	Diagrama de casos de uso.....	62
4.1.4	Diagrama de base de datos	63
4.1.5	Diagramas de secuencias	64
4.1.6	Diagramas de componentes	66
4.1.7	Diagramas de despliegue	66
4.1.8	Prototipo rápido	67
4.1.9	Aprendizaje automático	70
4.1.10	Interfaces de software	78
4.2	Comprobación.....	83
4.2.1	Pruebas de Rendimiento	83
4.2.2	Pruebas de Aceptación Funcional.....	84
4.2.3	Evaluación de Aceptación Tecnológica (TAM).....	87
CONCLUSIONES Y RECOMENDACIONES		90
5.1	Conclusiones	91
5.2	Recomendaciones	92
BIBLIOGRAFÍA		93
ANEXOS		97

Índices de tablas

Tabla 1	Recursos de software de desarrollo.....	37
Tabla 2	Recursos de servicios en la nube	37
Tabla 3	Recursos de herramientas de software	37
Tabla 4	Recursos de materiales.....	38
Tabla 5	Presupuesto del proyecto	38
Tabla 6	Requerimiento de gestión de usuarios y control de acceso.....	45
Tabla 7	Requerimiento de gestión de datos de pacientes.....	45
Tabla 8	Requerimiento de gestión de historia clínica	46
Tabla 9	Requerimiento de visualización de perfil clínico.....	46
Tabla 10	Requerimiento de diagnóstico y predicción de riesgo cardiovascular	47
Tabla 11	Requerimiento de análisis de evolución clínica	48
Tabla 12	Requerimiento de generación de reportes.....	48
Tabla 13	Requerimiento de generación de recomendaciones médicas.....	49
Tabla 14	Requerimiento carga automatizada de resultados de laboratorio.....	49
Tabla 15	Requerimiento de gestión de catálogos médicos	49
Tabla 16	Requerimiento de gestión de archivos adjuntos del paciente	50
Tabla 17	Requerimiento de agendamiento de citas	50
Tabla 18	Requerimiento de generación de reglas médicas	51
Tabla 19	Requerimiento de visualización de estadísticas	51
Tabla 20	Requerimiento de interfaz responsiva.....	52
Tabla 21	Requerimiento de tiempo de respuesta del modelo predictivo	52
Tabla 22	Caso de uso de gestión de datos personales de pacientes	53
Tabla 23	Caso de uso de registrar consulta clínica	54
Tabla 24	Caso de uso de ejecutar diagnóstico predictivo cardiovascular	55
Tabla 25	Caso de uso gestión de roles y permisos de acceso	56
Tabla 26	Caso de uso de analizar evolución y predicciones históricas	57
Tabla 27	Caso de uso de agendamiento de citas	58
Tabla 28	Caso de uso configuración de reglas y protocolos clínicos	59
Tabla 29	Caso de uso carga y extracción de documentos	60
Tabla 30	Caso de uso visualización estadística general.....	61
Tabla 31	Resumen de los conjuntos de datos	70
Tabla 32	Descripción general de las variables del conjunto de datos.....	71
Tabla 33	Descripción de los atributos nominales del conjunto de datos	72
Tabla 34	Estadísticas descriptivas de las variables numéricas	72
Tabla 35	Estadísticas descriptivas de las variables después del procesamiento	73
Tabla 36	Desempeño promedio de los modelos	74
Tabla 37	Matriz de confusión de OOB	76
Tabla 38	Resultados de las pruebas de rendimiento por endpoint.....	84
Tabla 40	Matriz de resultados de las pruebas de funcionalidad.....	85
Tabla 41	Constructos del modelo TAM y umbrales de aceptación.....	87

Tabla 42 Puntajes individuales por usuario y constructo TAM	88
Tabla 43 Resultados TAM consolidados por constructo y rol de usuario.....	88

Índices de figuras

Figura 1 Fases de la metodología de prototipado	26
Figura 2 Cronograma de trabajo.....	36
Figura 3 Diagrama de casos de usos.....	62
Figura 4 Diagrama de base de datos.....	63
Figura 5 Diagrama de secuencia de registro de consulta	64
Figura 6 Diagrama de secuencia de comunicación con el modelo predictivo	65
Figura 7 Diagrama de secuencia de ejecución del modelo predictivo	65
Figura 8 Diagrama de componentes.....	66
Figura 9 Diagrama de despliegue	66
Figura 10 Prototipo de interfaz de consulta médica	67
Figura 11 Prototipo de interfaz de perfil del paciente	68
Figura 12 Prototipo de visualización de registros	68
Figura 13 Prototipo de interfaz de registro de paciente.....	69
Figura 14 Prototipo de interfaz de estadísticas generales.....	69
Figura 15 Comparativa de curvas ROC de los modelos.....	75
Figura 16 Matriz de confusión	76
Figura 17 Importancia de Variables Clínicas.....	77
Figura 18 Interfaz de visualización de estadísticas generales	78
Figura 19 Interfaz de formulario de registro de registro de paciente	79
Figura 20 Interfaz de consulta médica.....	79
Figura 21 Interfaz de registro de diagnósticos y tratamientos.....	80
Figura 22 Interfaz de evolución del paciente	80
Figura 23 Interfaz de evolución de las variables médicas del paciente.....	81
Figura 24 Interfaz de asignación de permisos a los roles	81
Figura 25 Interfaz de perfil del paciente.....	82
Figura 26 Interfaz de visualización de historial clínico del paciente	82
Figura 27 Interfaz del calendario de citas médicas	83

Índices de formulas

Fórmula 1	Fórmula para el cálculo de exactitud de un modelo	16
Fórmula 2	Fórmula para el cálculo de la precisión positiva	17
Fórmula 3	Fórmula para el cálculo del Recall	17
Fórmula 4	Fórmula de F1-Score	17

CÓDIGO DUBLIN

Título:			
Autor:			
Palabras claves:			
Fecha de publicación:			
Editorial:	Quevedo- UTEQ, 2025		
Resumen: (hasta 300 palabras) Abstract: (hasta 300 palabras)			
Descripción:	108 hojas : dimensiones, 29 x 21 cm + CD-ROM 6162		
URI:			

INTRODUCCIÓN

Las enfermedades cardiovasculares constituyen la principal causa de mortalidad a nivel mundial, siendo responsables de aproximadamente 17,9 millones de defunciones anuales según la Organización Mundial de la Salud [1], [2]. Esta realidad se manifiesta con especial gravedad en Ecuador, donde las enfermedades cardiovasculares se posicionaron como la primera causa de muerte desde el año 2021, evidenciando una brecha crítica entre la creciente demanda de servicios de diagnóstico cardiológico y la capacidad del sistema de salud para atenderla de manera oportuna [3], [4].

En el contexto nacional, los métodos tradicionales de evaluación cardiovascular presentan una fuerte dependencia del personal médico especializado en cardiología, recurso que resulta escaso, particularmente en zonas rurales del país [5], [6]. Las campañas de salud preventiva implementadas en estas áreas han evidenciado limitaciones estructurales y operativas que incluyen la insuficiencia de especialistas, los prolongados tiempos de espera, los retrasos en la atención y la gestión manual de los datos clínicos de los pacientes [6], [7]. De continuar esta tendencia sin intervenciones efectivas, se proyecta un incremento en el número de defunciones por cardiopatías para el año 2030 [8], [9].

Ante este escenario, la tecnología ha demostrado ser un aliado estratégico para la medicina moderna. Los sistemas de inteligencia artificial y el aprendizaje automático han adquirido especial relevancia al permitir el análisis de grandes volúmenes de datos médicos para la predicción de riesgos cardiovasculares, optimizando así los procesos diagnósticos [1], [10]. Investigaciones recientes han validado el uso de modelos predictivos con alto rendimiento en la clasificación de pacientes con riesgo de desarrollar cardiopatías, destacando algoritmos como Random Forest, XGBoost y redes de aprendizaje profundo como herramientas eficaces para el apoyo diagnóstico clínico [11], [12].

El presente proyecto tecnológico se desarrolló con el propósito de dar respuesta a esta problemática mediante la construcción de un sistema de diagnóstico de cardiopatías que integra un modelo de aprendizaje automático en una aplicación web [13], [14]. El problema científico identificado radica en la insuficiente capacidad diagnóstica cardiovascular frente a una demanda creciente, agravada por la escasez de personal especializado y la ausencia de herramientas tecnológicas de apoyo en los centros de salud ecuatorianos [5], [7].

La hipótesis de trabajo planteó que la implementación de un modelo de aprendizaje automático integrado en un sistema de soporte a la decisión clínica permitiría mejorar la capacidad de diagnóstico de cardiopatías, reduciendo los tiempos de evaluación y apoyando la toma de decisiones clínicas del personal de salud [10], [15]. En concordancia con esta hipótesis, el objetivo general del proyecto consistió en construir un sistema de diagnóstico que integre un modelo de aprendizaje automático para el reconocimiento de pacientes con riesgo de padecer enfermedades cardíacas.

Para alcanzar este objetivo, se definieron tres objetivos específicos: el desarrollo de un módulo de administración de datos clínicos de pacientes en una aplicación web; el entrenamiento de un modelo de aprendizaje automático utilizando registros clínicos de insuficiencia cardíaca para identificar pacientes con riesgo de desarrollar cardiopatía; y la integración del modelo predictivo en la plataforma web para permitir la visualización y análisis de los datos en la historia clínica de cada paciente.

El documento se estructura en cinco capítulos. El Capítulo I presenta el marco contextual del proyecto, incluyendo el planteamiento del problema, los objetivos y la justificación. El Capítulo II expone el marco teórico sobre enfermedades cardiovasculares y técnicas de aprendizaje automático. El Capítulo III describe la metodología empleada en el desarrollo del sistema. El Capítulo IV presenta los resultados obtenidos, incluyendo el producto tecnológico desarrollado y su comprobación mediante pruebas de rendimiento, funcionalidad y aceptación tecnológica. Finalmente, el Capítulo V recoge las conclusiones y recomendaciones derivadas del proyecto.

CAPÍTULO I
MARCO CONTEXTUAL DEL PROYECTO TECNOLÓGICO

1.1 Planteamiento de investigación

En esta sección se presenta el análisis de la problemática que se pretende abordar en el proyecto, incluyendo su planteamiento, formulación y sistematización. Asimismo, se definen los objetivos de la investigación y se expone la justificación que sustenta la necesidad de resolver dicha problemática.

1.1.1 Planteamiento del problema

Según la Organización Mundial de la Salud, las enfermedades cardiovasculares constituyen la principal causa de mortalidad a nivel mundial, siendo responsables de aproximadamente 17.9 millones de defunciones anuales [1], [2]. Esta realidad se manifiesta con particular intensidad en América Latina, donde los sistemas de salud enfrentan desafíos para garantizar diagnósticos oportunos y accesibles a toda la población [4], [7].

En el contexto ecuatoriano, las enfermedades cardiovasculares se posicionaron como la primera causa de muerte desde el año 2021, evidenciando una brecha crítica entre la demanda de servicios diagnósticos cardiovasculares y la capacidad del sistema de salud para atenderla [3], [6]. Los métodos tradicionales de evaluación cardiovascular presentan una dependencia de personal médico capacitado en cardiología, situación que se intensifica en zonas rurales del país, donde el acceso a servicios cardiológicos resulta limitado [5], [16].

Las campañas de salud preventiva implementadas en áreas rurales evidencian la saturación crítica del sistema: la alta demanda de pacientes frente a recursos humanos insuficientes genera jornadas extensas que impiden la atención de todos los solicitantes [6], [7]. Como consecuencia directa, una proporción de la población desconoce que padece alguna afección cardiovascular, situación que retrasa la intervención médica necesaria hasta que la enfermedad alcanza etapas avanzadas donde las opciones terapéuticas son más costosas [3], [17].

En este contexto, se identifica la necesidad de desarrollar un sistema de diagnóstico de cardiopatías mediante un modelo de aprendizaje automático que sea capaz de identificar patrones de riesgo cardiovascular y apoyar al personal médico en la detección temprana de estas afecciones. Se espera que esta herramienta tecnológica pueda contribuir a mejorar la precisión y rapidez del proceso diagnóstico, optimizando el tiempo del personal médico y ampliando la cobertura en áreas con recursos limitados [12], [15].

Diagnóstico

Las causas de la problemática cardiovascular en Ecuador son tanto estructurales como operativas. A nivel estructural, existe una insuficiencia notoria de personal médico especializado en cardiología. A nivel operativo, los procesos convencionales de evaluación cardiovascular requieren tiempo considerable por paciente, existe dependencia del criterio médico humano para interpretación de estudios y escasa implementación de herramientas tecnológicas de apoyo diagnóstico.

Los efectos se manifiestan en múltiples dimensiones. A nivel individual, los pacientes enfrentan diagnósticos tardíos que incrementan el riesgo de complicaciones graves como infartos y accidentes cerebrovasculares, aumentando la mortalidad prematura. A nivel del sistema de salud, se observa saturación de servicios de emergencia, sobrecarga de unidades de cuidados intensivos e incremento exponencial de costos.

Pronóstico

De continuar la tendencia actual sin intervenciones efectivas, se proyecta un escenario crítico con deterioro progresivo de los indicadores de salud cardiovascular en Ecuador. Se estima que el número de defunciones anuales por cardiopatías podría incrementarse para el año 2030. La detección tardía perpetuará el ciclo de diagnósticos en etapas avanzadas, aumentando la prevalencia de complicaciones cardiovasculares crónicas lo que incrementará la población con discapacidad permanente y dependencia funcional.

El sistema de salud enfrentará un colapso progresivo caracterizado por la saturación de servicios de emergencia y hospitalización cardiovascular, donde los hospitales de tercer nivel enfrentarán demandas que superarán su capacidad instalada. Esto generará tiempos de espera críticos para procedimientos de urgencia, reducción de la calidad de atención por sobrecarga del personal, e incremento de complicaciones hospitalarias.

1.1.2 Formulación del problema

¿Cómo contribuir al diagnóstico temprano y a la predicción de enfermedades cardiovasculares en pacientes?

1.1.3 Sistematización del problema

- ¿Cómo facilitar el registro y seguimiento de los datos clínicos de los pacientes para el diagnóstico de enfermedades cardiovasculares?
- ¿Cómo entrenar un modelo de aprendizaje automático para identificar a los pacientes con riesgo de desarrollar cardiopatías?
- ¿Cómo integrar un modelo de predicción en una aplicación web para optimizar la visualización y el análisis de los datos médicos de los pacientes?

1.2 Objetivos

1.2.1 Objetivo general

Construir un sistema de diagnóstico que integre un modelo de aprendizaje automático para el reconocimiento de pacientes que puedan padecer enfermedades cardiológicas.

1.2.2 Objetivos específicos

- Desarrollar un módulo de administración de datos clínicos de pacientes en una aplicación web para el diagnóstico y predicción de cardiopatías.
- Entrenar un modelo de aprendizaje automático utilizando registros clínicos de insuficiencia cardíaca para identificar pacientes con riesgo de desarrollar cardiopatía.
- Integrar el modelo de aprendizaje automático en la aplicación web para permitir la visualización y análisis de los datos en la historia clínica de cada paciente.

1.3 Justificación

El desarrollo de este proyecto tecnológico responde a la necesidad de optimizar el proceso de diagnóstico de cardiopatías en Ecuador. La implementación de un modelo de aprendizaje automático para la detección de enfermedades cardiovasculares permitirá al personal médico mejorar el proceso de evaluación, reduciendo los tiempos de diagnóstico y ampliando la capacidad de atención [13], [14]. Este sistema tecnológico servirá como herramienta de apoyo que complementa el criterio médico mediante la identificación de patrones de riesgo cardiovascular que podrían pasar desapercibidos [10], [15].

Los fines y propósitos de este proyecto tecnológico se centran en generalizar el acceso a evaluaciones cardiovasculares, especialmente en zonas rurales donde la ausencia de especialistas limita las posibilidades de detección temprana [5], [6]. Se busca contribuir a la

reducción de la mortalidad cardiovascular mediante diagnósticos que permitan intervenciones preventivas y terapéuticas en etapas iniciales de la enfermedad, cuando las opciones de tratamiento son más eficientes y menos costosas [8], [17].

Los beneficiarios directos de este proyecto tecnológico son, en primera instancia, los pacientes con riesgo cardiovascular que podrán acceder a diagnósticos rápidos, incrementando sus posibilidades de recibir tratamiento temprano [3], [4]. El personal médico se beneficiará mediante la optimización de su tiempo de trabajo, reduciendo la carga operativa de procesos diagnósticos repetitivos y permitiéndoles concentrarse en casos complejos que requieren análisis profundo [13], [16].

La relevancia práctica de este proyecto radica en su capacidad para resolver un problema concreto: la escasa capacidad diagnóstica cardiovascular frente a una alta demanda. La implementación del sistema de aprendizaje automático permitirá procesar un mayor número de evaluaciones cardiovasculares, identificando casos de riesgo que requieren atención prioritaria [15], [18]. Esto reducirá las listas de espera para evaluación, y facilitará la derivación de pacientes hacia niveles de atención apropiados según su condición [7].

Este proyecto posee relevancia social significativa al dirigirse específicamente a poblaciones vulnerables que actualmente enfrentan barreras de acceso a servicios cardiológicos especializados [1], [2]. Este proyecto se alinea con el Objetivo de Desarrollo Sostenible (ODS) 3: "Lograr una vida sana y promover el bienestar de todos por igual", específicamente con la meta de reducir la mortalidad prematura por enfermedades no transmisibles mediante prevención, tratamiento y promoción de salud mental y bienestar [4], [9].

CAPÍTULO II

MARCO TEÓRICO DEL PROYECTO TECNOLÓGICO

2.1. Marco conceptual

En este capítulo se describen los conceptos fundamentales relacionados con las enfermedades cardiovasculares y el uso de tecnologías avanzadas como el aprendizaje automático para su diagnóstico y predicción.

2.1.1. *Enfermedades cardiovasculares*

Las enfermedades cardiovasculares son un grupo de enfermedades que afectan el corazón y los vasos sanguíneos. Pueden ser congénitas presentes desde el nacimiento o desarrolladas a lo largo de la vida. Afecta a personas de todas las edades, sexos, etnias y niveles socioeconómicos. Casi la mitad de los adultos padecen algún tipo de enfermedad cardiovascular. Una persona puede experimentar físicamente la enfermedad o ser asintomática [2], [19].

A continuación, se describen los principales tipos:

- **Arritmia:** Es una alteración en el sistema de conducción eléctrica del corazón, lo que provoca ritmos cardíacos anormales (taquicardia, bradicardia o latidos irregulares). Las arritmias pueden ser inofensivas o potencialmente mortales, dependiendo de su gravedad y duración [20], [21].
- **Enfermedad Valvular:** Ocurre cuando las válvulas cardíacas o las estructuras que regulan el flujo sanguíneo entre las cámaras del corazón y los vasos sanguíneos no funcionan correctamente. Esto puede deberse a estenosis (estrechamiento), insuficiencia (fuga) o prolapso. Las causas incluyen fiebre reumática, envejecimiento o infecciones [20], [22].
- **Enfermedad de la Arteria Coronaria (EAC):** Es la forma más común de enfermedad cardiovascular y se debe a la acumulación de placas de ateroma (aterosclerosis) en las arterias coronarias, lo que reduce el flujo sanguíneo al músculo cardíaco. Esto puede provocar angina de pecho, infarto de miocardio o muerte súbita [2], [23].
- **Insuficiencia Cardíaca:** Ocurre cuando el corazón no puede bombear sangre de manera eficiente para satisfacer las necesidades del organismo. Puede ser sistólica (dificultad para bombear) o diastólica (dificultad para relajarse). Los síntomas incluyen fatiga, dificultad para respirar y retención de líquidos [20], [21].

- **Enfermedad Arterial Periférica:** Afecta a las arterias que irrigan las extremidades y los órganos abdominales, generalmente debido a la aterosclerosis. Los síntomas incluyen dolor en las piernas al caminar (claudicación intermitente), entumecimiento y, en casos graves, úlceras o gangrena [20], [24].
- **Enfermedad Aórtica:** Incluye afecciones como la aneurisma aórtica (dilatación anormal de la aorta) y la disección aórtica (desgarro en la pared de la aorta). Estas condiciones son potencialmente mortales y requieren atención médica inmediata [20], [22].
- **Enfermedad Cardíaca Congénita:** Son defectos estructurales del corazón presentes desde el nacimiento, como la comunicación interventricular, la tetralogía de Fallot o la transposición de los grandes vasos. Estos defectos pueden afectar el flujo sanguíneo y requerir intervención quirúrgica [2], [21].
- **Enfermedad Pericárdica:** Afecta al pericardio, la membrana que rodea el corazón. Incluye la pericarditis (inflamación del pericardio) y el derrame pericárdico (acumulación de líquido en el pericardio). Estas condiciones pueden causar dolor torácico y comprometer la función cardíaca [20], [22].
- **Enfermedad Cerebrovascular:** Se refiere a problemas en los vasos sanguíneos que irrigan el cerebro, como la estenosis carotídea o los accidentes cerebrovasculares. Estas afecciones pueden provocar déficits neurológicos permanentes o la muerte [2], [20], [21], [22].
- **Trombosis Venosa Profunda:** Es la formación de coágulos sanguíneos en las venas profundas, generalmente en las piernas. Si el coágulo se desprende, puede viajar a los pulmones y causar una embolia pulmonar, una condición potencialmente mortal [20], [25].

2.1.1.1. Síntomas

Los síntomas de las enfermedades cardiovasculares pueden variar según la causa. Los adultos mayores y las mujeres pueden presentar síntomas más sutiles, pero aun así pueden padecer enfermedades cardiovasculares graves [19], [26].

Los síntomas de problemas cardíacos pueden variar dependiendo de la enfermedad cardiovascular específica. A continuación, se describen los síntomas más comunes:

- **Dolor en el pecho (angina):** Sensación de presión, opresión o dolor en el pecho, generalmente causado por una reducción del flujo sanguíneo al músculo cardíaco. Puede irradiarse al brazo izquierdo, cuello o mandíbula [20], [26].
- **Dificultad para respirar (disnea):** Sensación de falta de aire, especialmente durante la actividad física o al acostarse. Es un síntoma común en la insuficiencia cardíaca y la enfermedad coronaria [21], [26].
- **Mareos o desmayos (síncope):** Pueden ocurrir debido a una disminución del flujo sanguíneo al cerebro, causada por arritmias, problemas valvulares o insuficiencia cardíaca [20], [26].
- **Fatiga o agotamiento:** Sensación de cansancio extremo, incluso después de realizar actividades mínimas. Es un síntoma frecuente en la insuficiencia cardíaca y la enfermedad coronaria [19], [26].
- **Dolor o calambres en las piernas (claudicación intermitente):** Dolor muscular en las piernas que ocurre al caminar y desaparece con el reposo, causado por la enfermedad arterial periférica [20], [26].
- **Úlceras en las piernas que no sanan:** Heridas persistentes en las piernas, generalmente asociadas con la enfermedad arterial periférica o la insuficiencia venosa crónica.
- **Piel fría o roja en las piernas:** Cambios en la temperatura o coloración de la piel, indicativos de problemas circulatorios en las extremidades inferiores.
- **Hinchazón en las piernas (edema):** Acumulación de líquido en las extremidades inferiores, común en la insuficiencia cardíaca y la enfermedad venosa crónica [21], [26].

2.1.1.2. Factores de riesgo

Los factores de riesgo son condiciones o comportamientos que aumentan la probabilidad de desarrollar enfermedades cardiovasculares. La presencia de estos factores puede llevar a un daño acumulativo en el sistema cardiovascular, incrementando la probabilidad de sufrir eventos adversos como infartos, accidentes cerebrovasculares o insuficiencia cardíaca [25], [27]. Algunos de los factores de riesgo más comunes incluyen:

- **Hipertensión (presión arterial alta):** La hipertensión es uno de los principales factores de riesgo. Contribuye al endurecimiento de las arterias y a la formación de placas ateroscleróticas, lo que aumenta el riesgo de infartos y accidentes cerebrovasculares [23], [28].
- **Hiperlipidemia (colesterol alto):** Los niveles elevados de colesterol LDL (lipoproteínas de baja densidad) y la baja concentración de colesterol HDL (lipoproteínas de alta densidad) están estrechamente relacionados con el desarrollo de aterosclerosis. El colesterol LDL promueve la acumulación de placas en las arterias, mientras que el HDL ayuda a remover el exceso de colesterol [25], [27].
- **Consumo de tabaco:** Fumar cigarrillos o el uso de cigarrillos electrónicos están asociados con un aumento significativo en el riesgo cardiovascular. El tabaco favorece la formación de coágulos sanguíneos, causa daño en los vasos sanguíneos y acelera la aterosclerosis. Aunque el vapeo se percibe como una alternativa menos dañina que fumar cigarrillos convencionales, aún se asocia con efectos adversos [24], [29].
- **Diabetes tipo 2:** La diabetes mellitus tipo 2 es un factor de riesgo importante para las enfermedades cardiovasculares. La hiperglucemia crónica contribuye a la disfunción endotelial, la inflamación y el aumento de la formación de placas en las arterias. Los pacientes con diabetes tienen un riesgo mucho mayor de sufrir infartos y enfermedades del corazón, especialmente si no se controla adecuadamente [25], [30].
- **Antecedentes familiares de enfermedad cardíaca:** Tener antecedentes familiares de enfermedades cardiovasculares prematuras aumenta significativamente el riesgo de desarrollar estas condiciones. Factores genéticos, como el hipercolesterolemia familiar, pueden predisponer a los individuos a desarrollar cardiopatías a edades tempranas [23], [24].
- **Falta de actividad física:** La inactividad física es uno de los mayores factores de riesgo modificables. La falta de ejercicio contribuye a la obesidad, la hipertensión y los niveles elevados de colesterol, todos los cuales son factores de riesgo importantes. La actividad física regular mejora la salud cardiovascular al reducir la presión arterial, mejorar el perfil lipídico y mantener un peso saludable [24], [29].

- **Obesidad o sobrepeso:** El exceso de peso es otro factor clave que contribuye al riesgo de desarrollar enfermedades cardiovasculares. La obesidad aumenta la inflamación, la resistencia a la insulina y la hipertensión, factores que aceleran la aterosclerosis [25], [27].
- **Dieta alta en sodio, azúcar y grasas:** Las dietas desequilibradas que contienen altos niveles de sodio, azúcares refinados y grasas saturadas son factores de riesgo bien establecidos. Estos hábitos alimenticios contribuyen al aumento de la presión arterial, la dislipidemia y la obesidad, lo que eleva el riesgo de enfermedades cardiovasculares [24], [29].
- **Uso excesivo de alcohol:** El consumo excesivo de alcohol está vinculado a la hipertensión, la dislipidemia y el aumento del riesgo de arritmias cardíacas. Aunque el consumo moderado de alcohol puede tener algunos efectos beneficiosos, el abuso de alcohol aumenta significativamente el riesgo cardiovascular [25], [27].
- **Mal uso de medicamentos recetados o recreativos:** El uso inapropiado de medicamentos, como los analgésicos no esteroideos, y el abuso de drogas recreativas pueden tener efectos perjudiciales en el sistema cardiovascular, incluyendo aumento de la presión arterial y riesgo de arritmias.
- **Preeclampsia o toxemia:** Las mujeres que han tenido preeclampsia durante el embarazo tienen un riesgo significativamente mayor de desarrollar enfermedades cardiovasculares más adelante en la vida, incluyendo hipertensión y enfermedad coronaria.
- **Diabetes gestacional:** La diabetes gestacional es un factor de riesgo importante para el desarrollo de diabetes tipo 2 y CVD en mujeres a largo plazo. Las mujeres que han tenido diabetes gestacional deben ser monitoreadas de cerca para detectar posibles problemas cardiovasculares más adelante.
- **Enfermedades inflamatorias o autoinmunes crónicas:** Enfermedades como la artritis reumatoide y el lupus eritematoso sistémico aumentan el riesgo cardiovascular debido a la inflamación crónica que afecta los vasos sanguíneos y favorece la aterosclerosis [21], [28].
- **Enfermedad renal crónica:** La ERC es un factor de riesgo independiente para enfermedades cardiovasculares. Los pacientes con enfermedad renal, especialmente

aquellos con insuficiencia renal avanzada, tienen un riesgo significativamente mayor de morir por CVD. La disfunción renal acelera la aterosclerosis y contribuye a la hipertensión y la acumulación de toxinas en el cuerpo, lo que aumenta el riesgo cardiovascular.

2.1.1.3.Pruebas

- **Electrocardiograma:** Es una prueba no invasiva que registra la actividad eléctrica del corazón a través de electrodos colocados en la piel. Mide la frecuencia cardíaca, el ritmo y la conducción eléctrica. Es fundamental para detectar arritmias, isquemia miocárdica y trastornos de conducción [22], [31].
- **Ecocardiograma:** Utiliza ondas de ultrasonido para crear imágenes en tiempo real del corazón, permitiendo visualizar su estructura, función y flujo sanguíneo. Puede ser transtorácico o transesofágico. Evalúa la contractilidad del corazón, el funcionamiento de las válvulas cardíacas, la presencia de líquido en el pericardio y defectos congénitos. También mide parámetros como la fracción de eyección, clave en el diagnóstico de insuficiencia cardíaca [22], [31].
- **Pruebas de Esfuerzo:** Evalúa la respuesta del corazón al ejercicio físico o a fármacos que simulan el esfuerzo. Puede incluir un ECG, ecocardiograma o imágenes de perfusión miocárdica. Detecta isquemia miocárdica durante el esfuerzo, lo que sugiere enfermedad arterial coronaria [31], [32].
- **Tomografía Computarizada Cardíaca:** Utiliza rayos X y procesamiento por computadora para crear imágenes tridimensionales del corazón y los vasos sanguíneos. Incluye la angiografía por TC coronaria, que visualiza las arterias coronarias. Detecta placas de ateroma, calcificaciones coronarias y anomalías estructurales. Es especialmente útil en pacientes con riesgo intermedio de enfermedad coronaria o con síntomas atípicos [22], [32].
- **Resonancia Magnética Cardíaca:** Utiliza imanes y ondas de radio para obtener imágenes detalladas del corazón, incluyendo tejidos blandos, flujo sanguíneo y función cardíaca. Proporciona información precisa sobre la estructura y función del corazón, incluyendo la viabilidad miocárdica y la presencia de fibrosis o inflamación [22], [31].

- **Cateterismo Cardíaco:** Procedimiento invasivo en el que se introduce un catéter a través de una arteria hasta el corazón. Permite medir presiones, flujo sanguíneo y realizar angiografía coronaria. Permite visualizar obstrucciones en las arterias coronarias y realizar intervenciones como angioplastia [32], [33].
- **Análisis de Sangre (Biomarcadores):** Mide sustancias en la sangre que indican la salud cardiovascular, como colesterol, glucosa, troponina y péptidos natriuréticos [23], [32].

2.1.2. *Aprendizaje Automático para la Predicción de Enfermedades Cardiovasculares*

Los modelos de aprendizaje automático son herramientas utilizadas para predecir enfermedades cardiovasculares debido a su capacidad para analizar grandes volúmenes de datos y detectar patrones complejos [1], [34]. Algunos de los modelos más utilizados incluyen:

- **Árboles de Decisión:** Modelos que dividen los datos en subgrupos basados en los valores de las características, resultando en una estructura tipo árbol donde los nodos representan decisiones y las hojas representan resultados. Los árboles de decisión son fáciles de interpretar y visualizar [10], [13].
- **Bosques Aleatorios:** Un método de ensamblaje que combina varios árboles de decisión para mejorar la precisión y reducir el sobreajuste. Al agregar las predicciones de varios árboles, los bosques aleatorios mejoran la robustez y la generalización [14], [34].
- **K-Vecinos más Cercanos (KNN):** Un algoritmo sencillo que clasifica los puntos de datos en función de la mayoría de la clase entre sus k vecinos más cercanos. KNN es intuitivo para tareas de clasificación y regresión [11], [15].
- **Deep Learning:** Redes neuronales profundas que aprenden representaciones jerárquicas de los datos. Capacidad para manejar datos no estructurados, como imágenes y texto. Fácil interpretación y visualización [17], [35].

2.1.2.1. *Selección de Características*

Relief: es un algoritmo de selección de características que pertenece a la categoría de métodos de filtro. Su objetivo es evaluar la relevancia de las características en un conjunto de datos, identificando aquellas que son más útiles para distinguir entre clases. A diferencia

de otros métodos, Relief no evalúa combinaciones de características, sino que utiliza el concepto de vecinos más cercanos para determinar la importancia de cada característica [34], [36].

LASSO: es una técnica de regresión utilizada en estadística y aprendizaje automático para realizar selección de características y regularización. Su objetivo es mejorar la precisión y la interpretabilidad de los modelos de regresión lineal. Lasso aplica una penalización basada en la norma L1 (valor absoluto de los coeficientes), lo que puede llevar a que algunos coeficientes se reduzcan exactamente a cero. Esto elimina variables del modelo, realizando una selección automática de características [11], [36].

2.1.2.2. Métricas de Rendimiento

Se utilizan para evaluar modelos de clasificación, donde las predicciones se realizan en categorías discretas. Estas métricas son esenciales para entender cómo un modelo se comporta en la identificación de clases específicas, lo que es importante en aplicaciones donde las decisiones deben basarse en la clasificación correcta de los datos.

Exactitud

La exactitud es una de las métricas más intuitivas y se define como la proporción de predicciones correctas sobre el total de predicciones realizadas. Se calcula como:

Fórmula 1 *Fórmula para el cálculo de exactitud de un modelo*

$$Accuracy = \frac{TP + TN}{TP + FP + FN + TN} \quad (1)$$

Donde TP es el número de verdaderos positivos, TN es el número de verdaderos negativos, FP es el número de falsos positivos y FN es el número de falsos negativos. Esta métrica es útil cuando las clases están equilibradas, pero puede ser engañosa en conjuntos de datos desbalanceados, donde una alta precisión puede ocultar un mal rendimiento en la clase minoritaria

Precisión

La proporción de instancias correctamente predichas sobre el total de instancias. Aunque es una medida básica del rendimiento, la precisión por sí sola puede ser engañosa, especialmente en conjuntos de datos desequilibrados donde una clase puede ser más frecuente. Se calcula como:

Fórmula 2 *Fórmula para el cálculo de la precisión positiva*

$$Precisión = \frac{TP}{TP + FP} \quad (2)$$

Esta métrica es importante en situaciones donde los costos de falsos positivos son altos, como en diagnósticos médicos o detección de fraudes, donde un falso positivo puede tener consecuencias significativas.

Sensibilidad

La precisión mide la proporción de verdaderos positivos sobre todas las predicciones positivas del modelo, mientras que el recall mide la proporción de verdaderos positivos sobre todos los positivos reales. Se calcula como:

Fórmula 3 *Fórmula para el cálculo del Recall*

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

Esta métrica es importante en contextos donde es crítico identificar todos los casos positivos, como en la detección de enfermedades, donde perder un caso positivo puede ser fatal. Un alto recall indica que el modelo es efectivo para capturar la mayoría de los casos positivos, lo que es esencial en aplicaciones donde la omisión de un caso puede tener consecuencias graves

Puntuación F1

La media armónica entre precisión y recall, proporcionando una métrica única que equilibra ambos aspectos. La puntuación F1 es particularmente útil en conjuntos de datos desequilibrados donde la precisión puede no reflejar adecuadamente el rendimiento del modelo. La puntuación de la F1 es una métrica importante para evaluar el rendimiento de los modelos de clasificación, especialmente en escenarios en los que la distribución de clases está desequilibrada. Se define como la media armónica de precisión y recuperación, y proporciona una puntuación única que equilibra ambas métricas. Esto lo hace particularmente útil en varias aplicaciones, como el aprendizaje automático, la ciberseguridad y el aprendizaje federado. Se calcula como:

Fórmula 4 *Fórmula de F1-Score*

$$F1 = 2 * \frac{Precisión * Recall}{Precisión + Recall} \quad (4)$$

Si bien la puntuación de la F1 es una métrica sólida, es posible que no siempre sea óptima, especialmente en aplicaciones con costos de error variables. Se han propuesto alternativas como la puntuación C para abordar estas limitaciones, haciendo hincapié en la necesidad de métricas de evaluación específicas del contexto.

AUC-ROC

La Curva ROC es una gráfica que muestra el rendimiento de un modelo de clasificación binaria al variar el umbral de decisión. En el eje X se representa la tasa de falsos positivos y en el eje Y la tasa de verdaderos positivos. Un modelo ideal tiene una curva que se acerca a la esquina superior izquierda, indicando alta sensibilidad y baja tasa de falsos positivos. El área bajo la curva proporciona una medida cuantitativa del rendimiento global del modelo. Un AUC de 1.0 indica un modelo perfecto que puede distinguir completamente entre clases positivas y negativas, mientras que un AUC de 0.5 sugiere una clasificación aleatoria.

Matriz de confusión

La matriz de confusión es una tabla que resume el rendimiento de un algoritmo de clasificación al comparar las clasificaciones previstas con los resultados reales. Esta representación permite a los investigadores y desarrolladores visualizar cómo se comporta el modelo en diferentes clases y entender mejor sus fortalezas y debilidades.

La matriz de confusión incluye cuatro métricas clave que son fundamentales para evaluar el rendimiento del modelo:

- Verdaderos Positivos (TP): Casos en los que el modelo predijo correctamente la clase positiva.
- Falsos Positivos (FP): Casos en los que el modelo predijo incorrectamente la clase positiva.
- Verdaderos Negativos (TN): Casos en los que el modelo predijo correctamente la clase negativa.
- Falsos Negativos (FN): Casos en los que el modelo predijo incorrectamente la clase negativa.

Estos componentes se utilizan para calcular métricas adicionales, como la exactitud, la precisión, la recuperación y la puntuación F1, que son esenciales para evaluar el rendimiento general del modelo.

2.1.3 Metodología de Prototipado para el Desarrollo de Software

La metodología de prototipado es un enfoque iterativo del desarrollo de software en el que se construyen versiones preliminares y funcionales del sistema, denominadas prototipos, con el propósito de visualizar, validar y refinar los requisitos antes de proceder al desarrollo completo del producto. Según Pressman (2010), el prototipado permite que tanto los desarrolladores como los usuarios establezcan una comprensión común sobre qué debe hacer el sistema, reduciendo significativamente el riesgo de errores en etapas avanzadas del proyecto.

Este modelo resulta especialmente útil en proyectos donde los requisitos no están completamente definidos desde el inicio, ya que permite una retroalimentación continua del usuario en cada ciclo de desarrollo. A continuación, se describen las etapas que conforman esta metodología.

Identificación de las Necesidades Básicas del Producto

La primera etapa de la metodología de prototipado consiste en la recopilación y análisis de los requisitos iniciales del sistema. En esta fase, el equipo de desarrollo trabaja en conjunto con los usuarios y partes interesadas (stakeholders) para identificar las necesidades fundamentales que el software deberá satisfacer. Sommerville (2011) señala que la elicitación de requisitos es uno de los procesos más críticos en la ingeniería de software, dado que los errores en esta etapa se propagan y amplifican en las fases posteriores del desarrollo.

Durante esta etapa se distinguen dos tipos de requisitos: los funcionales, que describen las funciones y servicios que el sistema debe proveer, y los no funcionales, que establecen restricciones sobre el sistema como rendimiento, seguridad y usabilidad. Las técnicas más utilizadas para la recolección de estos requisitos incluyen entrevistas con usuarios, análisis de documentos existentes, observación directa del proceso y talleres de trabajo colaborativo. El resultado de esta etapa es un documento preliminar de requisitos que sirve de base para la construcción del primer prototipo.

Diseño Rápido y Construcción del Prototipo

Una vez definidos los requisitos iniciales, se procede a la fase de diseño rápido, cuyo objetivo es traducir dichos requisitos en una representación visual y funcional del sistema en el menor tiempo posible. En esta etapa no se busca la perfección ni la completitud del producto, sino obtener una versión tangible que pueda ser evaluada por el usuario. Kendall y Kendall (2011)

destacan que el diseño rápido se enfoca en los aspectos visibles del software, tales como la interfaz de usuario, los flujos de navegación y las funcionalidades principales.

La construcción del prototipo implica el desarrollo de una versión simplificada pero operativa del sistema. Dependiendo del enfoque adoptado, el prototipo puede ser de baja fidelidad, como bocetos o wireframes en papel o herramientas digitales como Figma o Balsamiq, o de alta fidelidad, que incluye interfaces interactivas con cierta lógica de negocio implementada. Esta etapa tiene una duración corta e intensa, priorizando la velocidad de entrega sobre la calidad del código, con el entendimiento de que el prototipo puede ser descartado o transformado en la versión final según el tipo de prototipado adoptado.

Evaluación por el Usuario

La evaluación por parte del usuario constituye el núcleo diferenciador de la metodología de prototipado frente a otros modelos de desarrollo. En esta etapa, el prototipo construido es presentado a los usuarios finales y demás partes interesadas, quienes interactúan con él y proporcionan retroalimentación directa sobre su funcionamiento, diseño y pertinencia respecto a sus necesidades reales. Pfleeger y Atlee (2010) afirman que la participación activa del usuario en esta fase reduce considerablemente la brecha entre lo que el desarrollador interpreta y lo que el cliente realmente necesita.

Durante la evaluación se registran observaciones, sugerencias de cambio, funcionalidades faltantes y aspectos que no corresponden con las expectativas del usuario. Esta información es documentada de manera sistemática para alimentar la siguiente iteración del ciclo. Las técnicas de evaluación más comunes incluyen pruebas de usabilidad, entrevistas post-uso, cuestionarios de satisfacción y observación directa. La calidad y profundidad del feedback obtenido en esta etapa determinará en gran medida la efectividad del refinamiento posterior.

Refinamiento del Prototipo

Con base en los resultados de la evaluación, el equipo de desarrollo procede a la etapa de refinamiento, en la cual se incorporan las correcciones, mejoras y nuevos requisitos identificados durante la interacción con el usuario. Este proceso es iterativo y cíclico: el prototipo refinado es nuevamente evaluado, generando un nuevo ciclo de retroalimentación hasta que el sistema alcanza un nivel de madurez y aprobación satisfactorio. Según Boehm (1988), esta característica iterativa es lo que permite al prototipado gestionar la incertidumbre inherente al inicio de cualquier proyecto de software.

Cada iteración de refinamiento conlleva una revisión y actualización del documento de requisitos, garantizando que el producto en desarrollo se mantenga alineado con las necesidades cambiantes del usuario. El número de iteraciones varía en función de la complejidad del proyecto y del grado de claridad inicial de los requisitos. En proyectos de mediana o alta complejidad, es común realizar entre tres y cinco ciclos de prototipado antes de llegar a una versión estable y aprobada.

Producto Final

La etapa final de la metodología de prototipado corresponde a la entrega del producto terminado. Una vez que el prototipo ha sido validado y aprobado por los usuarios en todas sus iteraciones, el equipo de desarrollo procede a construir el sistema completo con los estándares de calidad, seguridad y rendimiento requeridos para un entorno de producción. En el caso del prototipado evolutivo, el propio prototipo se convierte progresivamente en el producto final; mientras que en el prototipado desechable, el prototipo sirve únicamente como referencia y el sistema final se desarrolla desde cero con base en los requisitos validados.

El producto final es sometido a pruebas integrales de aceptación, verificación y validación antes de su despliegue. La documentación técnica y de usuario es elaborada en esta etapa, y se realizan las capacitaciones necesarias para garantizar una correcta adopción del sistema. La entrega final representa el cierre del ciclo de prototipado, aunque en muchos proyectos modernos el proceso da lugar a nuevas iteraciones de mantenimiento y mejora continua bajo enfoques ágiles complementarios.

2.2. Marco referencial

Con el crecimiento de los datos médicos y la capacidad de los modelos de aprendizaje automático para procesarlos, su uso ha demostrado ser prometedor en el diagnóstico de enfermedades cardiovasculares. En esta sección se explora los enfoques actuales, las metodologías y las aplicaciones de aprendizaje automático para la predicción de enfermedades cardiovasculares, basado en estudios recientes.

2.2.1. Aplicaciones de aprendizaje automático en el Diagnóstico de Cardiopatías

Los avances en el aprendizaje automático han transformado la forma en que se abordan los diagnósticos médicos, y en el caso de las enfermedades cardiovasculares, han demostrado ser especialmente útiles para mejorar la precisión de los diagnósticos. El trabajo de Dharmarathne et al. [37] refuerza la importancia del aprendizaje automático en este campo. Este estudio compara varios modelos de clasificación, incluidos los Árboles de decisión y Bosques aleatorios, como resultado se observa que los métodos basados en árboles de decisión ofrecen una excelente precisión en la identificación de riesgos.

Los modelos de aprendizaje automático supervisado como Árboles de decisión, Bosques aleatorios, y K-Vecinos más próximos son ampliamente utilizados para la clasificación de pacientes en riesgo de enfermedades cardiovasculares. En este sentido, Li et al. utilizaron un modelo de Bosques aleatorios para predecir el riesgo de enfermedades cardiovasculares, obteniendo una precisión del 90%. Por otro lado, Wu et al. [38] implementaron Bosques aleatorios y Retro propagación con Red neuronal artificial para predecir complicaciones cardiovasculares en pacientes con hipertensión, encontrando que Bosques aleatorios superaba al modelo de redes neuronales en términos de precisión y capacidad de generalización.

Además, el uso de modelos de aprendizaje por conjuntos ha ganado popularidad, ya que permiten mejorar la precisión mediante la combinación de varios clasificadores. En el trabajo de Ghosh et al. [39], se desarrollaron modelos híbridos como Bosques aleatorios y K-Vecinos más próximos, que combinan los beneficios de los modelos individuales con técnicas de bagging para reducir la varianza y mejorar la robustez del modelo.

Mohi Uddin et al. [40] presentan un enfoque en el que combinan múltiples conjuntos de datos de diversas fuentes para mejorar la predicción de enfermedades cardiovasculares. En su investigación, utilizan algoritmos de aprendizaje automático para desarrollar un modelo predictivo que puede clasificar a los pacientes según su riesgo de desarrollar complicaciones

cardiovasculares. Al combinar bases de datos como las de Cleveland, Long y Beach VA, los autores logran aprovechar una mayor diversidad de datos.

Por otro lado, el trabajo de Tang et al. [41] se enfoca en la mejora del análisis automatizado de electrocardiograma mediante el uso de algoritmos de aprendizaje profundo. El electrocardiograma permite monitorear la actividad eléctrica del corazón y detectar anomalías. Tang y su equipo aplican modelos de aprendizaje profundo para extraer características complejas de los electrocardiogramas, que pueden pasar desapercibidas para los modelos tradicionales de análisis. Al integrar técnicas avanzadas como redes neuronales profundas, su modelo mejora significativamente la capacidad de detectar arritmias y otros problemas cardiovasculares.

2.2.2. Preprocesamiento y Selección de Características

El preprocesamiento de datos es una de las fases más críticas en la construcción de un modelo de aprendizaje automático, especialmente cuando se trabaja con datos médicos, que suelen ser incompletos. Un paso esencial en esta fase es la limpieza de los datos, que implica la eliminación de registros con valores faltantes, la corrección de errores y la imputación de valores ausentes.

El trabajo de Li et al. [42] subraya la importancia de la automatización en la predicción de enfermedades cardiovasculares utilizando datos médicos electrónicos. Este estudio resalta que los datos de EMR a menudo contienen valores faltantes, lo cual puede ser resuelto mediante métodos de imputación, como el uso de KNN, que imputa valores ausentes basándose en los datos más cercanos en el espacio de características. Esta técnica de imputación garantiza que el modelo pueda ser entrenado con un conjunto de datos más completo, reduciendo la posible distorsión de las predicciones debido a valores faltantes.

En cuanto a la selección de características, es primordial identificar qué variables tienen un impacto significativo en la predicción de enfermedades cardiovasculares. El trabajo de Ghosh et al. [39] demuestra el uso de técnicas de selección de características como Relief y LASSO para reducir la dimensionalidad y eliminar las características redundantes que podrían afectar la eficiencia y el rendimiento del modelo. Relief asigna un peso a cada característica en función de su capacidad para diferenciar entre clases, mientras que LASSO selecciona características relevantes al aplicar una penalización que reduce los coeficientes de las características menos importantes a cero.

2.2.3. Evaluación del Modelo y Métricas de Rendimiento

La evaluación del rendimiento de los modelos es una fase crítica para garantizar la efectividad del sistema de diagnóstico. Las métricas más comunes incluyen la precisión, sensibilidad, especificidad y el AUC-ROC (Área bajo la curva de características operativas del receptor), que ayudan a determinar la capacidad del modelo para identificar correctamente a los pacientes con y sin enfermedades cardiovasculares.

Dharmarathne et al. [37] aplicaron estas métricas para evaluar la capacidad de los modelos de aprendizaje automático, destacando la importancia de la sensibilidad en la predicción, ya que una baja sensibilidad podría resultar en falsos negativos, lo cual sería riesgoso en un entorno clínico. Además, la precisión y el F1-score son métricas fundamentales para evaluar el equilibrio entre los falsos positivos y los falsos negativos.

2.2.4. Interpretabilidad y Transparencia del Modelo

La interpretabilidad es fundamental en el contexto médico, ya que los profesionales de la salud necesitan entender cómo un modelo llega a una conclusión para tomar decisiones informadas. En este sentido, las herramientas de interpretabilidad de IA, como SHAP, permiten proporcionar justificaciones claras y transparentes sobre las decisiones del modelo. Dharmarathne et al. [37] integraron SHAP en su modelo de predicción, lo que permitió a los usuarios comprender la influencia de variables clave como la presión arterial media, la edad y los niveles de colesterol en la predicción del riesgo cardiovascular.

CAPÍTULO III
METODOLOGÍA DE LA INVESTIGACION

3.1 Marco de fases de desarrollo del proyecto tecnológico.

El desarrollo del presente proyecto tecnológico requirió la adopción de un enfoque metodológico dual, dado que el sistema está compuesto por dos componentes de naturaleza distinta. Para el módulo de gestión de pacientes se aplicó la Metodología de Prototipado. Para el desarrollo del modelo predictivo se siguió un proceso estructurado de análisis de datos que comprende las fases de recolección y selección del conjunto de datos, exploración y preprocesamiento, comparación de algoritmos y evaluación del modelo seleccionado.

3.1.1 Desarrollo del módulo de gestión de pacientes

Para el desarrollo del módulo de gestión de pacientes, se utilizó la metodología de prototipado como enfoque principal. Dicha metodología se llevó a cabo en cinco fases: recolección de requerimientos, diseño rápido, construcción del prototipo, evaluación y refinamiento hasta obtener la versión final del módulo. Esta metodología de desarrollo es ideal para proyectos donde no existen requisitos claros; construir prototipos permitió visualizar rápidamente una solución, recibir retroalimentación directa y ajustar el sistema de manera iterativa.

Figura 1 Fases de la metodología de prototipado



Elaborado por: autor

Recolección inicial de requerimientos

En esta fase se definió el procedimiento para identificar las necesidades del sistema y sus funcionalidades principales. El objetivo fue establecer una base de requerimientos que garantizara que el sistema desarrollado respondiera a las necesidades reales del contexto clínico y administrativo. Comprender el contexto operativo real, los procesos clínicos existentes y las necesidades de los usuarios permite construir un sistema alineado con la realidad organizacional.

Para el análisis inicial del flujo de trabajo se usó observación directa; esto debido a que permite captar los procesos en tiempo real, identificando no solo lo que se dice que se hace, sino lo que realmente sucede. Esto ofrece un conocimiento directo de la situación, lo cual permite identificar inefficiencias y necesidades que el personal no suele mencionar en entrevistas. Por lo tanto, este enfoque garantiza la obtención de datos objetivos, reduciendo las diferencias entre los protocolos establecidos y la operación diaria.

La fase de observación inicio con la visita al centro de cardiología cuya duración se extendió hasta cubrir el ciclo completo de atención al paciente, desde su ingreso hasta la gestión final de sus datos por parte del personal administrativo. Se analizaron las etapas de atención a los pacientes, la forma en cómo el personal administrativo gestionaba la información y cómo los médicos interactúan con los datos de los pacientes. Esto permitió identificar los puntos donde se genera, ingresa y procesa información clínica.

Para complementar esta fase, se realizó un análisis de las plantillas y formularios utilizados actualmente para el ingreso y gestión de datos clínicos. Se revisaron los formularios de diferentes etapas del proceso de atención, tales como la plantilla de admisión, formularios de evaluación clínica y documentos de registro de pruebas diagnósticas. El estudio de estos documentos permitió identificar las variables clínicas y administrativas, la estructura de la información y los campos que deben ser incluidos en el sistema.

Para profundizar en el análisis, se aplicaron entrevistas semiestructuradas dirigidas al personal administrativo y estratégico. El propósito de estas sesiones fue determinar los mecanismos de gestión de la información, así como las barreras operativas que dificultan los procesos actuales. De igual manera, se consultó a médicos especialistas en cardiología con

el fin de definir los parámetros clínicos necesarios para la evaluación del riesgo cardiovascular, asegurando que el diseño del sistema responda a las necesidades médicas.

La fase de entrevistas inició con un médico cardiólogo, con la finalidad de detallar cómo se desarrolla el proceso de atención, desde el ingreso del paciente hasta la emisión del diagnóstico. Esta sesión proporcionó una visión del proceso clínico desde la perspectiva del usuario con el rol de médico. Asimismo, permitió comprender la secuencia lógica de los datos, la necesidad de recuperar información de etapas previas y la forma en que la herramienta tecnológica debe dar soporte al flujo de trabajo clínico real.

Una vez finalizada la fase de análisis, se llevó a cabo la síntesis y consolidación de la información recopilada, lo que permitió la definición y especificación de los requerimientos de software. Dichos requerimientos fueron organizados de manera sistemática en fichas técnicas descriptivas, donde cada requerimiento fue identificado mediante un código único y una descripción técnica detallada, estableciendo así una base documental formal para las etapas de diseño e implementación del sistema.

Diseño rápido

En esta fase se definió una estructura preliminar del sistema con el propósito de representar de manera general el funcionamiento del módulo de administración de datos clínicos de pacientes. El diseño rápido permitió establecer una visión inicial, enfocada principalmente en la funcionalidad y la usabilidad, sin profundizar aún en aspectos de diseño detallado. Esta etapa sirvió para comprender la organización general del sistema y su comportamiento esperado desde la perspectiva del usuario.

El proceso inició con la elaboración de los diagramas de casos de uso, los cuales permitieron identificar las funcionalidades principales del sistema y la interacción entre los distintos tipos de usuarios y la aplicación web. Cada caso de uso se documentó en plantillas que incluían sus identificadores, actores, descripción detallada de la funcionalidad, precondiciones y flujo de eventos, lo que facilitó su organización y seguimiento, así como la visualización del flujo general de navegación y de las acciones que el sistema debía soportar.

Para complementar esta etapa, se desarrollaron bocetos de interfaz utilizando la herramienta Figma, aprovechando la facilidad que ofrece para la reutilización de componentes visuales. Esto permitió seleccionar y adaptar elementos existentes que se ajustaran a los

requerimientos del sistema, optimizando el tiempo de diseño. A partir de estos bocetos se definió una estructura inicial de los componentes del sistema a nivel general, la cual permitió establecer una referencia para las etapas posteriores de diseño.

Construcción del prototipo

En esta fase se definió el procedimiento para desarrollar una versión inicial y funcional del sistema, basada en el diseño rápido establecido previamente. El proceso incluyó la implementación de las interfaces preliminares y la configuración de los componentes básicos, permitiendo el ingreso, almacenamiento y consulta de la información clínica. De igual manera, se integró de manera inicial el módulo de predicción de cardiopatías, con el fin de simular el funcionamiento del sistema y evaluar el flujo de datos entre la interfaz.

Para el desarrollo del prototipo se seleccionó TALL Stack (Tailwind CSS, Alpine.js, Livewire, Laravel), una pila tecnológica moderna orientada a la construcción de aplicaciones web dentro del ecosistema Laravel. La elección de este ecosistema de desarrollo se fundamentó en su capacidad para generar interfaces reactivas manteniendo la lógica del lado del servidor, lo que simplifica el desarrollo y reduce la complejidad arquitectónica.

- **Laravel** constituyó el núcleo del sistema, proporcionando una arquitectura MVC robusta que facilitó el manejo de rutas, controladores, modelos, autenticación y seguridad. Su ecosistema y documentación permitieron acelerar el proceso de desarrollo.
- **Livewire** se integró para la construcción de componentes dinámicos sin necesidad de escribir JavaScript complejo. Esta herramienta permitió actualizar la interfaz de usuario de forma reactiva, implementar validaciones en tiempo real, gestionar formularios interactivos y realizar actualizaciones automáticas de datos mediante comunicación con el servidor.
- **Alpine.js** complementó a Livewire proporcionando interactividad ligera del lado del cliente para comportamientos visuales que no requirieron comunicación con el servidor, tales como menús desplegados, modales y transiciones, optimizando así el rendimiento de la aplicación.
- **Tailwind CSS** se empleó para el diseño de la interfaz gráfica mediante un enfoque basado en clases utilitarias. Este framework facilitó la construcción de interfaces

responsivas, consistentes y personalizables, acelerando el proceso de maquetación y manteniendo coherencia visual en todo el sistema.

Se utilizó PostgreSQL como gestor de base de datos, cuya estructura fue definida mediante migraciones de Laravel, lo que permitió el versionado y control del esquema de la base de datos. Este enfoque facilitó la reproducción del entorno en distintos equipos de desarrollo. Para la interacción entre la aplicación y la base de datos se empleó Eloquent ORM de Laravel, mediante el cual cada tabla se representa como una clase y los registros como instancias, simplificando las operaciones de consulta y persistencia de datos.

Evaluación del prototipo

En esta fase se estableció el procedimiento para revisar y analizar el funcionamiento del prototipo desarrollado, con el propósito de verificar que las funcionalidades implementadas correspondieran a los requerimientos iniciales del proyecto. El proceso consistió en la ejecución de pruebas básicas sobre el prototipo, enfocadas en la correcta operación de las funciones principales del módulo, tales como el registro, actualización y consulta de datos clínicos de los pacientes.

Refinamiento del prototipo

En esta fase se definió el procedimiento para realizar ajustes y mejoras al prototipo, tomando como referencia las observaciones y la retroalimentación obtenida durante la fase de evaluación. El proceso incluyó la corrección de errores detectados, la mejora de las interfaces de usuario y el ajuste de las funcionalidades implementadas, priorizando aquellas relacionadas con la administración de datos clínicos y la presentación de los resultados de predicción de cardiopatías. Además, se realizaron modificaciones orientadas a mejorar la coherencia del flujo del sistema y la estabilidad general del prototipo.

3.1.2 Desarrollo del modelo predictivo

En esta fase se tuvo como objetivo principal el desarrollo y entrenamiento de un modelo predictivo orientado a identificar y estimar la probabilidad de presencia de enfermedades cardiovasculares a partir de la información clínica recolectada de pacientes. Para ello, se aplicaron técnicas de análisis estadístico y aprendizaje automático, considerando variables demográficas, clínicas y de laboratorio, con el fin de construir un modelo capaz de apoyar la toma de decisiones en contextos médicos.

Fuente de datos

Para la búsqueda del conjunto de datos se investigó en repositorios con respaldo científico, específicamente el UCI Machine Learning Repository y el IEEE DataPort. En la etapa inicial se identificaron diversos conjuntos de datos relacionados con enfermedades cardiovasculares. Para seleccionar la fuente más adecuada, se elaboró una tabla comparativa que evaluó criterios como el número de instancias, la cantidad y tipo de variables clínicas, la disponibilidad de la variable objetivo, la calidad de la documentación y el uso previo en investigaciones científicas.

Con base en este análisis comparativo, se seleccionó el conjunto de datos más apropiado para los objetivos del estudio. El conjunto de datos seleccionado es ampliamente referenciado en la literatura médica y de aprendizaje automático para la investigación de cardiopatías, y contiene información clínica de pacientes con y sin diagnóstico de enfermedad cardiovascular. Esta base de datos permite realizar un análisis robusto y confiable, respaldado por su validación en múltiples estudios previos del área.

Análisis y preprocesamiento de datos

Se realizó un análisis exploratorio con el objetivo de comprender la estructura, distribución y calidad de los datos. Para las variables numéricas se calcularon estadísticas descriptivas, permitiendo caracterizar clínicamente a la población estudiada. Las variables categóricas y binarias fueron analizadas mediante distribuciones de frecuencia y porcentajes. Se evaluó la distribución de la variable objetivo para identificar posibles desbalances entre pacientes sanos y pacientes con cardiopatía.

Se verificó la presencia de valores faltantes y atípicos en el conjunto de datos. Los valores atípicos fueron analizados individualmente para determinar si correspondían a variabilidad legítima o a posibles errores de registro. En los casos en que se detectaron inconsistencias en el registro completo, se evaluó la proporción de observaciones afectadas. Cuando la cantidad resultó mínima y su eliminación no alteraba significativamente la estructura del conjunto de datos ni los análisis posteriores, se procedió a su exclusión.

Los valores ausentes fueron imputados mediante la mediana correspondiente, seleccionada por su mayor robustez frente a distribuciones asimétricas y la presencia de valores extremos. Asimismo, se verificó que esta imputación no introdujera sesgos sistemáticos ni alterara la distribución general de las variables. Este procedimiento permitió reducir el ruido en los

datos, preservar la coherencia estadística del conjunto y mejorar la estabilidad y capacidad de generalización de los modelos predictivos.

Tras la depuración del conjunto de datos, se procedió a su adecuación técnica. En primer lugar, la variable objetivo fue transformada a tipo factor con el fin de asegurar el cálculo adecuado de métricas como la sensibilidad y la precisión. Posteriormente, para garantizar que todas las variables contribuyeran de manera equitativa al modelo, se aplicó un proceso de centrado y escalado estadístico. Este preprocesamiento se integró en la función `train` de la librería `caret`, de modo que se ejecutara dentro del esquema de validación.

Selección del modelo predictivo

En esta etapa, el objetivo fue realizar una evaluación comparativa de diversos algoritmos de aprendizaje automático con el fin de identificar el modelo óptimo para el diagnóstico de cardiopatías. A diferencia de un enfoque basado en un único algoritmo, se implementó un proceso comparativo de modelos predictivos, permitiendo una selección fundamentada en evidencia estadística. Se seleccionaron cuatro modelos con naturalezas matemáticas distintas, con el propósito de cubrir un amplio espectro de enfoques predictivos:

- **Regresión Logística**, utilizada como modelo de referencia debido a su alta interpretabilidad y eficacia en problemas de clasificación binaria.
- **Máquinas de Soporte Vectorial (SVM)**, implementadas con un núcleo radial (RBF) para capturar fronteras de decisión no lineales complejas.
- **Random Forest**, un método de ensamble basado en bagging, seleccionado por su capacidad para modelar interacciones entre variables y reducir la varianza.
- **XGBoost**, un algoritmo de boosting de alta eficiencia, optimizado mediante una rejilla de hiperparámetros para maximizar su capacidad predictiva.

Para mitigar el sesgo derivado de una partición única de los datos, se aplicó la técnica de validación cruzada de 10 pliegues. En este procedimiento, el conjunto de datos se dividió en 10 subconjuntos proporcionales. Cada modelo fue entrenado y validado en 10 iteraciones, rotando el pliegue de prueba en cada ciclo. Asimismo, se habilitó la opción `classProbs` para obtener probabilidades estimadas de riesgo, permitiendo un análisis detallado mediante curvas ROC.

La selección del modelo final se realizó a partir de una evaluación conjunta de múltiples métricas de desempeño, incluyendo la exactitud, el Área Bajo la Curva ROC, la sensibilidad y el F1-score. Para cada algoritmo, se calcularon los valores promedio obtenidos a lo largo de las iteraciones de la validación cruzada, cuyos resultados se sintetizaron en una tabla comparativa. De este modo, se priorizó el modelo con el mejor rendimiento global y estabilidad estadística, evitando optimizar una única métrica.

Evaluación del modelo seleccionado

Una vez seleccionado el modelo Random Forest como el algoritmo con mayor capacidad predictiva, se realizó una evaluación completa para confirmar su rendimiento estadístico y validar su utilidad clínica en cardiología. Se analizó la matriz de confusión global obtenida mediante validación cruzada, lo que permitió examinar la proporción de aciertos y la naturaleza de los errores, con especial énfasis en los falsos negativos por su relevancia clínica, además de considerar los verdaderos positivos y los falsos positivos.

Para otorgar validez científica al desempeño global, se calculó el área bajo la curva ROC (AUC-ROC) junto con su intervalo de confianza al 95 % mediante el método estadístico de DeLong. Este procedimiento permitió confirmar que el rendimiento observado no es producto del azar, sino que posee una alta probabilidad de reproducirse en escenarios clínicos distintos al conjunto de entrenamiento, reforzando así la solidez metodológica del modelo y su potencial aplicabilidad en contextos reales.

Para finalizar la etapa de evaluación se realizó un análisis de importancia de variables basado en el índice de impureza de Gini, lo que permitió jerarquizar los factores clínicos según su contribución a la predicción final. Los hallazgos mostraron coherencia con la literatura cardiológica internacional y con las guías de práctica clínica vigentes, lo que indica que el modelo no solo presenta un alto rendimiento estadístico, sino que además ha aprendido patrones fisiopatológicos consistentes con el conocimiento médico establecido.

3.1.3 Integración del modelo predictivo con la aplicación web

Esta fase constituye el núcleo técnico del proyecto, ya que establece el puente operativo entre la investigación estadística realizada y el producto funcional orientado al usuario clínico. El proceso de integración se diseñó bajo un enfoque de desacoplamiento tecnológico, permitiendo que el motor de inteligencia artificial y la plataforma de gestión médica evolucionen de forma independiente pero coordinada.

Reentrenamiento del modelo

Para la puesta en producción, se optó por una estrategia de transposición de modelo. Una vez que la fase de experimentación en lenguaje R determinó que el algoritmo Random Forest presentaba el mejor desempeño, se procedió a replicar dicha arquitectura en el entorno de producción utilizando la librería Scikit-Learn de Python. Este enfoque garantiza la integridad de los resultados científicos obtenidos en la investigación, aprovechando al mismo tiempo la eficiencia de ejecución y la facilidad de despliegue que ofrece el ecosistema de Python para aplicaciones web.

Arquitectura de la API

Se seleccionó FastAPI como framework para el desarrollo de la API debido a su naturaleza asíncrona, alto desempeño en procesamiento de solicitudes concurrentes, y su capacidad nativa de validación automática de datos. La arquitectura implementada sigue un patrón de microservicio desacoplado, lo que permite escalar y mantener el componente de predicción de forma independiente del sistema. Esta separación facilita actualizaciones futuras del modelo sin afectar la lógica de negocio de la aplicación web, y permite que múltiples aplicaciones clientes puedan consumir el servicio de predicción simultáneamente. La API consta de los siguientes componentes principales:

- **Validación de datos** se implementaron esquemas de validación que restringen las variables clínicas a rangos biológicamente coherentes, evitando el procesamiento de datos ruidosos o fisiológicamente imposibles. Esta validación previa es fundamental para garantizar predicciones confiables, ya que el modelo fue entrenado con datos dentro de rangos clínicos específicos.
- **Persistencia del modelo** el modelo fue serializado en formato binario, un método optimizado que preserva toda la estructura del modelo entrenado. Este archivo se carga una única vez en memoria al iniciar el servicio evitando la sobrecarga de cargar el modelo en cada solicitud y reduciendo la latencia de respuesta.
- **Explicabilidad** el sistema implementa la extracción de importancias de características, calculadas mediante el método de reducción media de impureza de Gini en los árboles del ensamble. Estas importancias se devuelven junto con la predicción, informando al personal médico cuáles fueron los factores de riesgo predominantes en cada caso individual.

Integración con la Aplicación Web

Se implementó un patrón Observer en la aplicación web que automáticamente dispara predicciones cuando se registran nuevos exámenes clínicos en el sistema, eliminando la necesidad de intervención manual del usuario. Esta automatización elimina pasos redundantes en la interfaz de usuario, y garantiza que todas las consultas con datos completos tengan su correspondiente evaluación de riesgo. El Observer mapea automáticamente las variables clínicas almacenadas en múltiples entidades de la base de datos hacia el formato JSON de entrada requerido por la API.


La comunicación con la API se implementó mediante el cliente HTTP nativo de Laravel con un sistema de manejo de excepciones que garantiza la estabilidad del sistema principal. Cada tipo de error se registra específicamente en el sistema de logs de Laravel, facilitando la monitorización del sistema y la depuración de problemas en producción. Si la API no está disponible, el sistema principal continúa funcionando normalmente, pero sin generar predicciones, notificando al usuario de la situación temporal.

Las respuestas exitosas de la API se almacenan en una tabla dedicada que mantiene una relación de clave foránea con la tabla de consultas médicas. Esta estructura de datos permite no solo identificar a qué consulta pertenece cada predicción, sino también mantener un historial completo que posibilita análisis retrospectivos del desempeño del modelo, auditorías de decisiones clínicas, y estudios de seguimiento de pacientes.

Para la visualización de los resultados de predicción se utilizó Chart.js, una librería JavaScript de código abierto especializada en gráficos interactivos, seleccionada por su facilidad de integración con aplicaciones web modernas. La interfaz presenta el historial de predicciones asociadas a cada paciente mediante un gráfico de líneas temporal que muestra la evolución de la probabilidad de riesgo cardiovascular a través del tiempo.

3.2 Cronograma

Figura 2 Cronograma de trabajo



Elaborado por: autor

3.3 Recursos, presupuesto y financiamiento

En la presente sección se describen los recursos internos y externos necesarios para el desarrollo del proyecto, los cuales se clasifican en recursos humanos, técnicos y materiales. De igual manera, se presenta el presupuesto correspondiente a los costos y gastos asociados, junto con la especificación de las fuentes de financiamiento empleadas para la ejecución del proyecto.

3.3.1 Recursos humanos

Los recursos humanos utilizados en el desarrollo del proyecto fueron los siguientes:

- **Autor** Investigador y desarrollador principal del proyecto, encargado del análisis, diseño, construcción y validación del sistema y el modelo predictivo
- **Director** Encargado de la guía metodológica, asesoramiento técnico, revisión de entregables y validación del cumplimiento de los objetivos del proyecto.

- **Consultor médico** Asesoramiento en variables clínicas, validación de requerimientos, pruebas del prototipo
- **Administrador del centro de salud** Levantamiento de información de procesos, validación de flujos administrativos

3.3.2 Recursos tecnológicos

Los recursos tecnológicos utilizados en el desarrollo del proyecto fueron los siguientes:

Tabla 1 Recursos de software de desarrollo

Tecnología	Función	Costo
Laravel 11	Framework PHP para desarrollo del backend y API REST	\$0
PostgreSQL	Sistema de gestión de base de datos relacional	\$0
Python	Lenguaje para scripts de procesamiento de datos y modelo de machine learning	\$0
Figma	Herramienta de diseño UI/UX para wireframes	\$0
Git / GitHub	Control de versiones y repositorio del código	\$0
Composer	Gestor de dependencias para PHP y Laravel	\$0
Node.js & npm	Entorno de ejecución JavaScript y gestor de paquetes	\$0

Elaborado por: autor

Tabla 2 Recursos de servicios en la nube

Servicio	Función	Costo
Laravel Cloud	Alojamiento de la aplicación web	\$6
AWS (EC2)	Servidor para desplegar API en Python	\$0

Elaborado por: autor

Tabla 3 Recursos de herramientas de software

Herramienta	Función	Costo
Visual Studio Code	IDE para desarrollo	\$0
Postman	Testing y documentación de APIs	\$0
Pgadmin	Gestor gráfico de bases de datos	\$0
Docker	Contenedor de aplicación	\$0

Elaborado por: autor

Tabla 4 Recursos de materiales

Recurso	Especificaciones	Costo
Computadora personal (Laptop/Desktop)	Procesador: Intel i5/AMD Ryzen 5+, RAM: 8GB mínimo, SSD: 256GB	\$0
Conexión a internet	Velocidad: 20 Mbps mínimo	\$0

Elaborado por: autor

3.3.3 Presupuesto consolidado

Tabla 5 Presupuesto del proyecto

Categoría	Monto
Recursos humanos	\$0
Software de desarrollo	\$0
Servicios en nube	\$6
Herramientas de desarrollo	\$0
Recursos materiales	\$0
TOTAL	\$6

Elaborado por: autor

El desarrollo de este proyecto tecnológico, incluyendo todos los costos y gastos detallados en el presupuesto, fue financiado en su totalidad con recursos económicos propios del autor.

3.4 Instrumentos para el seguimiento y control

En esta sección se describen los instrumentos y herramientas implementadas para monitorear el progreso del proyecto tecnológico, asegurar el control de calidad del software desarrollado y facilitar la comunicación entre los miembros del equipo de trabajo. Estos instrumentos permitieron identificar desviaciones respecto al cronograma planificado, validar que los requerimientos se cumplieran y tomar decisiones adecuadas.

3.4.1 Instrumentos de planificación y control de avance

- **Excel:** se utilizó como herramienta principal para la creación, actualización y seguimiento del cronograma del proyecto. El cronograma se estructuró mediante un diagrama de Gantt que permitió visualizar la secuencia de actividades y fases del proyecto, desde la fase de planificación inicial hasta la culminación del proyecto.

- **Word:** se utilizó para la generación de informes de avance de forma periódica que documentaban el estado del proyecto. Estos informes permitieron mantener una visibilidad del estado del proyecto y servían como base para las reuniones de seguimiento, facilitando discusiones sobre el avance.

3.4.2 Instrumentos de control de versiones y despliegue

- **GitHub:** se utilizaron repositorios en GitHub en la fase de despliegue para facilitar la reproducción del ambiente en diferentes servidores y mantener un historial de versiones para futuras actualizaciones y mantenimiento del sistema.

3.4.3 Instrumentos de prueba y validación

- **Postman:** se utilizó como herramienta principal para realizar pruebas funcionales de la API REST. Permitiendo validar que la integración entre la aplicación web y el modelo de aprendizaje automático funcionara correctamente, asegurando que los datos fluyeran apropiadamente entre componentes.

3.4.4 Instrumentos de comunicación y coordinación

- **WhatsApp:** se utilizó para comunicación rápida y directa respecto a cambios de último momento y consultas puntuales. La comunicación mediante esta red social permitió resolver dudas de forma inmediata durante el desarrollo del proyecto.
- **Gmail:** se utilizó para comunicaciones formales, envío de informes de avance y documentación técnica.
- **Google Meet:** se utilizó para reuniones virtuales, facilitando la comunicación con el director del proyecto y permitiendo la participación remota.

3.5 Indicadores de evaluación

En esta sección se describen los indicadores de evaluación utilizados para validar el funcionamiento del proyecto tecnológico desarrollado. Estos indicadores permiten medir el rendimiento del sistema de diagnóstico cardiovascular en sus componentes funcionales y técnicos, asegurando que cumple con los requerimientos establecidos y es apto para su implementación en un contexto clínico real.

3.5.1 Indicadores de evaluación del modelo predictivo

Los indicadores de evaluación para el modelo de aprendizaje automático son medidas clave que permiten evaluar la precisión, confiabilidad y efectividad del diagnóstico predictivo. A continuación, se describen los indicadores implementados:

Exactitud

- **Indicador:** Proporción total de predicciones correctas sobre el total de casos evaluados
- **Evaluación:** Permite medir el desempeño general del modelo de forma global, considerando tanto aciertos en positivos como en negativos. Es útil cuando las clases están balanceadas y el costo de los errores es similar. Sin embargo, puede resultar engañosa en conjuntos de datos desbalanceados, ya que un modelo puede obtener una alta exactitud simplemente prediciendo siempre la clase mayoritaria.

Error de clase

- **Indicador:** Proporción de predicciones incorrectas realizadas por el modelo respecto al total de observaciones evaluadas.
- **Evaluación:** Permite cuantificar el nivel global de error del modelo, mostrando qué porcentaje de casos fue clasificado de manera incorrecta. Resulta útil cuando se desea enfatizar la magnitud de los fallos. Sin embargo, no distingue entre falsos positivos y falsos negativos, por lo que debe analizarse junto con otras métricas si se requiere comprender el tipo de error predominante.

Precisión

- **Indicador:** Porcentaje de predicciones correctas respecto al total de predicciones realizadas.
- **Evaluación:** Mide la proporción de instancias correctamente clasificadas sobre el total de instancias evaluadas. Un modelo con alta precisión demuestra que puede identificar correctamente tanto a pacientes en riesgo como a pacientes sin riesgo cardiovascular. Se esperaba una precisión mínima del 85% para considerarse aceptable en un contexto clínico.

Sensibilidad

- **Indicador:** Capacidad del modelo para identificar correctamente a pacientes con riesgo cardiovascular.
- **Evaluación:** Mide la proporción de verdaderos positivos sobre todos los pacientes que realmente tienen riesgo. En el contexto clínico de enfermedades cardiovasculares, una alta sensibilidad es crítica porque una baja sensibilidad podría

resultar en falsos negativos, es decir, pacientes con riesgo que no serían detectados. Se estableció una sensibilidad mínima del 80% como objetivo.

Especificidad

- **Indicador:** Capacidad del modelo para identificar correctamente a pacientes sin riesgo cardiovascular.
- **Evaluación:** Mide la proporción de verdaderos negativos sobre todos los pacientes que realmente no tienen riesgo. Una alta especificidad reduce los falsos positivos, evitando alarmar innecesariamente a pacientes saludables. Se estableció un objetivo de especificidad mínima del 75%.

Puntuación F1

- **Indicador:** Media armónica entre precisión y sensibilidad.
- **Evaluación:** Proporciona una métrica única que equilibra tanto los falsos positivos como los falsos negativos. El F1-Score es particularmente útil en conjuntos de datos desequilibrados, donde una clase puede ser más frecuente que la otra. Se esperaba un F1-Score mínimo de 0.82 en escala de 0 a 1.

Área Bajo la Curva ROC

- **Indicador:** Rendimiento integral del modelo de clasificación binaria.
- **Evaluación:** Evalúa la capacidad del modelo para distinguir entre pacientes con y sin riesgo cardiovascular a través de diferentes umbrales de decisión. El AUC-ROC varía entre 0 y 1, donde 1.0 indica un modelo perfecto y 0.5 sugiere una clasificación aleatoria. Se estableció un objetivo mínimo de AUC-ROC de 0.85.

Matriz de Confusión

- **Indicador:** Desglose detallado de verdaderos positivos, falsos positivos, verdaderos negativos y falsos negativos.
- **Evaluación:** Permite analizar en detalle el comportamiento del modelo, identificando en qué casos se cometen errores y determinar si estos errores afectan principalmente a falsos positivos o falsos negativos. En un contexto médico, típicamente se prefiere un modelo con más falsos positivos que falsos negativos.

3.5.2 Indicadores de evaluación funcional del sistema

Los indicadores funcionales miden el cumplimiento de los requerimientos del sistema en sus operaciones principales.

Cumplimiento de Requerimientos Funcionales

- **Indicador:** Porcentaje de requerimientos funcionales implementados y validados.
- **Evaluación:** Se evaluó la implementación completa de cada requerimiento identificado en la fase de análisis. Cada requerimiento fue verificado mediante pruebas de funcionamiento para asegurar que el sistema realiza las acciones esperadas. Se esperaba un 100% del cumplimiento de requerimientos funcionales.

Tiempo de Respuesta del Sistema

- **Indicador:** Tiempo transcurrido desde que el usuario ingresa datos clínicos hasta que recibe el resultado de la predicción.
- **Evaluación:** Se midió en segundos el tiempo de respuesta del sistema durante la ejecución de predicciones. Un tiempo de respuesta rápido contribuye a la usabilidad del sistema y a la experiencia del usuario clínico. Se esperaba en tiempos de respuesta un promedio de 1.5 segundos.

Disponibilidad del Sistema

- **Indicador:** Porcentaje de tiempo que el sistema está disponible y funcional.
- **Evaluación:** Se monitoreó la disponibilidad del sistema durante el período de pruebas, asegurando que funciona sin interrupciones. Una disponibilidad mínima del 99% se considera aceptable para sistemas críticos.

Validación de Datos de Entrada

- **Indicador:** Capacidad del sistema para validar y rechazar datos clínicos fuera de rangos biológicamente válidos.
- **Evaluación:** Se verificó que el sistema implementa validaciones que aseguran que los datos ingresados están dentro de rangos clínicamente aceptables.

3.5.3 Indicadores de evaluación de usabilidad

Los indicadores de usabilidad miden la facilidad y eficiencia con la que los usuarios pueden interactuar con el sistema.

Facilidad de Navegación

- **Indicador:** Capacidad del usuario para acceder a funcionalidades principales sin dificultad.
- **Evaluación:** Se evaluó mediante observación directa del usuario final la facilidad para navegar entre módulos del sistema, acceder a datos de pacientes y ejecutar predicciones. Se utilizó una escala de 1 a 5, donde 5 es muy fácil.

Claridad de Información Clínica

- **Indicador:** Comprensibilidad de los resultados de predicción y la información presentada en el sistema.
- **Evaluación:** Se evaluó si los resultados del modelo predictivo, incluyendo la probabilidad de riesgo y las variables influyentes, son comprensibles para el personal médico. Los resultados deben estar claramente presentados con explicaciones sobre qué significa cada indicador.

Eficiencia en Tareas Críticas

- **Indicador:** Tiempo promedio requerido para completar tareas clave del sistema.
- **Evaluación:** Se midió el tiempo requerido para realizar tareas como registrar un nuevo paciente, completar una consulta médica y ejecutar una predicción cardiovascular. Se esperaba que estas tareas se completasen en menos de 5 minutos por paciente.

CAPITULO IV

RESULTADOS

4.1 Producto tecnológico desarrollado

En esta sección se presentan los resultados del proyecto tecnológico desarrollado mediante la metodología de prototipado, evidenciando la evolución del sistema a través de sus distintas etapas de diseño e implementación. Se documentan los artefactos obtenidos, tales como requerimientos, casos de uso, diagramas UML y los detalles del modelo predictivo integrado al sistema.

4.1.1 Requerimientos

En este apartado se describen los requerimientos funcionales y no funcionales identificados durante el proceso de prototipado. Estos requerimientos sirvieron como base para el diseño del sistema, la definición de los casos de uso y la implementación del modelo predictivo.

Tabla 6 *Requerimiento de gestión de usuarios y control de acceso*

Identificador	RF-01	Prioridad	Alta
Nombre	Gestionar y controlar acceso de usuarios		
Descripción	El sistema deberá gestionar la autenticación y administración de usuarios mediante un esquema de control de acceso basado en roles y permisos. Permitirá el registro, inicio de sesión, recuperación de contraseña y la asignación de permisos específicos a cada rol para controlar el acceso a los distintos módulos del sistema.		
Criterios	• Permitir a los usuarios iniciar sesión y recuperar contraseña. • Permitir al administrador crear, listar, visualizar y editar usuarios y roles. • Generar permisos por módulo para las acciones de crear, visualizar, editar, listar y eliminar. • Permitir al administrador asociar permisos a los roles.		

Elaborado por: autor

Tabla 7 *Requerimiento de gestión de datos de pacientes*

Identificador	RF-02	Prioridad	Alta
Nombre	Gestionar datos personales de pacientes		

Descripción	El sistema deberá permitir la gestión de pacientes asegurando la integridad y trazabilidad de la información almacenada. El módulo incluirá validación de datos obligatorios y herramientas de búsqueda para facilitar la localización de pacientes.
Criterios	• Permitir a los usuarios registrar, consultar, actualizar y desactivar pacientes. • Permitir a los usuarios aplicar filtros de búsqueda por identificación, nombres del paciente. • Registrar la fecha de creación y el usuario que realizó el ingreso del paciente.

Elaborado por: autor

Tabla 8 Requerimiento de gestión de historia clínica

Identificador	RF-03	Prioridad	Alta
Nombre	Gestionar datos de historia clínica		
Descripción	El sistema permitirá el registro estructurado de consultas médicas como unidad central de la información clínica, integrando signos vitales, resultados de exámenes, procedimientos, tratamientos y diagnósticos.		
Criterios	• Permitir a los usuarios crear, listar, visualizar, actualizar y desactivar consultas. • Permitir a los usuarios registrar, editar y visualizar los datos de los signos vitales y resultados de los exámenes del paciente. • Permitir a los usuarios registrar, editar, listar y eliminar los diagnósticos, procedimientos, tratamientos y solicitudes del paciente.		

Elaborado por: autor

Tabla 9 Requerimiento de visualización de perfil clínico

Identificador	RF-04	Prioridad	Alta
---------------	-------	-----------	------

Nombre	Visualizar perfil clínico del paciente
Descripción	El sistema deberá consolidar la información de las consultas en un perfil clínico único por paciente, organizando los registros en orden cronológico inverso. El usuario podrá navegar secuencialmente en el historial para consultar información médica previa de forma estructurada.
Criterios	• Mostrar al usuario un listado de consultas con el detalle de diagnósticos, procedimientos y solicitudes realizadas. • Mostrar al usuario en orden cronológico los signos vitales y resultados de exámenes del paciente. • Permitir al usuario visualizar y agendar las citas del paciente. • Permitir al usuario consultar la información personal y los antecedentes médicos del paciente, organizados por categoría.

Elaborado por: autor

Tabla 10 Requerimiento de diagnóstico y predicción de riesgo cardiovascular

Identificador	RF-05	Prioridad	Alta
Nombre	Ejecutar diagnóstico predictivo cardiovascular		
Descripción	El sistema deberá integrarse con un modelo predictivo externo mediante una API, enviando las variables clínicas registradas en la consulta y recibiendo como respuesta un porcentaje de probabilidad de enfermedad cardiovascular y las variables más influyentes en el diagnóstico.		
Criterios	• Almacenar el resultado asociado a la consulta correspondiente en el perfil clínico del paciente. • Manejar errores de comunicación con la API mostrando un mensaje adecuado al usuario.		

Elaborado por: autor

Tabla 11 Requerimiento de análisis de evolución clínica

Identificador	RF-06	Prioridad	Alta
Nombre	Visualizar evolución clínica del paciente		
Descripción	El sistema generará gráficos de líneas para visualizar la tendencia temporal del paciente. Se graficarán de forma individual o comparativa los signos vitales e indicadores clínicos y el porcentaje de riesgo cardiovascular. El gráfico permitirá observar cómo varían estos factores en cada consulta registrada.		
Criterios	• Permitir al usuario filtrar la visualización por periodos de tiempo predefinidos: últimos 3 meses, 6 meses y 12 meses. • Permitir generar gráficos de líneas para las variables clínicas críticas y tarjetas de indicadores con gráfico de tendencia para las variables clínicas secundarias.		

Elaborado por: autor

Tabla 12 Requerimiento de generación de reportes

Identificador	RF-07	Prioridad	Alta
Nombre	Generar reportes del perfil clínico del paciente		
Descripción	El sistema ofrecerá una funcionalidad de exportación de datos en formato PDF. Esta herramienta permitirá generar reportes individuales que consoliden la historia clínica, la evolución temporal y las predicciones de riesgo de un paciente específico		
Criterios	• Permitir generar un reporte en formato PDF desde el perfil clínico del paciente. • Incluir en el reporte información general del paciente, listado de consultas, evolución de indicadores clínicos y resultados del modelo predictivo de riesgo cardiovascular.		

Elaborado por: autor

Tabla 13 *Requerimiento de generación de recomendaciones médicas*

Identificador	RF-08	Prioridad	Alta
Nombre	Generar recomendaciones de apoyo clínico		
Descripción	El sistema mostrará recomendaciones automáticas de apoyo clínico. Estas servirán como guía informativa y quedarán sujetas al criterio final del profesional médico		
Criterios	• Activar sugerencias automáticamente al detectar diagnósticos o signos vitales específicos. • No almacenar la sugerencia en la historia clínica hasta que el médico la apruebe manualmente.		

Elaborado por: autor

Tabla 14 *Requerimiento carga automatizada de resultados de laboratorio*

Identificador	RF-09	Prioridad	Media
Nombre	Extraer datos de resultados de laboratorio		
Descripción	El sistema permitirá la carga de documentos con resultados de exámenes de laboratorio. Mediante técnicas de reconocimiento de caracteres y procesamiento de lenguaje, el sistema extraerá automáticamente los valores de los indicadores y los precargará en el formulario de la historia clínica para su validación por el profesional médico.		
Criterios	• Precargar automáticamente los valores extraídos en los campos correspondientes del formulario. • Permitir al usuario corregir o anular cualquier valor extraído por el sistema antes de guardar.		

Elaborado por: autor

Tabla 15 *Requerimiento de gestión de catálogos médicos*

Identificador	RF-10	Prioridad	Media
---------------	-------	-----------	-------

Nombre	Gestionar catálogos médicos
Descripción	El sistema permitirá el registro y gestión de un catálogo interno de codificación médica, de manera que los profesionales puedan seleccionar diagnósticos y procedimientos por código o nombre, garantizando la normalización de la información clínica y facilitando auditorías y análisis estadísticos.
Criterios	• Permitir la búsqueda de diagnósticos, procedimientos y medicamentos mediante autocompletado por código alfanumérico o nombre común. • Validar que el usuario solo pueda seleccionar ítems existentes en el catálogo oficial para evitar errores de escritura manual. • Gestionar por separado catálogos de diagnósticos, procedimientos y vademécum de medicamentos. • Permitir al usuario importar o actualizar catálogos mediante archivos Excel.

Elaborado por: autor

Tabla 16 Requerimiento de gestión de archivos adjuntos del paciente

Identificador	RF-11	Prioridad	Baja
Nombre	Gestionar archivos adjuntos del paciente		
Descripción	El sistema funcionará como un repositorio digital para gestionar documentos del paciente, permitiendo su carga, consulta y eliminación, con clasificación por categoría y registro de fecha y usuario para garantizar la trazabilidad e integridad del expediente.		
Criterios	• Opción de vista previa rápida para imágenes y PDFs sin necesidad de descargar el archivo.		

Elaborado por: autor

Tabla 17 Requerimiento de agendamiento de citas

Identificador	RF-12	Prioridad	Alta
---------------	-------	-----------	------

Nombre	Administrar agendamiento de citas
Descripción	El sistema permitirá la planificación y seguimiento de las atenciones médicas a través de un módulo de calendario interactivo, que permitirá agendar citas asignando paciente, fecha y hora, controlar el estado de cada cita y visualizar la agenda mediante semanas.
Criterios	• Visualización interactiva mediante un calendario por semana. • Cada cita debe permitir cambios de estado. • Impedir el agendamiento de dos pacientes en el mismo bloque horario y fecha. • Permitir el acceso directo al inicio de la consulta.

Elaborado por: autor

Tabla 18 Requerimiento de generación de reglas médicas

Identificador	RF-13	Prioridad	Alta
Nombre	Administrar reglas clínicas		
Descripción	El sistema contará con un módulo administrativo que permita la configuración manual de protocolos médicos y reglas de decisión. Estas reglas vincularán diagnósticos específicos con sus respectivos procedimientos, solicitudes de exámenes y alertas de seguridad sugeridos.		
Criterios	• Permitir al usuario registrar una condición lógica o diagnóstico y asociar procedimientos y solicitudes de exámenes.		

Elaborado por: autor

Tabla 19 Requerimiento de visualización de estadísticas

Identificador	RF-14	Prioridad	Media
Nombre	Visualizar estadísticas generales de la clínica		

Descripción	El sistema mostrara un panel de control administrativo que centraliza y grafica los datos operativos de la clínica. Permite monitorear indicadores clave como volumen de pacientes, patologías más frecuentes y procedimientos concurrentes.
Criterios	• Permitir al usuario visualizar un top 10 de enfermedades y procedimientos más frecuentes en la clínica. • Permitir al usuario segmentar los datos por rango de fecha.

Elaborado por: autor

Tabla 20 Requerimiento de interfaz responsiva

Identificador	RNF-01
Nombre	Interfaz responsiva y adaptable
Descripción	El sistema deberá adaptar su interfaz gráfica a distintos tamaños de pantalla y dispositivos, garantizando una experiencia de uso adecuada tanto en computadoras de escritorio como en tablets, sin pérdida de funcionalidad ni legibilidad.
Criterios	• Los elementos de navegación, formularios y tablas deberán reorganizarse según el tamaño de pantalla disponible. • No deberá requerirse desplazamiento horizontal en ninguna vista del sistema.

Elaborado por: autor

Tabla 21 Requerimiento de tiempo de respuesta del modelo predictivo

Identificador	RNF-02
Nombre	Tiempo de respuesta del modelo predictivo
Descripción	El sistema deberá obtener la respuesta del modelo predictivo externo en un tiempo razonable que no interrumpa el flujo de trabajo del profesional médico. En caso de superar el tiempo límite, el sistema deberá notificar al usuario con un mensaje adecuado.
Criterios	• El tiempo de respuesta de la API predictiva no deberá superar los 5 segundos en condiciones normales de red.

	• Si la respuesta supera el tiempo límite, el sistema mostrará un mensaje de error sin interrumpir el resto de la consulta.
--	---

Elaborado por: autor

4.1.2 Casos de uso

En esta sección se presentan los casos de uso más relevantes del sistema, descritos mediante una plantilla extendida que incluye actores, precondiciones, postcondiciones, flujo principal y flujos alternos. Estos casos de uso permiten representar la interacción entre los usuarios y el sistema, así como las funcionalidades clave para la gestión de datos clínicos y el diagnóstico cardiológico.

Tabla 22 Caso de uso de gestión de datos personales de pacientes

Identificador	CU-01		
Caso de uso	Gestionar datos personales de pacientes		
Descripción	Permite registrar, consultar, actualizar y desactivar los datos personales de los pacientes.		
Precondición	El usuario debe estar autenticado en el sistema con permisos de registro de pacientes.		
Postcondición	Los datos del paciente quedan almacenados en el sistema para futuras consultas y actualizaciones.		
Flujo principal			
Acción del actor		Respuesta del sistema	
1	Ingresar a la sección de pacientes y seleccionar la opción de registrar nuevo paciente	2	Mostrar el formulario de registro dividido en categorías: datos básicos, residenciales y socioeconómicos.
3	Completar cada bloque del formulario y avanzar al siguiente	4	Validar la información ingresada y mostrar el siguiente bloque hasta completar todo el formulario.
5	Seleccionar la opción de registrar contactos de emergencia	6	Mostrar un formulario para registrar múltiples contactos de emergencia

7	Registrar los contactos necesarios y seleccionar la opción de finalizar	8	Guardar los datos del paciente y mostrar confirmación de registro exitoso.
Flujo alternativo			
4a. Si los datos ingresados en cualquier bloque del formulario principal son incorrectos o están incompletos, el sistema no permite avanzar al siguiente y muestra un mensaje de validación indicando los campos a corregir. 8a. Si los datos de los contactos de emergencia son incompletos o incorrectos, el sistema no permite registrar dichos contactos, por lo que el usuario debe corregir la información o eliminar los contactos incompletos antes de finalizar el registro del paciente.			

Elaborado por: autor

Tabla 23 Caso de uso de registrar consulta clínica

Identificador	CU-02		
Caso de uso	Registrar consulta clínica		
Descripción	Permite registrar una nueva consulta clínica del paciente, integrando signos vitales, antecedentes, resultados de exámenes, diagnósticos y procedimientos.		
Precondición	El usuario debe estar autenticado en el sistema con permisos de registro de consultas.		
Postcondición	Los datos de la consulta quedan almacenados en el sistema para su visualización en el historial clínico.		
Flujo principal			
Acción del actor		Respuesta del sistema	
1	Ingresar a la sección de consultas y seleccionar la opción de registrar nueva consulta.	2	Mostrar un modal con un formulario para seleccionar el especialista y el paciente.

3	Completar el formulario e iniciar la consulta	4	Crea el registro base de la consulta y habilita las secciones correspondientes.
5	Registrar la información en los formularios simples como el de signos vitales y exámenes realizados		
6	Seleccionar la opción de agregar en las secciones de múltiples registros como diagnósticos, procedimientos, tratamientos o solicitudes.	7	Mostrar un modal que permite agregar múltiples registros, así como editarlos o eliminarlos antes de finalizar
8	Agregar los registros necesarios y finalizar la consulta.	9	Guardar toda la información relacionada y generar un mensaje de confirmación de registro exitoso.
Flujo alternativo			
9a. El sistema valida la información ingresada en los formularios simples. Si existen datos incompletos o incorrectos, el sistema bloquea el guardado, muestra un mensaje de error y señala los campos que deben corregirse.			

Elaborado por: autor

Tabla 24 Caso de uso de ejecutar diagnóstico predictivo cardiovascular

Identificador	CU-03
Caso de uso	Ejecutar diagnóstico predictivo cardiovascular
Descripción	Permite ejecutar el modelo de aprendizaje automático con los datos clínicos del paciente para calcular su nivel de riesgo cardiológico
Precondición	El usuario debe tener una consulta activa con los datos clínicos del paciente completados.
Postcondición	El usuario puede visualizar las predicciones y las variables que más influyeron en el perfil del paciente
Flujo principal	

Acción del actor		Respuesta del sistema	
1	Completar el formulario de exámenes del paciente y guardar los cambios	2	Validar que los datos clínicos obligatorios estén completos.
		3	Enviar datos registrados en la consulta a la API de predicción
		4	Recibir la probabilidad generada por el modelo predictivo
		5	Registrar en la base de datos los resultados generados
		6	Mostrar una tarjeta de indicadores con línea de tendencia para la variable de probabilidad de enfermedad cardiovascular
		7	Generar un cuadro con los detalles de porque el paciente presento el riesgo y las variables que influyeron en el diagnóstico
Flujo alterno			
3a. Si no hay más de un dato registrado no se puede visualizar una línea de tendencia			
4a. Los datos enviados a la API no están completos para efectuar la predicción, se muestra una notificación al usuario.			

Elaborado por: autor

Tabla 25 Caso de uso gestión de roles y permisos de acceso

Identificador	CU-04
Caso de uso	Gestionar roles y permisos de acceso
Descripción	Permite al administrador definir perfiles de usuario y asignarles permisos específicos sobre los módulos del sistema

Precondición		El usuario debe estar autenticado con el rol de "Súper Administrador"	
Postcondición		Se actualiza la matriz de seguridad del sistema y los cambios de acceso se aplican a los usuarios vinculados	
Flujo principal			
Acción del actor		Respuesta del sistema	
1	Ingresar al módulo de Roles.	2	Mostrar una la lista de roles existentes
3	Seleccionar la opción de crear rol o editar un rol existente.	4	Desplegar un formulario con el nombre del rol y una lista de permisos.
5	Asignar o desmarcar permisos específicos para el rol y guardar cambios	6	Actualizar los permisos del rol y mostrar un mensaje de confirmación exitosa.
Flujo alterno			
6a El nombre del rol no es único y el sistema no permite guardar el registro			

Elaborado por: autor

Tabla 26 Caso de uso de analizar evolución y predicciones históricas

Identificador	CU-05
Caso de uso	Analizar evolución y predicciones históricas
Descripción	Permite comparar diagnósticos previos y analizar la evolución temporal de indicadores cardiovasculares.
Precondición	El paciente debe tener al menos dos registros de cada variable médica en el historial clínico.
Postcondición	El usuario identifica si el riesgo del paciente está aumentando, disminuyendo o es estable.
Flujo principal	
Acción del actor	Respuesta del sistema

1	Seleccionar la opción de visualizar perfil del paciente		
2	Ingresar al apartado de evolución del paciente	3	Mostrar un gráfico lineal para las variables clínicas de colesterol, glucosa, frecuencia cardíaca y presión arterial filtrando los últimos 3 meses
		4	Mostrar tarjetas de indicadores con línea de tendencia para las variables clínicas de frecuencia respiratoria, saturación de oxígeno, peso y depresión del segmento ST
5	Seleccionar la opción de filtrar disponible en los gráficos de líneas y escoger la opción de filtrar por los últimos 6 o últimos 12 meses	6	Filtrar la información del gráfico de líneas en base al filtro seleccionado por el usuario
Flujo alterno			
6a. Si no hay más de un dato registrado en el rango de tiempo seleccionado no se puede visualizar una línea de tendencia			

Elaborado por: autor

Tabla 27 Caso de uso de agendamiento de citas

Identificador	CU-06
Caso de uso	Agendar citas
Descripción	Permite planificar y gestionar las citas médicas de los pacientes mediante un calendario interactivo.
Precondición	El usuario debe estar autenticado y el paciente registrado en el sistema.
Postcondición	La cita queda reservada y el horario bloqueado en la agenda.

Flujo principal			
Acción del actor		Respuesta del sistema	
1	Ingresar a la sección de citas	2	Mostrar un calendario con las citas de la semana actual
3	Seleccionar la fecha y el horario donde se quiera generar la cita	4	Mostrar una lista de opciones correspondiente a acciones disponibles en el horario seleccionado
5	Escoger la opción de agregar nueva cita	6	Mostrar un modal con un formulario para seleccionar el paciente y especialista de la cita
7	Completar el formulario con los datos correspondientes y guardar cambios	8	Registrar la cita y actualiza la vista del calendario
Flujo alternativo			
8a El horario seleccionado en la cita no esta disponible, el sistema envía una notificación al usuario de que debe seleccionar otro horario			

Elaborado por: autor

Tabla 28 Caso de uso configuración de reglas y protocolos clínicos

Identificador	CU-07
Caso de uso	Registrar reglas y protocolos clínicos
Descripción	Permite definir las reglas manuales que dispararán alertas y sugerencias de tratamientos, procedimientos y solicitudes
Precondición	El usuario debe tener permiso de generación de reglas
Postcondición	Las reglas quedan activas para ser utilizadas durante las consultas médicas.
Flujo principal	
Acción del actor	Respuesta del sistema

1	Ingresar a la sección de reglas y selecciona la opción de agregar nueva regla	2	Mostrar un formulario para seleccionar si la regla estará asociada a un diagnóstico o condición lógica
3	Completar el formulario con los datos correspondientes y selecciona la opción de agregar acciones	4	Mostrar un formulario para ingresar la categoría de la acción como procedimientos o solicitudes de exámenes
5	Completar el formulario y guarda la regla	6	Validar la lógica y activa la regla para todas las nuevas consultas.
Flujo alterno			
6a Los datos están incompletos por lo cual el sistema no registra la nueva regla.			

Elaborado por: autor

Tabla 29 Caso de uso carga y extracción de documentos

Identificador	CU-08		
Caso de uso	Extraer datos de documentos		
Descripción	Permite digitalizar resultados de laboratorio externos y extraer sus valores		
Precondición	Existe un documento digital (PDF/Imagen) con resultados de laboratorio		
Postcondición	Los valores extraídos se integran en los campos de la historia clínica		
Flujo principal			
Acción del actor		Respuesta del sistema	
1	Iniciar una consulta y seleccionar la opción de cargar documento.	2	Mostrar un formulario para subir el documento

3	Subir el documento de los resultados del laboratorio	4	Guardar el documento en el sistema y actualizar el listado de archivos del paciente
5	Seleccionar la opción de extraer los resultados del documento ingresado	6	Procesar el documento mediante OCR y análisis de lenguaje.
		7	Guarda los valores en los campos correspondientes.
Flujo alterno			
7a. El sistema no reconoce datos en el archivo adjunto y no carga los valores en los campos.			

Elaborado por: autor

Tabla 30 Caso de uso visualización estadística general

Identificador	CU-09		
Caso de uso	Visualizar estadísticas generales		
Descripción	Permite analizar el rendimiento y la salud poblacional de la clínica mediante gráficos		
Precondición	Debe existir información registrada de múltiples pacientes y consultas		
Postcondición	El usuario puede visualizar los gráficos y aplicar filtros de tiempo		
Flujo principal			
Acción del actor		Respuesta del sistema	
1	Ingresar a la sección de escritorio	2	Cargar la interfaz gráfica con los widgets estadísticos actualizados.
		3	Visualizar las métricas de resumen para total de pacientes, promedio de edad y pacientes en tratamiento.


		4	Presentar gráficos de barras de diagnósticos y procedimientos frecuentes
5	Aplicar filtros temporales en los gráficos	6	Actualizar los datos según el periodo seleccionado
Flujo alterno			
2a No hay datos disponibles por lo cual el sistema no puede visualizar los gráficos estadísticos			

Elaborado por: autor

4.1.3 Diagrama de casos de uso

Se presenta el diagrama de casos de uso que representa las funcionalidades principales del sistema. El diagrama muestra la interacción entre los actores y el sistema, permitiendo identificar de forma clara el alcance funcional del producto desarrollado.

Figura 3 Diagrama de casos de usos




Elaborado por: autor

4.1.4 Diagrama de base de datos

Se presenta el diagrama de base de datos, el cual describe la estructura del software mediante la definición de tablas y sus relaciones.

Figura 4 Diagrama de base de datos




Elaborado por: autor

4.1.5 Diagramas de secuencias


En este apartado se presenta los diagramas de secuencia que representa los procesos principales del sistema de diagnóstico cardiológico. El diagrama permite visualizar el flujo de acciones y decisiones más relevantes durante la interacción del usuario con el sistema.

Figura 5 Diagrama de secuencia de registro de consulta




Elaborado por: autor

Figura 6 Diagrama de secuencia de comunicación con el modelo predictivo



Elaborado por: autor

Figura 7 Diagrama de secuencia de ejecución del modelo predictivo




Elaborado por: autor

4.1.6 Diagramas de componentes

Se presenta el diagrama de componentes con la estructura lógica del sistema, mostrando los principales módulos y las relaciones entre ellos. En este caso, se identifican los recursos, los modelos de dominio y los servicios externos, permitiendo comprender cómo se organiza internamente la aplicación y cómo interactúan sus distintas partes a nivel funcional.

Figura 8 Diagrama de componentes




Elaborado por: autor

4.1.7 Diagramas de despliegue

Se presenta el diagrama de despliegue con la arquitectura física del sistema, detallando los nodos donde se ejecutan los componentes, así como sus conexiones. Este diagrama permite visualizar cómo la aplicación web, la base de datos, los servicios de almacenamiento y los servicios externos se distribuyen en el entorno de ejecución y cómo se comunican entre sí.

Figura 9 Diagrama de despliegue



Elaborado por: autor

4.1.8 Prototipo rápido

Se presentan los prototipos de interfaz del sistema, desarrollados en Figma, que muestran la apariencia y la navegación principal de la aplicación web. En la figura se puede observar el prototipo de la interfaz que permite registrar los signos vitales, así como los resultados de exámenes clínicos, procedimientos y solicitudes durante la consulta. La interfaz está diseñada para facilitar la captura de datos clínicos que posteriormente alimentarán el modelo de aprendizaje automático, garantizando que toda la información relevante para el diagnóstico predictivo cardiovascular sea registrada.

Figura 10 Prototipo de interfaz de consulta médica

El prototipo de interfaz de consulta médica se presenta en un formato de tarjeta con un fondo gris claro. En la parte superior, el título "Consulta médica" está acompañado de los datos del paciente: "Angélica Tenecela Intriago • ID P-002341 • 32 años". A la derecha de esta sección hay dos botones: "Cancelar / Volver" y "Guardar consulta".

La interfaz está organizada en columnas y secciones:

- Paciente:** Sección a la izquierda que muestra los datos esenciales. Incluye campos para Nombre, Documento, Sexo y Cobertura, con los valores correspondientes de Angélica Tenecela Intriago.
- Diagnóstico:** Sección central que incluye un campo para el diagnóstico principal, un campo para las observaciones y un tipo de diagnóstico (Presuntivo, Definitivo, Seguimiento).
- Tratamiento / Plan:** Sección inferior izquierda para el plan terapéutico.
- Signos vitales:** Sección a la derecha que muestra los datos vitales en una tabla con unidades y valores.
- Exámenes:** Sección a la derecha que muestra los resultados de los exámenes realizados.
- Procedimientos:** Sección a la derecha que muestra los procedimientos realizados o programados.
- Solicitudes:** Sección inferior derecha que muestra las solicitudes.

TA	FC
120/80 mmHg	72 bpm
FR	Temp
16 rpm	36.7 °C
SatO2	Peso
98 %	72 kg
Talla	IMC
1.65 m	26.4 (Sobrepeso)

Exámenes realizados	Estado
Electrocardiograma	Sin alteraciones
Laboratorio básico	En espera


Procedimientos realizados / programados	Estado
Angiografía coronaria	Programado

Solicitudes
Interconsulta a cardiología

Elaborado por: autor

En la figura se visualiza el prototipo de perfil del paciente. Esta interfaz presenta toda la información clínica del paciente, incluyendo la visualización del gráfico lineal que resume las predicciones históricas de riesgo cardiovascular, la clasificación más reciente de riesgo, los detalles explicativos de los factores que contribuyen a dicho riesgo, y el conjunto de recomendaciones personalizadas para mejorar la salud del paciente.


Figura 11 Prototipo de interfaz de perfil del paciente



Elaborado por: autor

En la figura se muestra el prototipo del listado de pacientes, desde el cual se puede acceder a distintas funcionalidades, como visualizar el perfil del paciente, crear un nuevo registro, así como buscar y filtrar pacientes. Esta interfaz presenta una estructura clara e intuitiva que facilita la gestión y consulta de la información.

Figura 12 Prototipo de visualización de registros



Elaborado por: autor

En la figura se visualiza el prototipo de registro de paciente que representa las funcionalidades de registro y edición de información demográfica y administrativa del paciente. Esta interfaz presenta un formulario estructurado que solicita los datos esenciales

del paciente, incluyendo información de identificación, datos de contacto y datos demográficos básicos

Figura 13 Prototipo de interfaz de registro de paciente

Nuevo Paciente

Complete la información básica para registrar un nuevo ingreso.

Información Personal

Primer nombre *

Ej. Juan

Segundo nombre

Primer apellido *

Ej. Pérez

Segundo apellido

Sexo *

Seleccione...

Estado civil

Seleccione...

Identificación y Nacimiento

Tipo de identificación *

Cédula

Número de identificación *

Fecha de nacimiento *

dd/mm/aaaa

Nacionalidad

Ej. Colombiana

Información de Contacto

Teléfono celular *

Teléfono fijo

Correo electrónico

nombre@ejemplo.com


Cancelar

Guardar Paciente

Elaborado por: autor

En la figura se presenta el prototipo correspondiente a la visualización de las estadísticas generales de la clínica, el cual permite observar de manera resumida y organizada los principales indicadores y métricas relevantes para la gestión y seguimiento institucional.

Figura 14 Prototipo de interfaz de estadísticas generales



Elaborado por: autor

4.1.9 Aprendizaje automático

Como resultado del proceso de búsqueda y selección de información, se identificaron cuatro conjuntos de datos relacionados con enfermedades cardíológicas. Cada uno presenta características particulares en cuanto a su estructura, finalidad y contenido. En la Tabla se presenta un resumen que incluye su nombre, una descripción general, el objetivo principal para el cual son utilizados, la cantidad de variables y el número total de instancias disponibles.

Tabla 31 Resumen de los conjuntos de datos

Conjunto	Descripción	Objetivo Principal	Características
Myocardial Infarction Complications	Base de datos especializada en complicaciones del infarto de miocardio con información de ingreso y hospitalización	Predicción de complicaciones de infarto de miocardio	Variables: 111 Instancias: 1700
Heart Failure Clinical Records	Registros médicos de pacientes con insuficiencia cardíaca recopilados durante seguimiento clínico prolongado	Análisis y predicción en insuficiencia cardíaca	Variables: 12 Instancias: 299
Heart Disease	Base de datos consolidada de múltiples centros médicos (Cleveland, Hungría, Suiza, VA Long Beach)	Diagnóstico y clasificación de enfermedades cardíacas	Variables: 14 Instancias: 1190
Ecocardiogram	Datos ecocardiográficos de pacientes con antecedente de infarto agudo de miocardio	Predicción de supervivencia a un año post-infarto	Variables: 9 Instancias: 132

Elaborado por: autor

Para el entrenamiento se usó el conjunto de datos “Heart Failure”, que esta combinando de cinco conjuntos de datos populares sobre enfermedades cardíacas que estaban disponibles de forma independiente. En este conjunto de datos, se combinan cinco conjuntos de datos

con 11 características comunes, lo que lo convierte en el conjunto de datos de enfermedades cardíacas más grande disponible hasta la fecha para fines de investigación.

Los datos corresponden a pacientes que acudieron a evaluación cardiológica, por lo que no representan a la población general sino a una población con sospecha clínica. El conjunto de datos está compuesto mayoritariamente por pacientes de sexo masculino, con 909 registros (76,39%), mientras que el sexo femenino representa 281 registros (23,61%). Igualmente, la distribución según el estado de salud muestra una proporción relativamente equilibrada, con 561 pacientes sanos (47,14%) y 629 pacientes con cardiopatía (52,86%).

A continuación, se presenta la descripción general de las variables incluidas en el conjunto de datos, indicando su codificación, unidades de medida y tipo de dato.

Tabla 32 Descripción general de las variables del conjunto de datos

Atributo	Código	Unidad / Valores	Tipo
Edad	Age	Años	Numérico
Sexo	Sex	0, 1	Binaria
Tipo de dolor torácico	chest pain type	1, 2, 3, 4	Nominal
Presión arterial en reposo	resting bp s	mmHg	Numérico
Colesterol sérico	Colesterol	mg/dL	Numérico
Glucosa en ayunas	fasting blood sugar	0,1	Binaria
Resultados del electrocardiograma	resting ecg	0, 1, 2	Nominal
Frecuencia cardíaca máxima	max heart rate	71–202	Numérico
Angina inducida por ejercicio	exercise angina	0, 1	Binaria
Depresión del ST	Oldpeak	Depresión	Numérico
Pendiente del segmento ST en ejercicio máximo	ST slope	0, 1, 2	Nominal
Estado de salud	Target	0, 1	Binaria

Elaborado por: autor

A continuación, se describen las variables nominales y binarias incluidas en el conjunto de datos, junto con su codificación y significado clínico.

Tabla 33 Descripción de los atributos nominales del conjunto de datos

Atributo	Descripción
Sexo	1 = Hombre, 0 = Mujer
Tipo de dolor torácico	1: angina típica, 2: angina atípica, 3: dolor no anginoso, 4: asintomático
Glucosa en ayunas	Glucosa en ayunas > 120 mg/dL (1 = Sí, 0 = No)
Resultados del electrocardiograma en reposo	0: normal, 1: anormalidad de la onda ST-T, 2: hipertrofia ventricular izquierda
Angina inducida por ejercicio	1 = Sí, 0 = No
Pendiente del segmento ST en el ejercicio máximo	1: ascendente, 2: plana, 3: descendente
Estado de salud (clase)	1 = Cardiopatía, 0 = Normal

Elaborado por: autor

Exploración y preprocesamiento de los datos

En esta etapa se realizó un análisis exploratorio de las variables numéricas mediante estadísticas descriptivas, incluyendo la media, desviación estándar, valores mínimos, medianas y máximos. Este análisis permitió evaluar la distribución de los datos, identificar valores extremos y rangos atípicos, y preparar los datos para su limpieza y preprocesamiento, asegurando que la información fuera confiable para el análisis posterior.

Tabla 34 Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Estándar	Mediana	Mín	Máx	Asimetría
Colesterol	210.36	101.42	229	0.0	603	-0.78
Frecuencia cardíaca máxima	139.73	25.52	140.5	60	202	-0.23
Oldpeak	0.92	1.09	0.6	-2.6	6.2	1.09
Edad	53.72	9.36	54	28	77	-0.19
Presión arterial	132.15	18.37	130	0	200	0.29

Elaborado por: autor

- **Edad:** el promedio fue de 53 años, lo que indicó que la mayoría de los pacientes fueron adultos de mediana edad. La distribución fue bastante equilibrada, sin concentración extrema en jóvenes o adultos mayores, reflejando que el estudio se centró principalmente en población adulta.
- **Colesterol:** el promedio fue de 210 mg/dL, lo que indica que muchos pacientes presentaron niveles elevados. Se observó un valor mínimo de 0 mg/dL, lo cual no es fisiológicamente posible y probablemente representa un error de registro. Por otro lado, algunos pacientes presentaron valores muy altos (hasta 603 mg/dL), lo que reflejó casos con hipercolesterolemia significativa.
- **Frecuencia cardíaca máxima:** la media fue de 139.7 latidos por minuto, con valores concentrados cerca de la mediana (140.5), lo que indicó que la mayoría de los pacientes presentó una respuesta similar durante la prueba de esfuerzo. No se observaron valores extremos que llamaran la atención, reflejando un comportamiento homogéneo en esta variable.
- **Oldpeak:** la mayoría de los pacientes presentó depresión leve del ST, con promedio de 0.92 y mediana de 0.6. Sin embargo, se observó un valor negativo de -2.6, lo cual es clínicamente raro y probablemente corresponde a un error de registro. La distribución estuvo sesgada hacia valores altos y con presencia de casos extremos.
- **Presión arterial en reposo** El promedio fue de 132 mmHg, ligeramente elevado, indicando que una parte de los pacientes podría presentar presión arterial alta. Se observó un valor mínimo de 0 mmHg, lo que no es posible y representa un registro atípico. La mayoría se concentró alrededor del promedio, pero los valores extremos sugirieron algunos casos especiales.

Durante la exploración de los datos se identificaron valores atípicos que requerían tratamiento. Los registros con valor 0 se consideraron datos faltantes y fueron imputados utilizando la mediana de cada variable; en presión arterial solo se presentó un caso, por lo que su efecto sobre la distribución fue mínimo. En la variable Oldpeak, se encontraron 13 registros con valores negativos, que fueron considerados errores de registro; al ser muy pocos datos se optó por eliminarlos del análisis.

Tabla 35 Estadísticas descriptivas de las variables después del procesamiento

Variable	Media	Desv. Estándar	Mediana	Mín	Máx	Asimetría
Colesterol	245.18	53.22	240	85	603	1.35

Oldpeak	0.94	1.07	0.6	0	6.2	1.18
Presión arterial	132.46	17.93	130	80	200	0.63

Elaborado por: autor

Después de este procesamiento, se observó que la desviación estándar de colesterol disminuyó, reflejando menor influencia de los valores atípicos, y la media aumentó al reemplazar los valores de 0 por la mediana. Oldpeak quedó con valores más coherentes tras eliminar los negativos. En conjunto, estos cambios permitieron que los datos fueran más consistentes y confiables, manteniendo la información clínica importante y reduciendo la influencia de errores o valores extremos.

Comparación del desempeño de los modelos

Se evaluaron cuatro algoritmos de aprendizaje automático para el diagnóstico de enfermedad cardiopatía. La Tabla presenta las métricas de rendimiento obtenidas por cada modelo en el conjunto de prueba.

Tabla 36 *Desempeño promedio de los modelos*

Modelo	AUC	Sensibilidad	Especificidad	F1 Score
Logistic	0.904	0.826	0.840	0.824
SVM	0.923	0.822	0.889	0.844
Random Forest	0.963	0.934	0.940	0.934
XGBoost	0.956	0.910	0.911	0.907

Elaborado por: autor


Los modelos basados en ensambles de árboles demostraron un desempeño superior al resto. Random Forest alcanzó los mejores resultados globales con un AUC de 0.965 y un F1-Score de 0.934, exhibiendo además mayor sensibilidad y especificidad. Por otra parte, XGBoost obtuvo el segundo mejor rendimiento con un AUC de 0.956 y un F1-Score de 0.907. Ambos modelos superaron a los métodos tradicionales, mostrando una diferencia de más de 4 puntos en AUC respecto a la regresión logística.

Los modelos clásicos presentaron rendimientos más modestos. SVM alcanzó un AUC de 0.923 con buena especificidad de 0.889, mientras que la regresión logística obtuvo el desempeño más bajo del conjunto con un AUC de 0.904, aunque mantuvo resultados aceptables y consistentes. Cabe destacar que todos los modelos superaron el umbral de 0.90

en AUC, lo cual se considera excelente desempeño diagnóstico según los criterios establecidos en la literatura médica.

La Figura refuerza estos hallazgos, mostrando las curvas ROC de los cuatro modelos evaluados. Se observa que Random Forest y XGBoost mantienen tasas de verdaderos positivos superiores a lo largo de todo el espectro de umbrales de clasificación, confirmando su predominio en la capacidad discriminativa. Las curvas de SVM y regresión logística, aunque con buen desempeño, se ubican consistentemente por debajo de los métodos de ensamble.


Figura 15 Comparativa de curvas ROC de los modelos



Elaborado por: autor

La mayor área bajo la curva de Random Forest indica que este modelo tiene la mejor capacidad para distinguir entre pacientes sanos y enfermos en diferentes puntos de corte. Esta característica es valiosa en el contexto clínico, donde puede ser necesario ajustar el umbral de decisión según las prioridades diagnósticas. Con base en estos resultados, se seleccionó Random Forest como el modelo más adecuado para el sistema de diagnóstico de cardiopatía, considerando su desempeño superior en todas las métricas evaluadas.

Figura 16 Matriz de confusión



Elaborado por: autor

La matriz de confusión mostró que el 43.8% de los casos fueron correctamente clasificados como Sano, mientras que el 49.9% fueron correctamente identificados como Enfermo. Por otra parte, el 3.5% de los casos sanos fueron clasificados incorrectamente como enfermos y el 2.8% de los casos enfermos fueron clasificados erróneamente como sanos. En conjunto, La validación cruzada mostró una exactitud promedio de 0.937, lo que confirma la estabilidad del modelo y su capacidad de generalización.

Interpretación del modelo

El modelo fue entrenado con un bosque de 500 árboles, un volumen que permite estabilizar el error sin incurrir en un costo computacional excesivo. El proceso de optimización determinó que el número ideal de variables por división es 6, lo que significa que en cada nodo el algoritmo selecciona aleatoriamente 6 variables para identificar la mejor partición. El error estimado Out-of-Bag (OOB) fue de 5.61%, reflejando una alta precisión general del modelo.

Tabla 37 Matriz de confusión de OOB

Predicción	Sano	Enfermo	Error de clase
Sano	516	41	0.0736
Enfermo	25	595	0.0403


Elaborado por: autor

La matriz de confusión resultante del entrenamiento muestra los siguientes resultados: el modelo clasificó correctamente a 516 pacientes sanos, con un error de clase del 7.36% (41

individuos clasificados erróneamente como enfermos); y correctamente a 595 pacientes enfermos, con un error de clase del 4.03% (25 individuos clasificados erróneamente como sanos). Estos valores indican que el modelo presenta una mayor capacidad discriminadora para identificar pacientes enfermos que pacientes sanos, aunque ambas tasas de error se mantienen en niveles bajos.

Se realizó un análisis para determinar la contribución específica de cada variable al diagnóstico. Este proceso se basó en el cálculo de la importancia de características mediante el índice de descenso medio de impureza de Gini, el cual permite jerarquizar los atributos según su capacidad para discriminar entre pacientes sanos y aquellos con cardiopatía. Los resultados obtenidos revelan una estructura de decisión en la que los signos dinámicos y sintomáticos predominan sobre los factores de riesgo estáticos.

Figura 17 Importancia de Variables Clínicas



Elaborado por: autor

El análisis jerárquico posiciona a la variable del segmento ST con un valor de importancia de 143.77, identificándola como el predictor más crítico del sistema. Esto se debe a que es un marcador electrocardiográfico clave para detectar anomalías en la repolarización ventricular bajo estrés físico. El tipo de dolor torácico ocupa el segundo lugar en relevancia con un peso de 86.18, lo que confirma que el modelo otorga una prioridad significativa a la caracterización cualitativa del síntoma principal reportado por el paciente.

En un segundo nivel de importancia se encuentran la frecuencia cardíaca máxima (68.20) y oldpeak (57.01), métricas que reflejan la respuesta cardiovascular durante la actividad física. Que estas variables superen en importancia a los factores de riesgo tradicionales sugiere que el modelo ha aprendido a valorar la capacidad funcional del corazón como un indicador de

riesgo más preciso. Esto indica que el sistema puede ayudar a identificar pacientes con cardiopatía incluso cuando los signos en reposo no son concluyentes.


Las variables relacionadas con el perfil crónico del paciente, tales como el colesterol (49.63), la presión arterial sistólica (49.50) y la edad (46.49), mostraron una importancia moderada y equilibrada en la estructura del modelo. Aunque estos factores son precursores conocidos de enfermedades cardiovasculares, su posición intermedia en la jerarquía indica que el algoritmo los utiliza para contextualizar el riesgo global en lugar de basar el diagnóstico exclusivamente en ellos.

Variables como el sexo (24.17), los resultados del electrocardiograma en reposo (13.11) y el azúcar en sangre en ayunas (10.15) presentaron los pesos más bajos, indicando que, para este conjunto de datos, poseen una capacidad discriminatoria menor frente a los indicadores de esfuerzo y sintomatología aguda.

4.1.10 Interfaces de software

La interfaz presenta un panel de estadísticas con indicadores clave del sistema, mostrando métricas globales como total de pacientes, consultas registradas y predicciones realizadas. Los datos se presentan mediante tarjetas y gráficos que permiten una lectura rápida del estado general del sistema.

Figura 18 Interfaz de visualización de estadísticas generales



Elaborado por: autor

La interfaz implementa el registro de pacientes mediante un formulario tipo wizard dividido en tres pasos: datos personales, datos domiciliarios y datos socioculturales. Este diseño guía al usuario secuencialmente asegurando la captura completa de la información requerida.

Figura 19 Interfaz de formulario de registro de paciente

Elaborado por: autor


La interfaz centraliza el registro de la atención médica, organizando en secciones los signos vitales, exámenes clínicos y motivo de consulta. Permite al médico documentar de forma estructurada cada atención sin abandonar la pantalla principal.

Figura 20 Interfaz de consulta médica

Elaborado por: autor

La interfaz permite registrar los diagnósticos asociados a una consulta, clasificándolos como definitivos o presuntivos. Complementariamente incluye secciones para procedimientos realizados, solicitudes médicas y prescripción de la receta médica.


Figura 21 Interfaz de registro de diagnósticos y tratamientos



Elaborado por: autor

La interfaz consolida el seguimiento longitudinal del paciente mostrando el historial de predicciones de riesgo cardiovascular junto con sus variables influyentes. Permite visualizar la progresión del riesgo a lo largo del tiempo mediante gráficos cronológicos.

Figura 22 Interfaz de evolución del paciente




Elaborado por: autor

La interfaz presenta gráficos de línea para el seguimiento temporal de variables clínicas como presión arterial, colesterol, glucosa y frecuencia cardíaca. Cada gráfico dispone de

filtros por período permitiendo comparar la evolución en rangos de 3 meses, 6 meses o un año.


Figura 23 Interfaz de evolución de las variables médicas del paciente



Elaborado por: autor

La interfaz permite gestionar los permisos del sistema asignándolos a roles específicos como administrador, doctor o enfermero. Presenta una matriz de acciones disponibles por recurso, facilitando un control granular sobre las funcionalidades accesibles para cada perfil.


Figura 24 Interfaz de asignación de permisos a los roles



Elaborado por: autor

La interfaz muestra el expediente completo del paciente organizando su información demográfica, de contacto y sociocultural en pestañas navegables. Sirve como punto de acceso central desde donde se puede navegar hacia otras secciones del historial.


Figura 25 Interfaz de perfil del paciente



Elaborado por: autor

La interfaz presenta de forma cronológica todas las consultas médicas registradas para el paciente, mostrando fecha, médico responsable, diagnósticos y procedimientos. Desde cada registro se puede acceder al detalle completo de la consulta correspondiente.


Figura 26 Interfaz de visualización de historial clínico del paciente



Elaborado por: autor

La interfaz despliega un calendario interactivo que muestra las citas médicas programadas por día y hora. Permite agendar nuevas citas, visualizar disponibilidad y gestionar el estado de cada cita desde una vista semanal.

Figura 27 Interfaz del calendario de citas médicas



Elaborado por: autor

4.2 Comprobación

Los resultados presentados en esta sección corresponden a la fase de comprobación del sistema de diagnóstico cardiológico, la cual se estructuró en tres etapas secuenciales: pruebas de rendimiento, pruebas de aceptación funcional y evaluación de aceptación tecnológica.

4.2.1 Pruebas de Rendimiento

El escenario de carga configurado simuló 15 usuarios virtuales concurrentes durante un período sostenido de 90 segundos, representando la demanda estimada en una jornada de atención clínica de alta concurrencia en el centro de cardiología. Los resultados fueron capturados en su totalidad por la herramienta Artillery, la cual generó un reporte detallado por endpoint evaluado.

En la tabla presentan los resultados obtenidos para cada uno de los seis endpoints críticos del sistema. Las métricas reportadas corresponden al tiempo de respuesta promedio, el percentil 95 (P95) y el percentil 99 (P99), expresados en segundos. El umbral de aceptación definido en la sección de indicadores de evaluación establece que ninguna solicitud debe superar los 1.5 segundos en el P99, criterio que fue utilizado como referencia para determinar el cumplimiento de cada endpoint evaluado.

Tabla 38 Resultados de las pruebas de rendimiento por endpoint

Endpoint	Ruta	Tiempo Prom.	P95	P99	Cumple
Registro de consulta clínica	POST /consultas	0.74 s	1.12 s	1.38 s	Si
Carga de perfil del paciente	GET /pacientes/{id}	0.52 s	0.89 s	1.21 s	Si
Ejecución del modelo predictivo	POST /prediccion	1.03 s	1.31 s	1.47 s	Si
Listado de pacientes con filtros	GET /pacientes	0.41 s	0.76 s	1.03 s	Si
Generación de reporte PDF	GET /reportes/{id}	0.88 s	1.18 s	1.43 s	Si
Visualización de evolución clínica	GET /evolucion/{id}	0.63 s	0.94 s	1.29 s	Si

Elaborado por: autor

Los resultados obtenidos confirman que la totalidad de los endpoints evaluados cumplen con el umbral de aceptación establecido. El endpoint con mayor tiempo de respuesta correspondió a la ejecución del modelo predictivo, cuyo P99 alcanzó 1.47 segundos. El endpoint de listado de pacientes con filtros registró el menor tiempo promedio con 0.41 segundos, mientras que el endpoint de generación de reporte PDF alcanzó un P99 de 1.43 segundos, resultado esperado dado el proceso de compilación y renderizado del documento. En conjunto, los resultados indican que el sistema mantiene una capacidad de respuesta adecuada bajo condiciones de carga concurrente representativas del entorno clínico objetivo.

4.2.2 Pruebas de Aceptación Funcional

Las pruebas de aceptación funcional fueron ejecutadas en una sesión estructurada con la participación de los cinco usuarios finales del sistema: dos médicos cardiólogos, dos enfermeros y un administrador del centro de salud. Cada usuario llevó a cabo los casos de

prueba asignados según su rol, interactuando directamente con el sistema desplegado en producción mediante sus credenciales de acceso configuradas. En la sesión se ejecutaron un total de 17 casos de prueba que cubren la totalidad de los requerimientos funcionales identificados en la fase de análisis.

En la tabla se presenta la matriz de casos de prueba con los resultados obtenidos para cada caso ejecutado. Para cada caso se registró el resultado esperado según la especificación del requerimiento y el resultado efectivamente observado durante la ejecución. El estado final de cada caso fue determinado contrastando ambos resultados, clasificándolo como Aprobado cuando el comportamiento observado correspondió exactamente con el resultado esperado, o como Fallido en caso contrario.

Tabla 39 *Matriz de resultados de las pruebas de funcionalidad*

ID	RF	Descripción del caso	Resultado esperado	Estado
CP-01	RF-01	Inicio de sesión con credenciales válidas	Acceso concedido y redirección al dashboard	Aprobado
CP-02	RF-01	Gestión de roles y asignación de permisos por módulo	Permisos actualizados e inmediatamente vigentes	Aprobado
CP-03	RF-02	Registro de nuevo paciente con datos completos	Paciente creado y confirmación visible	Aprobado
CP-04	RF-03	Creación de consulta con signos vitales y exámenes	Consulta guardada e integrada al historial	Aprobado
CP-05	RF-03	Guardar consulta con campos obligatorios vacíos	Sistema impide guardar y señala campos	Aprobado
CP-06	RF-04	Visualización del perfil clínico con historial	Historial ordenado cronológicamente visible	Aprobado

CP-07	RF-05	Ejecución del modelo predictivo con datos completos	Probabilidad y variables influyentes mostradas	Aprobado
CP-08	RF-05	Ejecución del modelo con datos incompletos	Notificación de campos faltantes al usuario	Aprobado
CP-09	RF-06	Visualización de evolución clínica filtro 6 meses	Gráfico actualizado con periodo seleccionado	Aprobado
CP-10	RF-07	Generación de reporte PDF del perfil del paciente	Archivo PDF generado con datos correctos	Aprobado
CP-11	RF-08	Activación de recomendaciones ante diagnóstico CIE	Sugerencias mostradas pendientes de aprobación	Aprobado
CP-12	RF-09	Carga de documento PDF de laboratorio con OCR	Valores extraídos precargados en formulario	Aprobado
CP-13	RF-11	Adjuntar archivo de imagen al expediente	Archivo vinculado con vista previa disponible	Aprobado
CP-14	RF-12	Agendar cita en horario disponible	Cita registrada y reflejada en el calendario	Aprobado
CP-15	RF-12	Agendar cita en horario ya ocupado	Sistema bloquea y notifica conflicto de horario	Aprobado
CP-16	RF-13	Creación de regla clínica con procedimiento asociado	Regla activa y aplicada en consultas nuevas	Aprobado

CP-17	RF-14	Visualización de estadísticas con filtro por fecha	Gráficos actualizados según rango seleccionado	Aprobado
-------	-------	--	--	----------

Elaborado por: autor

Los resultados de la ejecución evidencian que los 17 casos de prueba evaluados obtuvieron el estado Aprobado, lo que representa un porcentaje de cumplimiento del 100% sobre el total de requerimientos funcionales del sistema. Este resultado supera el umbral mínimo de aceptación definido en los indicadores de evaluación, confirmando que el sistema implementa correctamente todas las funcionalidades especificadas.

4.2.3 Evaluación de Aceptación Tecnológica (TAM)

La evaluación de aceptación tecnológica fue aplicada a los cinco usuarios participantes inmediatamente al concluir la sesión de pruebas de aceptación funcional. El instrumento empleado consistió en un cuestionario estructurado en cuatro constructos adaptados al contexto de sistemas de salud digital: Utilidad Percibida (UP), Facilidad de Uso Percibida (FUP), Intención de Uso (IU) y Confianza en el Modelo Predictivo (CMP). Cada constructo fue evaluado mediante cuatro ítems con escala Likert de cinco puntos, donde 1 corresponde a Totalmente en desacuerdo y 5 a Totalmente de acuerdo.

Tabla 40 Constructos del modelo TAM y umbrales de aceptación

Constructo	Descripción	Umbral mínimo
Utilidad Percibida	El usuario considera que el sistema mejora su desempeño clínico y administrativo	≥ 4.00
Facilidad de Uso Percibida	El usuario considera que la operación del sistema no requiere esfuerzo adicional significativo	≥ 4.00
Intención de Uso	El usuario tiene la disposición de incorporar el sistema en su flujo de trabajo habitual	≥ 4.00
Confianza en el Modelo Predictivo	El personal clínico confía en que las predicciones de riesgo son válidas como apoyo diagnóstico	≥ 3.75

Elaborado por: autor

En la tabla se presentan los puntajes promedio obtenidos por cada usuario participante en los cuatro constructos evaluados. Los valores corresponden al promedio aritmético de las cuatro respuestas por constructo, expresado en la escala de 1 a 5. Se asignó el código de identificación del usuario para preservar la confidencialidad de los participantes, manteniendo visible únicamente el rol desempeñado dentro del sistema.

Tabla 41 *Puntajes individuales por usuario y constructo TAM*

Usuario	UP	FUP	IU	CMP
Médico A	4.50	4.25	4.75	4.00
Médico B	4.75	4.50	4.50	4.25
Enfermero A	4.25	4.75	4.25	3.75
Enfermero B	4.50	4.50	4.00	3.75
Administrador	4.75	4.75	4.50	—
—	4.55	4.55	4.40	3.94

Elaborado por: autor

En la tabla se presentan los promedios consolidados por constructo y segmentados según el rol de los participantes, permitiendo identificar variaciones en la percepción entre el personal clínico y el administrativo. Esta desagregación resulta relevante dado que los médicos y enfermeros interactúan con módulos clínicos de mayor complejidad, mientras que el personal administrativo concentra su uso en los módulos de gestión de pacientes, agendamiento y control de acceso.

Tabla 42 *Resultados TAM consolidados por constructo y rol de usuario*

Constructo	Médicos (n=2)	Enfermeros (n=2)	Administrativo (n=1)	Promedio General
UP	4.63	4.38	4.75	4.55
FUP	4.38	4.63	4.75	4.55
IU	4.63	4.13	4.50	4.40
CMP	4.13	3.75	—	3.94

Elaborado por: autor

Los resultados obtenidos indican que todos los constructos evaluados superaron sus umbrales mínimos de aceptación. La Utilidad Percibida alcanzó un promedio general de 4.55 sobre 5.00, siendo el personal administrativo el que registró la valoración más alta con 4.75, lo que refleja que el sistema optimiza los procesos de gestión de información clínica. La Facilidad de Uso Percibida obtuvo igualmente un promedio de 4.55, con el grupo de enfermeros registrando el puntaje más elevado del constructo con 4.63, resultado que se asocia a la estructura modular e intuitiva de la interfaz desarrollada. La Intención de Uso alcanzó un promedio de 4.40, con los médicos obteniendo el puntaje más alto con 4.63.

El constructo de Confianza en el Modelo Predictivo, aplicado exclusivamente al personal clínico, registró un puntaje promedio de 3.94, valor que supera el umbral mínimo establecido de 3.75. Los médicos otorgaron una puntuación promedio de 4.13, mientras que los enfermeros registraron 3.75. Esta diferencia entre grupos es esperable considerando que los médicos disponen de mayor contexto para interpretar las variables clínicas que fundamentan la predicción, mientras que los enfermeros, expresaron una confianza más moderada en su aplicabilidad como herramienta de apoyo diagnóstico. En términos globales, los resultados del TAM confirman que el sistema alcanza un nivel de aceptación tecnológica satisfactorio en todos los constructos evaluados, con una valoración promedio general de 4.36 sobre 5.00, lo que representa una percepción positiva del sistema por parte de los distintos perfiles de usuarios del centro de cardiología.

CAPITULO V
CONCLUSIONES Y RECOMENDACIONES

5.1 Conclusiones

- La integración de un modelo de aprendizaje automático en una aplicación web permitió mejorar la capacidad de diagnóstico de cardiopatías, reduciendo la dependencia de procesos manuales y apoyando la toma de decisiones clínicas del personal de salud. El sistema desarrollado transformó datos clínicos estructurados en predicciones de riesgo cardiovascular, demostrando que la combinación de tecnologías de software y aprendizaje automático establece una solución viable para la problemática identificada.
- La evaluación comparativa de **cuatro** algoritmos de aprendizaje automático determinó que los métodos de ensamble de árboles presentan superioridad estadística para el diagnóstico de cardiopatías. El algoritmo Random Forest fue seleccionado como el más idóneo al alcanzar un AUC de 0,965 y un F1-Score de 0,934, con una exactitud promedio por validación cruzada de 0,937. La tasa de error Out-of-Bag del 5,61% confirma la estabilidad y capacidad de generalización del modelo.
- El análisis de importancia de características reveló que los signos dinámicos predominan sobre los factores de riesgo estáticos en la estructura de decisión del modelo. La pendiente del segmento ST y el tipo de dolor torácico resultaron los predictores más críticos, seguidos por la frecuencia cardíaca máxima y el oldpeak. Esta jerarquía es coherente con el juicio clínico especializado, ya que valora la respuesta cardiovascular bajo estrés como indicador de riesgo más preciso que parámetros en reposo.
- El sistema superó la totalidad de los indicadores de evaluación funcional establecidos: los 17 casos de prueba de aceptación funcional obtuvieron estado Aprobado, representando un cumplimiento del 100% sobre los requerimientos especificados. Las pruebas de rendimiento bajo carga concurrente de 15 usuarios simultáneos confirmaron que todos los endpoints evaluados mantuvieron tiempos de respuesta por debajo del umbral máximo de 1,5 segundos en el percentil 99.
- La evaluación de aceptación tecnológica mediante el modelo TAM confirmó que el sistema alcanza niveles satisfactorios de percepción en todos sus constructos. La Utilidad Percibida y la Facilidad de Uso Percibida obtuvieron un promedio de 4,55 sobre 5,00; la Intención de Uso alcanzó 4,40; y la Confianza en el Modelo Predictivo registró 3,94, superando el umbral mínimo de 3,75 establecido. La valoración promedio general de 4,36 sobre 5,00 valida la aceptación del sistema por parte de los distintos perfiles de usuarios.

5.2 Recomendaciones

- Se recomienda ampliar y diversificar el conjunto de datos utilizado para el entrenamiento del modelo predictivo. El conjunto empleado en este proyecto, aunque de reconocida validez internacional, proviene mayoritariamente de registros de pacientes masculinos (76,39%), lo que puede limitar la capacidad de generalización del modelo hacia la población femenina y hacia los perfiles epidemiológicos específicos del Ecuador. La incorporación progresiva de registros clínicos locales permitirá adaptar el modelo a la realidad demográfica nacional y mejorar su precisión diagnóstica.
- Se recomienda implementar mecanismos de interpretabilidad del modelo directamente en la interfaz del sistema. La Confianza en el Modelo Predictivo registró el puntaje más bajo de todos los constructos TAM evaluados (3,94). Incorporar visualizaciones que expliquen en lenguaje clínico por qué el modelo asigna un determinado nivel de riesgo a cada paciente, señalando las variables que más contribuyen a la predicción en cada caso individual.
- Se recomienda establecer un protocolo formal de reentrenamiento periódico del modelo con los nuevos registros clínicos capturados por el sistema en producción. Un modelo de aprendizaje automático estático puede experimentar degradación de su precisión diagnóstica a medida que los perfiles epidemiológicos de la población cambian o cuando se incorporan nuevas variables clínicas. Un ciclo de actualización semestral o anual, respaldado por la monitorización continua de las métricas de rendimiento, aseguraría que el sistema mantenga su capacidad predictiva y se adapte a la evolución de los patrones de cardiopatías en el entorno de uso.
- Se recomienda extender la evaluación de aceptación tecnológica a una muestra de mayor tamaño y diversidad de perfiles, incluyendo personal de instituciones de salud públicas y privadas de distintas regiones del Ecuador. La evaluación TAM realizada contó con la participación de cinco usuarios de un único centro de cardiología, lo que, aunque suficiente para la fase de comprobación del proyecto, limita la generalización de los resultados sobre la percepción del sistema. Un estudio de aceptación con mayor alcance muestral aportaría evidencia más robusta sobre la viabilidad de adopción del sistema a escala institucional.

BIBLIOGRAFÍA

- [1] M. M. Ahsan and Z. Siddique, “Machine Learning-Based Heart Disease Diagnosis: A Systematic Literature Review,” Dec. 2021, [Online]. Available: <http://arxiv.org/abs/2112.06459>
- [2] G. A. Roth *et al.*, “Global Burden of Cardiovascular Diseases and Risk Factors, 1990-2019: Update From the GBD 2019 Study,” Dec. 22, 2020, *Elsevier Inc.* doi: 10.1016/j.jacc.2020.11.010.
- [3] M. Fornasini, I. Sisa, and M. E. Baldeon, “Increased Cardiovascular Mortality in Ecuador during COVID-19 Pandemic,” 2023, *Ubiquity Press*. doi: 10.5334/aogh.4021.
- [4] L. Fernando, S. Pamela, and L. Alejandra, “Cardiovascular disease in latin america: The growing epidemic,” *Prog. Cardiovasc. Dis.*, vol. 57, no. 3, pp. 262–267, Nov. 2014, doi: 10.1016/j.pcad.2014.07.007.
- [5] A. Rodriguez, A. Romero-Sandoval, B. A. Sandoval, and N. Romero, “Medical specialist distributions in Ecuador: a geographical and temporal analysis of data from 2000 to 2017,” *BMC Health Serv. Res.*, vol. 22, no. 1, Dec. 2022, doi: 10.1186/s12913-022-08056-5.
- [6] D. Romero-Alvarez, D. F. López-Cevallos, and I. Torres, “Doctors for the people? The problematic distribution of rural service doctors in Ecuador,” *Health Policy Plan.*, vol. 38, no. 7, pp. 851–861, Aug. 2023, doi: 10.1093/heapol/czad040.
- [7] S. C. Thompson, L. Nedkoff, J. Katzenellenbogen, M. A. Hussain, and F. Sanfilippo, “Challenges in managing acute cardiovascular diseases and follow up care in rural areas: A narrative review,” Dec. 02, 2019, *MDPI AG*. doi: 10.3390/ijerph16245126.
- [8] B. Chong *et al.*, “Global burden of cardiovascular diseases: projections from 2025 to 2050,” *Eur. J. Prev. Cardiol.*, vol. 32, no. 11, pp. 1001–1015, Aug. 2025, doi: 10.1093/eurjpc/zwae281.
- [9] H. Yang, Q. Ma, L. Han, and H. Liu, “A global prediction of cardiovascular disease from 2020 to 2030,” *Front. Cardiovasc. Med.*, vol. 12, 2025, doi: 10.3389/fcvm.2025.1462705.
- [10] S. Safdar, S. Zafar, N. Zafar, and N. F. Khan, “Machine learning based decision support systems (DSS) for heart disease diagnosis: a review,” *Artif. Intell. Rev.*, vol. 50, no. 4, pp. 597–623, Dec. 2018, doi: 10.1007/s10462-017-9552-8.
- [11] A. Ogunpola, F. Saeed, S. Basurra, A. M. Albarrak, and S. N. Qasem, “Machine Learning-Based Predictive Models for Detection of Cardiovascular Diseases,” *Diagnostics*, vol. 14, no. 2, Jan. 2024, doi: 10.3390/diagnostics14020144.
- [12] Y. Muhammad, M. Tahir, M. Hayat, and K. T. Chong, “Early and accurate detection and diagnosis of heart disease using intelligent computational model,” *Sci. Rep.*, vol. 10, no. 1, Dec. 2020, doi: 10.1038/s41598-020-76635-9.

- [13] V. Chang, V. R. Bhavani, A. Q. Xu, and M. A. Hossain, "An artificial intelligence model for heart disease detection using machine learning algorithms," *Healthcare Analytics*, vol. 2, Nov. 2022, doi: 10.1016/j.health.2022.100016.
- [14] C. M. Bhatt, P. Patel, T. Ghetia, and P. L. Mazzeo, "Effective Heart Disease Prediction Using Machine Learning Techniques," *Algorithms*, vol. 16, no. 2, Feb. 2023, doi: 10.3390/a16020088.
- [15] A. U. Haq, J. P. Li, M. H. Memon, S. Nazir, R. Sun, and I. Garcíá-Magarinõ, "A hybrid intelligent system framework for the prediction of heart disease using machine learning algorithms," *Mobile Information Systems*, vol. 2018, 2018, doi: 10.1155/2018/3860146.
- [16] J. P. Li, A. U. Haq, S. U. Din, J. Khan, A. Khan, and A. Saboor, "Heart Disease Identification Method Using Machine Learning Classification in E-Healthcare," *IEEE Access*, vol. 8, pp. 107562–107582, 2020, doi: 10.1109/ACCESS.2020.3001149.
- [17] N. A. Baghdadi, S. M. Farghaly Abdelaliam, A. Malki, I. Gad, A. Ewis, and E. Atlam, "Advanced machine learning techniques for cardiovascular disease early detection and diagnosis," *J. Big Data*, vol. 10, no. 1, Dec. 2023, doi: 10.1186/s40537-023-00817-1.
- [18] U. Nagavelli, D. Samanta, and P. Chakraborty, "Machine Learning Technology-Based Heart Disease Detection Models," *J. Healthc. Eng.*, vol. 2022, 2022, doi: 10.1155/2022/7351061.
- [19] V. L. Roger *et al.*, "Executive summary: Heart disease and stroke statistics-2012 update: A report from the American heart association," *Circulation*, vol. 125, no. 1, pp. 188–197, Jan. 2012, doi: 10.1161/CIR.0b013e3182456d46.
- [20] I. Ara and M. Maqbool, "A Review of Recent Developments and Future Challenges in the Implementation of Universal Health Coverage Policy Framework in Some Countries," *Journal of Pharmaceutical Research & Reports*, pp. 1–8, Jun. 2022, doi: 10.47363/JPRSR/2022(3)127.
- [21] N. Conrad *et al.*, "Trends in cardiovascular disease incidence among 22 million people in the UK over 20 years: population based study," *BMJ*, 2024, doi: 10.1136/bmj-2023-078523.
- [22] A. Baggiano *et al.*, "Changing Paradigms in the Diagnosis of Ischemic Heart Disease by Multimodality Imaging," Feb. 01, 2022, *MDPI*. doi: 10.3390/jcm11030477.
- [23] R. Hajar, "Framingham contribution to cardiovascular disease," *Heart Views*, vol. 17, no. 2, p. 78, 2016, doi: 10.4103/1995-705x.185130.
- [24] H. E. Bays *et al.*, "Ten things to know about ten cardiovascular disease risk factors – 2022," Jun. 01, 2022, *Elsevier B.V.* doi: 10.1016/j.ajpc.2022.100342.
- [25] M. M. Hussain, U. Rafi, A. Imran, M. U. Rehman, and S. K. Abbas, "Risk Factors Associated with Cardiovascular Disorders," *Pakistan BioMedical Journal*, pp. 03–10, Feb. 2024, doi: 10.54393/pbmj.v7i02.1034.
- [26] C. Y. Jurgens *et al.*, "State of the Science: The Relevance of Symptoms in Cardiovascular Disease and Research: A Scientific Statement from the American

- Heart Association,” Sep. 20, 2022, *Lippincott Williams and Wilkins*. doi: 10.1161/CIR.0000000000001089.
- [27] D. Adhikary, S. Barman, R. Ranjan, and H. Stone, “A Systematic Review of Major Cardiovascular Risk Factors: A Growing Global Health Concern,” *Cureus*, Oct. 2022, doi: 10.7759/cureus.30119.
 - [28] A. V. Poznyak *et al.*, “Hypertension as a risk factor for atherosclerosis: Cardiovascular risk assessment,” Aug. 22, 2022, *Frontiers Media S.A.* doi: 10.3389/fcvm.2022.959285.
 - [29] V. V. Gafarov, D. O. Panov, E. A. Gromova, I. V. Gagulin, A. V. Gafarova, and E. A. Krymov, “Sex Differences in Long-Term Trends of Psychosocial Factors and Gender Effect on Risk of Cardiovascular Diseases: Arterial Hypertension, Myocardial Infarction and Stroke,” in *Risk Factors for Cardiovascular Disease*, IntechOpen, 2022. doi: 10.5772/intechopen.99767.
 - [30] T. R. Einarson, A. Acs, C. Ludwig, and U. H. Panton, “Prevalence of cardiovascular disease in type 2 diabetes: A systematic literature review of scientific evidence from across the world in 2007-2017,” Jun. 08, 2018, *BioMed Central Ltd*. doi: 10.1186/s12933-018-0728-6.
 - [31] D. E. Winchester *et al.*, “ACC/AHA/ASE/ASNC/ASPC/HFSA/HRS/SCAI/SCCT/SCMR/STS 2023 Multimodality Appropriate Use Criteria for the Detection and Risk Assessment of Chronic Coronary Disease,” Dec. 01, 2023, *BioMed Central Ltd*. doi: 10.1186/s12968-023-00958-5.
 - [32] G. C. M. Siontis *et al.*, “Outcomes of non-invasive diagnostic modalities for the detection of coronary artery disease: Network meta-analysis of diagnostic randomised controlled trials,” *BMJ (Online)*, vol. 360, 2018, doi: 10.1136/bmj.k504.
 - [33] U. Sechtem, “Non-invasive testing in patients with suspected coronary artery disease: Some may be more equal than others,” *Eur. Heart J.*, vol. 39, no. 35, pp. 3331–3333, Sep. 2018, doi: 10.1093/eurheartj/ehy364.
 - [34] C. Krittanawong *et al.*, “Machine learning prediction in cardiovascular diseases: a meta-analysis,” *Sci. Rep.*, vol. 10, no. 1, Dec. 2020, doi: 10.1038/s41598-020-72685-1.
 - [35] A. Ameen, I. E. Fattoh, T. Abd El-Hafeez, and K. Ahmed, “Advances in ECG and PCG-based cardiovascular disease classification: a review of deep learning and machine learning methods,” *J. Big Data*, vol. 11, no. 1, Dec. 2024, doi: 10.1186/s40537-024-01011-7.
 - [36] Z. Noroozi, A. Orooji, and L. Erfannia, “Analyzing the impact of feature selection methods on machine learning algorithms for heart disease prediction,” *Sci. Rep.*, vol. 13, no. 1, Dec. 2023, doi: 10.1038/s41598-023-49962-w.
 - [37] G. Dharmarathne, M. Bogahawaththa, U. Rathnayake, and D. P. P. Meddage, “Integrating explainable machine learning and user-centric model for diagnosing cardiovascular disease: A novel approach,” *Intelligent Systems with Applications*, vol. 23, Sep. 2024, doi: 10.1016/j.iswa.2024.200428.

- [38] Y. Wu, B. Xin, Q. Wan, Y. Ren, and W. Jiang, “Risk factors and prediction models for cardiovascular complications of hypertension in older adults with machine learning: A cross-sectional study,” *Heliyon*, vol. 10, no. 6, Mar. 2024, doi: 10.1016/j.heliyon.2024.e27941.
- [39] P. Ghosh *et al.*, “Efficient prediction of cardiovascular disease using machine learning algorithms with relief and lasso feature selection techniques,” *IEEE Access*, vol. 9, pp. 19304–19326, 2021, doi: 10.1109/ACCESS.2021.3053759.
- [40] K. M. Mohi Uddin, R. Ripa, N. Yeasmin, N. Biswas, and S. K. Dey, “Machine learning-based approach to the diagnosis of cardiovascular vascular disease using a combined dataset,” *Intell. Based. Med.*, vol. 7, Jan. 2023, doi: 10.1016/j.ibmed.2023.100100.
- [41] K. Tang, S. Ma, X. Sun, and D. Guo, “Optimizing machine learning for enhanced automated ECG analysis in cardiovascular healthcare,” *Egyptian Informatics Journal*, vol. 28, Dec. 2024, doi: 10.1016/j.eij.2024.100578.
- [42] Q. Li, A. Campan, A. Ren, and W. E. Eid, “Automating and improving cardiovascular disease prediction using Machine learning and EMR data features from a regional healthcare system,” *Int. J. Med. Inform.*, vol. 163, Jul. 2022, doi: 10.1016/j.ijmedinf.2022.104786.

ANEXOS